LAB01

Clusters com o Algoritmo k-NN

Objetivos

Implementar um dos principais algoritmos de agrupamento de dados utilizados no mercado. Aprofundar conhecimentos essenciais para trabalhar com bases de dados de maior porte. Exercitar o uso de bibliotecas em Python na área de aprendizagem de máquina com aplicações e foco em agrupamento de dados.

Conceitos Teóricos Adicionais

Revisar conceitos teóricos e experimentais apresentados nas aulas presenciais.

Datas Importantes

Aula(s) destinada a esta atividade: 13/03.

Data da entrega deste relatório: não será entregue relatório desta atividade.

Procedimento de Avaliação deste Laboratório:

Não será apresentada nenhuma tarefa para avaliação relacionada a este laboratório.

Procedimentos

1.1 Materiais e Ferramentas Computacionais

- 01 Computador adequado
- 01Ambiente adequado para programar em Python

1.2. Desenvolver:

i. *Tarefa no Laboratório*: baixar a base de dados sobre Doenças Cardíacas (**arquivo heart.csv**) disponibilizado na nossa Comunidade da disciplina no Moodle. Para maiores

UFRGS, ©Balbinot, Alexandre

detalhes sobre esta base de dados, consultar o site (https://archive.ics.uci.edu/ml/datasets/Heart+Disease). Vamos agora implementar o algoritmo *k-NN* usando a biblioteca *sckit-learn* para agrupar os dados da base de dados disponibilizada. Para isso **baixar o arquivo Lab01Tarefa01** disponibilizado na nossa Comunidade da disciplina no Moodle©. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo. **Sugestão:** consultar o manual da biblioteca *sckit-learn* para maiores detalhes e exemplos dos módulos e funções em (https://scikit-learn.org/stable/api/index.html).

ii. *Tarefa no Laboratório*: vamos agora analisar a escolha do hiperparâmetro *k* do algoritmo *k-NN*. Para esta análise **baixar o arquivo Lab01Tarefa02** disponibilizado na nossa Comunidade da disciplina no Moodle©. Basicamente iniciaremos o algoritmo com vários valores de *k* e acompanharemos os erros. Em função do gráfico obtido selecionar o melhor valor de *k* e refazer a *Tarefa i*. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo. A principal questão: a seleção do hiperparâmetro impactou no resultado?

iii. *Tarefa no Laboratório*: vamos agora analisar o impacto da normalização dos dados da correspondente base de dados. Para esta análise **baixar o arquivo Lab01Tarefa03** disponibilizado na nossa Comunidade da disciplina no Moodle. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

iv. *Tarefa no Laboratório*: para esta próxima atividade baixar o arquivo **cliente.csv** disponibilizado na nossa Comunidade da disciplina no Moodle. Podemos utilizar esta base de dados para analisar um pedido de empréstimo. Considerar que a renda (*income*) e a pontuação de crédito são as características (*score*) e a variável padrão (default) é o rótulo, ou seja, temos uma base supervisionada (rótulo = NO = cliente terá seu pedido de empréstimo negado e YES terá seu pedido de empréstimo aceito). Para esta análise **baixar o arquivo Lab01Tarefa04** disponibilizado na nossa Comunidade da disciplina

UFRGS ©Balbinot, Alexandre

no Moodle©. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

v. *Tarefa para Casa*: **baixar o arquivo de dados RHdataset.xls**. Propor um algoritmo k-NN para classificar a base de dados de um setor de Recursos Humanos de uma empresa. Esta base de dados contém 10 características e 1 de saída que são usadas para determinar se um empregado vai sair ou não do emprego. As características de entrada são as seguintes: Porcentagem de atrasos, Porcentagem de iniciativa do projeto, Porcentagem do projeto entregue no prazo, Porcentagem de e-mails trocados, Porcentagem da capacidade de resposta, Porcentagem de resposta de e-mail, Porcentagem de compartilhamento de ideias, Porcentagem de ajuda aos colegas, Porcentagem de postagens empreendedoras no LinkedIn e Porcentagem de comentários no Facebook. A saída chamada de "Desistir" é uma classe binária onde 0 representa um empregado que permanece na empresa e 1 que representa um empregado que se demite – neste exemplo retirar esta última coluna do *dataset*. Mesmo com os dados em porcentagens vamos normalizar (apesar de não necessitar, pois já estão na mesma escala). Abrir o ambiente de programação Python, propor o algoritmo k-NN com divisão dos dados em 70%-30%, executar seu código, analisar e discutir. Observação: para ler esta planilha é importante utilizar a instrução adequada: ***pd.read_excel('C:/....')*** no local evidentemente que armazenaram o correspondente arquivo.

UFRGS ©Balbinot, Alexandre