UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

IA PARA ENGENHEIROS
UFRGS

Curso de Especialização

Inteligência Artificial para Engenheiros

Disciplina: **Algoritmos para Agrupamento de Dados**

Aula: **Algoritmos k-Means e k-Medoids**

Professor: **Maurício Cagliari Tosin**

2026

Agrupamento de Particionamento: Classificação Não-Supervisionada

Agrupamento de Particionamento

Características Básicas:

- Classificação de dados com base na sua similaridade;
- Necessário a especificação inicial do número de clusters a serem gerados.

Técnicas mais comumente usadas:

- **k-means clustering (MacQueen, 1967):** cada cluster é representado pelo centro (centróide) ou pela média dos dados pertencentes a um dado cluster. Método é sensível a dados anômalos e dispersos;
- **k-medoids ou PAM (Partitioning Around Medoids, Kaufman & Rousseuw, 1990):** algoritmo PAM é menos sensível aos dados dispersos quando comparado ao k-means;
- **Algoritmo CLARA (Clustering Large Applications):** adaptação do método PAM destinado a classificação de grande conjunto de dados.

Agrupamento de Particionamento: Método K-Means

Agrupamento de Dados pelo Método k-means

Características Básicas:

- Algoritmo padrão proposto por Stuart Lloyd (1957) em estudos na área de modulação de sinais;
- Versão mais eficiente proposta por Hartigan e Wong entre 1975 e 1979;

Objetivo: Encontrar o melhor agrupamento de n dados em k grupos de tal forma que a distância total entre os membros de um dado cluster e seu centróide seja minimizada.

Divisão dos dados ($x_1, x_2, \ldots, x_k$) $\in S_i$ **em *k clusters* para que cada dado** ($x_1, x_2, \ldots, x_k$) **pertença ao *cluster* que possui a média mais próxima** (minimização da Soma dos Quadrados de um dado *cluster*), ou seja:

$$SQ = \sum_{i=1}^{k} \sum_{x \in S_i} \|x - \mu_i\|^2$$

μ_i é o centroide do cluster i

Observações:

- Tipicamente cada *cluster* é representado pelo seu centróide (média dos dados atribuídos ao *cluster*).
- Pertence à categoria dos métodos baseados em protótipo.

Fluxo Lógico – Método de Stuard Lloyd

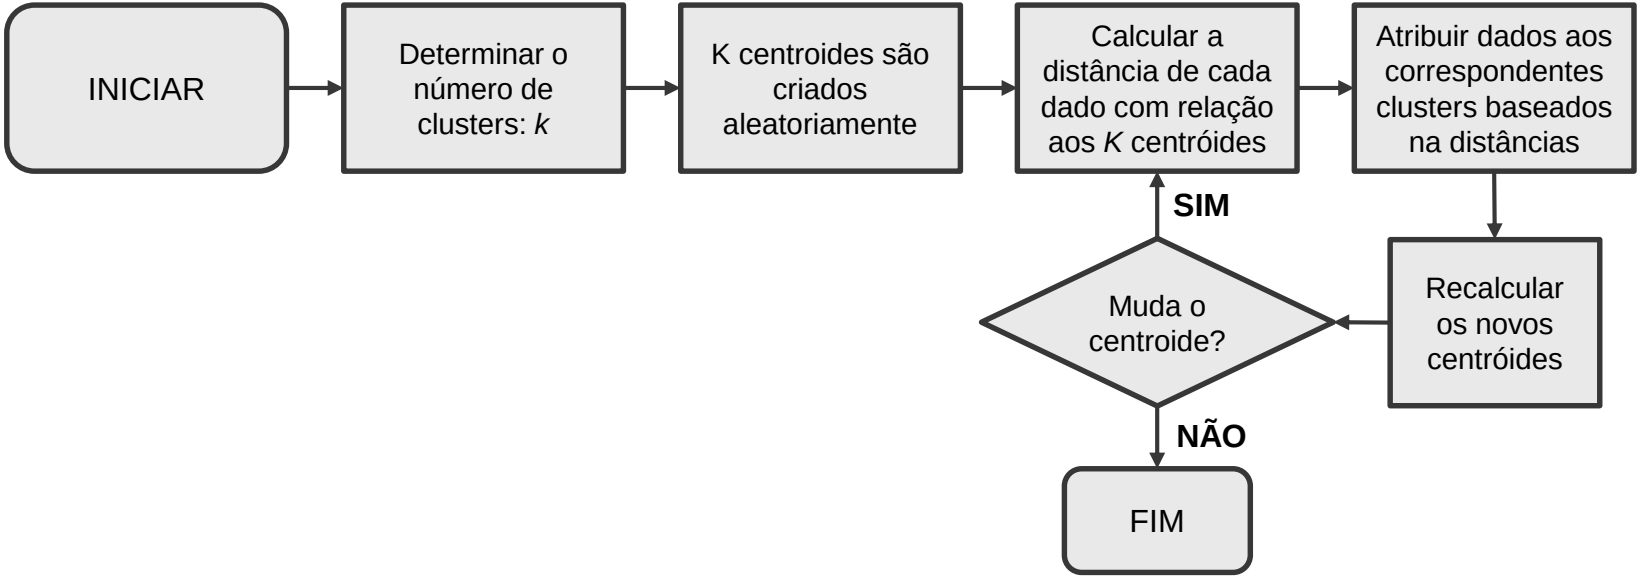

Exemplo 01 – Método de Stuard Lloyd

Exemplo gráfico sobre o funcionamento básico do k-means.

Criação de 3 clusters (k = 3) em um classificador 3-means.

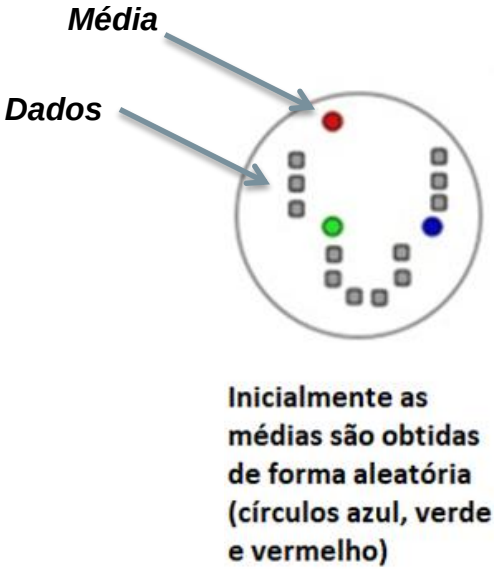

Exemplo 01 – Método de Stuard Lloyd

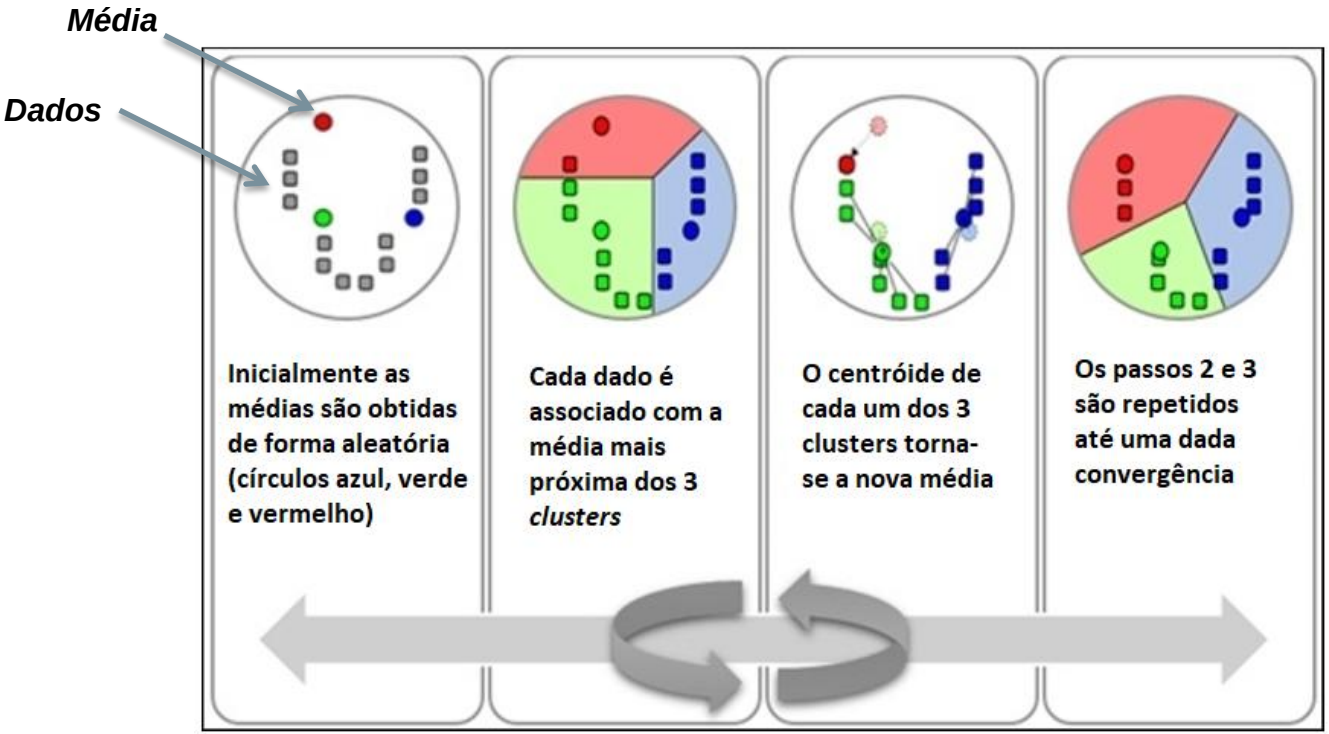

Exemplo 02 – Método de Stuard Lloyd

Aplicar o método k-means para o conjunto de dados abaixo. Considerar k=2.

Instâncias	X	Y
1	7	8
2	2	4
3	6	4
4	3	2
5	6	5
6	5	7
7	3	3
8	1	4
9	5	4
10	7	7
11	7	6
12	2	1

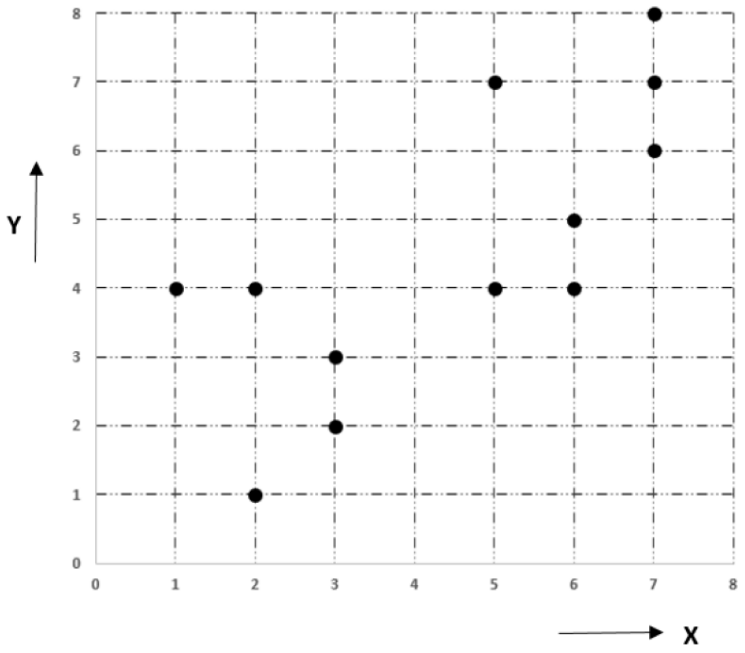

Exemplo 02 – Método de Stuard Lloyd

Iteração 1: assumindo $Centroide_1 = (X = 1, Y = 4)$ e $Centroide_2 = (X = 7, Y = 8)$

Instâncias	X	Y	$Dist._{C1}$	$Dist._{C2}$	Cluster
1	7	8			
2	2	4			
3	6	4			
4	3	2			
5	6	5			
6	5	7			
7	3	3			
8	1	4			
9	5	4			
10	7	7			
11	7	6			
12	2	1			

$$Dist._{I6-C1} = \sqrt{(5-1)^2 + (7-4)^2} = 5{,}00$$

$$Dist._{I6-C2} = \sqrt{(5-7)^2 + (7-8)^2} = 2{,}24$$

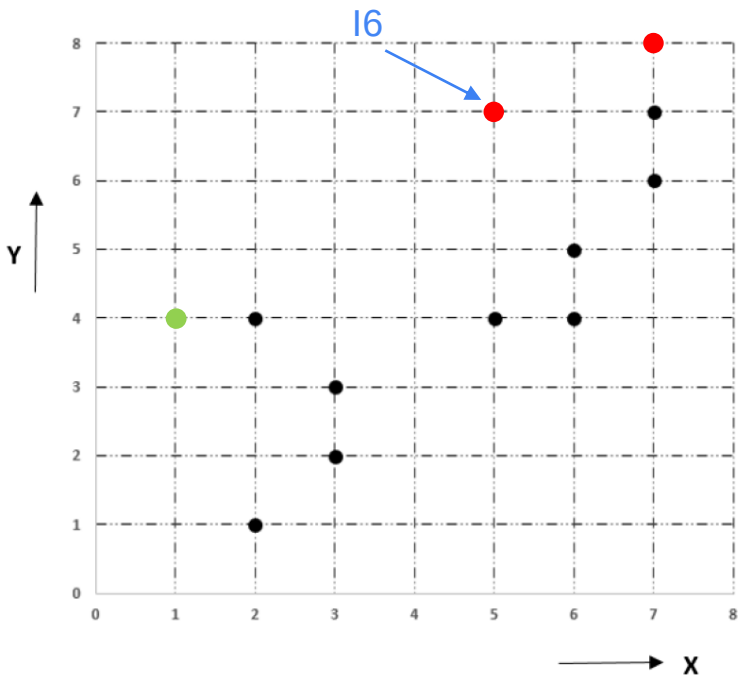

Exemplo 02 – Método de Stuard Lloyd

Iteração 1: assumindo $Centroide_1 = (X = 1, Y = 4)$ e $Centroide_2 = (X = 7, Y = 8)$

Instâncias	X	Y	$Dist._{C1}$	$Dist._{C2}$	Cluster
1	7	8	**7,21**	**0,00**	C2
2	2	4	**1,00**	**6,40**	C1
3	6	4	**5,00**	**4,12**	C2
4	3	2	**2,83**	**7,21**	C1
5	6	5	**5,10**	**3,16**	C2
6	5	7	**5,00**	**2,24**	C2
7	3	3	**2,24**	**6,40**	C1
8	1	4	**0,00**	**7,21**	C1
9	5	4	**4,00**	**4,47**	C1
10	7	7	**6,71**	**1,00**	C2
11	7	6	**6,32**	**2,00**	C2
12	2	1	**3,16**	**8,60**	C1

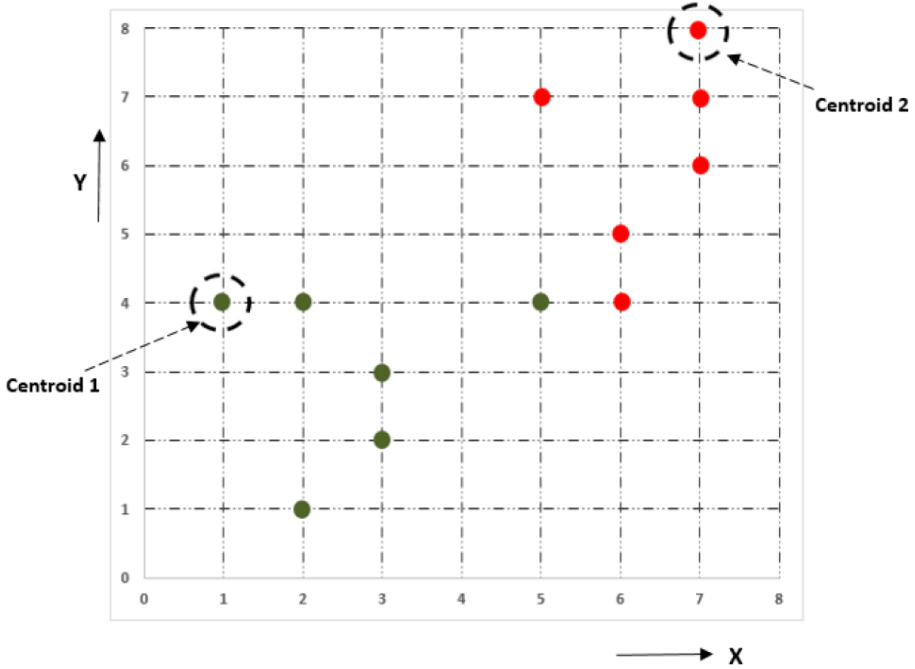

Exemplo 02 – Método de Stuard Lloyd

Iteração 1: assumindo $Centroide_1 = (X = 1, Y = 4)$ e $Centroide_2 = (X = 7, Y = 8)$

Instâncias	X	Y	$Dist._{C1}$	$Dist._{C2}$	Cluster
1	7	8	**7,21**	**0,00**	C2
2	2	4	**1,00**	**6,40**	C1
3	6	4	**5,00**	**4,12**	C2
4	3	2	**2,83**	**7,21**	C1
5	6	5	**5,10**	**3,16**	C2
6	5	7	**5,00**	**2,24**	C2
7	3	3	**2,24**	**6,40**	C1
8	1	4	**0,00**	**7,21**	C1
9	5	4	**4,00**	**4,47**	C1
10	7	7	**6,71**	**1,00**	C2
11	7	6	**6,32**	**2,00**	C2
12	2	1	**3,16**	**8,60**	C1

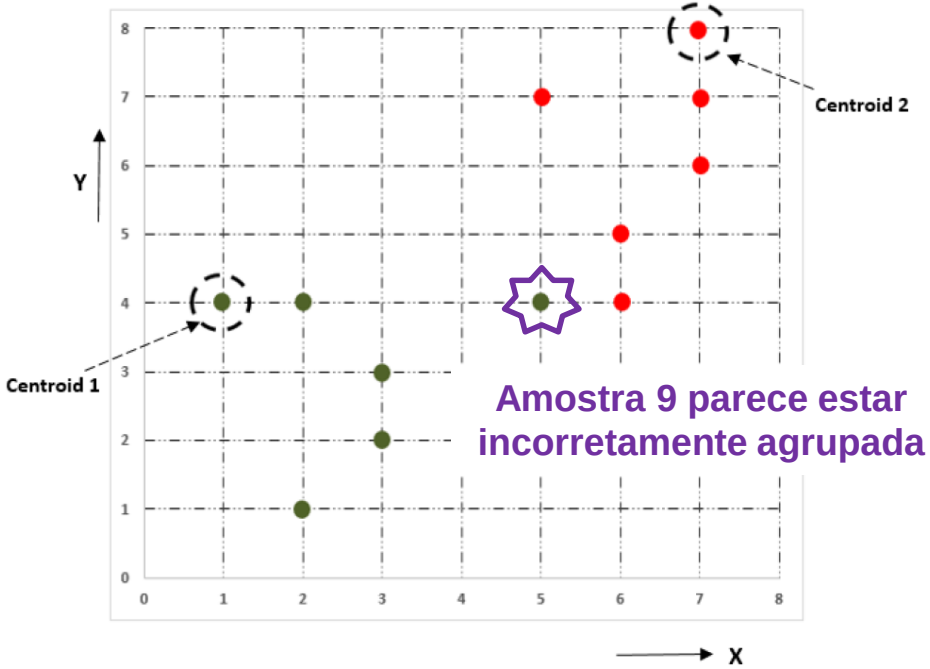

Exemplo 02 – Método de Stuard Lloyd

Iteração 2: calcular novos centroides.

Instâncias	X	Y	Cluster
1	7	8	C2
2	2	4	C1
3	6	4	C2
4	3	2	C1
5	6	5	C2
6	5	7	C2
7	3	3	C1
8	1	4	C1
9	5	4	C1
10	7	7	C2
11	7	6	C2
12	2	1	C1

$$C_{1X} = \frac{2+3+3+1+5+2}{6} = 2{,}67$$

$$C_{1Y} = \frac{4+2+3+4+4+1}{6} = 3{,}00$$

$$C_{2X} = \frac{7+6+6+5+7+7}{6} = 6{,}33$$

$$C_{2Y} = \frac{8+4+5+7+7+6}{6} = 6{,}17$$

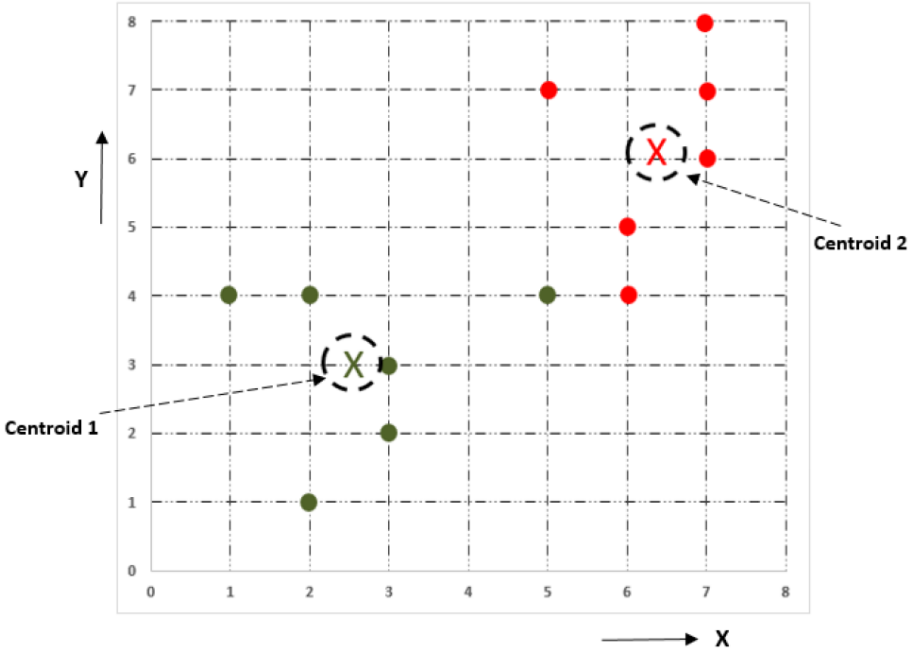

Exemplo 02 – Método de Stuard Lloyd

Iteração 2: $Centroide_1 = (X = 2{,}67, Y = 3)$ e $Centroide_2 = (X = 6{,}33, Y = 6{,}17)$

Instâncias	X	Y	$Dist._{C1}$	$Dist._{C2}$	Cluster1	Cluster2
1	7	8	**6,61**	**1,95**	C2	
2	2	4	**1,20**	**4,84**	C1	
3	6	4	**3,48**	**2,19**	C2	
4	3	2	**1,05**	**5,34**	C1	
5	6	5	**3,88**	**1,22**	C2	
6	5	7	**4,63**	**1,57**	C2	
7	3	3	**0,33**	**4,60**	C1	
8	1	4	**1,95**	**5,75**	C1	
9	5	4	**2,54**	**2,55**	C1	
10	7	7	**5,89**	**1,07**	C2	
11	7	6	**5,27**	**0,69**	C2	
12	2	1	**2,11**	**6,74**	C1	

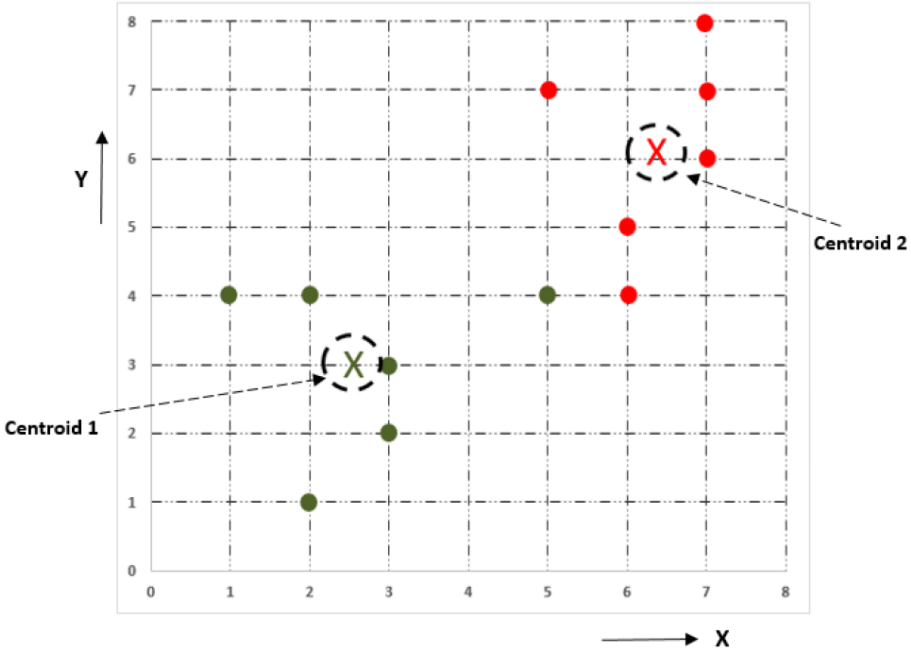

Exemplo 02 – Método de Stuard Lloyd

Iteração 2: $Centroide_1 = (X = 2{,}67, Y = 3)$ e $Centroide_2 = (X = 6{,}33, Y = 6{,}17)$

Instâncias	X	Y	$Dist._{C1}$	$Dist._{C2}$	Cluster1	Cluster2
1	7	8	**6,61**	**1,95**	C2	**C2**
2	2	4	**1,20**	**4,84**	C1	**C1**
3	6	4	**3,48**	**2,19**	C2	**C2**
4	3	2	**1,05**	**5,34**	C1	**C1**
5	6	5	**3,88**	**1,22**	C2	**C2**
6	5	7	**4,63**	**1,57**	C2	**C2**
7	3	3	**0,33**	**4,60**	C1	**C1**
8	1	4	**1,95**	**5,75**	C1	**C1**
9	5	4	**2,54**	**2,55**	C1	**C1**
10	7	7	**5,89**	**1,07**	C2	**C2**
11	7	6	**5,27**	**0,69**	C2	**C2**
12	2	1	**2,11**	**6,74**	C1	**C1**

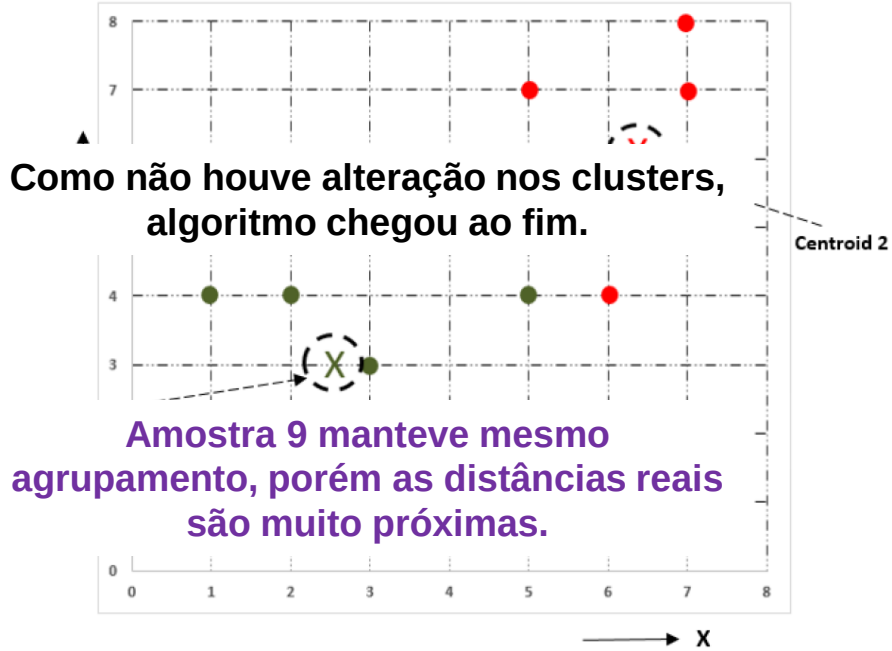

Algoritmo de Hartigan-Wong para o k-means

Cada dado (x_i) é associado a um cluster quando a Soma dos Quadrados (SQ) é mínima:

$$SQ = \sum_{k=1}^{k} W(C_k) = \sum_{k=1}^{k} \sum_{x_i \in C_k} (x_i - \mu_k)^2$$

x_i é o dado pertencente ao Cluster C_k
μ_k é o valor médio dos dados pertencentes ao Cluster C_k (centroide)

Métrica baseada na medida da compactação: ***quanto menor melhor!***

Algoritmo de Hartigan-Wong para o k-means

- A atualização dos centroides é realizada iterativamente a cada novo dado considerado;
- O dado é testado em cada cluster. Os centroides de cada cluster é atualizado assim como a Soma dos Quadrados;

$$SQ = \sum_{k=1}^{k} W(C_k) = \sum_{k=1}^{k} \sum_{x_i \in C_k} (x_i - \mu_k)^2$$

- O dado é atribuído ao cluster que resultar na menor Soma dos Quadrados;

Pseudocódigo do K-Means – Hartigan-Wong

1.
Especificar o número de *cluster* (*k*) a serem criados

2.
Atribuir aleatoriamente todos os dados a um *cluster*

3.
Calcular os centroides por meio da média de seus dados atribuídos

4.
Repita
    Para cada dado *d*
        Para cada cluster *c*
            Atribua o dado *d* ao cluster *c,* atualize os centroides e calcule a soma do quadrado da distância
        Fim do laço
        Atribua *d* ao cluster que resultou na menor soma e atualize os centroides como a média de todos os pontos
    Fim do laço
Até a convergência (**não ocorra mais** alteração dos *clusters* ou quando o número máximo de iterações seja alcançada)

Algoritmo de Hartigan-Wong x Stuard Lloyd

No método Hartigan-Wong, o dado não será atribuído necessariamente ao cluster com centroide mais próximo

- Método mais robusto que o de Stuart Lloyd, porém mais custoso computacionalmente;
- Menos suscetível a convergir em um mínimo local.

Algoritmo de Hartigan-Wong x Stuard Lloyd

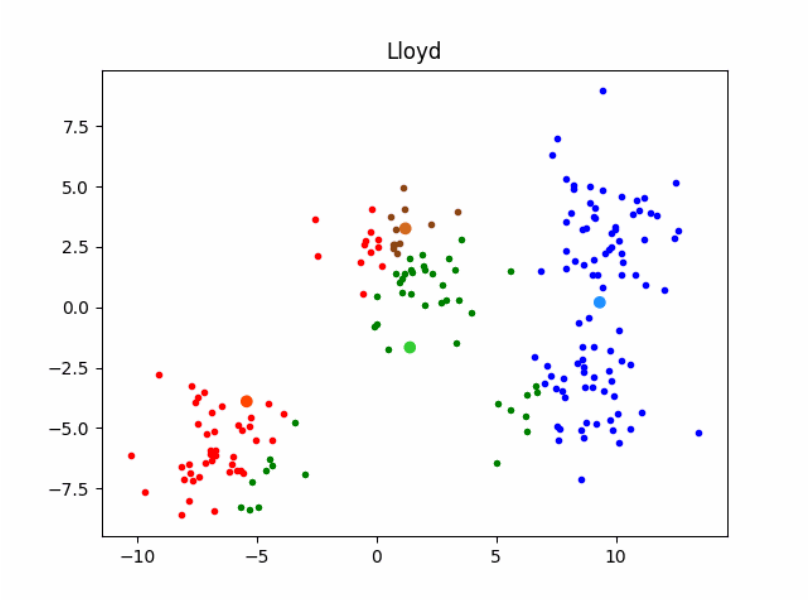

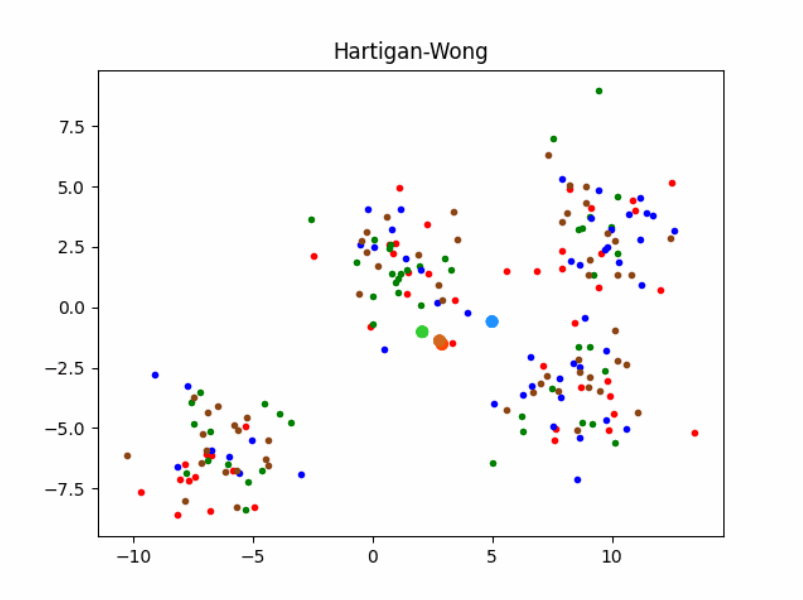

Vantagens e desvantagens do agrupamento *k-means*

Vantagens:

- *algoritmo rápido;*
- *algoritmo muito eficiente com conjunto de dados "muito grande";*

Desvantagens:

- *necessário conhecimento a priori dos dados, pois requer a escolha do número adequado de cluster;*
- *resultado sensível a seleção aleatória inicial dos centros dos clusters;*
- *em cada execução do algoritmo (para o mesmo conjunto de dados) poderemos ter conjuntos diferentes de centros iniciais;*
- *portanto poderemos ter agrupamentos diferentes em diferentes execuções do algoritmo;*
- *algoritmo sensível a dados dispersos.*

Vantagens e desvantagens do agrupamento *k-means*

Algumas soluções para as desvantagens:

- **problema do *k* inicial:** calcular o *k-means* para uma faixa de *k* valores, por exemplo, variando *k* entre 2 e 10. Escolher o melhor valor de *k* baseado na média da soma dos quadrados dentro de cada cluster;
- **alteração do centroide em cada nova execução do algoritmo:** calcular o algoritmo *k-means* algumas vezes com diferentes centroides iniciais. A execução com menor Soma dos Quadrados será selecionada como a solução final para a clustering;
- **distorções nos resultados causadas por dados dispersos:** sugiro o uso do algoritmo PAM (menos sensível a dados esparsos).

Agrupamento de Particionamento: Método K-Medoids (PAM e CLARA)

Método K-Medoids (PAM)

Observações:

- cada *cluster* é representado por algum dado (chamado de *medoid*);
- *medoid* será o ponto mais central localizado no *cluster* (**dado** mais próximo no qual a média da não similaridade entre este ponto e todos os outros membros do *cluster* será mínima);
- alternativa mais robusta quando comparada ao *k-means*, pois é menos sensível ao ruído e dados dispersos (pois usa cada *medoid* como o centro do *cluster* no lugar do valor médio dos dados);
- requer também que o usuário especifique o valor de *k* (número de *clusters* que devem ser gerados);
- algoritmo *k-medoid* mais comum é o PAM (Kaufman & Rouseeuw de 1990).

Pseudocódigo resumido do K-Medoids

1.
Selecionar *k* dados como os *medoids*, ou fornecer os *medoids*

2.
Calcular a matriz de não similaridade se não foi fornecida

3.
Associar cada dado ao *medoid* mais próximo

4.
Para cada *cluster* procurar se qualquer outro dado do *cluster* diminui o coeficiente de não similaridade média; se isso ocorrer, selecionar esse dado como o *medoid* deste *cluster*

5.
Se no mínimo um *medoid* foi alterado ir para o passo 3, caso não, fim do algoritmo.

PAM utiliza uma matriz de não similaridades (normalmente usando uma das 2 métricas):

- Distância Euclidiana;
- Distância Manhattan (soma das distâncias absolutas).

Em geral os resultados são similares usando qualquer uma das 2 métricas de distância.
Porém, para dados esparsos ou dispersos a distância Manhattan fornece normalmente resultados mais robustos.

Método CLARA (*Clustering Large Applications*)

Observações:

- Aplicação do método PAM para grandes bases de dados;
- Em vez de encontrar os medoides considerando todos os objetos, faz uma amostragem e aplica o PAM;
- Resultados experimentais mostram que 5 amostras de tamanho 40 + 2*k* são suficiente.

Uma heurística útil para extrair amostras é, a exceção da primeira amostragem, as amostras subsequentes incluem o melhor conjunto de *k* medoides encontrado até o momento. Em outras palavras, após a primeira iteração, as iterações subsequentes extraem 40 + *k* objetos para adicionar aos *k* melhores medoides.

Pseudocódigo resumido do CLARA

1.
Selecionar uma amostra de dados com tamanho 40 + 2*k*

2.
Encontrar *k medoids* pelo método PAM

3.
Para cada objeto do banco inteiro, determinar o *medoid* mais próximo

4.
Encontrar a qualidade do cluster obtido no passo anterior usando o banco inteiro (cálculo do coeficiente de não similaridade média).

5.
Se a qualidade é a melhor encontrada até o momento, armazenar os *k medoids*.

6.
Repita até número máximo de iterações (cerca de 5).

Sugestão de leitura: Ng, Raymond T and Han, Jiawei. ***Efficient and Effective Clustering Methods for Spatial Data Mining****, 1994*

Biblioteca python para K-Medoids (PAM) e CLARA

- Biblioteca *scikit-learn* não conta com função para implementação de k-medoids;
- Métodos PAM e CLARA podem ser implementados via *sklearn_extra*, através das classes:
  - *sklearn_extra.cluster.KMedoids*
  - *sklearn_extra.cluster.CLARA*

- Sugestão de consulta:

https://scikit-learn-extra.readthedocs.io/en/stable/api.html#clustering

Método para escolha do número adequado de *K*

Método do cotovelo para encontrar o número ótimo de *k*

- Em aprendizagem não supervisionada é difícil de se estimar a qualidade de um agrupamento, pois não dispomos do valor verdadeiro das classes;
- O método do cotovelo apresenta o valor da função de custo (média da soma dos quadrados, por ex.) produzida por diferentes valores de *k*;
- A medida em que se aumenta k, há uma tendência de redução da dispersão média dos dados (menor média da soma dos quadrados).
- Escolhe-se o menor k que garanta a estabilização da função de custo.

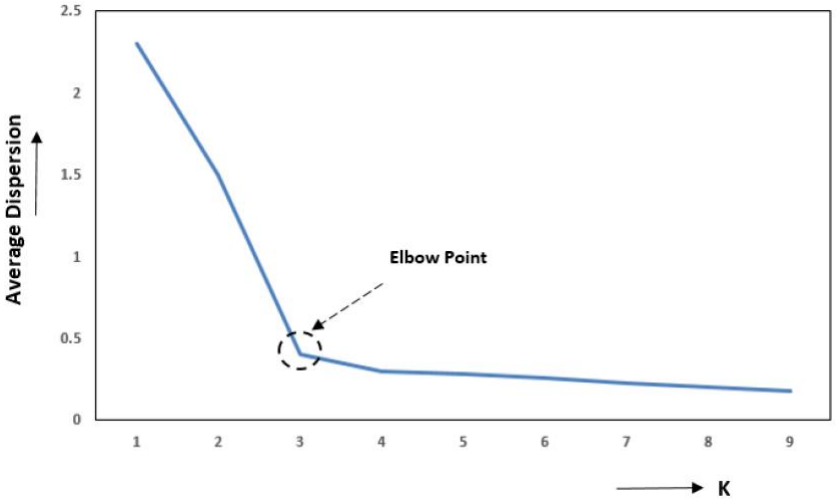

Atividade Prática

Atividade Prática

- Faça o download do arquivo “Lab02” disponibilizado em nossa página no moodle.

- **Sugestão:** usar o GoogleColab (https://colab.research.google.com/) para o desenvolvimento e execução dos códigos em python;
- Outras alternativas: Pycharm, Jupyter, Spyder, Visual Studio Code, etc.