LAB02

Clusters com o Algoritmo k-means

Objetivos

Implementar um dos principais algoritmos de agrupamento de dados utilizados no mercado. Aprofundar conhecimentos essenciais para trabalhar com bases de dados de maior porte. Exercitar o uso de bibliotecas em Python na área de aprendizagem de máquina com aplicações e foco em agrupamento de dados.

Conceitos Teóricos Adicionais

Revisar conceitos teóricos e experimentais apresentados nas aulas presenciais.

Datas Importantes

Aula(s) destinada a esta atividade: 20/03.

Data da entrega deste relatório: até as 23:59 de 27/03, via moodle.

Procedimento de Avaliação deste Laboratório:

Será cobrada a entrega do item *iii* na forma de relatório.

Procedimentos

Digitar, executar e avaliar os seguintes códigos:

1.1 Materiais e Ferramentas Computacionais

- 01 Computador adequado
- 01Ambiente adequado para programar em Python

1.2. Desenvolver:

i. *Tarefa em aula*: baixar uma base de dados que foi adaptada de um órgão da ONU sobre dados relacionados a diversos países, como qualidade de vida, índice relacionado a

UFPGS, ©Balbinot, Alexandre

percepção de corrupção, entre diversos outros. Para trabalhar nesta tarefa baixar o arquivo **DadosWH.csv** disponibilizado no Moodle.

Vamos agora implementar o algoritmo *k-means* usando a biblioteca *sckit-learn* para agrupar os dados da base de dados disponibilizada. Para isso **baixar o arquivo Lab02Tarefa01** disponibilizado na nossa Comunidade da disciplina no Moodle.

ii. *Tarefa em aula*: utilizar a mesma base de dados da *Tarefa i*, mas trabalhar com um espaço dimensional de característica bem maior. Para trabalhar nesta tarefa baixar o arquivo **DadosWH.csv** disponibilizado na nossa Comunidade da disciplina no Moodle. Para isso **baixar o arquivo Lab02Tarefa02** disponibilizado na nossa Comunidade da disciplina no Moodle.

iii. *Tarefa para Casa*: baixar e executar o **arquivo Lab02Tarefa03** disponibilizado na nossa Comunidade da disciplina no Moodle. Este programa trabalha com um tipo de gráfico denominado de blobs e foi implementado um cluster pelo algoritmo *k-means*. Vamos escolher o número de clusters, para esta base de dados, treinando o algoritmo *k-means* com diferentes valores de *k* e observando a "Soma dos Quadrados *Dentro* de cada Cluster" – WCSS. Basicamente a distância dos dados ao seu centroide é calculada e elevada ao quadrado. Em seguida, todas as distâncias ao quadrado são somadas para calcular o erro. Em função do valor do *k* ótimo obtido da Curva do Cotovelo treinar o modelo e avaliar o mesmo. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

UFRGS, ©Balbinot, Alexandre