LAB03

Clusters com o Algoritmos Hierárquicos

UFRGS, © Tosin, Maurício; Balbinot, Alexandre

Objetivos

Implementar algoritmos hierárquicos aglomerativos para agrupamento de dados. Aprofundar conhecimentos essenciais para trabalhar com bases de dados de maior porte. Exercitar o uso de bibliotecas em Python na área de aprendizagem de máquina com aplicações e foco em agrupamento de dados.

Conceitos Teóricos Adicionais

Revisar conceitos teóricos e experimentais apresentados nas aulas presenciais.

Datas Importantes

Aula(s) destinada a esta atividade: 27/03.

Data da entrega deste relatório: até as 23:59 de 10/04, via moodle.

Procedimento de Avaliação deste Laboratório:

Será cobrada a entrega do item *v* na forma de relatório.

Procedimentos

Digitar, executar e avaliar os seguintes códigos:

1.1 Materiais e Ferramentas Computacionais

- 01 Computador adequado
- 01Ambiente adequado para programar em Python

1.2. Desenvolver:

i. *Tarefa em aula*: vamos implementar um agrupamento hierárquico scipy (https://docs.scipy.org/doc/scipy/reference/cluster.html). Para isso baixar o arquivo **Lab03Tarefa01** disponibilizado na nossa Comunidade da disciplina no Moodle.

ii. *Tarefa em aula*: vamos implementar um agrupamento hierárquico. Para isso baixar o arquivo **Lab03Tarefa02** disponibilizado na nossa Comunidade da disciplina no Moodle.

iii. *Tarefa para aula*: vamos implementar um agrupamento hierárquico estimando a matriz de dissimilaridades. Para isso baixar o arquivo **Lab03Tarefa03** disponibilizado na nossa Comunidade da disciplina no Moodle.

iv. *Tarefa para aula*: vamos trabalhar com a mesma base de dados utilizada na aula passada, que foi adaptada de um órgão da ONU sobre dados relacionados a diversos países, como qualidade de vida, índice relacionado a percepção de corrupção, entre diversos outros. Para trabalhar nesta tarefa baixar o arquivo DadosWH.csv disponibilizado no Moodle. Vamos agora implementar o algoritmo hierárquico baseado no método de Ward usando as bibliotecas sckit-learn e scipy para agrupar os dados da base de dados disponibilizada, encontrando o melhor número de *clusters* pelo método de Mojena. Para isso baixar o arquivo **Lab03Tarefa04** disponibilizado na nossa Comunidade da disciplina no Moodle.

v. *Tarefa para casa*: refaça a *Tarefa iv* considerando os métodos do vizinho mais próximo (*single*) e vizinho mais distante (*complete*). Determine o melhor número de clusters para cada caso e compare os resultados obtidos, inclusive com o método de Ward implementado na *Tarefa iv*. Utilize o código **Lab03Tarefa04** como referência.

UFRGS, © Tosin, Maurício; Balbinot, Alexandre