UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Curso de Especialização

Inteligência Artificial para Engenheiros

Análise de Dados e Engenharia de Características

AULA 01A

Introdução e Revisão Básica de Estatística

Professor Dr. Alexandre Balbinot

2026

IA PARA ENGENHEIROS
UFRGS

Universidade Federal do Rio Grande do Sul
Escola de Engenharia
Curso de Especialização Inteligência Artificial para Engenheiros
Laboratório de Sistemas Eletrônicos Inteligentes (LASEI)

Análise de Dados e Engenharia de Características

Aula 01A

Introdução e Revisão Básica de Estatística

Prof. Dr. Alexandre Balbinot

Contatos

Prof. Dr. Alexandre ***Balbinot***

Curso de Especialização Inteligência Artificial para Engenheiros

Escola de Engenharia – UFRGS

Prédio do Instituto Eletrotécnico

Departamento de Engenharia Elétrica - DELET

Laboratório de Sistemas Eletrônicos Inteligentes (LASEI)

Sala 206D – (51) 3308-**4442**

alexandre.balbinot@ufrgs.br

Direitos Autorais

Este material possui Direitos Autorais e Direitos de Imagem e não pode ser duplicado, reproduzido, no todo ou em parte, sob quaisquer formas ou por quaisquer meios (eletrônicos, mecânico, gravação, fotocópia, distribuição na internet ou outros), sem permissão expressa do autor.

©

Termo de Responsabilidade da Própria UFRGS

Todos os materiais disponibilizados nos Ambientes Virtuais da UFRGS são exclusivamente para usos e fins didáticos, sendo vedada a sua utilização para qualquer outra finalidade, sob as penas legais.

Todos os materiais de terceiros que venham a ser utilizados ou disponibilizados devem ser referenciados, sob as penas legais, inclusive de plágio.

Tenho liberdade de expor ou não a minha imagem e voz nas atividades, o que não me desonera da participação efetiva nas mesmas.

Todas as gravações de atividades síncronas devem ser previamente informadas por parte dos professores.

Os alunos somente poderão gravar, armazenar ou compartilhar atividades mediante concordância prévia do professor, sob as penas legais.

Os alunos somente poderão armazenar ou compartilhar materiais mediante concordância prévia do professor ou se permitido no material, sob as penas legais.

É proibido disponibilizar, por quaisquer meios digitais ou físicos, os dados, a imagem e a voz dos alunos, dos colegas e do professor, sem autorização específica para a finalidade pretendida.

Para Meditar

Decisões Importantes para a Sociedade

TOMAR
DECISÕES
SEM DADOS É
COMO ESTAR
NO ESCURO
SEM LUZ!

SUAS DECISÕES ESTÃO GUIADAS
POR ESTRATÉGIAS OU PELA SORTE?
Você realmente sabe
o que está fazendo?

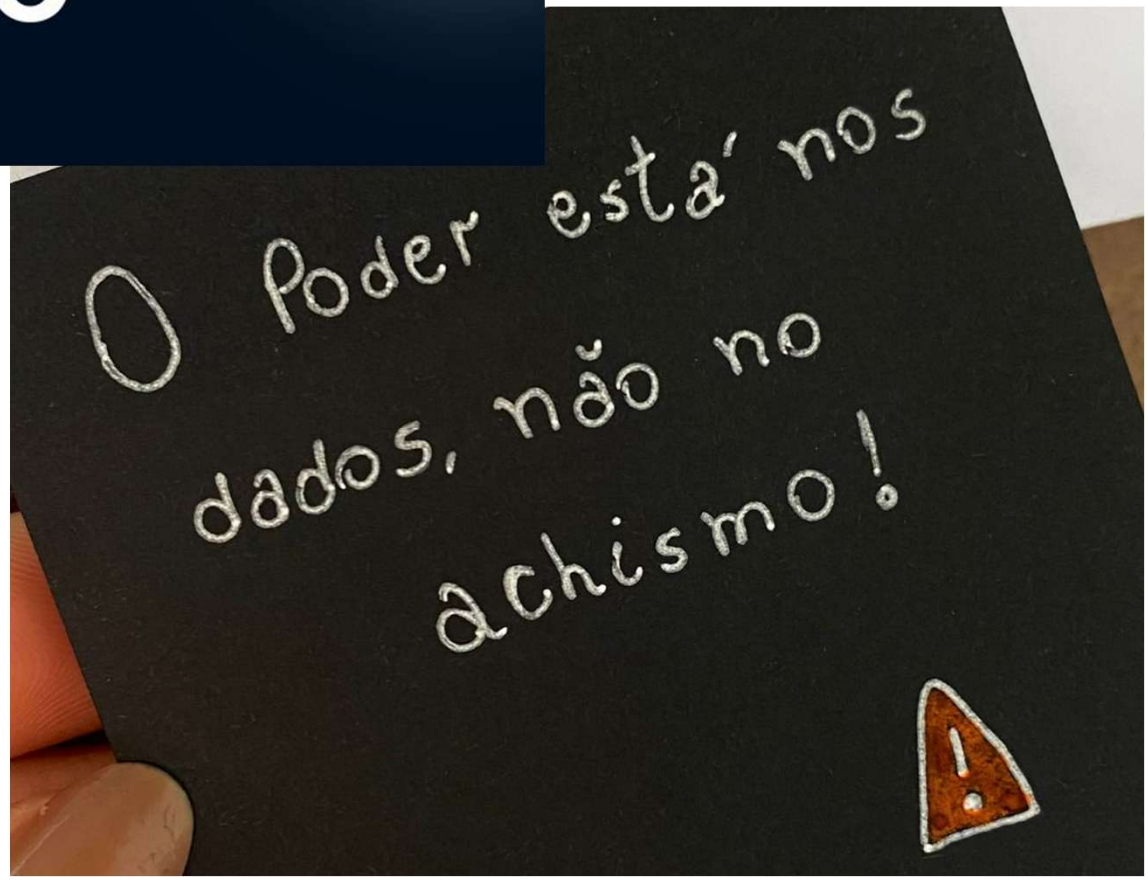
O Poder está nos
dados, não no
achismo!

ANALISAR DADOS
NÃO É APENAS
ARMAZENAR DADOS

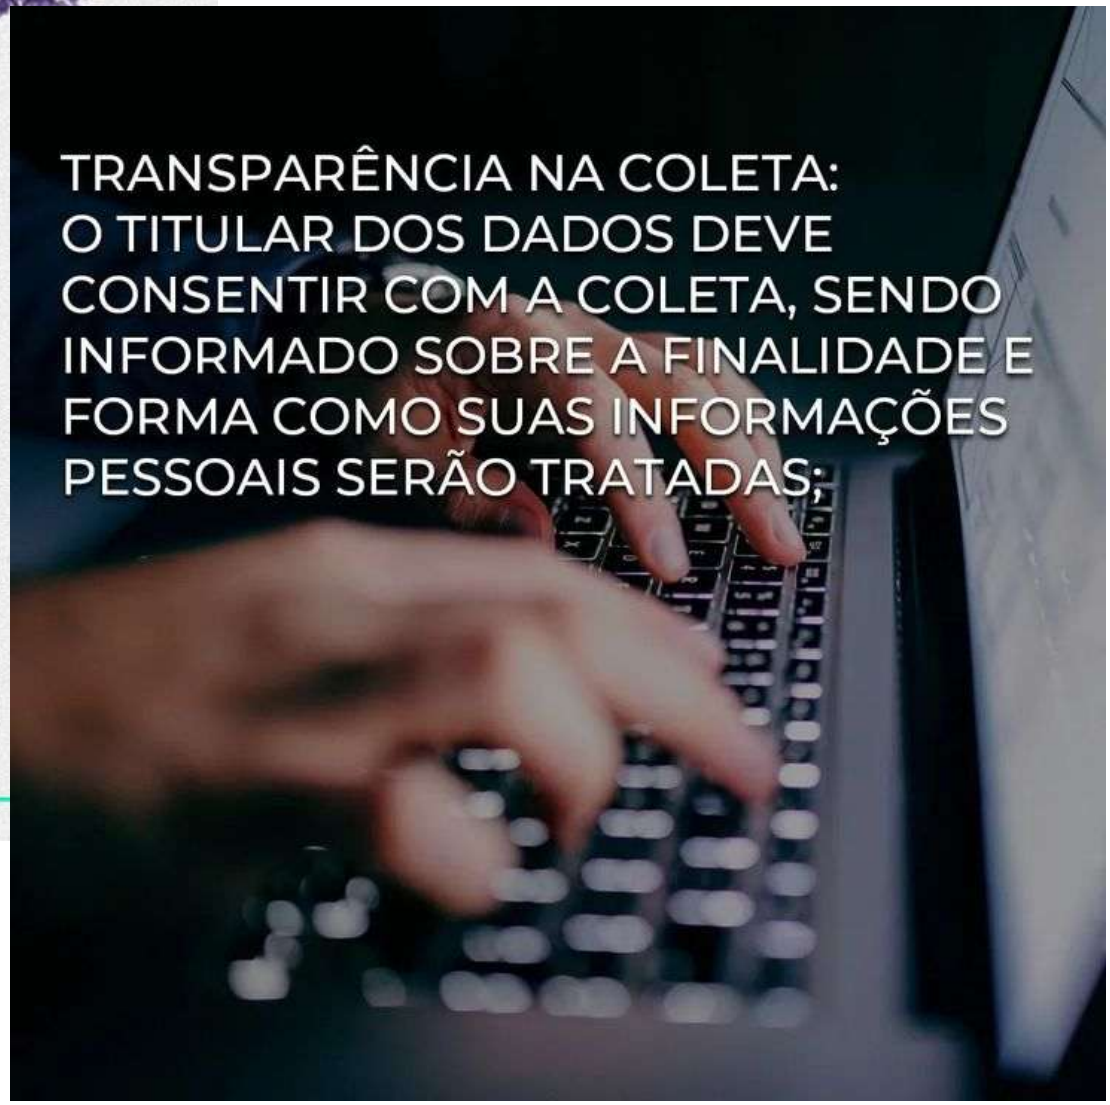
TRANSPARÊNCIA NA COLETA:
O TITULAR DOS DADOS DEVE CONSENTIR COM A COLETA, SENDO INFORMADO SOBRE A FINALIDADE E FORMA COMO SUAS INFORMAÇÕES PESSOAIS SERÃO TRATADAS;

Engenharia de Características: conceitos essenciais

Introdução

- IA apenas centrada nos modelos;
- pouca ou nenhuma consideração é dada aos dados.

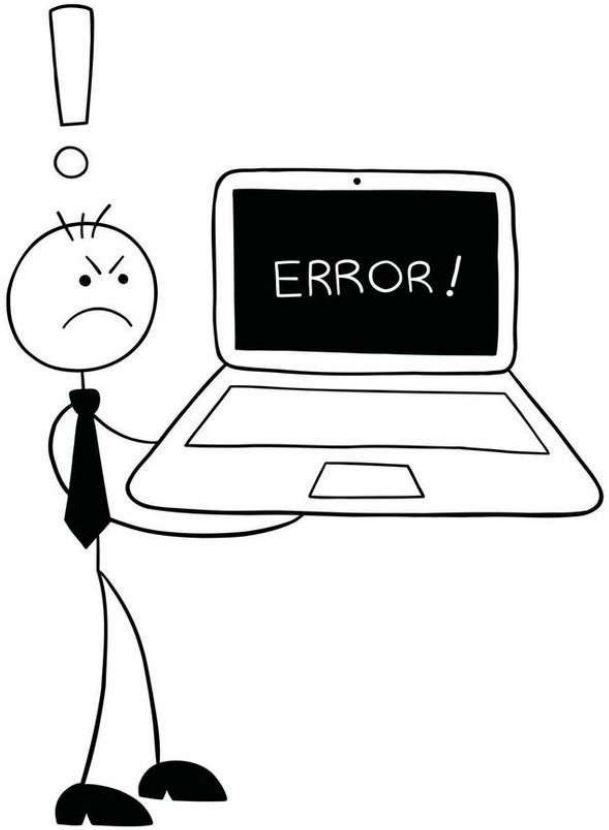

GRANDE ERRO!

Objetivo da Abordagem Centrada nos Dados

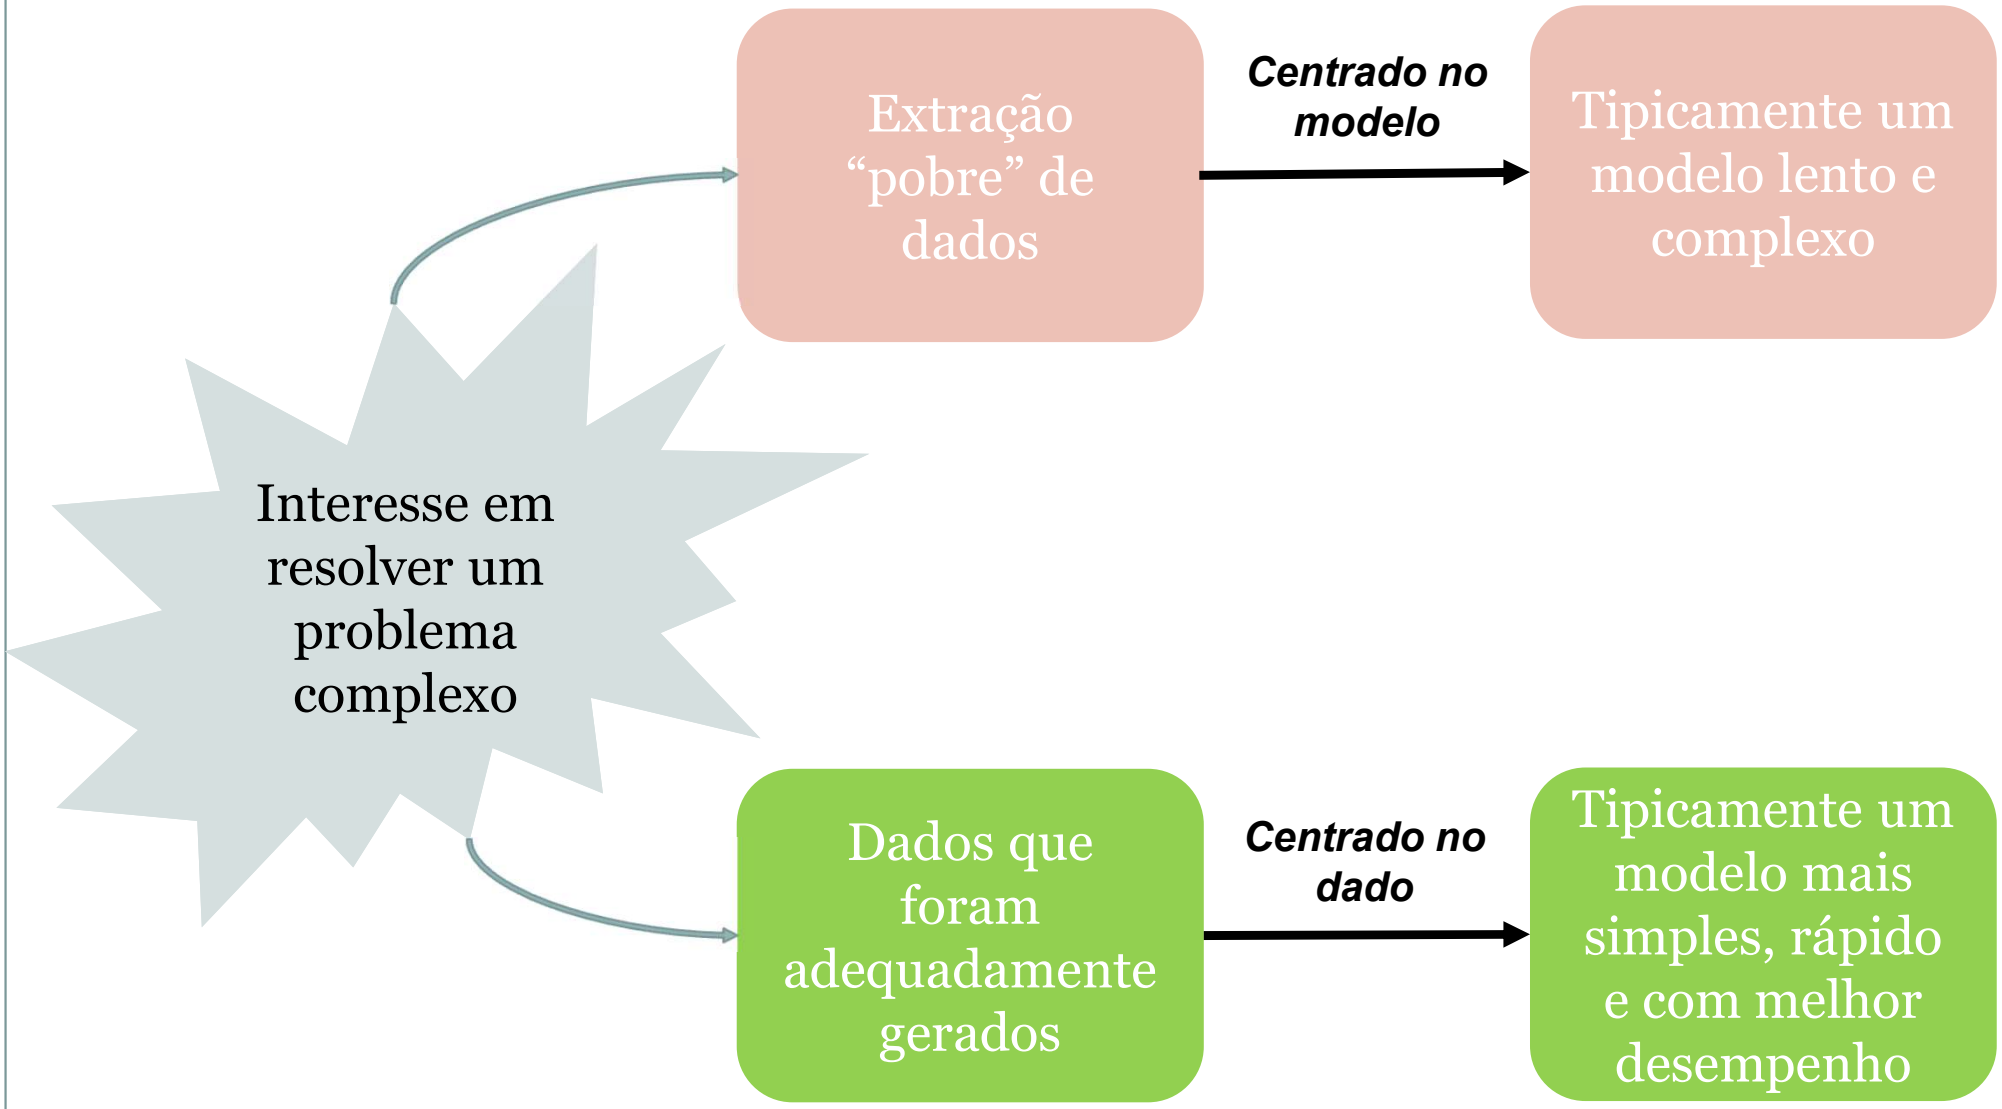

Pipeline Típico para Engenharia de Características

- 1º Definição do problema e pontos cruciais para avaliar o modelo inteligente;
- 2° Obteção dos dados para representar de forma adequada o problema de interesse;
- 3° Engenharia de características ou de recursos - foco principal na área de IA;
- 4º Seleção e treinamento de modelos - normalmente é a maior parte do *pipeline*;
- 5° Implantação e avaliação do modelo.

Dados Estruturados versus Não Estruturados

Estruturados ou Organizados	**Não Estruturados**
Modelo de organização rígido	Não tem uma organização pré-definida e não seguem nenhum modelo
Normalmente representados no formato tabular (linhas/colunas)	A própria definição é vaga
Normalmente as linhas representam as amostras e as colunas as características	Não se encaixa realmente em uma estrutura de linhas e colunas de forma organizada
Exemplos: banco de dados relacionais e tabelas de dados; documentos de dados de planilhas	Exemplos: transcrições de conversas de atendimento ao cliente, vídeos em plataformas genéricas, áudio de um podcast, imagens, etc.

Estruturados ou Organizados	Não Estruturados
Dados tabulares podem ser representados em linhas e colunas ou no formato de um banco de dados relacional	Não podem ser representados como dados tabulares. Geralmente considerados como uma massa de dados
Geralmente mais fáceis de usar como dados de imputação para aprendizado de máquina	Mais difíceis de usar como dados de imputação, pois precisam ser estruturados primeiro
Requerem menos capacidade de armazenamento	Requerem mais capacidade de armazenamento
Estima-se em torno de 20% dos dados do meio corporativo, como por exemplo, planilhas e arquivos CSV	Estima-se em torno de 80% dos dados do meio corporativo, como por exemplo, textos, vídeos e imagens

	2014	2015	2016	2017	2018	Desempenho
Carlos	497	904	8	643	405	
Emanuel	629	384	446	137	109	
Camila	44	697	216	664	905	
Fábio	748	567	308	965	569	
Fabiula	609	691	425	735	172	
Marta	370	820	119	550	112	
João	60	400	536	381	610	
Maria	198	260	49	72	3	
Alberto	912	318	679	125	590	
Daniel	485	548	233	761	66	
Cássia	124	248	534	295	306	
Mauro	243	306	912	983	258	
Roberta	928	494	52	213	944	
Walisson	676	228	459	50	96	

<u>Exemplo 01</u>: dados com porções estruturada e não estruturada

Considere, por exemplo, um conjunto de dados de chamadas telefônicas, onde um subconjunto desses dados inclui a data em que a chamada telefônica foi realizada e o nome da pessoa que a escreveu – são dados estruturados. Porém, o áudio bruto da chamada é não estruturado.

Outros Exemplos	Porção Estruturada	Porção Não Estruturados
Formulário de Seguro	Data do arquivamento, nome de quem arquivou e etc	Conteúdo das perguntas abertas
Podcasts	Data de lançamento do podcast, nome da plataforma hospedeira, categoria do podcast, etc	Áudio do podcast, a transcrição escrita do podcast
Logs de um Servidor	O registro da data/hora do log, local de origem do serviço, etc	O conteúdo do log

Como sugestão consultar: https://www.gartner.com/en/documents/3989657

Principais Metodologias da Engenharia de Características

Seleção de Características

- escolha das melhores características de um conjunto de características com o objetivo
- seleção de Característivas normalmente é usada quando:

Caract. 1	Caract. 2	...	Caract. n

Dimensão d X n

Caract. 2	...	Caract. k

Dimensão d X k (com k < n)

Processo de seleção do melhor subconjunto de características existentes:
reduz a dependência entre características e maximiza a eficiência dos dados e dos modelos.

Melhoria das Características

- aumento do número de características estruturadas por transformações matemáticas

Renda (milhares de R$)
100
NaN
...
20
NaN

Imputação pelo valor médio da coluna para os dados ausentes →

Renda (milhares de R$)
100
79
...
20
79

- Normalmente executamos a Melhoria de Características quando as características

Construção de Características

- **criação manual** de novas características usando

Dado Original

Renda Familiar (milhares de R$)
100
45
...
20
180

+

Novo Dado

Número de Pessoas na Família
2
3
...
1
5

Nova Fonte de Dados

Construção de uma nova característica usando uma nova fonte

Número de Pessoas na Família	Número de Pessoas na Família
100	2
45	3
...	...
20	1
180	5

- outro exemplo:

Renda (milhares de R$)
100
45
...
20
180

Agrupando de uma coluna numérica em uma categórica →

Renda Rotulada (formato binário)
≥ 100
< 100
...
< 100
≥ 100

- Construção de Características é muito usada quando

- Principais Dificuldades

Extração de Características

- **criação automática** de novas características

Texto Bruto
Parabéns pelo conceito em IC02!
Quem são os docentes desta linha de pesquisa?
Qual a linha de pesquisa do Balbinot?
Porque o discente mereceu parabéns? Pelo conceito A em IC02.
As disciplinas da linha de métodos inteligentes tem um potencial elevado de empregabilidade.

Aplicar a codificação *bag-of-words* para converter texto em um vetor →

Parabéns	Pelo	...	Empregabilidade
1	1	...	0
0	0	...	0
0	0	...	0
0	1	...	0
0	0	...	1

Codificação *multi-hot* para contagem de palavras

Aprendizagem de Características

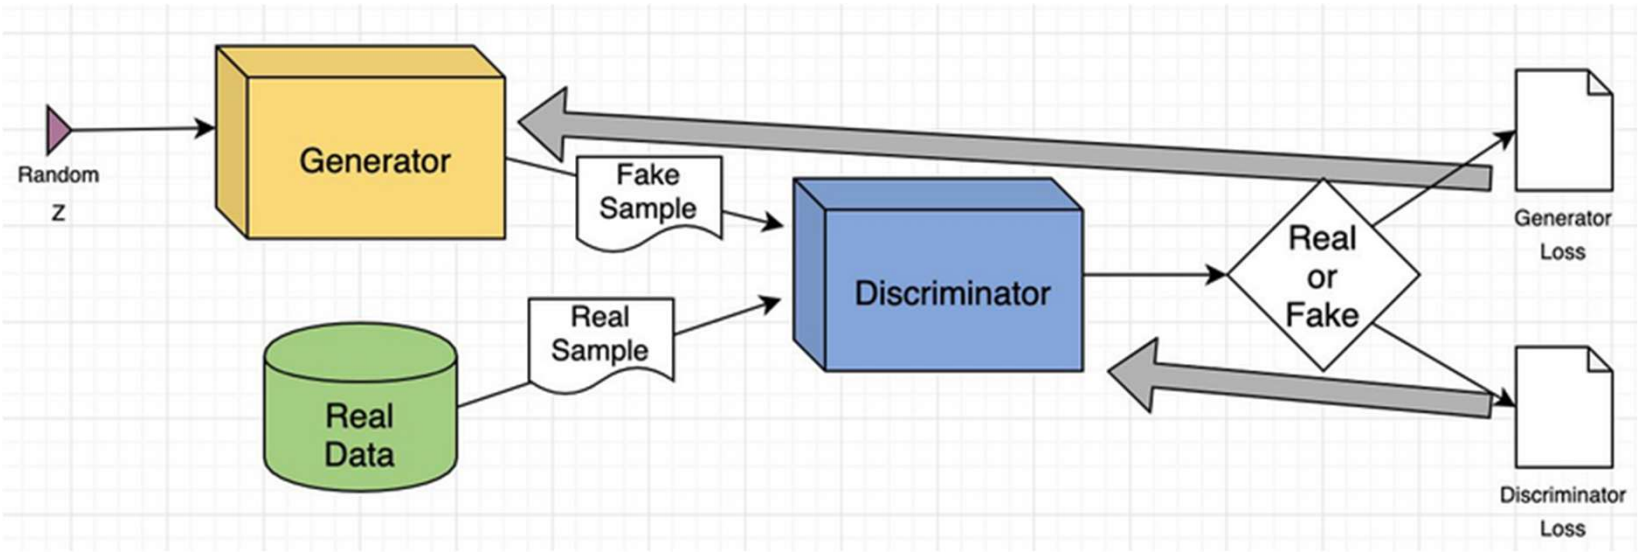

Modelo aprenderá uma representação vetorizada dos dados brutos

Modelo de Aprendizagem de Características

Modelo de aprendizado de recursos converterá dados não estruturados em dados estruturados

Texto Bruto
Parabéns pelo conceito em IC02!
Quem são os docentes desta linha de pesquisa?
Qual a linha de pesquisa do Balbinot?
Porque o discente mereceu parabéns? Pelo conceito A em IC02.
As disciplinas da linha de métodos inteligentes tem um potencial elevado de empregabilidade.

Caract. 1	Caract. 2	...	Caract. n
-0,20255	-0,785	...	0,45265
0,95262	0,3895	...	1,2582
1,0235	0,9858	...	0,4259
-0,3989	-0,4525	...	1,0125
0,8758	-1,5894	...	-0,5458

Resumo para Auxiliar na Escolha de Vocês

Técnicas de Engenharia de Características	**Descrição**	**Exemplos dos Principais Métodos**
Melhoria de Características	Uso de equações matemáticas para aumentar a previsibilidade de uma característica específica	Imputação Padronização/Normalização
Seleção de Características	Eliminação de um subconjunto de características existentes para isolar o subconjunto mais útil de características	Teste de hipóteses, DoE Eliminação recursiva de características
Construção de Características	Criação de novas características usando caractestícas existentes ou uma nova fonte de dados	Multiplicação/Divisão de características (união delas) União com um novo conjunto de dados
Extração de Características	Aplicação de transformações matemáticas em um subconjunto de características para criar um novo conjunto de características	Análise dos Componentes Principais Decomposição do Valor Singular
Aprendizado de Características	Uso de métodos não paramétricos para criar um conjunto de recursos estruturados, geralmente de uma fonte não estruturada	Redes Adversariais Generativas Autoencoders Máquinas de Boltzmann Restritas

Ferramentas em Python para Instalar e usarmos na próxima aula

- Jupyter Notebook;
- Pandas;
- Numpy;
- matplotlib;
- seaborn;
- scikit-learn;
- statsmodels;
- scipy.

Estatística Descritiva em Python: Algumas Métricas de Tendência Central

Analisando a Média de um Conjunto de Dados

<u>Exemplo 02</u>: média aritmética populacional

Suponha que você está jogando o famoso Rummikub e um colega resolveu jogar considerando que possamos ganhar R$20, R$40 ou R$60. Todas as possibilidades são igualmente prováveis. Gostaríamos de saber quanto podemos esperar ganhar se jogarmos este jogo, ou seja, qual é o valor esperado?

<u>Exemplo 03</u>: média aritmética amostral

Muitas vezes, não é possível medir μ diretamente, pois pode exigir muitas pessoas, muito dinheiro ou a população pode ser muito grande. Uma alternativa é estimá-lo com base em uma amostra aleatória (mas representativa) de n observações (observar que: n é menor, muitas vezes muito menor que N). Conhecemos esta métrica de média amostral:

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \cdots + x_N}{n}$$

Considere que você foi contratado para avalair o consumo típico de energia no mês de fevereiro na área circundante de Porto Alegre (RS), Rio Grande do Sul, usando dados de quilowatt-hora (kWh) de 2024 de 40 códigos postais. Os dados ordenados são

DADOS					
40	471	668	1064	4605	5222
5222	9755	10118	12713	16300	19126
23291	28025	44520	44520	46800	49739
96971	102947	104021	106050	107158	107158
115635	115747	116000	219895	219999	229661
231616	233812	235999	259975	299999	310098
313198	326418	439999	441205	449900	449999
454214	500928	561900	562460	631200	681073

DADOS					
40	471	668	1064	4605	5222
5222	9755	10118	12713	16300	19126
23291	28025	44520	44520	46800	49739
96971	102947	104021	106050	107158	107158
115635	115747	116000	219895	219999	229661
231616	233812	235999	259975	299999	310098
313198	326418	439999	441205	449900	449999
454214	500928	561900	562460	631200	681073

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \cdots + x_N}{n}$$

Analisando a Mediana de um Conjunto de Dados

Exemplo 04: mediana

Considere o conjunto de dados do Exemplo 03. Para obter a mediana os dados devem ser classificados inicialmente. Abaixo encontram-se os dados ordenados:

Ordem	DADOS						Ordem
1º dado →	40	471	668	1064	4605	5222	← 6º dado
7º dado →	5222	9755	10118	12713	16300	19126	← 12º dado
13º dado →	23291	28025	44520	44520	46800	49739	← 18º dado
19º dado →	96971	102947	104021	106050	107158	107158	← 24º dado
25º dado →	115635	115747	116000	219895	219999	229661	← 30º dado
31º dado →	231616	233812	235999	259975	299999	310098	← 36º dado
37º dado →	313198	326418	439999	441205	449900	449999	← 42º dado
43º dado →	454214	500928	561900	562460	631200	681073	← 48º dado

<u>Exemplo 05</u>: média versus mediana

Considerando os <u>Exemplo 03 e 04</u>. A média e a mediana são substancialmente diferentes:

$$\bar{X} = 194738{,}2kWk$$

$$Mediana = 111396{,}5kWh$$

Observar que ambas as métricas medem uma tendência central. Qual é a métrica mais confiável como um indicador para o consumo de energia mais típico desta base de dados?

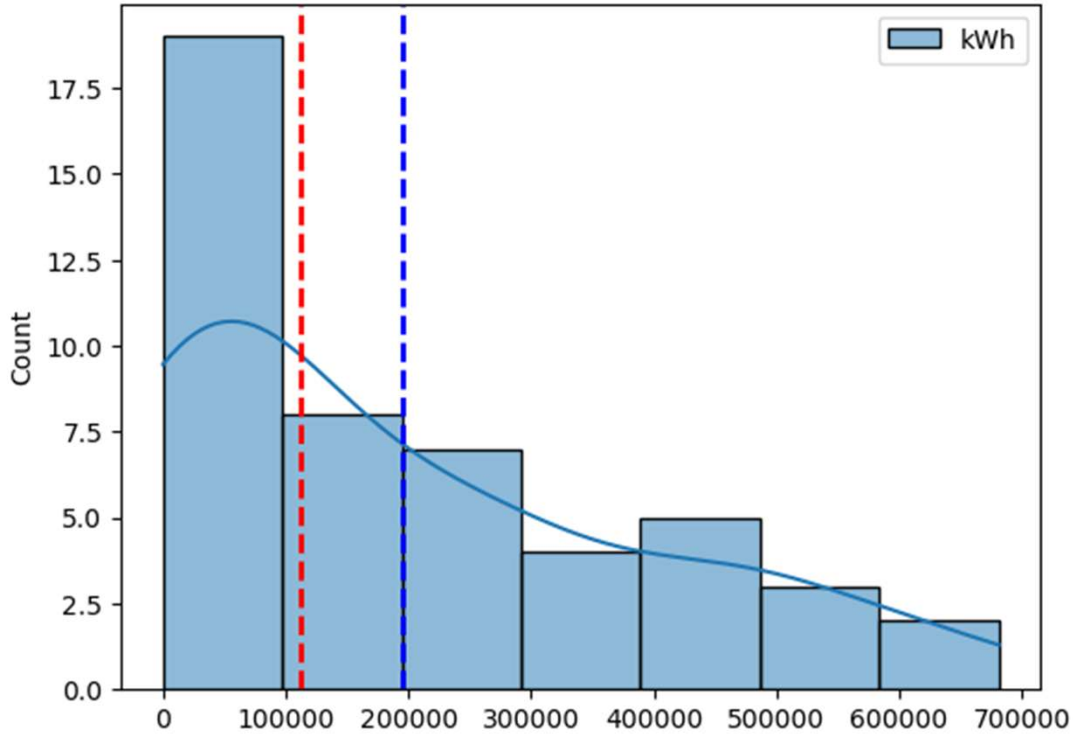

Comparando a Média e a Mediana

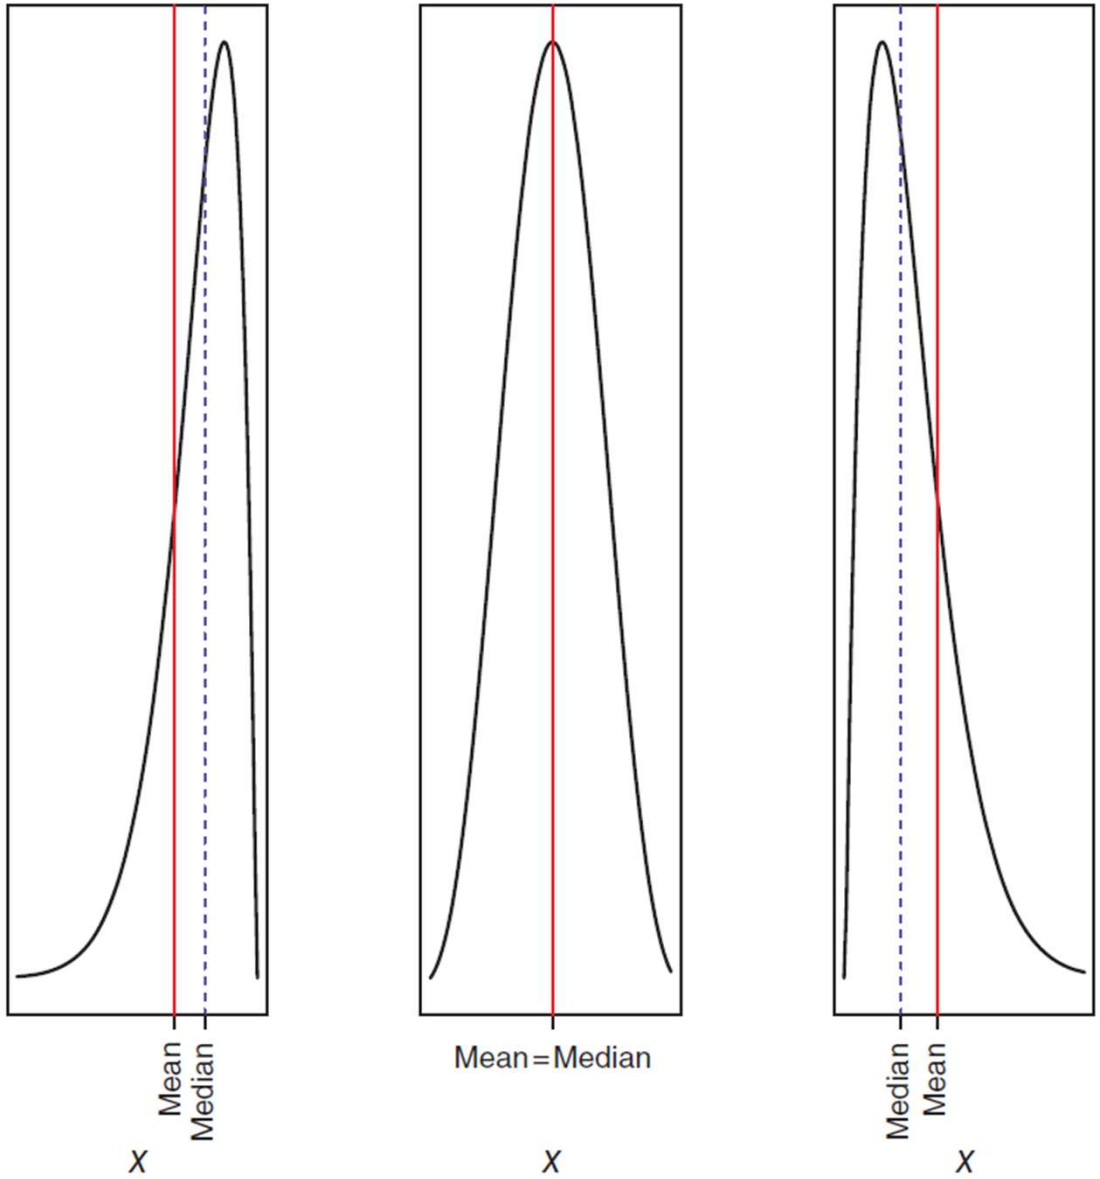

Exemplo 06:

Suponha que em uma dada comunidade um pesquisador está interessado em avaliar a gravidez na adolescência. Nesta pesquisa 120 adolescentes responderam a uma pesquisa, e uma das perguntas foi “Quantos filhos nascidos vivos você tem?”

Número de Filhos	**Frequência/Sexo**	
	Masculino	Feminino
0	48	43
1	10	13
2	2	4
Total	60	60

Analisando a Moda de um Conjunto de Dados

<u>Exemplo 07</u>:

Um estudante de pós-graduação está trabalhando em um projeto para determinar a quantidade de horas que os alunos do segundo ano de administração dedicam aos estudos em geral a cada semana. Oito das respostas da amostra aleatória foram:

2	1	4	2	3	8	5	2

Estatística Descritiva em Python: Algumas Métricas de Dispersão de Dados

Analisando a Variância e o Desvio Padrão de um Conjunto de Dados

Variância Amostral

- determinada por:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} = \frac{n\sum_{i=1}^{n} x_i^2 - (\sum_{i=1}^{n} x_i)^2}{n(n-1)}$$

Desvio Padrão Amostral

- determinado por:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Exemplo 08:

A seguir estão algumas das respostas de alunos do segundo ano do primário quando perguntados quantas mensagens de texto enviaram na última hora:

3, 27, 3, 5, 2

Qual é o desvio padrão do número de mensagens de texto?

i	x_i	$x_i - \overline{x}$	$(x_i - \overline{x})^2$	x_i^2
1	3	-5	25	9
2	27	19	361	729
3	3	-5	25	9
4	5	-3	9	25
5	2	-6	36	4
Soma	40	0	456	776
$\overline{x}$	8			

Estatística Básica em Python: Outras Métricas Importantes

Analisando a Faixa ou Amplitude de um Conjunto de Dados

Identificando os Percentis de um Conjunto de Dados

Identificando o Quartil de um Conjunto de Dados

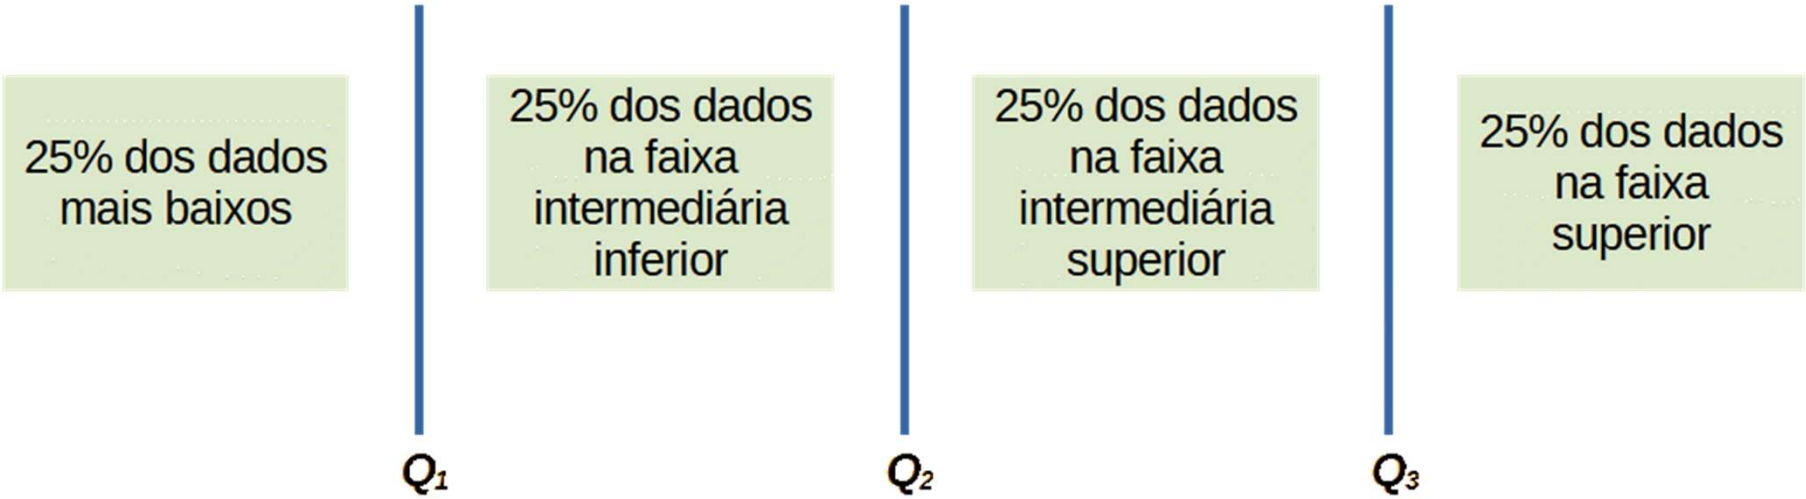

Exemplo 09:

Considere o seguinte conjunto de dados (86 observações):

Ordem	DADOS							
[1°]	40	471	668	1064	4605	5222	9755	10118
[9°]	12713	16300	19126	23291	28025	44520	46800	49739
[17°]	53640	63720	99794	121500	130944	133812	153037	153499
[25°]	173118	176418	331200	362460	404021	419895	447340	491964
[33°]	516000	535234	559975	581073	615747	673198	696971	754214
[41°]	761900	764775	829661	831616	836826	907158	915635	970928
[49°]	972945	1062664	1235538	1276576	1309065	1502947	1630032	1798960
[57°]	1937568	2540797	2814565	2902660	2949790	3206050	4315417	4490491
[65°]	5009918	5060494	6454158	6882965	8158407	8292035	8325783	8335953
[73°]	8574076	9235521	9859196	12209694	12450797	12568467	13864886	16382338
[81°]	16897434	19503463	21193679	21919235	23689663	54015896		

Determinar Q_1 e Q_3.

Identificando o Intervalo Interquartil de um Conjunto de Dados

$$IQR = Q_3 - Q_1$$

O IQR é o intervalo associado aos 50% centrais dos dados:

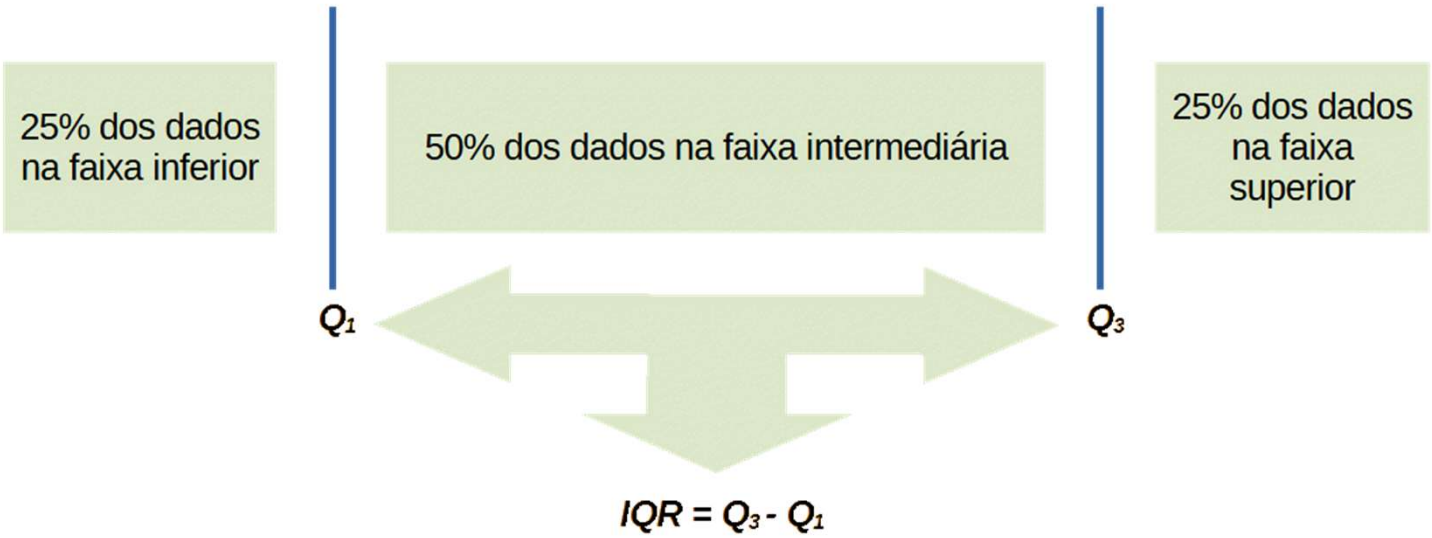

Exemplo 10:

Uma pesquisa foi realizada em 2011 pelos administradores do aeroporto de São Francisco (SFO) para analisar a satisfação dos passageiros. Uma das variáveis coletadas foi o tempo decorrido entre a chegada do passageiro ao SFO e a partida do voo (em minutos). A distribuição dos minutos desde a chegada ao Aeroporto Internacional de São Francisco (SFO) até a partida do voo foi apresentada no seguinte histograma:

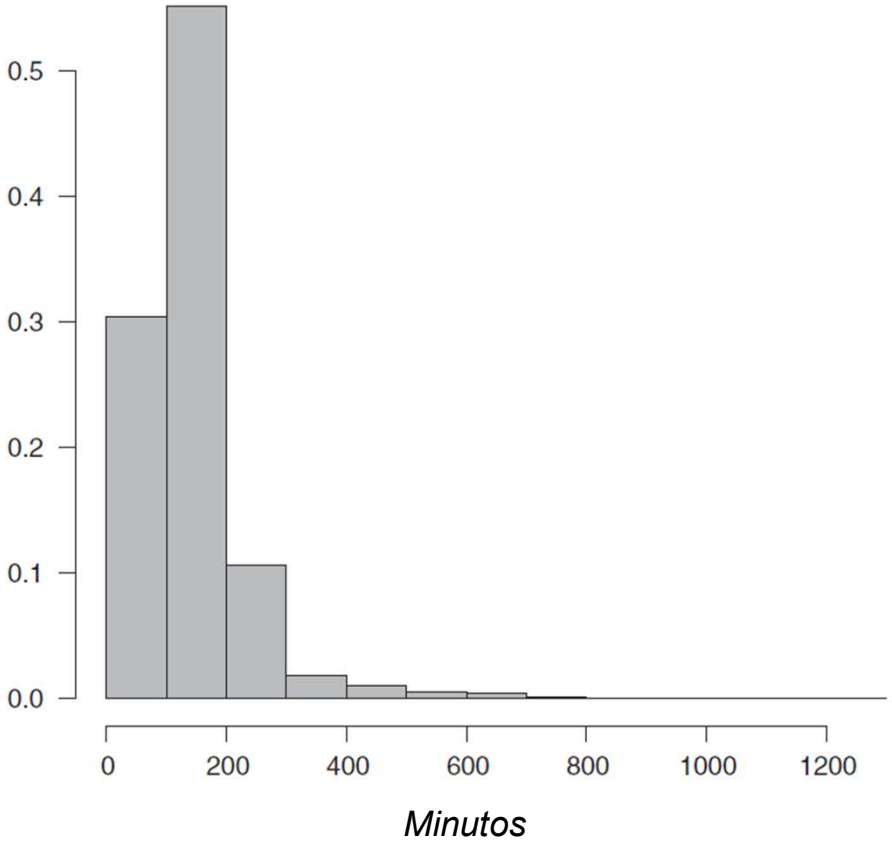

A maioria dos passageiros precisou esperar entre alguns minutos a cerca de 200 minutos.
Os dados são claramente assimétricos à direita, com alguns passageiros tendo que esperar muito mais do que 200 minutos.
Um passageiro teve um tempo de espera substancialmente maior, de 1300 minutos.
De posse da base de dados e de um código desenvolvido em Python encontramos:

$$Q_1 = 95 \; e \; Q_3 = 170$$

$$IQR = Q_3 - Q_1 = 170 - 95 = 75$$

Já o Desvio Padrão encontrado foi de
$s = 84{,}97$
provavelmente influenciado pelos valores discrepantes (*outliers*) dos dados.

Resumindo o gráfico Boxplot

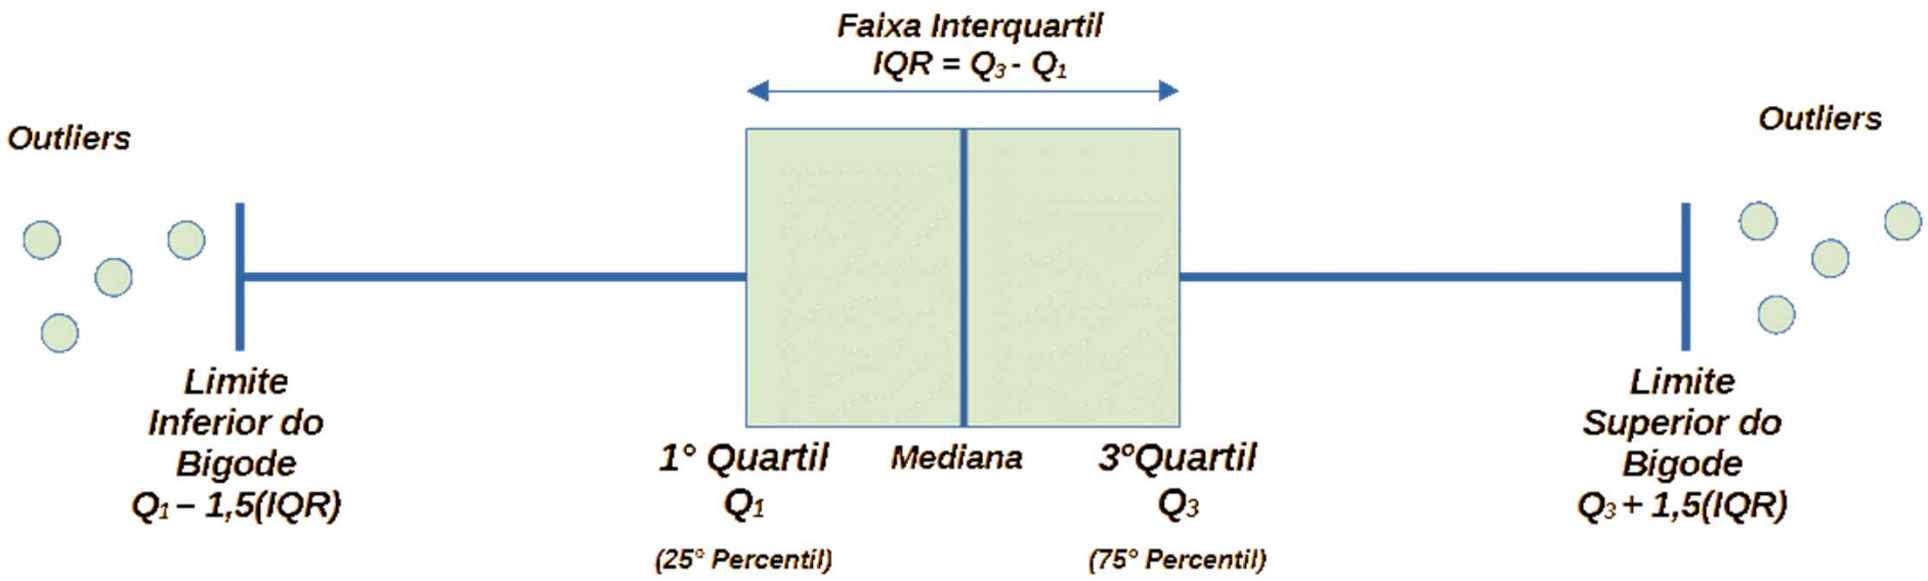

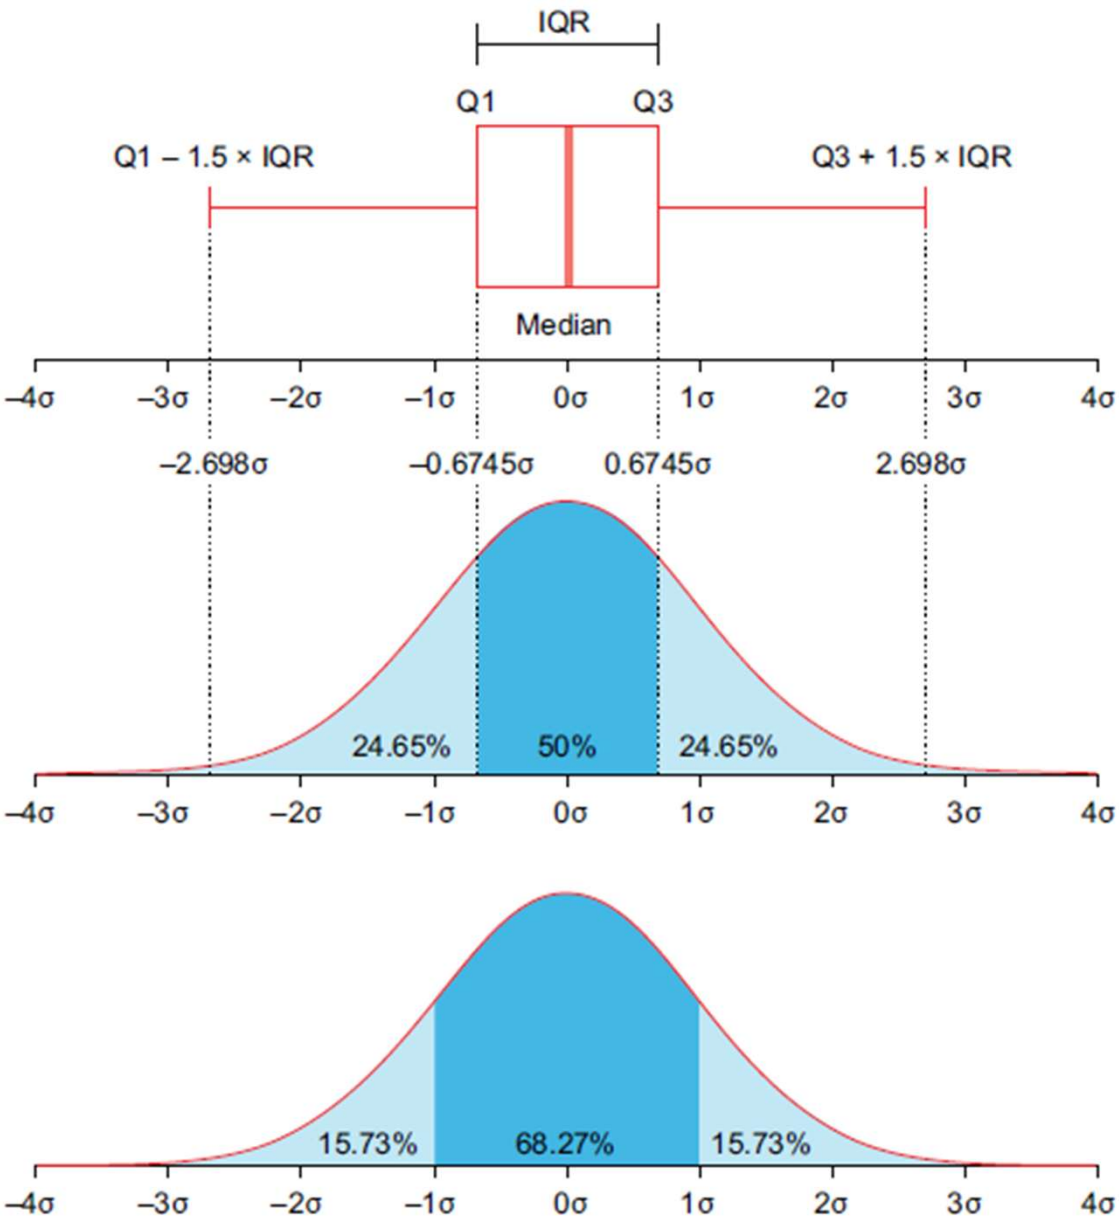

Variação Interquartil:

- imputação como *outliers*:
  - Q1 - 1,5 × IQR;
  - ou Q3 + 1,5 × IQR

Atividades de Laboratório

LAB01

- Acessar o Moodle:
  - para baixar os códigos
- Acessa o MCONF:
  - para baixar os dados
- Executar as tarefas solicitadas
- Vamos discutir as partes essenciais de cada tarefa
- Mãos à obra