UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Curso de Especialização

Inteligência Artificial para Engenheiros

Análise de Dados e Engenharia de Características

AULA 02B

Análise Multivariada

Professor Dr. Alexandre Balbinot

2026

IA PARA ENGENHEIROS
UFRGS

Universidade Federal do Rio Grande do Sul
Escola de Engenharia
Curso de Especialização Inteligência Artificial para Engenheiros
Laboratório de Sistemas Eletrônicos Inteligentes (LASEI)

Análise de Dados e Engenharia de Características

Aula 02B

Análise Multivariada

Prof. Dr. Alexandre Balbinot

Contatos

Prof. Dr. Alexandre ***Balbinot***

Curso de Especialização Inteligência Artificial para Engenheiros

Escola de Engenharia – UFRGS

Prédio do Instituto Eletrotécnico

Departamento de Engenharia Elétrica - DELET

Laboratório de Sistemas Eletrônicos Inteligentes (LASEI)

Sala 206D – (51) 3308-**4442**

alexandre.balbinot@ufrgs.br

Direitos Autorais

Este material possui Direitos Autorais e Direitos de Imagem e não pode ser duplicado, reproduzido, no todo ou em parte, sob quaisquer formas ou por quaisquer meios (eletrônicos, mecânico, gravação, fotocópia, distribuição na internet ou outros), sem permissão expressa do autor.

©

Termo de Responsabilidade da Própria UFRGS

Todos os materiais disponibilizados nos Ambientes Virtuais da UFRGS são exclusivamente para usos e fins didáticos, sendo vedada a sua utilização para qualquer outra finalidade, sob as penas legais.

Todos os materiais de terceiros que venham a ser utilizados ou disponibilizados devem ser referenciados, sob as penas legais, inclusive de plágio.

Tenho liberdade de expor ou não a minha imagem e voz nas atividades, o que não me desonera da participação efetiva nas mesmas.

Todas as gravações de atividades síncronas devem ser previamente informadas por parte dos professores.

Os alunos somente poderão gravar, armazenar ou compartilhar atividades mediante concordância prévia do professor, sob as penas legais.

Os alunos somente poderão armazenar ou compartilhar materiais mediante concordância prévia do professor ou se permitido no material, sob as penas legais.

É proibido disponibilizar, por quaisquer meios digitais ou físicos, os dados, a imagem e a voz dos alunos, dos colegas e do professor, sem autorização específica para a finalidade pretendida.

Análise Multivariada

Algoritmo *K-means* e Métricas de Medição de Similaridade

Implementando Análise por *Cluster* de Variáveis Múltiplas usando o Algoritmo *k-Means*

Exercício 01:

Analisar os seguintes dados representando as diferenças entre peças de um vetor com atributos discretos. Considerar o ***Dado x*** como nossa referência. Determinar: (a) qual elemento é mais similar ao *objeto x* considerando-se os 12 elementos do vetor ? (b) qual é a classe do *objeto x*?

		Casca		Preenchimento		
Dado	**Formato**	***Tamanho***	***Sombra***	***Tamanho***	***Sombra***	**Classe**
x	***Quadrado***	***Grande***	***Cinza***	***Fino***	***Branca***	***?***
Dado1	Círculo	Grande	Cinza	Grande	Preta	Pos
Dado2	Círculo	Grande	Branca	Grande	Preta	Pos
Dado3	Triângulo	Grande	Preta	Grande	Cinza	Pos
Dado4	Círculo	Fina	Branca	Fino	Preta	Pos
Dado5	Quadrado	Grande	Preta	Fino	Branca	Pos
Dado6	Círculo	Grande	Branca	Fino	Preta	Pos
Dado7	Círculo	Grande	Cinza	Grande	Branca	Neg
Dado8	Quadrado	Grande	Branca	Grande	Cinza	Neg
Dado9	Triângulo	Fina	Cinza	Fino	Preta	Neg
Dado10	Círculo	Grande	Preta	Grande	Branca	Neg
Dado11	Quadrado	Grande	Branca	Grande	Preta	Neg
Dado12	Triângulo	Grande	branca	Grande	Cinza	Neg

<u>Exercício 02</u>:

Você é o responsável por gerenciar uma grande loja virtual e gostaria de conhecer o comportamento dos usuários durante o momento da compra:

(a) Qual o verdadeiro objetivo deste tipo de estudo?
(b) Forneça sugestões para alcançar o objetivo proposto.

Objetivo*?*

Soluções Possíveis*:* ?

Distância Euclidiana

Procedimento Básico

Encontrar vizinhos próximos de ***x*** (dado a ser classificado) comparando as distâncias de cada objeto do conjunto de treinamento em relação a ***x***.

Distância Euclidiana no Plano 2D

Distância entre 2 pontos (***x*** = (x_1, x_2) e ***y*** = (y_1, y_2)) usando o Teorema de Pitágoras:

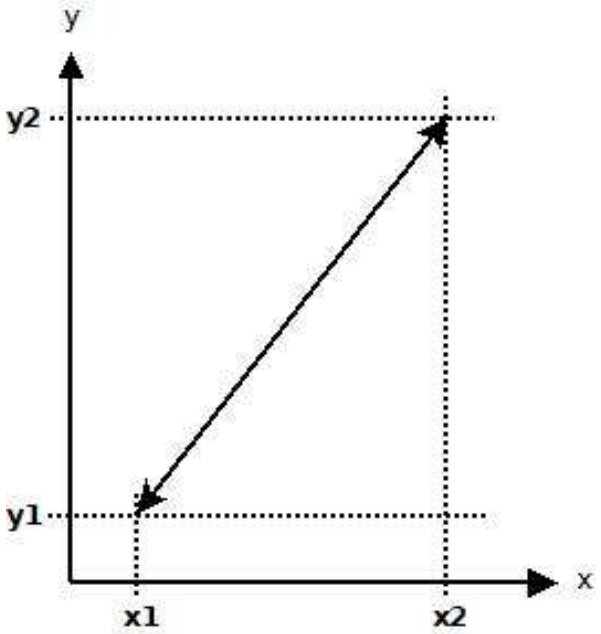

$$d_E(x, y) = \sqrt{(x1 - y1)^2 + (x2 - y2)^2}$$

Generalizando:

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Exercício 03:

Considerar o conjunto de treinamento indicado na tabela abaixo formada por 4 objetos ($Dado_1$ a $Dado_4$) representados por 3 atributos numéricos (características) e sua correspondente classe. Qual é a classe do objeto ou dado ***x = [2, 4, 2]*** utilizando o princípio do "*Vizinho Mais Próximo"* em um Espaço Euclidiano 3D (3 atributos para cada elemento do vetor)?

$Dado_1$	{[1,3,1], pos}
$Dado_2$	{[3,5,2], pos}
$Dado_3$	{[3,2,2], neg}
$Dado_4$	{[5,2,3], neg}

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Distância entre $Dado_{i=1\ a\ 4}$ e [2, 4, 2]?		
$Dado_1$	*{[1,3,1], pos}*	
$Dado_2$	*{[3,5,2], pos}*	
$Dado_3$	*{[3,2,2], neg}*	
$Dado_4$	*{[5,2,3], neg}*	

Principais Métricas: decisão crítica

Métodos Clássicos:

- Distância Euclidiana: $d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$

- Distância Manhattan (*city block distance*): $d_M(\boldsymbol{x}, \boldsymbol{y}) = \sum_{i=1}^{n} |x_i - y_i|$

x e y são vetores de comprimento n

Medidas Baseadas em Correlação ***(amplo uso na análise de dados estocásticos, dados genéticos, ...):***

- Distância da correlação de Pearson:

$$d_{correlação}(\boldsymbol{x}, \boldsymbol{y}) = 1 - \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2 \sum_{i=1}^{n} (y_i - \bar{y})^2}}$$

e etc...

O Agrupamento de Dados pelo Método *k*-means

Primórdios deste Algoritmo:

- algoritmo padrão proposto por Stuard Lloyd (1957) em estudos na área de modulação de sinais;
- versão mais eficiente proposta por Hartigan e Wong entre 1975 e 1979.

$$\underset{S}{argmin} \sum_{i=1}^{k} \sum_{x \in S_i} \|x - \mu_i\|^2$$

Lloyd, S. P. (1957). Least square quantization in PCM. Bell Telephone Laboratories Paper Published in journal much later: Lloyd., S. P. (1982). Least squares quantization in PCM. IEEE Transactions on Information Theory. 28 (2): 129–137. doi:10.1109/TIT.1982.1056489.

Fluxo Lógico

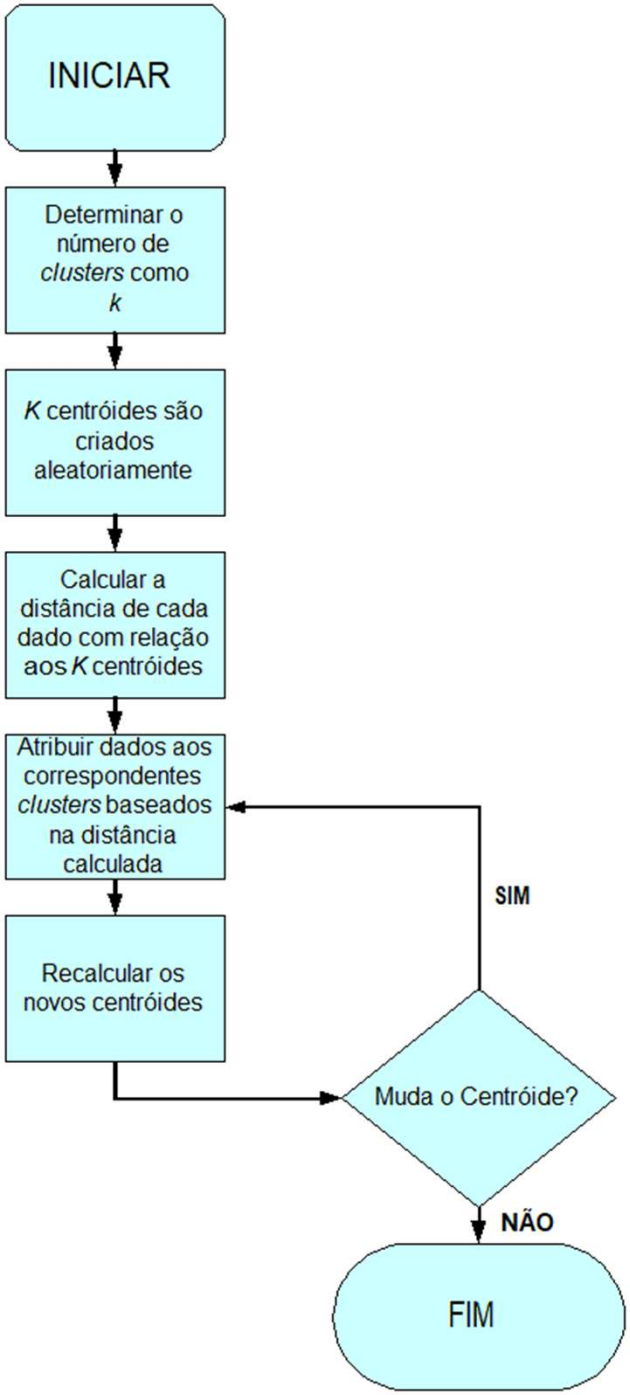

<u>Exemplo 04</u>: exemplo gráfico sobre o funcionamento básico do *k-means.*

Criação de 3 *clusters* (*k* = 3) em um classificador *3-means.*

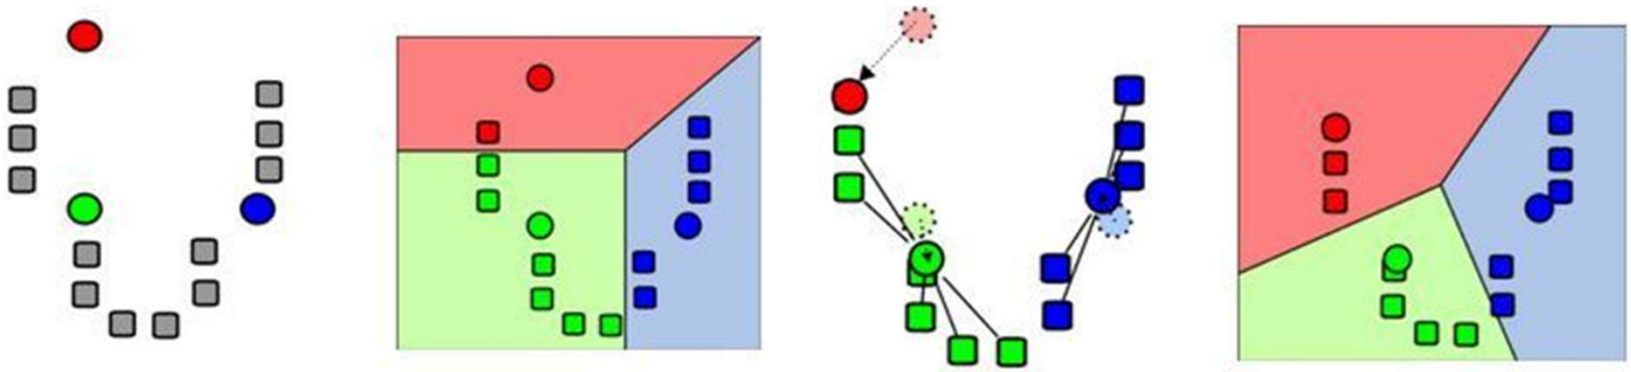

Algoritmo de Hartigan-Wong para o *k*-means

Cada dado (x_i) é associado a um cluster quando a distância da Soma dos Quadrados (SS) é mínima:

$$SS = SQ = \sum_{k=1}^{k} W(C_k) = \sum_{k=1}^{k} \sum_{x_i \in C_k} (x_i - \mu_k)^2$$

x_i é o dado pertencente ao Cluster C_k
μ_k é o valor médio dos dados pertencentes ao Cluster C_k

Métrica baseada na medida da compactação: ***quanto menor melhor!***

Pseudocódigo do *k-means*

1.
Especificar o número de *cluster* (k) a serem criados

2.
Selecionar aleatoriamente k elementos do conjunto de dados que representarão o centróide do *cluster* inicial

3.
Associar cada dado ao seu centróide mais próximo (com base na métrica de similaridade Distância Euclidiana entre o dado e o centróide)

4.
Em cada k cluster atualizar seu centróide calculando o novo valor médio de todos os dados
Centróide do $k^{ésimo}$ *cluster* é um vetor de comprimento p contendo as médias de todas variáveis dos dados do $k^{ésimo}$ *cluster*; p é o número de variáveis

5.
Iterativamente realizar o cálculo da soma dos quadrados (minimização)
Os passos 3 e 4 serão executados até que **não ocorra mais** alteração dos *clusters* ou quando o número máximo de iterações seja alcançada
Obs.: o padrão em muitas ferramentas computacionais é utilizar o valor máximo de 10 iterações

Principais Desvantagens do *k-means*

- não funciona muito bem com variáveis categóricas
  - sugestão:
    - algoritmo *K-Prototype* projetado para variáveis numéricas e categóricas.
- sensível a *outliers*
  - sugestão:
    - aconselhável tratá-los antes de usar o *k-means*;
    - ou usar um algoritmo baseado em densidade:
      - por exemplo o DBSCAN que funciona bem com *outliers*.
- número de *clusters* (k) precisa ser predefinido pelo usuário.

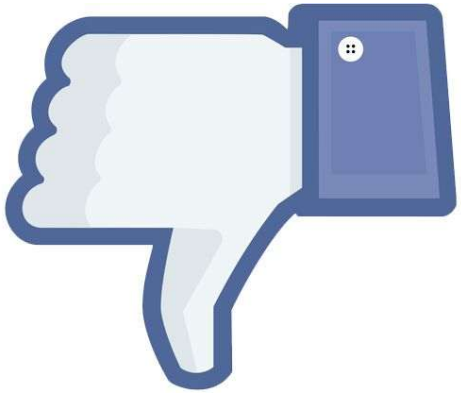

ALGORITMO PCA (*ANÁLISE DO COMPONENTE PRINCIPAL*)

Redução de Dimensionalidade (RD)

- objetivo:
  - reduzir o número de características preservando a qualidade das entradas;
- dados resultantes podem ser divididos em 2 tipos:
  - novas características: valores novos são gerados (muito conhecido como engenharia de características);
  - características antigas – apenas as características mais úteis foram preservadas;
- qual o motivo para um projetista de IA ou um cientista de Dados eliminar características depois que alguém (considerado um profissional habilitado) passou por tanta coisa para montar um conjunto adequado de dados?
  - a idéia não é necessariamente eliminar dados, mas sim explorar os dados de um jeito diferente, sendo assim, talvez encontrarmos alguns novos *insights* que possamos não ter visto usando o conjunto de dados original;
  - desenvolver modelos com muitas características é um processo computacionalmente caro, portanto, treinar um modelo de IC usando menor quantidade de características é mais rápido, computacionalmente menos intensivo e mais favorável;
  - usar RD pode ajudar a reduzir o ruído de um conjunto de dados para melhorar ainda mais os modelos, assim como, a visualizações dos dados.

REDUÇÃO DE DIMENSIONALIDADE

Conjunto de dados original com suas características

Mesmo conjunto de dados com menos características

O Curso da Dimensionalidade (CoD)

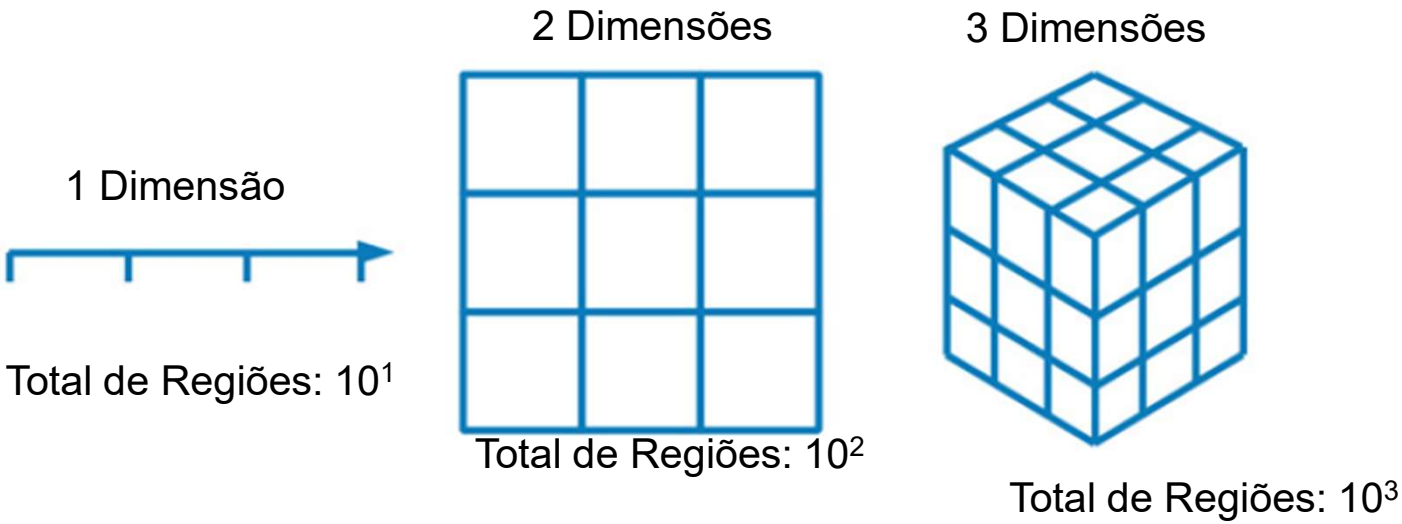

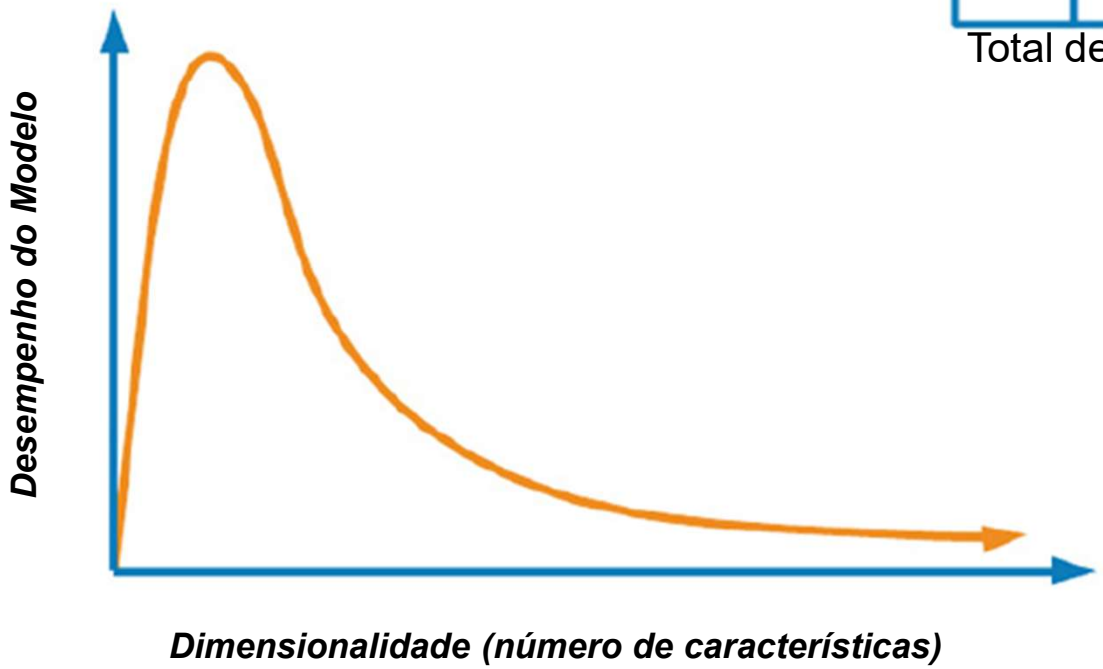

- irei focar no método mais usado (PCA), mas deixo como sugestão o estudo dos seguintes métodos:
  - o SVD (Decomposição do Valor Singular);
  - nos métodos não lineares sugiro os modelos t-SNE *(Stochastic Neighbor Embedding)* e o modelo UMAP *(Aproximação e Projeção Uniforme de Manifold)*.

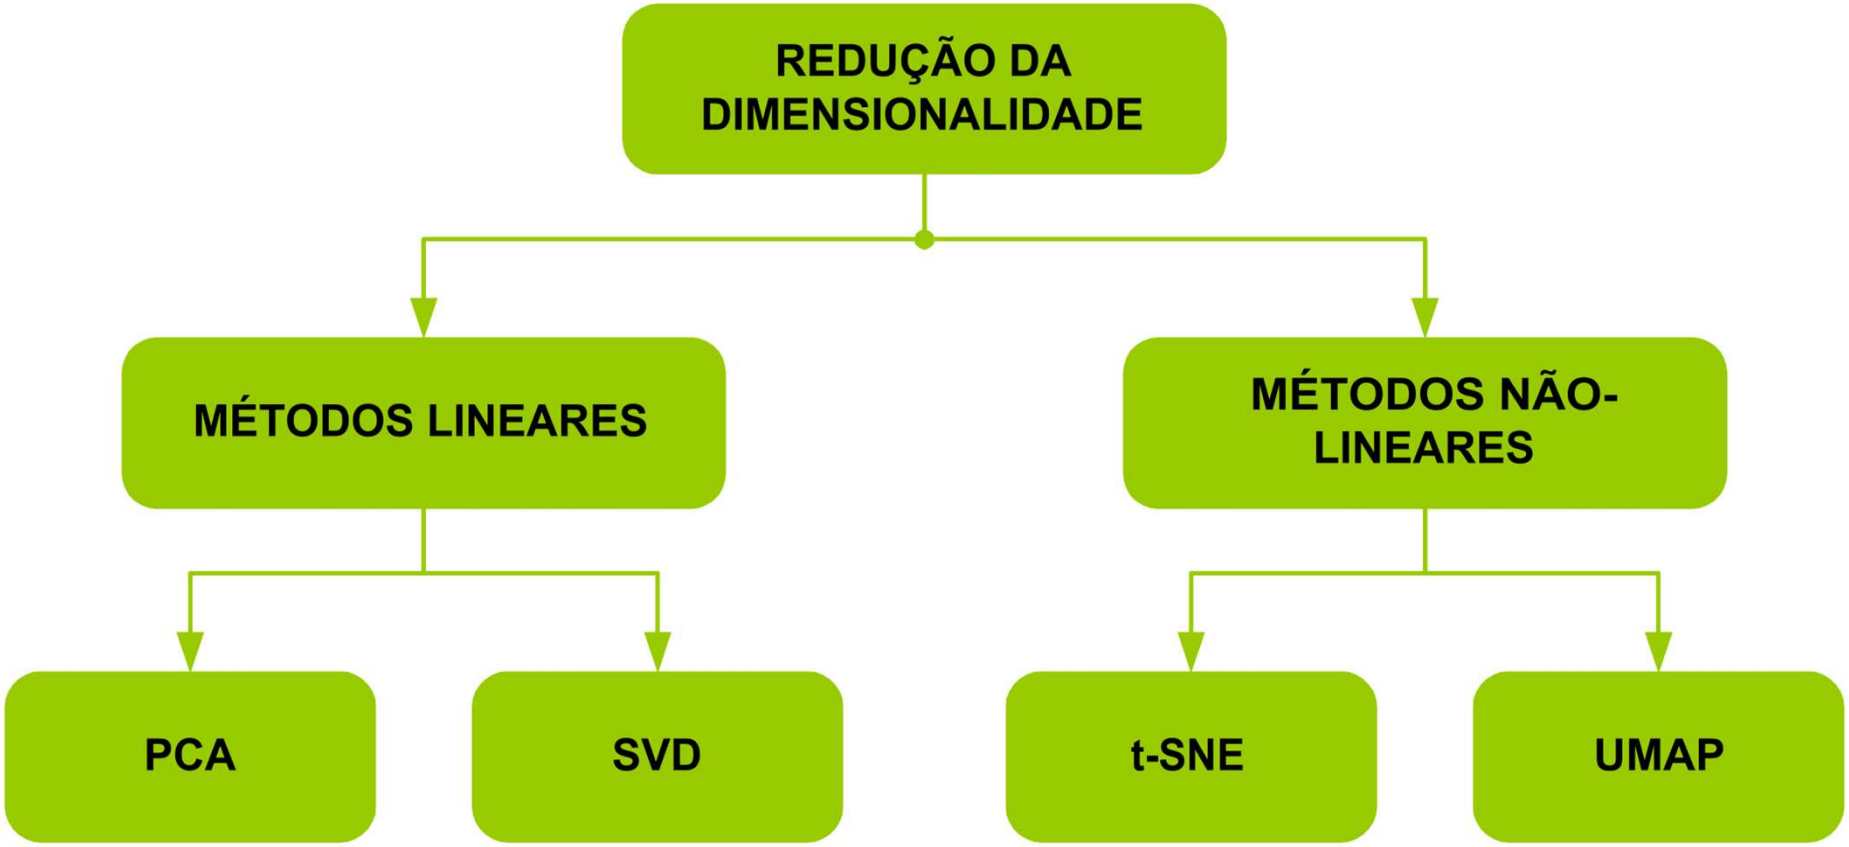

Implementando a Análise por Componente Principal (PCA) nas Variáveis Múltiplas

- método popular de Redução de Dimensionalidade usado para reduzir a dimensão de conjuntos de dados muito grandes;
- realiza este procedimento combinando múltiplas variáveis em novas variáveis chamadas de Componentes Principais (independentes entre si e que contêm informações valiosas das variáveis originais);
- observar que o PCA não fornece uma representação exata dos dados originais, mas tenta preservar o máximo possível as suas informações valiosas;
    - na maioria das vezes, produz um resultado suficientemente próximo para que possamos extrair *insights* (percepções).

PCA

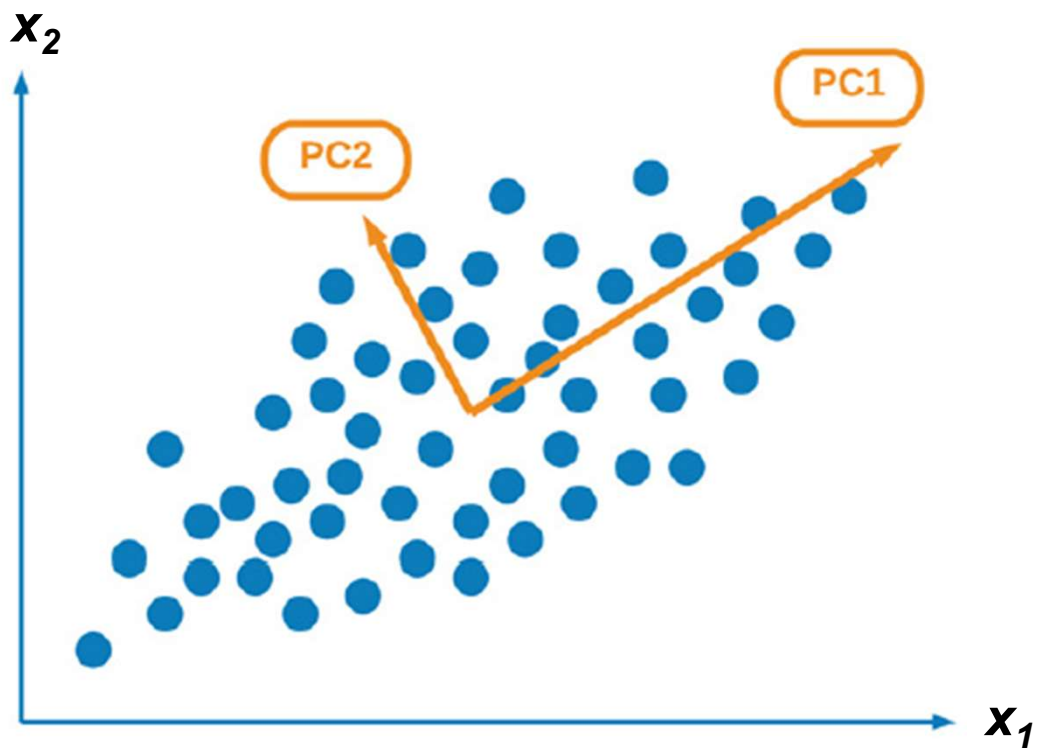

Representação Gráfica dos dados com caracterísricas 2D (original) e dos Componentes Principais (PC) do PCA.

Pseudocódigo do PCA:

- normalizar os dados para garantir que a média é 0 e o desvio padrão é 1;
- calcular a Matriz de Covariância (MC)
  - exemplo da MC para um conjunto de características (2D):

$$Matriz_de_Covariância = \begin{bmatrix} Var[X_1] & Cov[X_1, X_2] \\ Cov[X_2, X_1] & Var[X_2] \end{bmatrix}$$

- calcular os autovalores e os autovetores da Matriz de Covariância:

$$det(\lambda I - A) = 0$$

sendo λ o autovalor da matriz A e I a matriz Identidade

- determinar o autovetor v:

$$(\lambda I - A)v = 0$$

- ordenar os autovalores do maior para o menor (são os componentes em ordem de significância);
    - observar que um conjunto de dados com n características tem n autovalores e autovetores;
- podemos limitar o número de autovalores ou autovetores para um número pré-determinado, sendo assim, reduzindo as dimensões do conjunto de dados. Então formamos o que chamamos de vetor de características usando os autovetores de interesse.

- e finalmente formar os CPs como segue:

$$Componentes_Principais = Vetores_Novas_Características^T * Dados_Originais^T$$

Atividades de Laboratório

LAB02B

- Acessar o Moodle:
  - para baixar os códigos
- Acessa o MCONF:
  - para baixar os dados
- Executar as tarefas solicitadas
- Vamos discutir as partes essenciais de cada tarefa
- Mãos à obra