LAB04B

Revisar e Reforçar a Análise Exploratória de Dados: dados desbalanceados

UFRGS, DELET, Análise de Dados e Engenharia de Características, ©Balbinot, Alexandre

Objetivos

Revisitar e reforçar o estudo experimental sobre Análise Exploratória de Dados (EDA). Revisar conceitos básicos sobre *pipeline* e engenharia de características para nivelar os conhecimentos de todos com relação a área de Inteligência Computacional. Este laboratório apresenta alguns algoritmos para lidar com dados desbalanceadoss.

Conceitos Teóricos Adicionais

Revisar conceitos teóricos e experimentais apresentados nas aulas do Curso de Especialização Inteligência Artificial para Engenheiros. Apenas para registrar a biblioteca *Scikit-Learn* foi criada em 2007 por David Cournapeau como parte do projeto *Google Summer of Code* e é basicamente uma biblioteca Python de código aberto desenvolvida para facilitar o processo de construção de algoritmos estatísticos e de *Machine Learning* (ML) – na atualidade é constantemente melhorada por colaboradores. Caso tenha interesse em pesquisar mais sobre esta biblioteca sugiro acessar: https://scikit-learn.org/ e para conhecer algumas empresas que a usam acessar: https://scikit-learn.org/stable/testimonials/testimonials.html. É possível listar uma grande quantidade de vantagens no uso desta biblioteca, mas gostaria de ressaltar as principais desvantagens: (a) devido a sua facilidade de uso a mesma é pouco flexível, ou seja, o usuário não tem muita liberdade no ajuste de parâmetros ou na construção da arquitetura do modelo – isso pode acarretar sérios problemas para quem trabalha com problemas mais complexos e (b) esta biblioteca **não é considerada, por muitos, a melhor opção para quem trabalha com aprendizagem profunda**. Além disso, é importante ressaltar que a escolha do

algoritmo de *Machine Learning* (ML) adequado nem sempre é uma tarefa simples, pois muitas vezes pode não existir apenas uma solução para um problema envolvendo dados e/ou não existir um algoritmo que se adapta a todos os problemas que envolvam dados. Portanto, a escolha do(s) melhor(es) algoritmo(s) para um dado problema envolvendo dados é muitas vezes o ponto de virada em comparação as soluções medíocres. Este tipo de decisão vai necessitar um trabalho árduo da parte de vocês e muito estudo no decorrer das disciplinas deste curso, assim como, um avançado conhecimento da área ou das áreas de interesse (aplicação ou aplicações) – tarefa inerente a qualquer pessoa que trabalha nesta área de ML (*Machine Learning*) e DL (*Deep Learning*). Para esta árdua e essencial escolha sugiro seguir as seguintes etapas preliminares: (1) não despreze os dados, ou seja, entenda os dados ("gosto de brincar com esta frase: "namore os dados"): os dados são a chave para poder desenvolver qualquer boa solução de ML ou DL, sendo assim, o primeiro passo é compreender os dados para ter a capacidade de filtrar qualquer algoritmo que seja incapaz de processar tais dados. Observar que o número de características (ou instâncias) de um conjunto de dados depende do tipo de problema, da quantidade de saídas, da quantidade de medidas, da qualidade das medidas, da significância das características envolvidas, se as características envolvidas são dependentes ou independente entre si e assim por diante; (2) após o primeiro item é importante categorizar o tipo de problema com base nos dados que possui. Sendo assim você deve analisar seus dados de entrada para determinar, por exemplo, se o conjunto de dados é estruturado (tipicamente dados organizados em tabelas) ou não estruturado (por exemplo as imagens). Além disso, é necessário avaliar se todo o conjunto de dados contém um rótulo (ou alvo ou saída desejada), ou se parte menor dos dados contém um rótulo e a parte maior não possui rótulos, ou se todos os dados não possuem rótulos e etc. Assim será possível determinar se a base de dados é supervisionada, semi-supervisionada ou não supervisionada e com isso selecionar a família de algoritmos adequada, ou seja, se os dados possuem características (entradas) e rótulos (saída desejada) o algoritmo selecionado será um algoritmo de aprendizagem supervisionada e (3) na sequência você deve escolher um conjunto de algoritmos considerando-se as etapas (1) e a (2). Assim será possível avaliar qual o melhor algoritmo do conjunto de algoritmos selecionados – outros assuntos como alguns dos métodos

UFRGS DELET, Análise de Dados e Engenharia de Características, ©Bolbinot, Alexandre

para "alavancar o aluno mais fraco" são assuntos tratados ao longo de outras disciplinas do curso. **Mas é importante observar que é uma boa prática trabalhar e avaliar mais de um algoritmo nas aplicações de interesse de vocês**.

Datas Importantes

Aula(s) presencial(is) em ambiente de laboratório destinada a esta atividade: extraclasse.

Data da entrega deste relatório: não será entregue relatório desta atividade.

Procedimento de Avaliação deste Laboratório:

Não será apresentada nenhuma tarefa para avaliação relacionada a este laboratório.

Procedimentos

Digitar, executar e avaliar os seguintes códigos:

1.1 Materiais e Ferramentas Computacionais

- 01 Computador adequado
- 01Ambiente adequado para programar em Python com a instalação das bibliotecas necessárias as atividades (Numpy, Pandas, Matplotlib e etc)
- Acesso ao Moodle© e se necessário à nossa comunidade no MCOnf©

1.2. Desenvolver:

i. *Tarefa no Laboratório*: considerar a base de dados desbalanceada e avaliar seu impacto com uma matriz de confusão. Portanto, para exercitar e reforçar a importância da análise adequada dos dados selecionei um conjunto de dados disponibilizado pela UCI. Estes dados são utilizados para classificarmos se a renda anual excede ou não os 50.000 USD. Utilizar APENAS os dados disponibilizados no Moodle baixando o arquivo rotulado como ***adultoUCI.csv***. Para análise desta atividade **baixar o arquivo Lab04BIAENGTarefa01.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

ii. *Tarefa no Laboratório*: outra abordagem bem interessante para lidar com um conjunto de dados desbalanceado é atribuir uma penalidade a cada previsão errada sobre a classe

UFRGS DELET, Análise de Dados e Engenharia de Características ©Balbinot, Alexandre

minoritária. Isso pode ser feito usando, por exemplo, um parâmetro peso disponível no *scikit-learn* (*class_weight*) que permite atribuir uma penalidade para cada previsão errada relacionada a classe minoritária. Para análise desta atividade **baixar o arquivo Lab04BIAENGTarefa02.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

iii. *Tarefa no Laboratório*: avaliar uma demonstração extremamente simples do algoritmo SMOTE. Para análise desta atividade **baixar o arquivo Lab04BIAENGTarefa03.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

iv. *Tarefa no Laboratório*: avaliar o impacto do algoritmo SMOTE na base de dados utilizada em algumas das tarefas anteriores (baixar a base de dados ***adultoUCI.csv***). Para análise desta atividade **baixar o arquivo Lab04BIAENGTarefa04.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

v. *Tarefa no Laboratório*: avaliar o algoritmo disponibilizado no **arquivo Lab04BIAENGTarefa05.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

vi. *Tarefa no Laboratório*: avaliar o algoritmo disponibilizado no **arquivo Lab04BIAENGTarefa06.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

vii. *Tarefa no Laboratório*: avaliar o algoritmo disponibilizado no **arquivo Lab04BIAENGTarefa07.html**. Abrir o ambiente de programação Python, utilizar o código disponibilizado no arquivo e analisar o mesmo.

UFRGS, DELET, Análise de Dados e Engenharia de Características, ©Balbinot, Alexandre