Análise Comparativa de Predição de Churn via Inteligência Artificial: Abordagem Bibliométrica e Exploratória de Dados

Leonardo Scholl Sternberg
Análise De Dados E Engenharia De Características – IA para Engenheiros
UFRGS
Porto Alegre, Brasil
leossberg@gmail.com

Este artigo apresenta um estudo de predição de evasão de clientes (*churn*) em telecomunicações, unindo pesquisa bibliométrica e Análise Exploratória de Dados (EDA). O mapeamento da literatura na Scopus via VOSviewer destacou a intersecção entre *machine learning* e o ciclo de vida do cliente (CLV). Na etapa prática, aplicou-se uma EDA (manual e automática em Python) sobre o dataset "IBM Telco Customer Churn". A exploração evidenciou uma taxa geral de *churn* de 26,54% e revelou uma forte interdependência de serviços: contratos sem fidelização ('Month-to-month') com internet de fibra óptica atingem 54,61% de evasão. Conclui-se que o tratamento dos dados assegurou uma base íntegra e sem vazamentos, ideal para o treinamento futuro de algoritmos preditivos avançados .
Palavras-chave: Predição de *Churn*, *Machine Learning*, Análise Exploratória de Dados, Bibliometria, Telecomunicações.

I. Introdução

No cenário competitivo das telecomunicações, prever a evasão de clientes (*churn*) e gerenciar o valor do ciclo de vida do cliente (CLV) tornaram-se prioridades de negócio. Para solucionar esse desafio e evitar a perda de receita, o uso de inteligência artificial e aprendizado de máquina vem assumindo um protagonismo global na identificação de padrões de cancelamento.

Para atender aos requisitos propostos de consolidação teórica e prática da disciplina, este trabalho integra a fundamentação bibliométrica a uma exploração de dados aplicada. O primeiro objetivo é realizar um mapeamento da literatura sobre predição de *churn* e aprendizagem de máquina, diagnosticando os principais algoritmos e autores. O segundo pilar consiste em desenvolver uma Análise Exploratória de Dados (EDA) utilizando a linguagem Python sobre a base "Telco Customer Churn" da IBM, preparando o conjunto de dados contra anomalias e ruídos por meio de métodos manuais e automáticos.

O documento está estruturado da seguinte maneira: A Seção II apresenta a Metodologia, englobando a arquitetura de busca teórica e os procedimentos técnicos de limpeza de dados. A Seção III concentra os Resultados e a Discussão, ilustrando as redes bibliométricas e o diagnóstico estatístico multivariado do dataset. Por fim, a Seção IV expõe as conclusões sobre a estruturação e a robustez da base analisada.

II. Materiais e Métodos

Esta seção detalha a metodologia adotada para o desenvolvimento do projeto. Primeiramente, descreve-se a pesquisa bibliométrica, detalhando a estratégia de busca na literatura e as ferramentas de mapeamento computacional utilizadas para fundamentar o estado da arte. Na sequência, expõe-se o *dataset* que é o objeto de estudo, a configuração do ambiente de desenvolvimento, a técnica da limpeza de dados, e por último, na Análise Exploratória de Dados (EDA), conduzidas tanto de forma manual quanto automatizada para identificar padrões e preparar a base para modelagem.

A. Extração da Base para Pesquisa Bibliométrica

A coleta de dados foi realizada na base de dados Scopus [1], selecionada por sua abrangência em periódicos de alto impacto nas áreas de Engenharia e Ciência da Computação. A busca foi estruturada para identificar a interseção entre modelos de aprendizado de máquina e a retenção de clientes. A *query* de busca utilizada foi:

("churn prediction" OR "customer lifetime value") AND ("machine learning" OR "artificial intelligence")

Os critérios de refinamento aplicados foram:

- Intervalo temporal: últimos 5 anos (2021–2026), visando capturar o estado da arte e modelos de *Deep Learning* recentes.
- Tipo de documento: artigos de periódicos e revisões (*Article* e *Review*).
- Idioma: inglês.

A busca resultou em um corpo de 340 documentos, exportados em formato .csv contendo metadados completos (citações, referências e palavras-chave). O volume reduzido da amostra pode limitar a generalização dos resultados bibliométricos, favorecendo a detecção de nichos específicos de produção.

B. Ferramenta Computacional para Estratégia de Mapeamento

Para a visualização e análise bibliométrica, utilizou-se o software VOSviewer (v.1.6.20) [2]. O processamento dos metadados resultaram em análises distintas para fundamentar o desenvolvimento do projeto.

1. Análise de coocorrência: utilizada para mapear as palavras-chave dos autores, permitindo identificar os algoritmos de IA mais prevalentes (e.g., *Random Forest*, *XGBoost*), nichos tecnológicos e as tendências de aplicação sua relação com o termo *Customer Lifetime Value* (CLV).
2. Cocitações de autores: para identificar as bases teóricas que sustentam o estado da arte na predição de *churn*, realizou-se uma análise de cocitação. Esta técnica mapeia a frequência com que dois autores são citados juntos em um mesmo artigo, revelando a

estrutura de influência intelectual na área de inteligência de negócios.

3. Análise de distribuição geográfica: ele é fundamental para mostrar a distribuição geográfica da produção científica e identificar os centros de excelência global no tema.

4. Acoplamento bibliográfico: esta análise é utilizada para justificar a relevância científica do seu projeto, pois identifica quais periódicos estão publicando as pesquisas mais conectadas e influentes sobre a interseção entre IA, Churn e CLV.Descrição dos Datasets

C. *Objeto de Estudo: Dataset IBM Telco Customer Churn*

Este trabalho optou por concentrar a análise no *dataset* Telco Customer Churn, disponibilizado pela IBM [3]. A escolha justifica-se por este ser considerado um "padrão da indústria" em competições de Ciência de Dados e estudos acadêmicos, oferecendo uma estrutura rica que simula desafios reais de retenção de clientes em telecomunicações.

O conjunto de dados compreende informações de 7.043 clientes na Califórnia, contendo 33 variáveis que abrangem:

- Perfil demográfico: gênero, idade e presença de dependentes.
- Serviços contratados: telefonia, múltiplas linhas, internet, segurança online, *backup*, proteção de dispositivos e suporte técnico.
- Informações de conta: tempo de permanência (*tenure*), tipo de contrato, método de faturamento (com ou sem papel) e forma de pagamento.
- Métricas financeiras: cobranças mensais e cobranças totais.
- Variável alvo (Target): indicação se o cliente abandonou o serviço no último mês (*churn*).

D. *Ambiente de Desenvolvimento e Bibliotecas*

Para a implementação técnica, manipulação dos dados e análises exploratórias, optou-se pela linguagem de programação Python (v3.12.10) [4]. As ferramentas computacionais e bibliotecas aplicadas dividem-se de acordo com suas finalidades de processamento (estas também dispostas no arquivo requirements.txt no anexo):

- Carregar o *dataset*: a biblioteca kagglehub (v.1.0.0) [5] foi acionada para executar o download direto e descompactação do conjunto de dados. Para a etapa de conversão dos dados em um formato estruturado tabular e operações matriciais, empregou-se a biblioteca pandas (v.2.3.3) [6], auxiliada pelo módulo nativo os para a gestão de diretórios de arquivos locais.
- Visualização de dados: o desenvolvimento da análise gráfica manual foi suportado pelas bibliotecas matplotlib (v.3.10.0) [7] e seaborn (v.0.13.2) [8], responsáveis por gerar representações estatísticas.
- EDA automática: para a geração da EDA automática, fez-se uso das bibliotecas sweetviz (v.2.3.3) [9], e alternativamente, ydata-profiling (v.4.18.4) [10]. Ambas são similares, e foram encarregadas de varrer o dataset limpo para exportar relatórios estatísticos em formato HTML.

E. *Limpeza de Dados*

A higienização do *dataset* visou assegurar a consistência matemática das variáveis e corrigir anomalias que pudessem enviesar as análises. Os principais processamentos executados foram:

- Tratamento de valores ausentes e tipagem: realizou-se uma varredura para diagnosticar registros duplicados, campos vazios, campos com espaço (vazios ocultos). Foram retiradas colunas que não agregavam para a análise posterior, e preenchidos campos seguindo de forma lógica.
- Redução de dimensionalidade e prevenção de vazamento (d*ata leakage*): o vetor de atributos passou por uma filtragem para manter apenas variáveis com potencial preditivo. Descartaram-se sistematicamente colunas atuantes como identificadores únicos e constantes (que não possuem variância); características de geolocalização com granularidade redundante; e, fundamentalmente, rótulos paralelos com a variável alvo que pudessem causar *data leakage*.

F. *Análise Exploratória de Dados (EDA)*

A Análise Exploratória de Dados (EDA) constitui a etapa fundamental de transição entre a fundamentação teórica bibliométrica e a modelagem preditiva. O objetivo desta fase é realizar um diagnóstico do *dataset*, identificando padrões ocultos, anomalias e as relações de dependência entre os atributos e a variável alvo. A execução da EDA foi estruturada:

- Diagnóstico de integridade e engenharia de dados: verificação da consistência estatística das variáveis, tratamento de tipagem, garantindo que não existam inconsistências que possam comprometer a precisão dos algoritmos de IA.
- Análise univariada e perfil de evasão: caracterização estatística de variáveis isoladas. O objetivo é definir a função de densidade de probabilidade das variáveis contínuas e a distribuição de frequência das variáveis categóricas. Aplicação para identificação de *outliers* e desbalanceamento de classes.
    - Análise bivariada e matriz de associações: investigação de existência de dependência estatística entre pares de variáveis (Xi, Xj) ou entre um preditor e o rótulo (Xi, Y). Aplicação em determinar o poder preditivo de cada *feature*.
- Análise multivariada: centraram-se na extração de coeficientes de correlação linear e mapas de correlação pareada (*pairplots*), buscando identificar as forças de interdependência mais expressivas do sistema.

O protocolo desta fase seguiu duas abordagens, que apresentam as análises univariadas, bivariadas e multivariadas:

- EDA manual: criação de gráficos individualmente para análise dentro do notebook.

- EDA automática: geração de relatórios automatizados (*profiling*), com relatório exportado em arquivo HTML.

III. Resultados Bibliométricos

Como resultados da pesquisa biométrica, seguindo a fundamentação descrita nos Materiais e Métodos, encontramos os seguintes:

1. Análise de coocorrência: A análise, apresentada na Fig. 1, revelou que o termo central "*Machine Learning*" atua como uma ponte entre dois grandes polos: um focado em algoritmos clássicos (como *Logistic Regression*, *Decision Trees* e *Random Forest*) e outro focado em métodos avançados (*Deep Neural Networks*). Adicionalmente, o mapa evidenciou que a predição de *churn* é tratada de forma integrada com a análise de "*Sales*" e "*Forecasting*", consolidando a importância estratégica da IA para a retenção de receita. Observa-se nitidamente a segmentação da rede em três áreas de foco predominantes: o *cluster* metodológico de algoritmos em verde/ciano, o *cluster* de negócios e estratégia de vendas no azul e o *cluster* de métodos avançados no ciano superior.

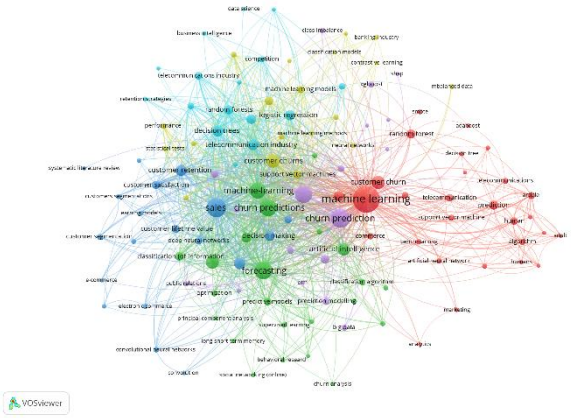

Fig. 1 - Mapa de rede de coocorrência de palavras-chave.

2. Cocitações de autores: A análise de cocitação, ilustrada na Fig. 2, identifica os pesquisadores cujas obras formam o alicerce acadêmico para o uso de modelos preditivos. A rede é caracterizada por três *clusters* principais, liderados por autoridades mundialmente reconhecidas na ciência de dados aplicada ao marketing: o *cluster* de modelos preditivos e *benchmarking* em verde, o *cluster* de engenharia de crédito e dados bancários em azul e o *cluster* de aplicações em redes e sistemas de recomendação em vermelho.

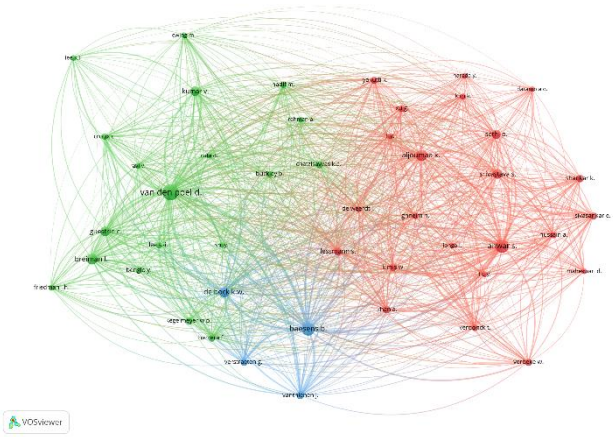

Fig. 2 - Mapa de rede de cocitação de autores.

3. Análise de distribuição geográfica: A análise geográfica da Fig. 3 demonstra que o desenvolvimento de modelos de IA aplicados ao ciclo de vida do cliente é um domínio científico liderado por potências tecnológicas globais. Vemos os três principais núcleos como Índia, China e United States respectivamente na imagem.

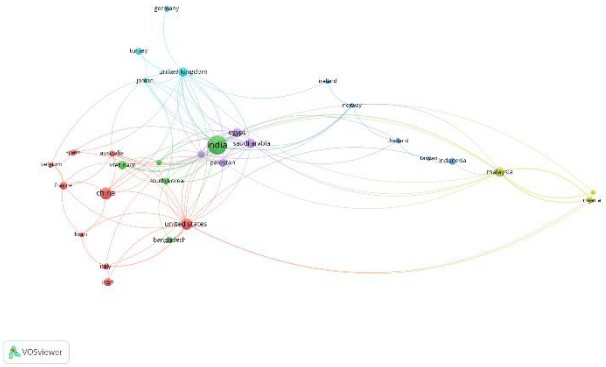

Fig. 3 - Mapa de distribuição geográfica por país.

4. Acoplamento bibliográfico: A análise apresentada na Fig. 4 revela um ecossistema de publicações de alto impacto, estruturado em dois *clusters* principais que definem a natureza multidisciplinar do tema: o *cluster* de engenharia e IA aplicada em vermelho (com a revista IEEE sendo a revista mais citada) e o *cluster* de ciência computacional e matemática em verde.

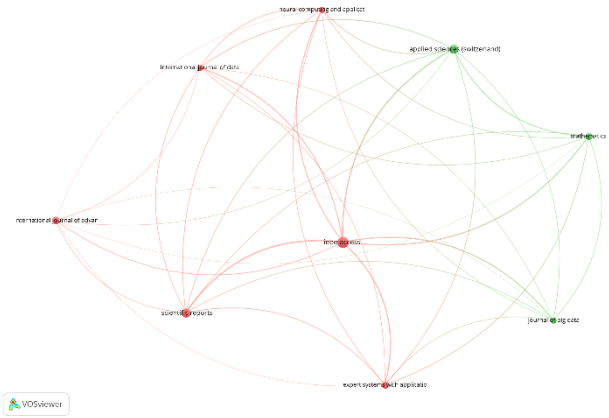

Fig. 4 - Mapa de acoplamento bibliográfico.

IV. Resultados e Discussão

Nesta seção, apresentam-se os resultados práticos obtidos após a execução das rotinas desenvolvidas em Python. A partir da carga da base de dados, o script executou de forma sequencial o diagnóstico das variáveis, o tratamento de inconsistências e a plotagem das análises exploratórias (EDA), cujos desfechos estatísticos são detalhados nas subseções a seguir.

A. Carregamento do Dataset

O processamento computacional foi iniciado com a importação bem-sucedida do dataset bruto. Ele foi estruturado em um *dataframe* utilizando a biblioteca pandas, retornando inicialmente uma matriz composta por 7043 registros e 33 colunas.

B. Limpeza de Dados

A primeira etapa de diagnóstico atestou a integridade estrutural das linhas, não sendo encontrado nenhum registro duplicado no conjunto. Durante o tratamento de dados ausentes, identificou-se que a coluna 'Total Charges' possuía 11 entradas preenchidas apenas com espaços em branco. Estes campos foram forçados para valores nulos (NaN) e, em seguida, imputados com o valor 0, assumindo que se tratam de clientes novos com zero meses de contrato consolidado. A variável 'Churn Reason' apresentou 5.174 valores com espaço, que também foram tratados como nulos, os quais foram substituídos pela categoria 'Still a Customer', indicando a permanência do usuário no serviço.

Para a redução de dimensionalidade e rigorosa prevenção de *data leakage*, efetuou-se a remoção de 11 colunas. Foram descartadas variáveis de identificação que não carregam valor preditivo, redundâncias de geolocalização ('CustomerID', 'Count', 'Country', 'State', 'Lat Long', 'Zip Code', 'Latitude' e 'Longitude'), além de atributos que configuram eventos post-facto, ou seja, que explicam o *churn* apenas após a sua ocorrência ou que são paralelos à variável alvo ('Churn Label', 'Churn Reason' e 'Churn Score')

C. Extração da Base para Pesquisa Bibliométrica

A execução da Análise Exploratória de Dados permitiu extrair o comportamento estatístico e as interdependências que direcionam o abandono do cliente.

- Análise univariada: a investigação da variável alvo ('Churn Value') revelou um claro desbalanceamento de classes: 73,46% dos clientes compõem o grupo retido, enquanto 26,54% representam os que evadiram. A distribuição contínua do tempo de permanência 'Tenure Months' exibe um comportamento bimodal intenso, com densidades máximas concentradas nos primeiros meses de assinatura e perto dos 70 meses. No que tange às características categóricas demográficas, o público possui distribuição de gênero homogênea, mas é majoritariamente não-idoso e sem dependentes. A modalidade de contrato dominante é a 'Month-to-month'.
- Análise bivariada: o cruzamento das features com o target evidenciou fortes indicativos de evasão. Clientes no plano de internet 'Fiber optic' e aqueles submetidos a contratos mensais registram taxas absolutas e proporcionais de *churn* marcadamente superiores aos demais grupos. Sob a ótica demográfica, clientes 'Senior Citizen, apesar de comporem uma fatia menor da base, possuem maior propensão ao cancelamento proporcional. Graficamente, por meio de boxplots, notou-se que clientes que evadiram estão submetidos a mensalidades 'Monthly Charges' mais elevadas (mediana próxima a 80) e tendem a ter um tempo de casa muito mais curto do que os clientes fiéis.
- Análise multivariada e correlações: o mapa de calor de correlação estatística destacou uma forte associação linear positiva (0,83) entre o tempo de contrato e as cobranças totais ('Tenure Months' e 'Total Charges'). Observou-se também que a probabilidade de *churn* guarda uma relação linear direta com mensalidades mais altas (0,19) e uma relação inversa com a longevidade do cliente (-0,35). A gravidade deste cenário foi consolidada por uma tabela dinâmica, que identificou uma taxa de evasão de 54,61% no subnicho de usuários que combinam contrato mensal com serviço de fibra óptica.
- EDA automática: em paralelo ao processo manual, as varreduras sistêmicas utilizando as bibliotecas 'sweetviz' e 'ydata-profiling' foram concluídas com êxito, consolidando relatórios secundários de estatística descritiva em arquivos HTML (eda_telco_sweetviz.html e eda_telco_ydata.html) para apoiar as conclusões visuais similares.

V. Conclusões

O presente estudo atingiu o objetivo de estruturar um embasamento técnico e de engenharia de dados robusto em predição de *churn*, interligando os achados da literatura a um estudo de caso prático no setor de telecomunicações. O mapeamento bibliométrico justificou a centralidade das técnicas de inteligência artificial para otimizar o ciclo de vida do cliente e maximizar a receita.

A execução da etapa de limpeza de dados e EDA confirmou que o abandono de clientes no dataset IBM Telco tende a obedecer a padrões lógicos e rastreáveis. A descoberta de que clientes com pagamentos mensais elevados e planos de fibra óptica sem fidelização (contrato 'Month-to-month') configuram a zona de maior risco evidencia a utilidade

prática da análise exploratória no suporte à inteligência de negócios.

Por fim, os dados se encontram estatisticamente íntegros, sem informações vazadas que poderiam enviesar algoritmos preditivos, e com suas não-linearidades e classes minoritárias documentadas. Esta estrutura higienizada estabelece o alicerce ideal e validado cientificamente para a aplicação futura de modelos avançados de Aprendizado de Máquina, visando a classificação otimizada e a tomada de decisão para a retenção proativa de clientes.

REFERÊNCIAS

[1] B.V., Elsevier, “Scopus,” 2026. [Online]. Available: https://www.scopus.com. [Acesso em 26 04 2026].

[2] Eck, N. J. van; Waltman, L., "Software survey: VOSviewer, a computer program for bibliometric mapping," *Scientometrics,* p. 523–538, 2010.

[3] IBM, "Telco Customer Churn Dataset," Kaggle, 2020. [Online]. Available: https://www.kaggle.com/datasets/yeanzc/telco-customer-churn-ibm-dataset. [Accessed 26 04 2026].

[4] Python Software Foundation, *Python 3.12.10,* 2024.

[5] The Pandas Development Team, "pandas-dev/pandas: Pandas 2.3.3," *https://pandas.pydata.org,* 2024.

[6] John D. Hunter, "Matplotlib: A 2D Graphics Environment," *Computing in Science & Engineering,* Vols. vol. 9, no. 3, pp. 90-95, 2007.

[7] Michael L. Waskom, "seaborn: statistical data visualization," *Journal of Open Source Software,* Vols. 6(60), 3021, 2021.

[8] Francois Bertrand, "Sweetviz: Visual EDA, target analysis and dataset comparison," 2020.

[9] YData, "ydata-profiling: Exploratory Data Analysis reports," 2024.

[10] Kaggle, "Kagglehub: Tool for downloading Kaggle datasets and models," 2024.