UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Curso de Especialização

Inteligência Artificial para Engenheiros

Métodos Clássicos de Aprendizagem de Máquina (AMClas)

AULA 02A

Conceitos Básicos e Regressão Linear

Professor Dr. Alexandre Balbinot

2026

IA PARA ENGENHEIROS
UFRGS

Universidade Federal do Rio Grande do Sul
Escola de Engenharia
Curso de Especialização Inteligência Artificial para Engenheiros
Laboratório de Sistemas Elétricos Inteligentes (LASEI)

Métodos Clássicos de Aprendizagem de Máquina (AMClas)

Aula 02A

Conceitos Básicos e Regressão Linear

Prof. Dr. Alexandre Balbinot

Contatos

Prof. Dr. Alexandre ***Balbinot***

Curso de Especialização Inteligência Artificial para Engenheiros

Escola de Engenharia – UFRGS

Prédio do Instituto Eletrotécnico

Departamento de Engenharia Elétrica - DELET

Laboratório de Sistemas Elétricos Inteligentes (LASEI)

Sala 206D – (51) 3308-**4442**

alexandre.balbinot@ufrgs.br

Direitos Autorais

Este material possui Direitos Autorais e Direitos de Imagem e não pode ser duplicado, reproduzido, no todo ou em parte, sob quaisquer formas ou por quaisquer meios (eletrônicos, mecânico, gravação, fotocópia, distribuição na internet ou outros), sem permissão expressa do autor.

©

Termo de Responsabilidade da Própria UFRGS

Todos os materiais disponibilizados nos Ambientes Virtuais da UFRGS são exclusivamente para usos e fins didáticos, sendo vedada a sua utilização para qualquer outra finalidade, sob as penas legais.

Todos os materiais de terceiros que venham a ser utilizados ou disponibilizados devem ser referenciados, sob as penas legais, inclusive de plágio.

Tenho liberdade de expor ou não a minha imagem e voz nas atividades, o que não me desonera da participação efetiva nas mesmas.

Todas as gravações de atividades síncronas devem ser previamente informadas por parte dos professores.

Os alunos somente poderão gravar, armazenar ou compartilhar atividades mediante concordância prévia do professor, sob as penas legais.

Os alunos somente poderão armazenar ou compartilhar materiais mediante concordância prévia do professor ou se permitido no material, sob as penas legais.

É proibido disponibilizar, por quaisquer meios digitais ou físicos, os dados, a imagem e a voz dos alunos, dos colegas e do professor, sem autorização específica para a finalidade pretendida.

Diferentes Abordagens para Aprendizagem de Máquina: relembrando

CLASSICAL MACHINE LEARNING

Data is pre-categorized or numerical

Data is not labeled in any way

SUPERVISED

Predict a category

Predict a number

CLASSIFICATION

«Divide the socks by color»

REGRESSION

«Divide the ties by length»

UNSUPERVISED

Divide by similarity

Find hidden dependencies

Identify sequences

CLUSTERING

«Split up similar clothing into stacks»

ASSOCIATION

«Find what clothes I often wear together»

DIMENSION REDUCTION (generalization)

«Make the best outfits from the given clothes»

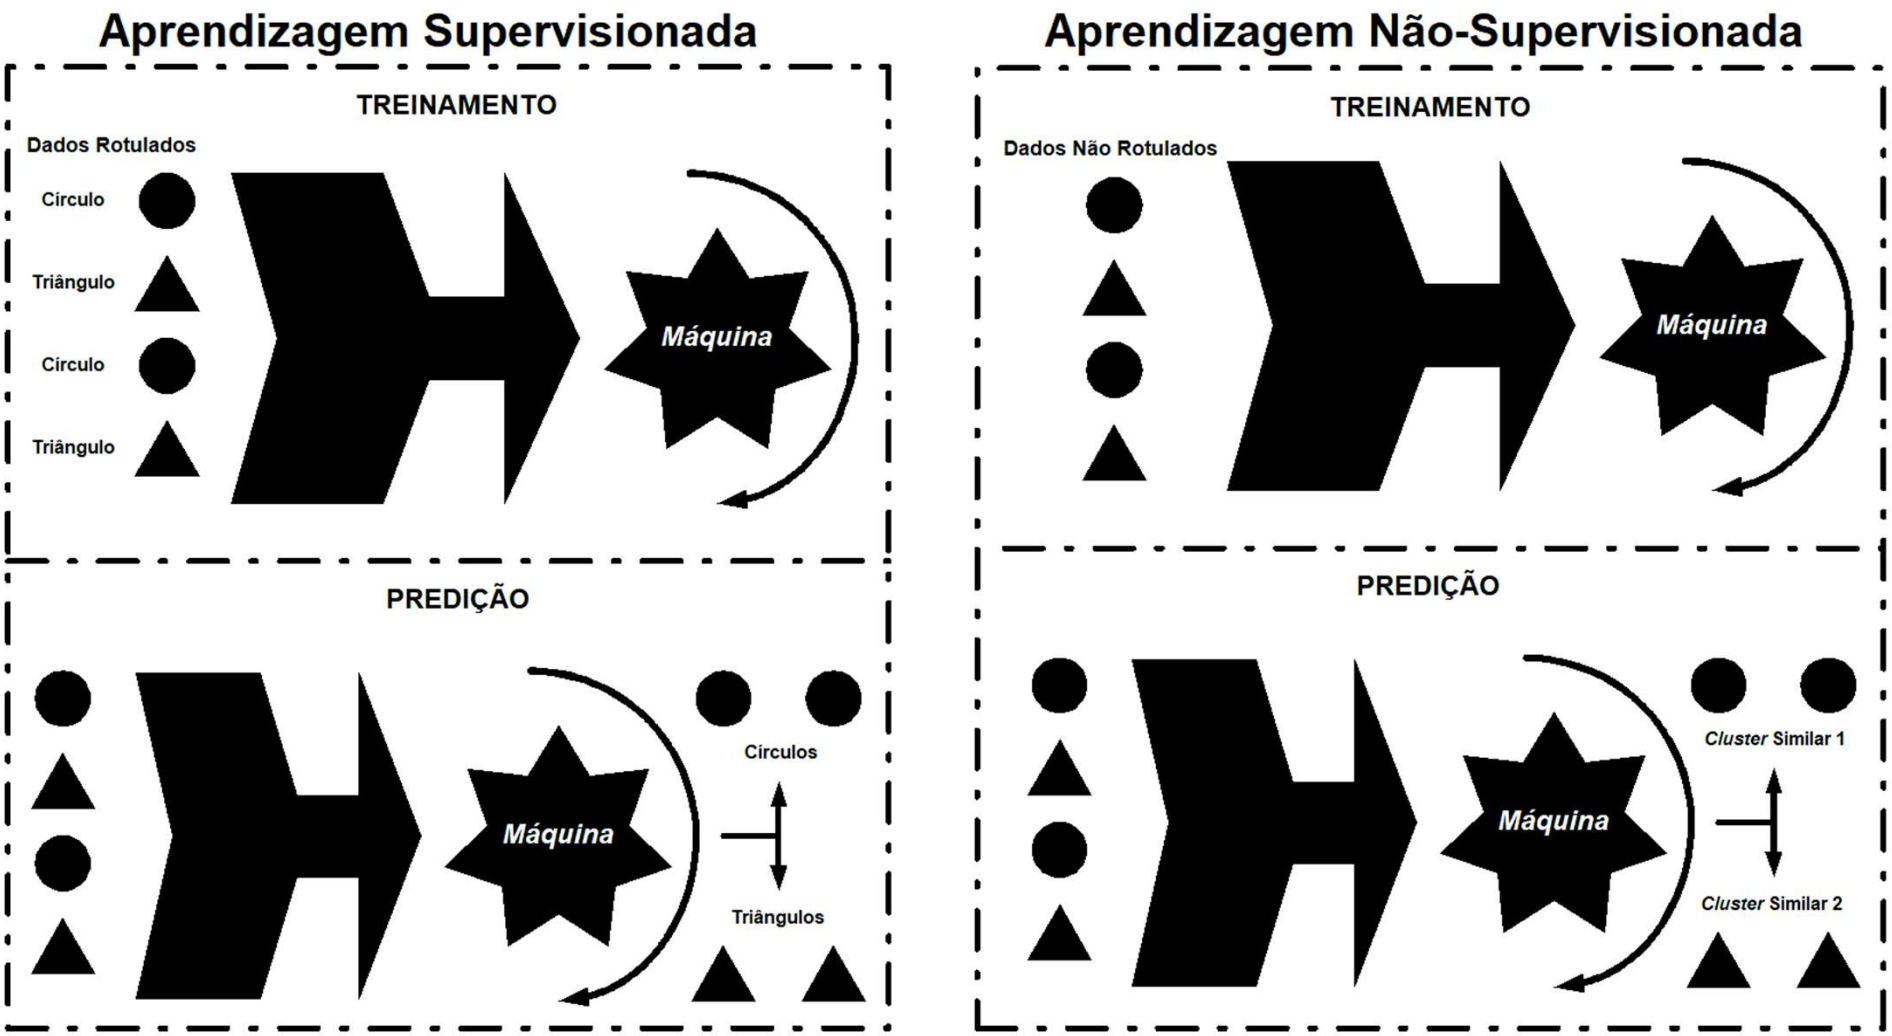

Comparativo entre os dois modelos básicos de aprendizagem: Supervisionado (durante o treinamento os dados são rotulados) e Não-Supersionado (dados não possuem rótulos).

Observações Gerais

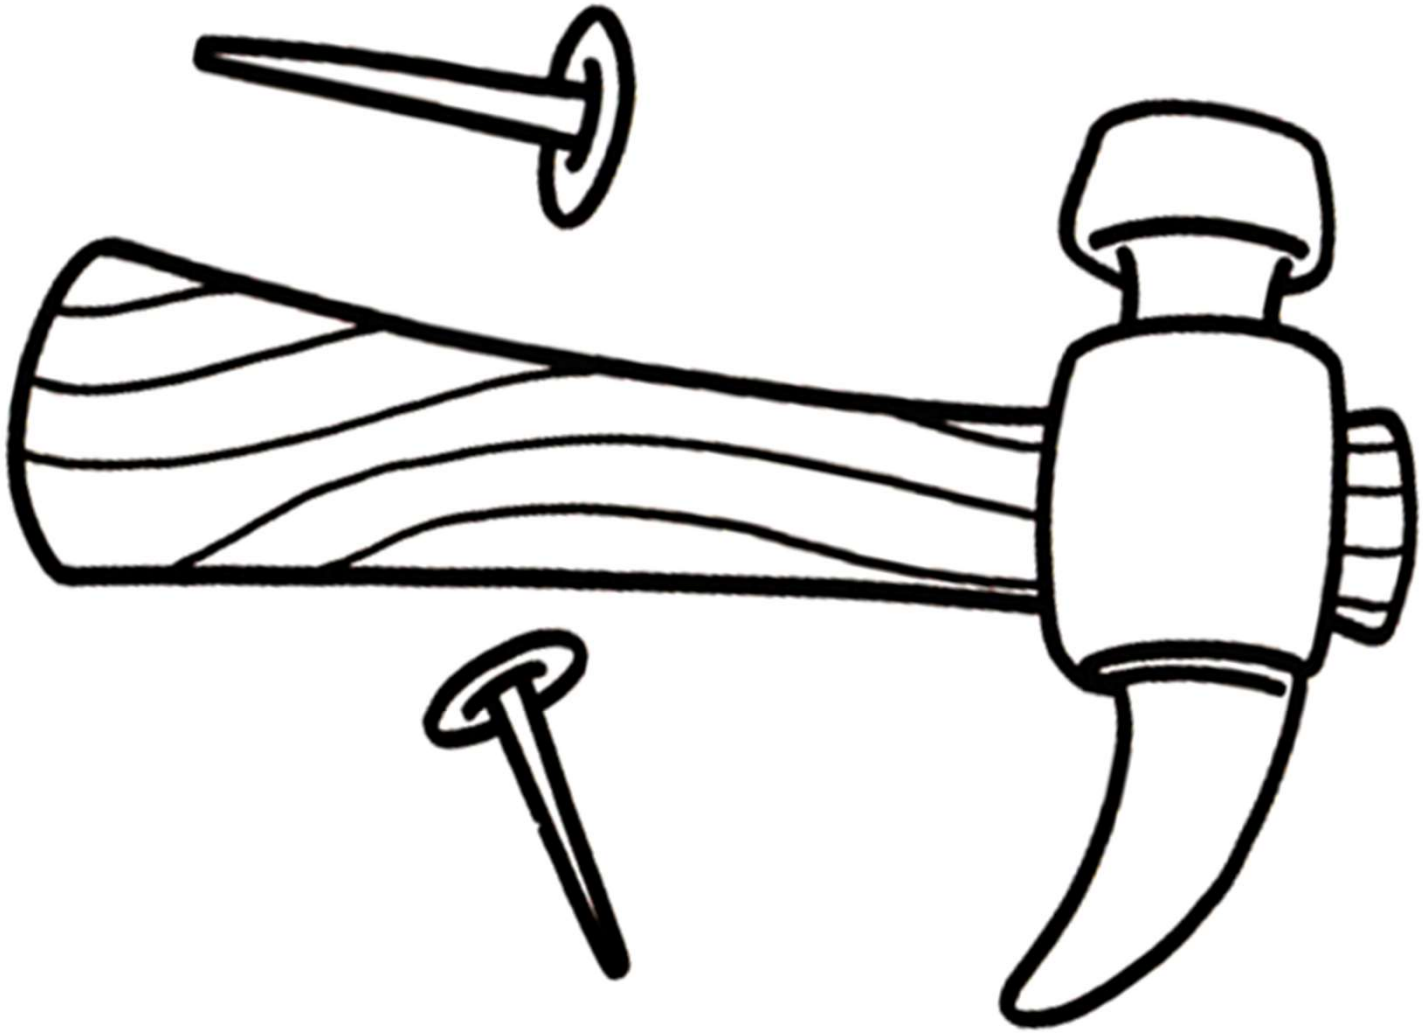

Predição e Classificação

- NORMALMENTE, quando usamos o termo **PREVISÃO ➔** é prever um **valor numérico**;
- a previsão de uma **classe ou rótulo ➔** usamos o termo **CLASSIFICAÇÃO**.

Análise de Regressão

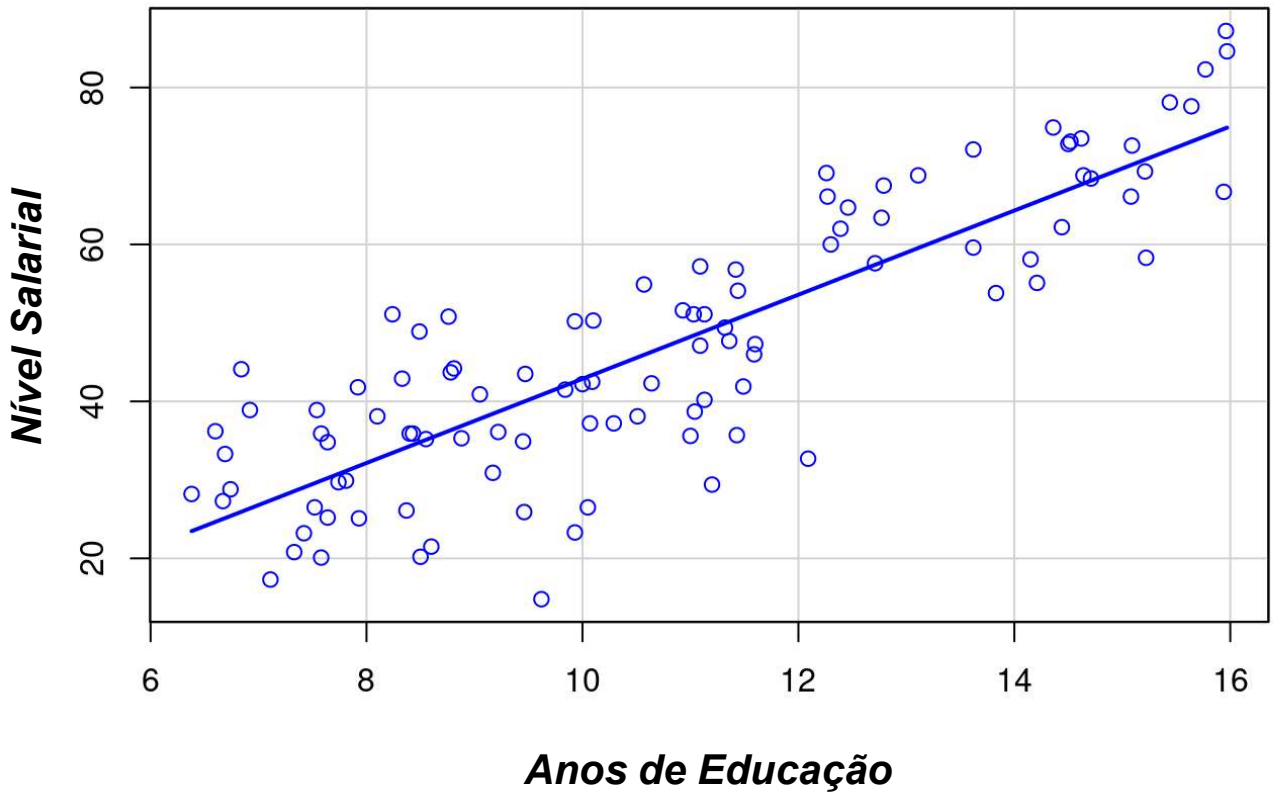

A Biblioteca Scikit-Learn em Python

https://scikit-learn.org/stable/

Install User Guide API Examples Community More

scikit-learn

Machine Learning in Python

Getting Started | Release Highlights for 1.2 | GitHub

- Simple and efficient tools for predictive data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable - BSD license

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition.
Algorithms: SVM, nearest neighbors, random forest, and more...

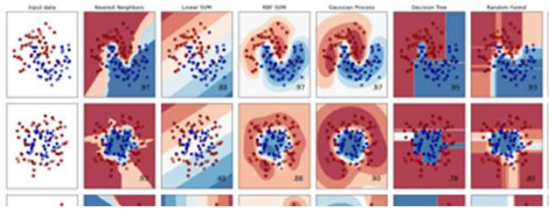

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.
Algorithms: SVR, nearest neighbors, random forest, and more...

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes
Algorithms: k-Means, spectral clustering, mean-shift, and more...

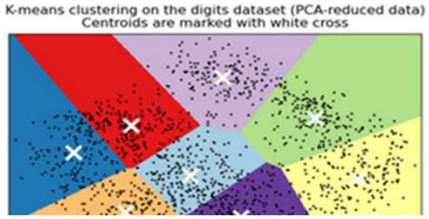

Introdução a Classificação

Técnicas para Classificação por Aprendizado Supervisionado

- modelo aprenderá a partir de um conjunto de dados de treinamento rotulado;
- rótulos funcionam como um Supervisor ou Professor para o processo de aprendizagem;

- Algoritmos de Aprendizagem Supervisionada resolvem dois tipos de problemas:
  - classificação: existe uma variável-alvo categórica;
    - exemplo:
      - *status* de solicitação de um empréstimo como “seguro” ou “arriscado”;
      - um paciente sofre de uma "doença" ou "não“;
      - uma pessoa é “um potencial cliente" ou "não“.
  - ou regressão.

- foco principal destas próximas aulas:
  - uso experimental dos seguintes métodos para classificação:
    - Regressão Linear
    - Regressão Logística;
    - Naive Bayes;
    - Árvores de Decisão;
    - Floresta Aleatória;
    - Máquina de Vetor de Suportes (SVM).

Classificação de Dados

<u>Exemplo 01</u>: um Analista de Dados tem como trabalho:

- identificar pacientes que possuem uma maior chance de sofrer de uma determinada doença:
  - previsões ajudarão no tratamento precoce dos pacientes antes que a doença piore;

- prever potenciais clientes que têm mais chances de comprar um produto:
  - categorizar os pacientes ou clientes em duas ou mais categorias;

- tarefa conhecida como **Classificação** e envolve basicamente três estágios:
  - treinamento de um modelo com os dados disponíveis;
  - realização de previsões;
  - avaliação do desempenho do modelo.

Processos de Treinamento de Modelos de IA: relembrando

Processo de Treinamento sem Otimização dos Hiperparâmetros

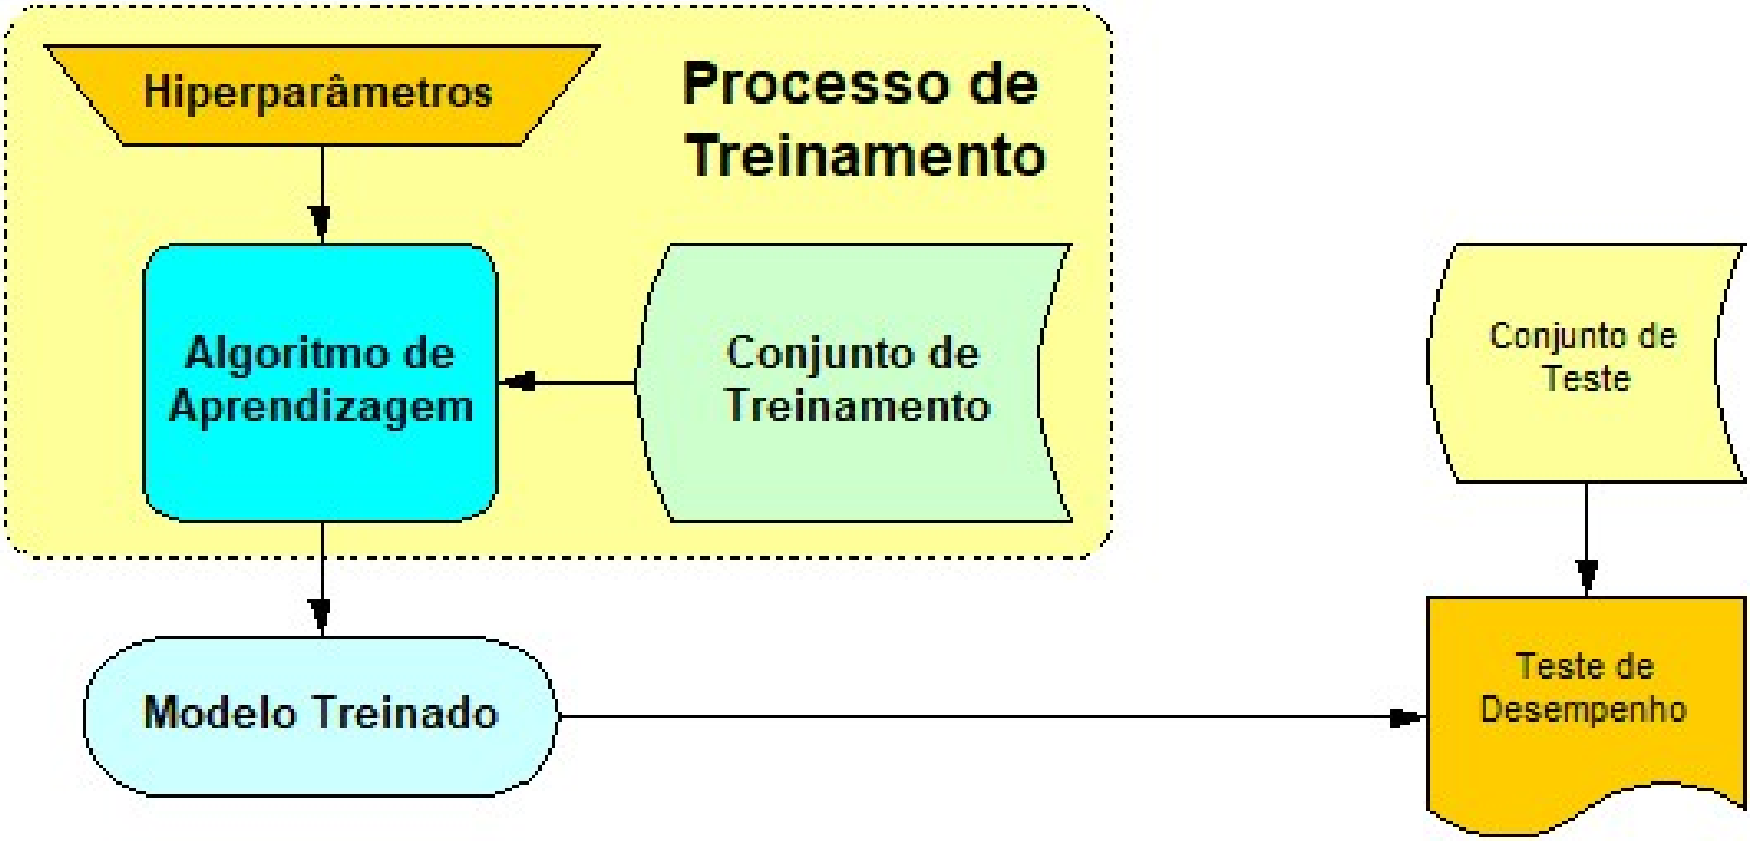

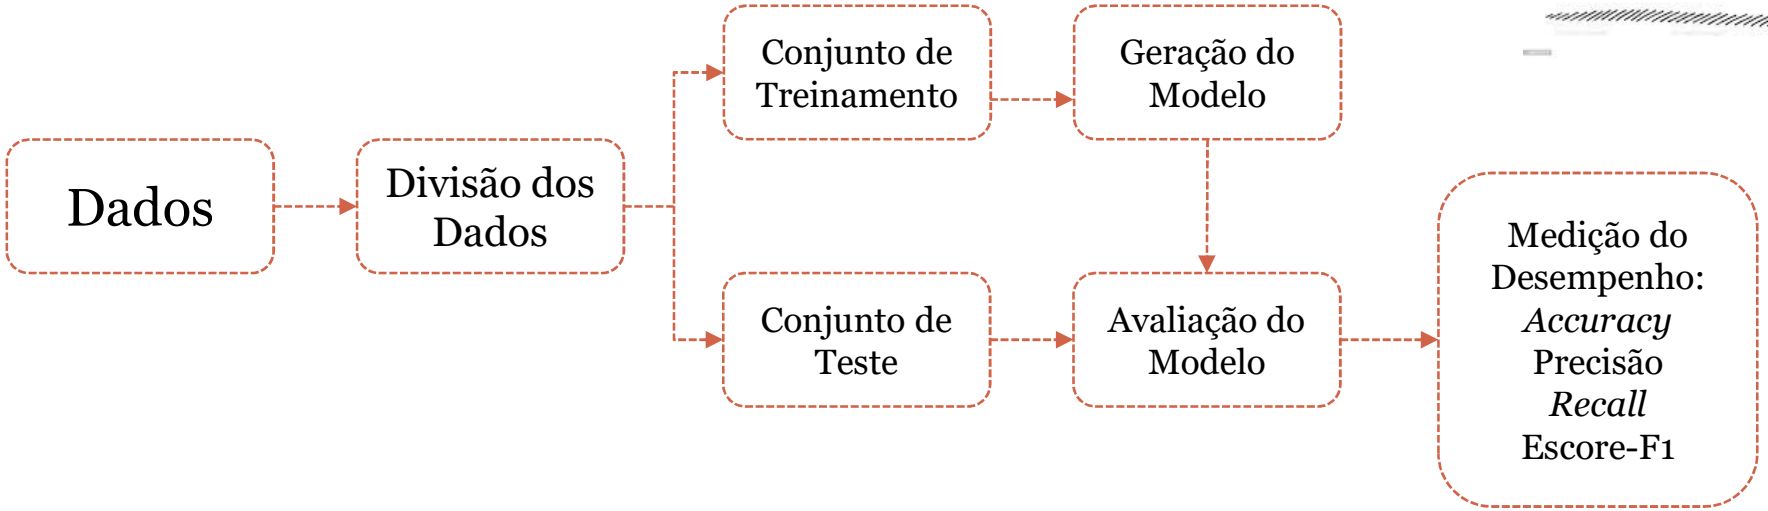
Dados
Divisão dos Dados
Conjunto de Treinamento
Conjunto de Teste
Geração do Modelo
Avaliação do Modelo
Medição do Desempenho:
Accuracy
Precisão
Recall
Escore-F1

Processo de Treinamento com Ajuste Incorreto dos Hiperparâmetros

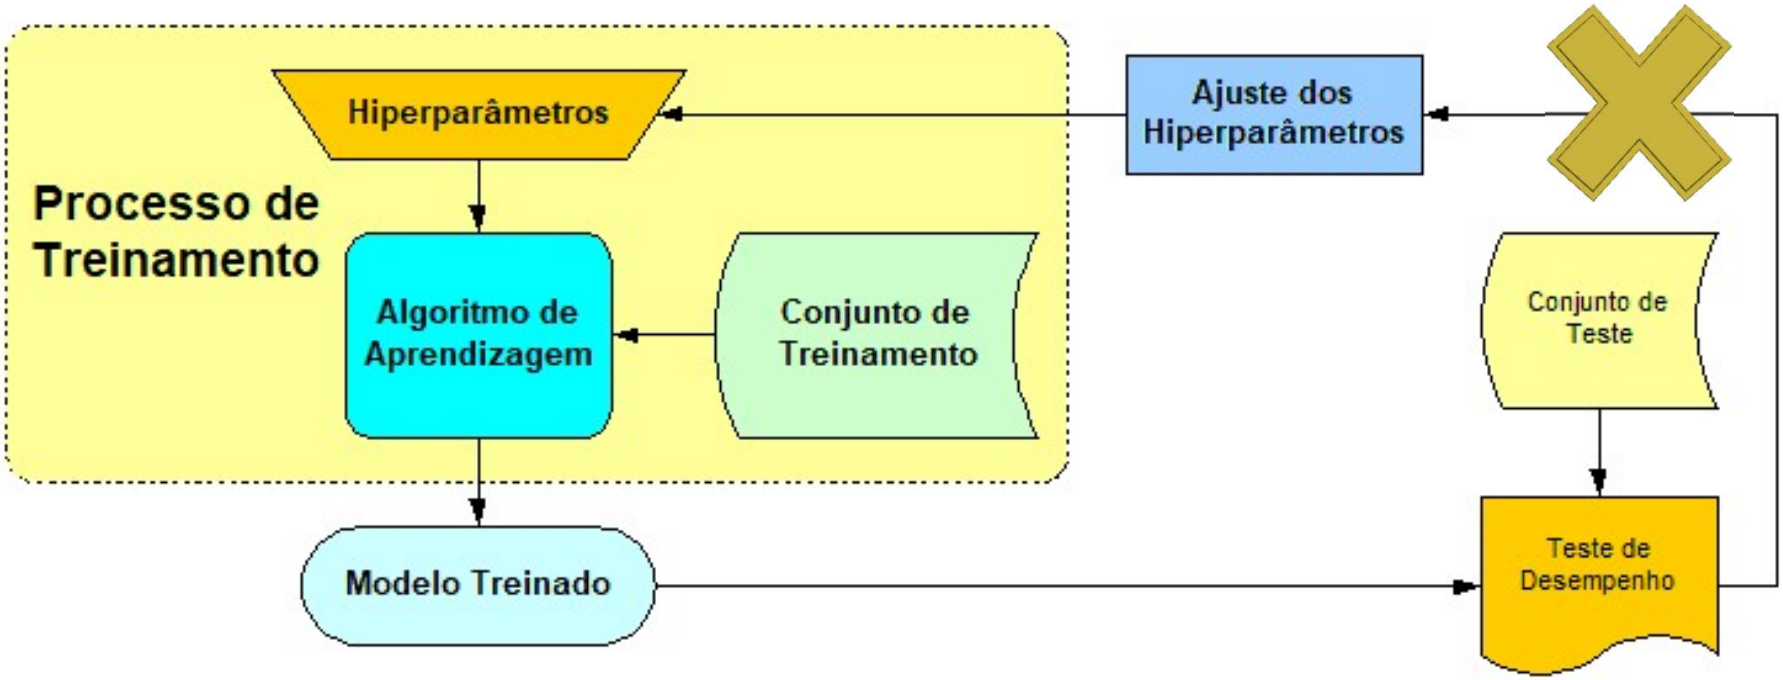

Processo de Treinamento com Ajuste dos Hiperparâmetros usando o Conjunto de Validação

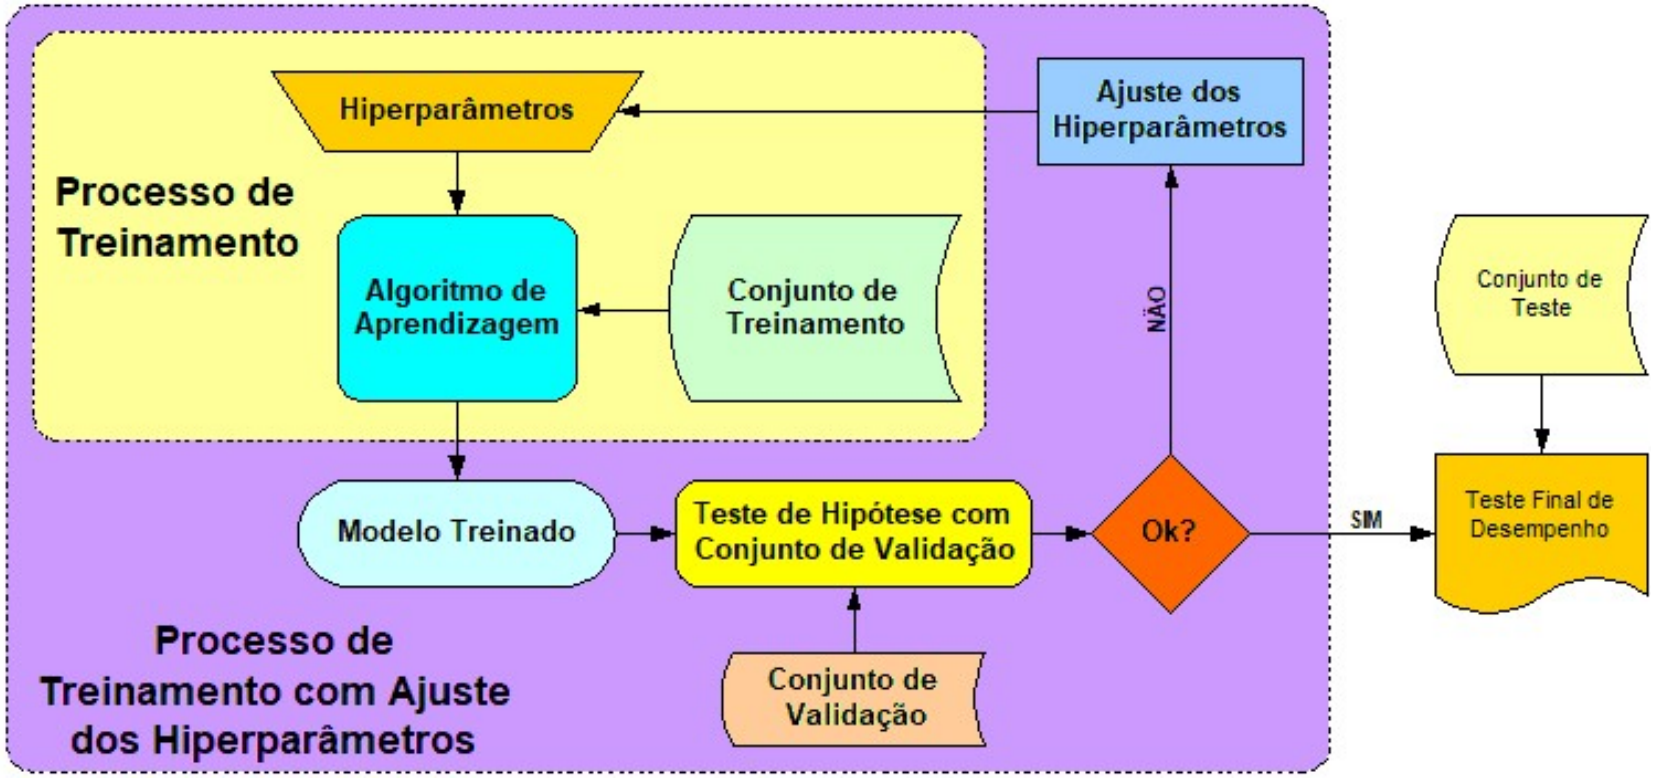

Generalização da Aprendizagem

<u>Exemplo 02</u>: reconhecer objetos em novas imagens, classificar texturas de novas amostras de tecidos, classificar novas amostras de áudio, etc...

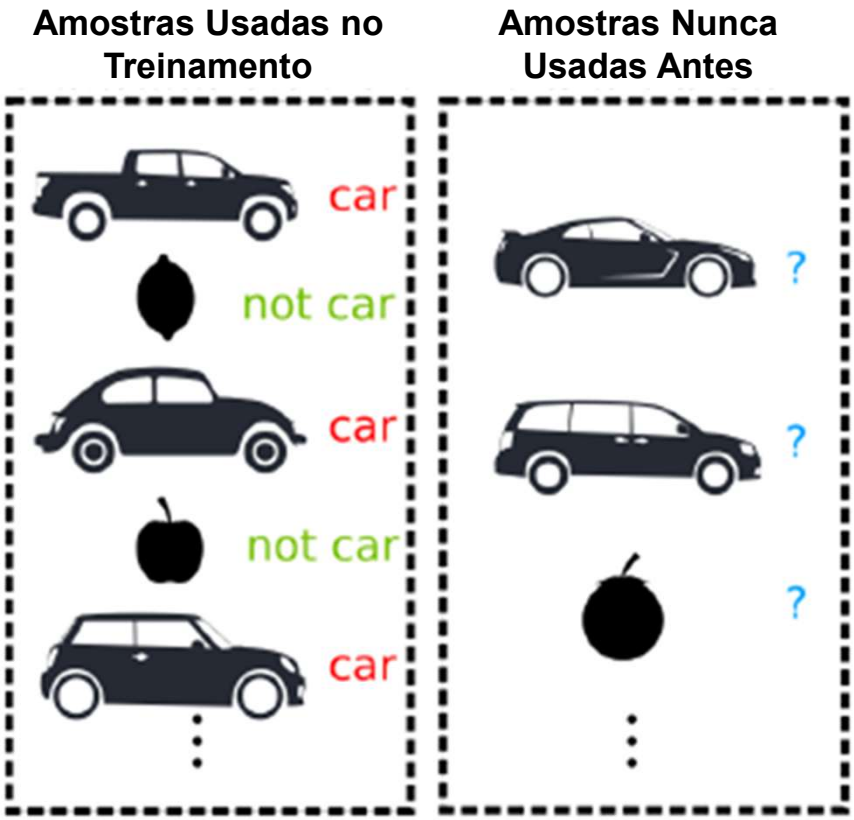

Reforço Conceitual e uma Pequena Introdução ao Gradiente Descendente

Uma simples homenagem aos Grandes Mestres

Adrien-Marie Legendre
18/Set/1752 –
10/01/1833
Matemático Francês

Johann Carl Friedrich Gauss
30/04/1777 –
23/02/1855
Matemático, astrônomo e físico alemão

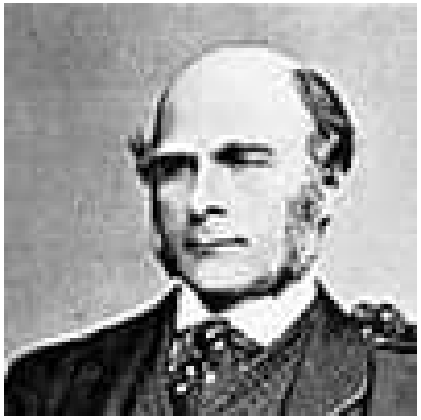

Francis Galton
16/02/1822 – 17/01/1911
Antropólogo, meteorologista, matemático e estatístico inglês.

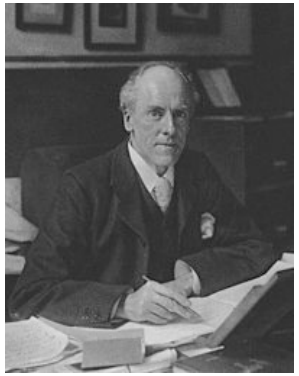

Karl Pearson
27/03/1857 –
27/04/1936
Estatístico Britânico
Fundador do Departamento de Estatística Aplicada na University College London em 1911 - primeiro departamento universitário dedicado à estatística em todo o mundo.

George Udny Yule
18/02/1871 –
26/05/1951
Estatístico Britânico
(nasceu na Escócia)

Regressão Linear: a aprendizagem

$$y = B_0 + B_1 x$$

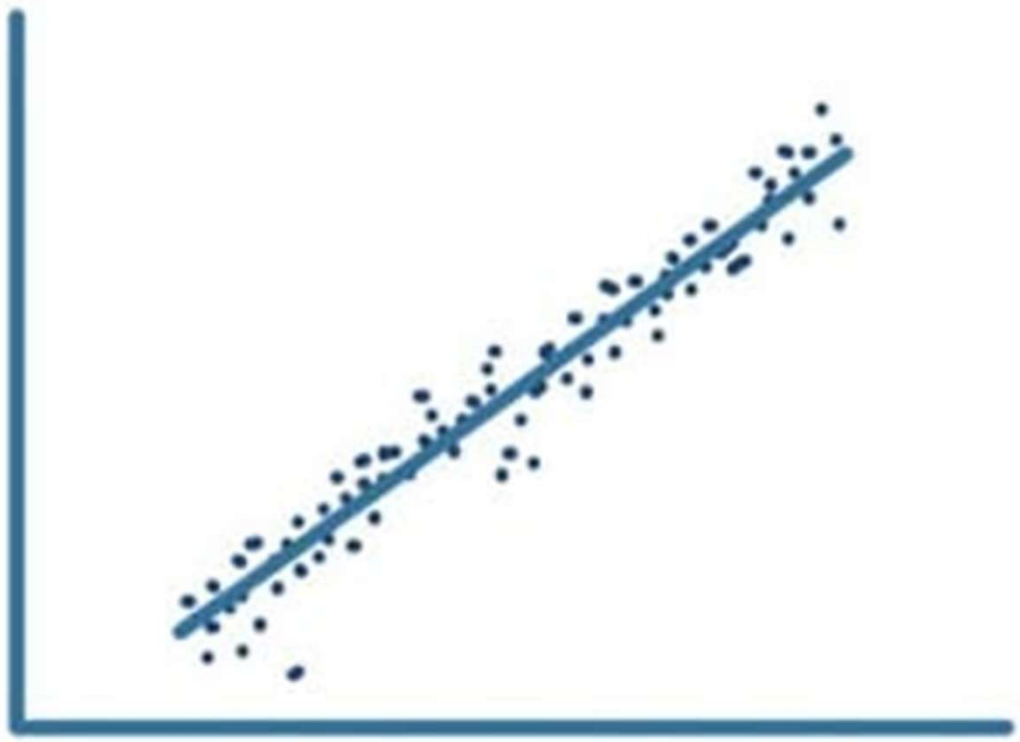

<u>Exemplo 03</u>: realização de uma previsão com a regressão linear

Considere um modelo preditor que relaciona o peso (y) e a altura (x) em centímetros representado pelo seguinte modelo Regressor Linear:

$$y = B_0 + B_1 x$$

$$peso = B_0 + B_1 . altura$$

Suponha que após o treinamento com uma base de dados temos:

$$B_0 = 0{,}1$$
$$B_1 = 0{,}5$$

$$peso = 0{,}1 + 0{,}5 . altura$$

Logo, como prever o peso de uma pessoa com altura de 182 centímetros (base de teste)?

$$peso = 0{,}1 + 0{,}5.182$$

$$\boxed{peso = 91{,}1}$$

Solução gráfica do Exemplo 03

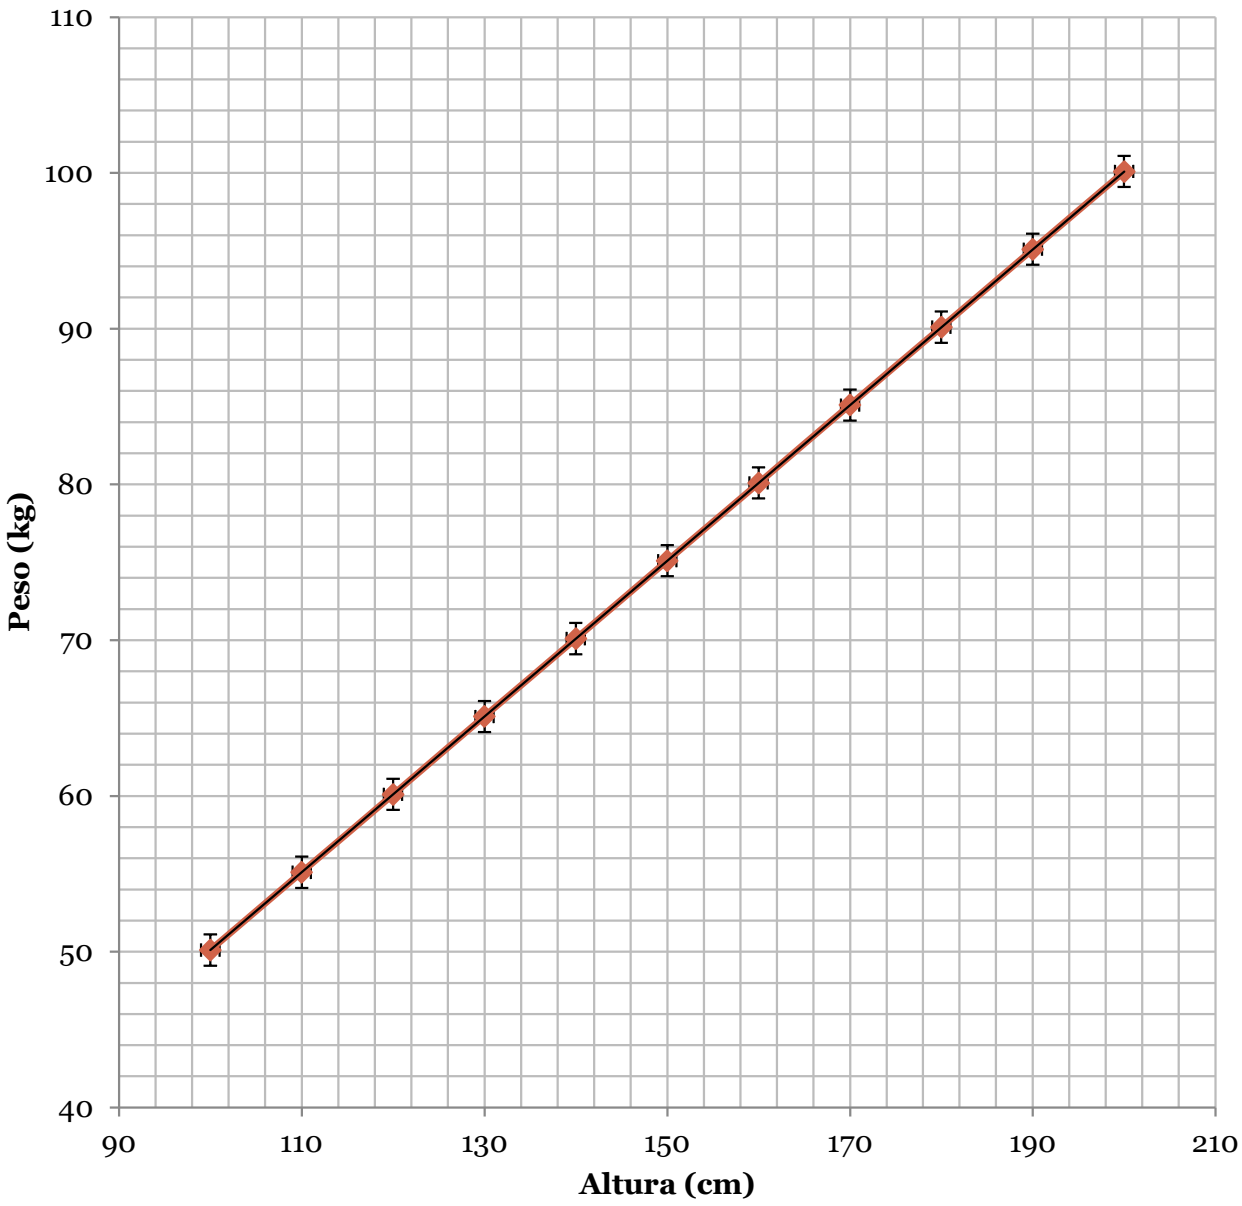

Sugestões de Preparo dos Dados para uso da Regressão Linear

- Suposição Linear
- Remoção de Ruído
- Remoção da Colinearidade
- Distribuições Gaussianas
- Redimensionamento das Entradas

Exemplo 04: modelo analítico completo do processo de aprendizagem

Considere o seguinte conjunto de **dados de treinamento**:

x_i (entrada)	y_i (saída)
1	1
2	3
4	3
3	2
5	5

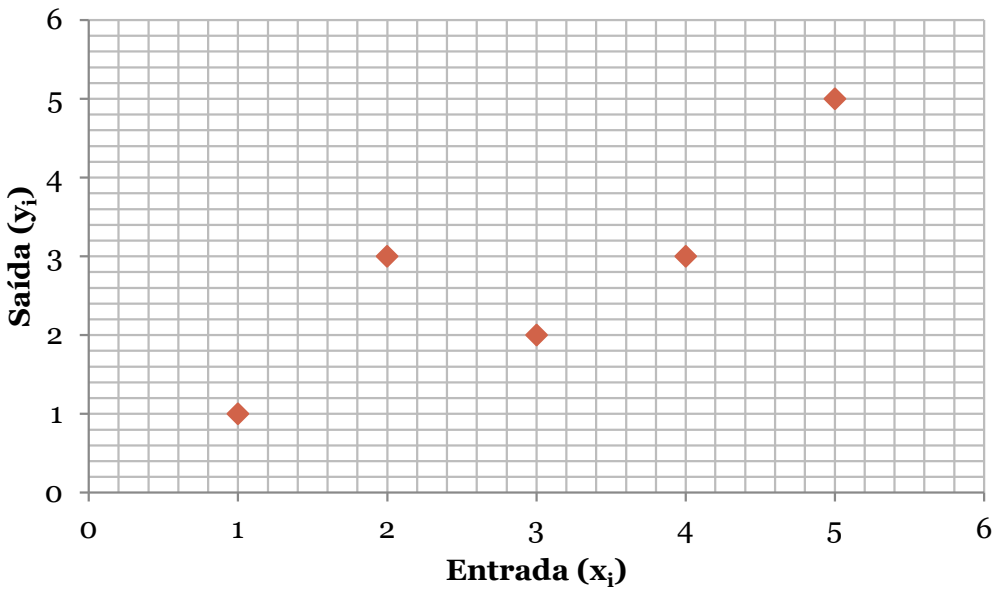

Considerando um simples modelo de Regressão Linear para este problema

1º. Vamos usar o Procedimento Clássico para estimar B_1 e B_0 com base nos <u>dados de treinamento</u>:

$$y_{p_i} = B_0 + B_1 x_i$$

$$B_1 = \frac{\sum_{i=1}^{n}\left(x_i - média(x_i)\right) \times \left(y_i - média(y_i)\right)}{\sum_{i=1}^{n}\left(x_i - média(x_i)\right)^2}$$

$$B_0 = média(y_i) - B_1 \times média(x_i)$$

xi	yi	média (xi)	xi-média(xi)	média(yi)	yi-média(yi)	Multiplicação	Quadrado		
1	1	3	-2	2,8	-1,8	3,6	4		
2	3		-1		0,2	-0,2	1		
4	3		1		0,2	0,2	1		
3	2		0		-0,8	0	0		
5	5		2		2,2	4,4	4		
						TOTAL	TOTAL	B1	B0
						8	10	0,8	0,4

$$y_{p_i} = 0{,}4 + 0{,}8x_i$$

Considerando a saída predita:

x_i (entrada)	$y_{p_i} = 0{,}4 + 0{,}8x_i$ (saída)
1	1,2
2	2,0
4	3,6
3	2,8
5	4,4

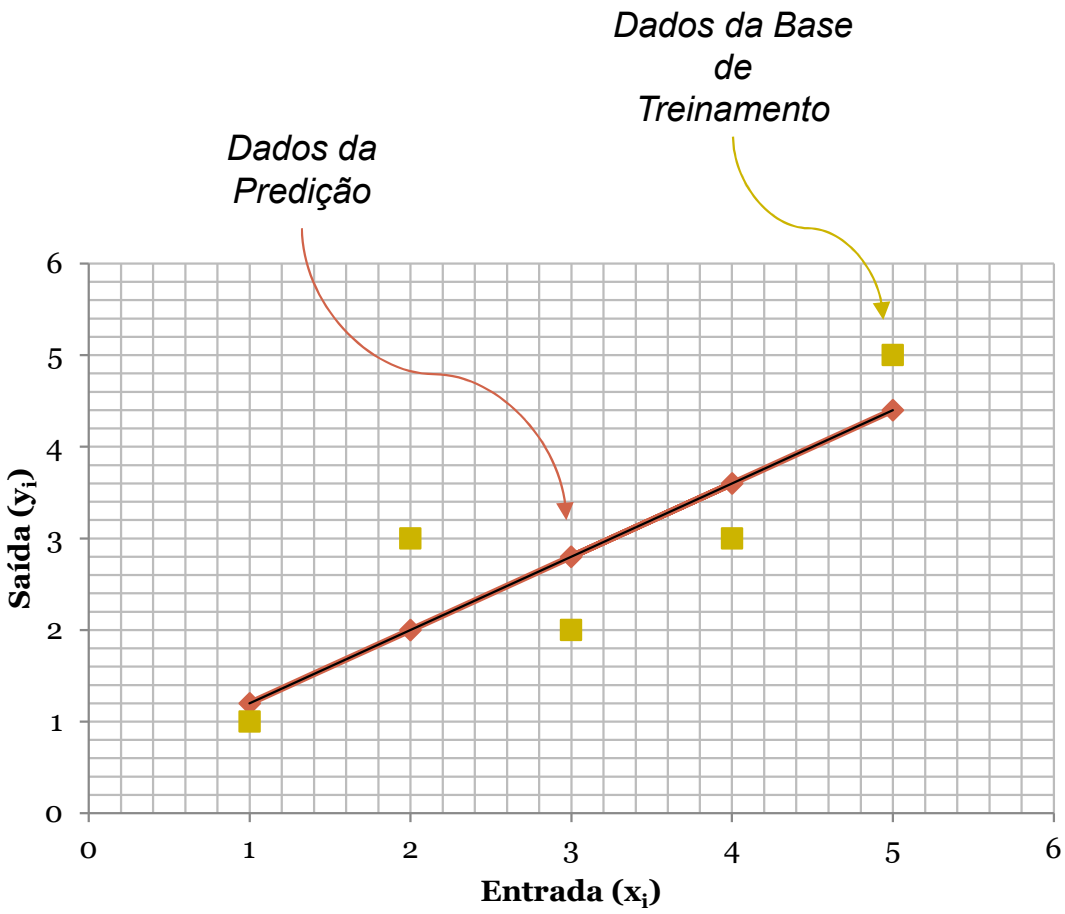

Erro do Modelo:

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}\left(y_{p_i} - y_i\right)^2}{n}} = 0{,}69$$

2º. Agora vamos usar o GD para estimar B_1 e B_0 com base nos dados de treinamento:

x_i (entrada)	y_i (saída)
1	1
2	3
4	3
3	2
5	5

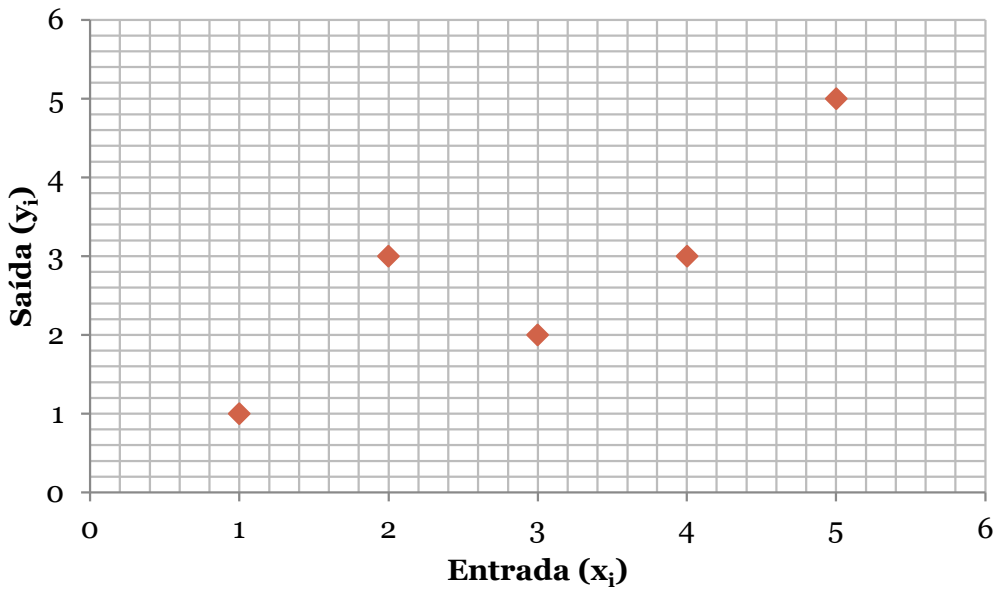

$$w = w - \alpha \times delta$$

Dados iniciais:

x_i (entrada)	y_i (saída)
1	1
2	3
4	3
3	2
5	5

Atualizando os pesos

(os pesos neste modelo são os coeficientes):

Como exercício deixo a tarefa de executar 4 épocas (20 iterações)
(verificar se encontraram os mesmos valores - arredondei):

		Coeficientes Atualizados				**Coeficientes Atualizados**	
Época	It	B_0	B_1	Época	It	B_0	B_1
1º	1º	0,01	0,01	**3º**	11º	0,183	0,625
	2º	0,397	0,0694		12º	0,198	0,656
	3º	0,0665	0,177		13º	0,200	0,663
	4º	0,0806	0,219		14º	0,198	0,657
	5º	0,119	0,410		15º	0,213	0,733
2º	6º	0,123	0,415	**4º**	16º	0,214	0,734
	7º	0,144	0,456		17º	0,227	0,760
	8º	0,154	0,497		18º	0,224	0,749
	9º	0,158	0,508		19º	0,220	0,735
	10º	0,181	0,623		20º	0,231	0,790

Resultado final

Como exercício deixo a tarefa de determinar o erro de predição para as 20 iterações:

$$y_{p_i} = B_0 + B_1 x_i \quad \Rightarrow \quad erro_{predição} = y_{p_i} - y_i$$

		B_0	B_1		
x_i	y_i	0	0	y_{p_i}	$erro_p$
1	1	0,01	0,01	0,0	-1
2	3	0,397	0,0694	0,03	-2,97
...					

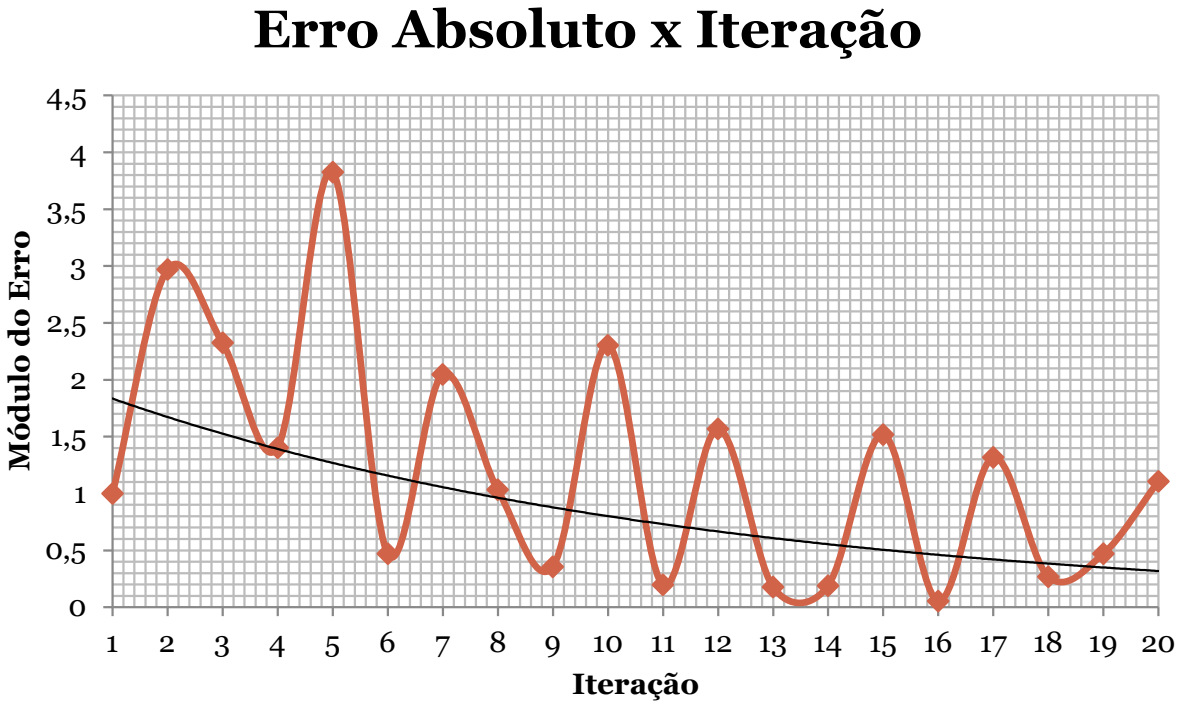

Apenas para Comparação do Exercício Solicitado

			Bo	B1				
it	x	y	o	o	yp	erro	erro^2	|erro|
1	1	1	0,01	0,01	0,000	-1,00	1,00	1
2	2	3	0,397	0,0694	0,030	-2,97	8,82	2,97
3	4	3	0,0665	0,177	0,675	-2,33	5,41	2,3254
4	3	2	0,0806	0,219	0,598	-1,40	1,97	1,4025
5	5	5	0,119	0,41	1,176	-3,82	14,63	3,8244
6	1	1	0,123	0,415	0,529	-0,47	0,22	0,471
7	2	3	0,144	0,456	0,953	-2,05	4,19	2,047
8	4	3	0,154	0,497	1,968	-1,03	1,07	1,032
9	3	2	0,158	0,508	1,645	-0,36	0,13	0,355
10	5	5	0,181	0,623	2,698	-2,30	5,30	2,302
11	1	1	0,183	0,625	0,804	-0,20	0,04	0,196
12	2	3	0,198	0,656	1,433	-1,57	2,46	1,567
13	4	3	0,2	0,663	2,822	-0,18	0,03	0,178
14	3	2	0,198	0,657	2,189	0,19	0,04	0,189
15	5	5	0,213	0,733	3,483	-1,52	2,30	1,517
16	1	1	0,214	0,734	0,946	-0,05	0,00	0,054
17	2	3	0,227	0,76	1,682	-1,32	1,74	1,318
18	4	3	0,224	0,749	3,267	0,27	0,07	0,267
19	3	2	0,22	0,735	2,471	0,47	0,22	0,471
20	5	5	0,231	0,79	3,895	-1,11	1,22	1,105

Usando o resultado final do GD com 20 iterações para determinar a predição teremos:

$$B_0 = 0{,}231$$

$$B_1 = 0{,}790$$

$$y_{p_i} = B_0 + B_1 x_i$$

x_i	$y_{predição}$
1	1,021
2	1,811
4	3,391
3	2,601
5	4,181

Comparando a predição com a saída rotulada

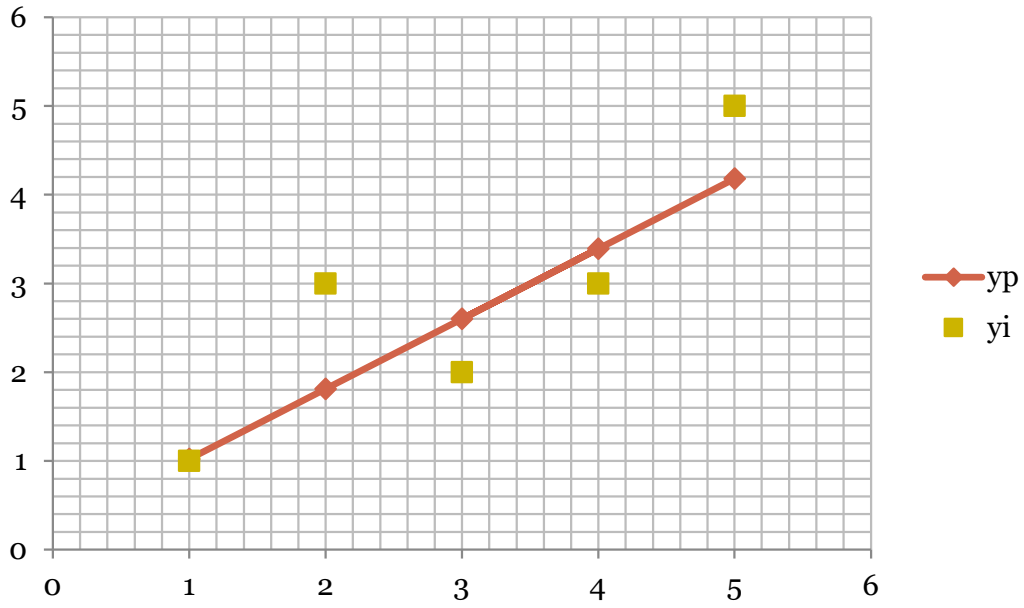

Homework: determinar o RMSE deste <u>Procedimento 2</u> e comparar com o RMSE do <u>Procedimento 01</u>.

O Problema da Multicolinearidade

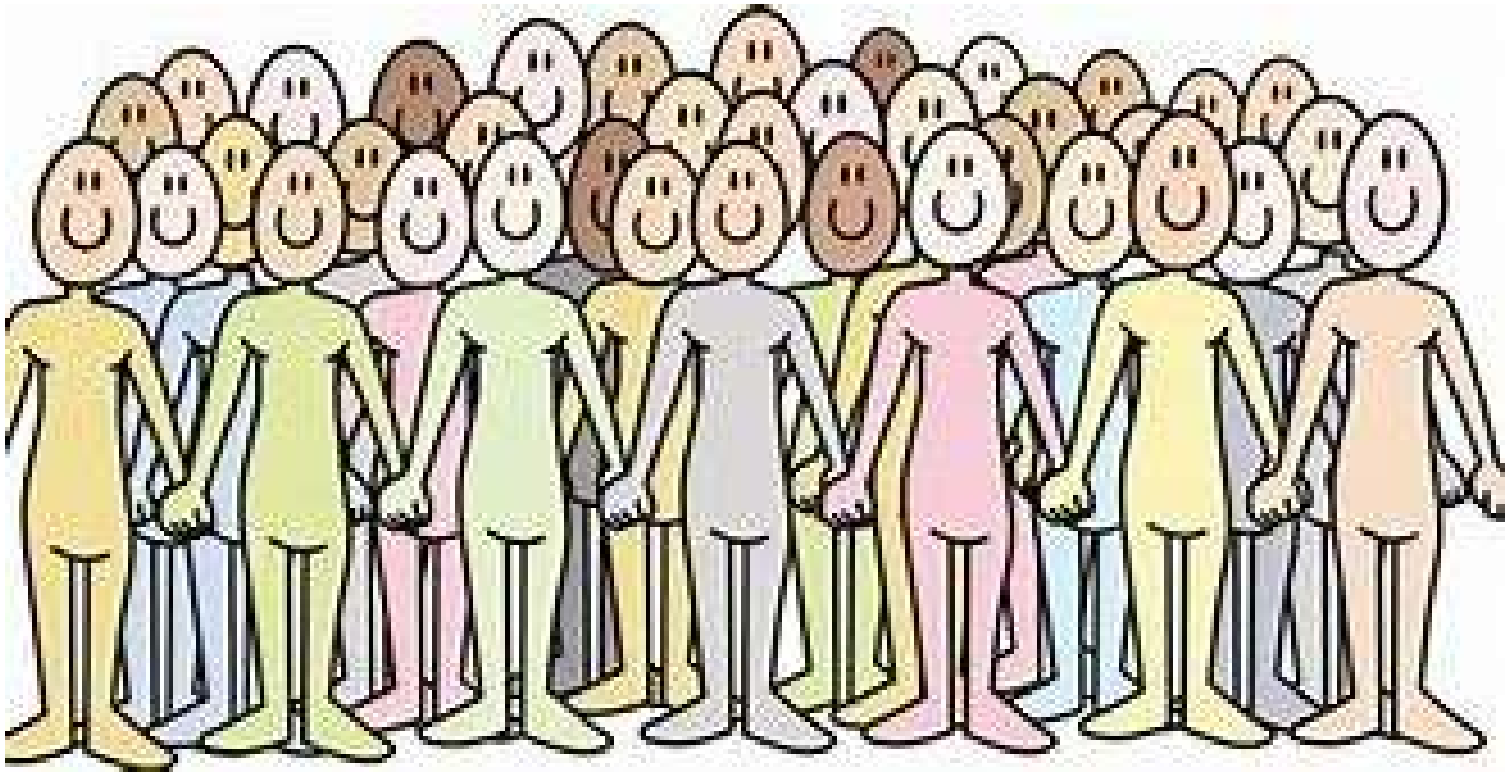

Avaliação de Modelos

120
118
119
108

Principais Métricas Usadas em Classificadores

MATRIZ DE CONFUSÃO		**CLASSE PREDITA**	
		Predito Positivo (1)	**Predito Negativo (0)**
CLASSE ORIGINAL	**Realmente Positivo (1)**	Verdadeiro Positivo (TP)	Falso Positivo (FP)
	Realmente Negativo (0)	Falso Negativo (FN)	Verdadeiro Negativo (TN)

INDICA A QUANTIDADE DE OCORRÊNCIAS OU DE AMOSTRAS

- **Métricas mais comuns em modelos de IC para classificação:**

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

- Precisão (*Precision*):

$$P = \frac{TP}{TP + FP}$$

- *Recall (sensitividade ou revocação)*:

$$R = \frac{TP}{TP + FN}$$

- Escore F1 (*F1 Score*):

$$F1 = 2\frac{P \times R}{P + R}$$

Exemplo 05: considerar um classificador binário relacionado a possibilidade de ocorrência de uma fraude em um banco: SIM = ocorreu fraude e NÃO = não ocorreu fraude. Analisar a matriz de confusão resultante de um dado classificador.

Realidade	***Preditor***		***Métricas***
	SIM	***NÃO***	
SIM	*TP = 500*	*FN = 25*	***Recall = TP/TP+FN = 500/500+25 = 0,9524***
NÃO	*FP = 50*	*TN = 250*	***Especificidade = TN/TN+FP = 250/250+50 = 0,8333***
Métricas	***Precisão = TP/TP+FP = 500/500 + 50 = 0,9091***	***Predições Negativas = TN/TN+FN = 250/250+25 = 0,9091***	*TOTAL = 825*

- Curva ROC (*Receiver Operating Characteristics Curve*):

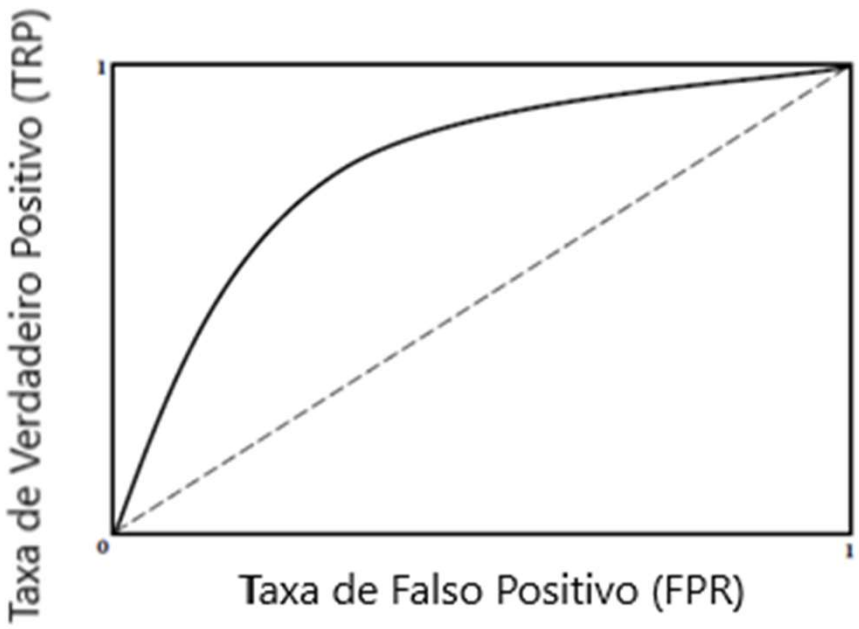

- também podemos avaliar a ROC através de um único número usando o parâmetro AUC:

AUC	*0,5*	*Sem Discriminação*
	0,6 – 0,7	*Pobre*
	0,7 – 0,8	*Aceitável (fraca)*
	0,8 – 0,9	*Excelente (boa)*
	> 0,9	*Destacado*

Métricas para Avaliar o Desempenho de Regressores

- **Métricas mais comuns em modelos de IC para Regressão**

Estima a diferença entre o valor previsto e a média dos dados

Estima a mudança entre o original e o valor previsto

$$R^2 = \frac{SQ_{regressão}}{SQ_{total}} = 1 - \frac{SQ_{erros}}{SQ_{total}}$$

Representar a mudança entre o valor original e a média dos dados

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(y_{original} - y_{previsto}\right)^2$$

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_{original} - y_{previsto}\right|$$

$$RMSE = \sqrt{MSE}$$

A Origem

Teste de Hipótese

<u>Exemplo 06</u>:

Suponha a realização de um experimento para avaliar o desempenho de crianças em um teste nacional de leitura e interpretação. Neste experimento 50 crianças foram preparadas com um novo método de aprendizagem para leitura e interpretação (Grupo Teste) e 50 crianças foram preparadas pelo método tradicional (Grupo Controle).

Vamos supor que o Grupo Teste alcançou um desempenho médio superior a 6 pontos quando comparado ao Grupo Controle no correspondente teste nacional de até 100 pontos.

Questões essenciais:

1. Esse resultado indica que o novo método de aprendizagem é realmente melhor?
2. A diferença de 6 pontos indica que o novo método de aprendizagem é realmente melhor?

Para isso utilizamos o procedimento estatístico mais comum: Teste de Hipótese

<u>Exemplo 07</u>:

Para o <u>Exemplo 06</u>:

- H_0: o novo modelo de aprendizagem não tem efeito na aprendizagem das crianças
- H_1: o novo modelo de aprendizagem tem efeito na aprendizagem das crianças

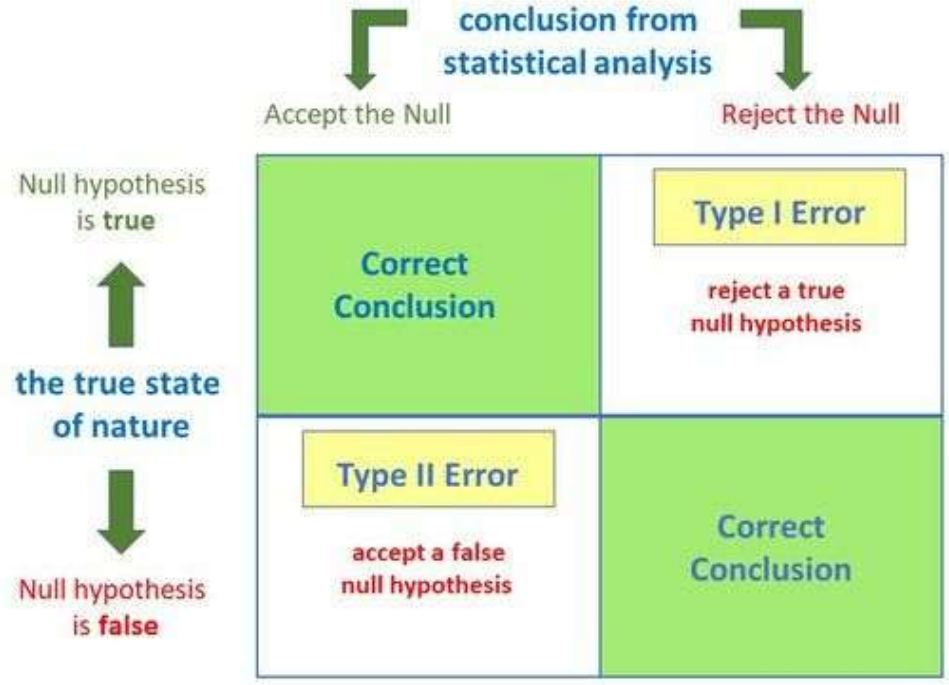

Potência Estatística (Poder[1])

		População	
		H_o **é Verdadeira**	***H_o*** **é Falsa**
Teste Estatístico (baseado na amostra de dados)	***Não Rejeita H_o***	Confiança $1 - \alpha$ ***(Conclusão Correta)***	Erro do Tipo II β ***(Falso Negativo)***
	Rejeita H_o	Erro do Tipo I α ***(Falso Positivo)***	Potência Estatística $1 - \beta$ ***(Conclusão Correta)***

α
Erro do Tipo I
(Falso Positivo)

β
Erro do Tipo II
(Falso Negativo)

[1]Termo também usado em Língua Portuguesa.
Sugiro utilizar apenas Potência Estatística.

Fatores Principais na Análise da Potência Estatística

Fator	**Para aumentar a Potência Estatística ($1 - \beta$)**
Significância Estatística (α)	Aumentando o α (Erro do Tipo I) reduzimos o β (Erro do Tipo II) – é um teste menos conservador
Tamanho da amostra usada para detectar o efeito	Aumentando o tamanho da amostra se aumenta a ($1 - \beta$) - maneira mais fácil e usual de aumentar a Potência Estatística

Exemplo 08:

Você foi contratado para avaliar experimentalmente a diferença na distância média percorrida por 3 diferentes bolas de golfe. Os dados experimentais com a métrica distância percorrida em jardas para as 3 diferentes bolas são :

Bola 1	Bola 2	Bola 3
285	292	291
290	272	269
271	279	295
288	283	273

One-way ANOVA: Distancia Media versus Marca Bola

```
Method

Null hypothesis         All means are equal
Alternative hypothesis  At least one mean is different
Significance level      α = 0,05

Equal variances were assumed for the analysis.


Factor Information

Factor      Levels  Values
Marca Bola       3  1; 2; 3


Analysis of Variance

Source      DF   Adj SS   Adj MS  F-Value  P-Value
Marca Bola   2    8,667    4,333     0,04    0,959
Error        9  930,000  103,333
Total       11  938,667
```

Portanto, não existe evidência para afirmar que as distâncias percorridas pelas 3 diferentes bolas sejam diferentes!

Exemplo 09:

Suponha que queremos determinar se a amostra que coletamos de nosso experimento das bolas de golfe tem ao mínimo 80% de Potência Estatística, ***para detectar uma diferença de aproximadamente 10 jardas*** entre as médias das diferentes marcas de bolas de golfe. Do projeto de experimentos anteriormente executado temos:

One-way ANOVA: Distancia Media versus Marca Bola

```
Method

Null hypothesis         All means are equal
Alternative hypothesis  At least one mean is different
Significance level      α = 0,05

Equal variances were assumed for the analysis.


Factor Information

Factor      Levels  Values
Marca Bola       3  1; 2; 3


Analysis of Variance

Source      DF   Adj SS   Adj MS  F-Value  P-Value
Marca Bola   2    8,667    4,333     0,04    0,959
Error        9  930,000  103,333
Total       11  938,667
```

Worksheet 1 ***

↓	C1	C2
	Marca Bola	Distancia Media
1	1	285
2	1	290
3	1	271
4	1	288
5	2	292
6	2	272
7	2	279
8	2	283
9	3	291
10	3	269
11	3	295
12	3	273
13		

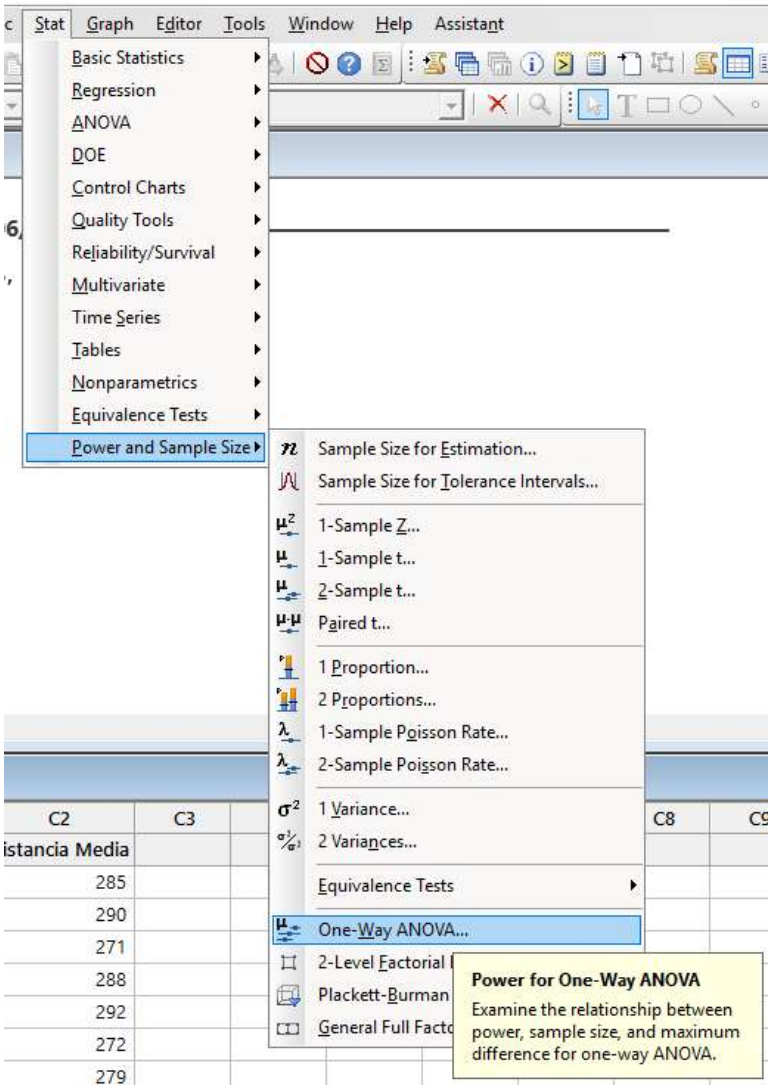

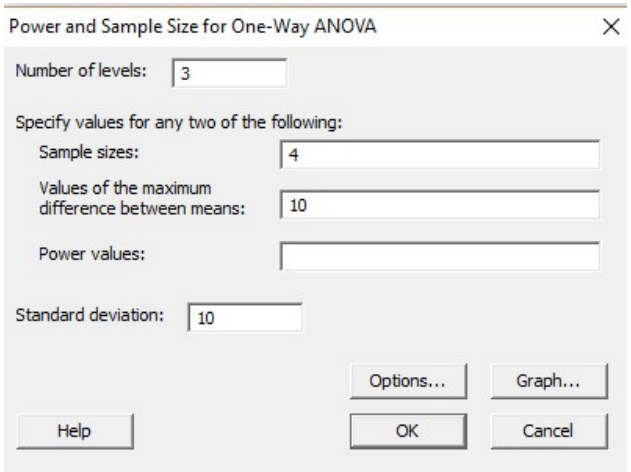

Análise de Potência Estatística para o Exemplo 09

Power and Sample Size

```
One-way ANOVA

α = 0,05  Assumed standard deviation = 10

Factors: 1  Number of levels: 3


   Maximum  Sample
Difference    Size     Power
        10       4  0,173282

The sample size is for each level.
```

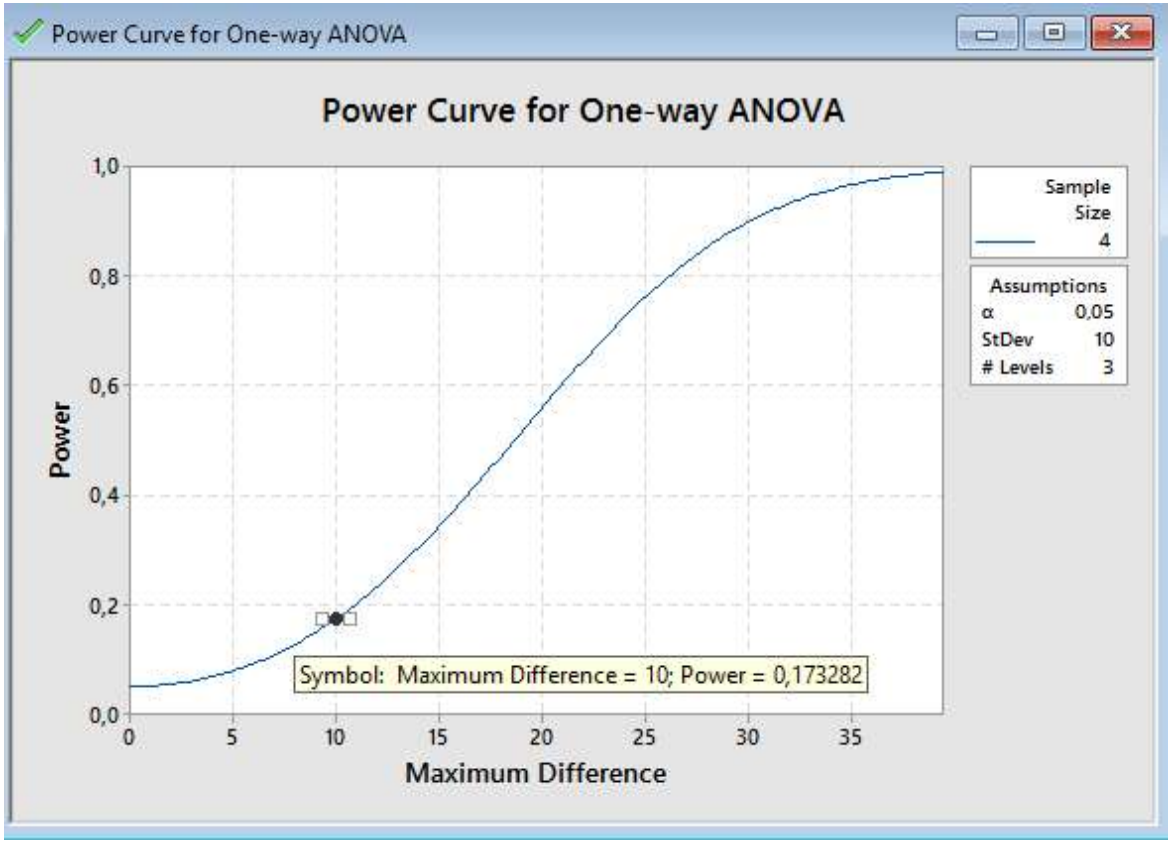

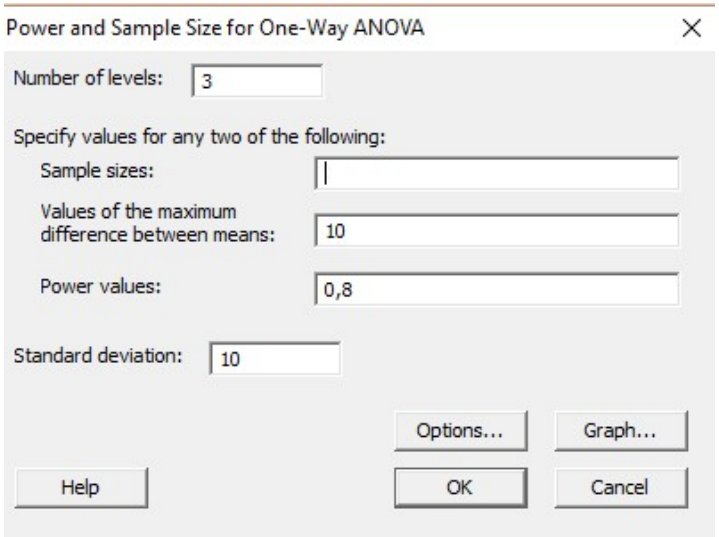

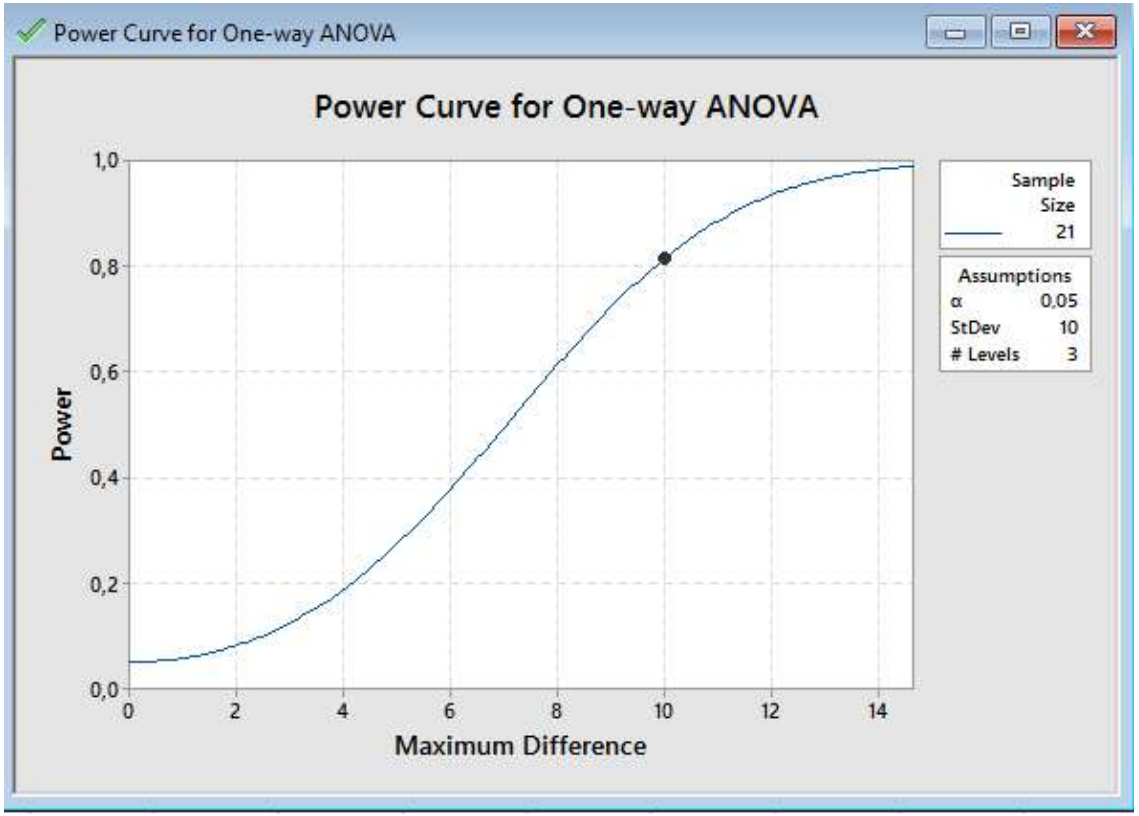

Power and Sample Size

One-way ANOVA

α = 0,05 Assumed standard deviation = 10

Factors: 1 Number of levels: 3

Maximum Difference	Sample Size	Target Power	Actual Power
10	21	0,8	0,814770

The sample size is [illegible] each level.

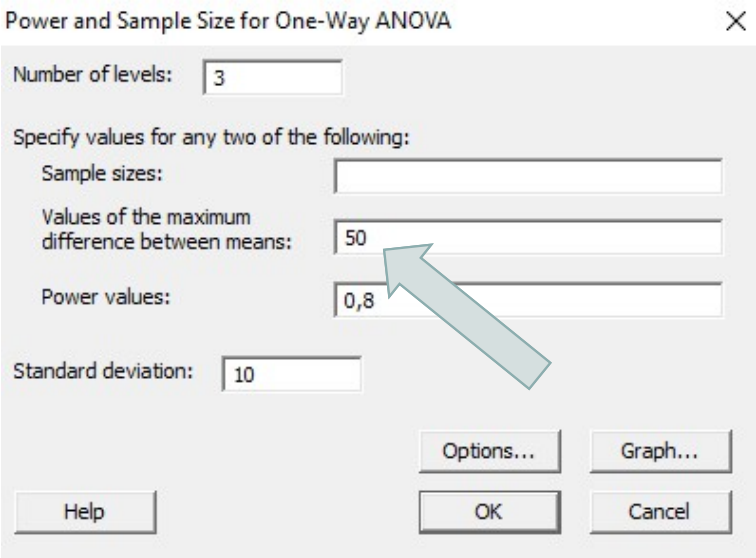

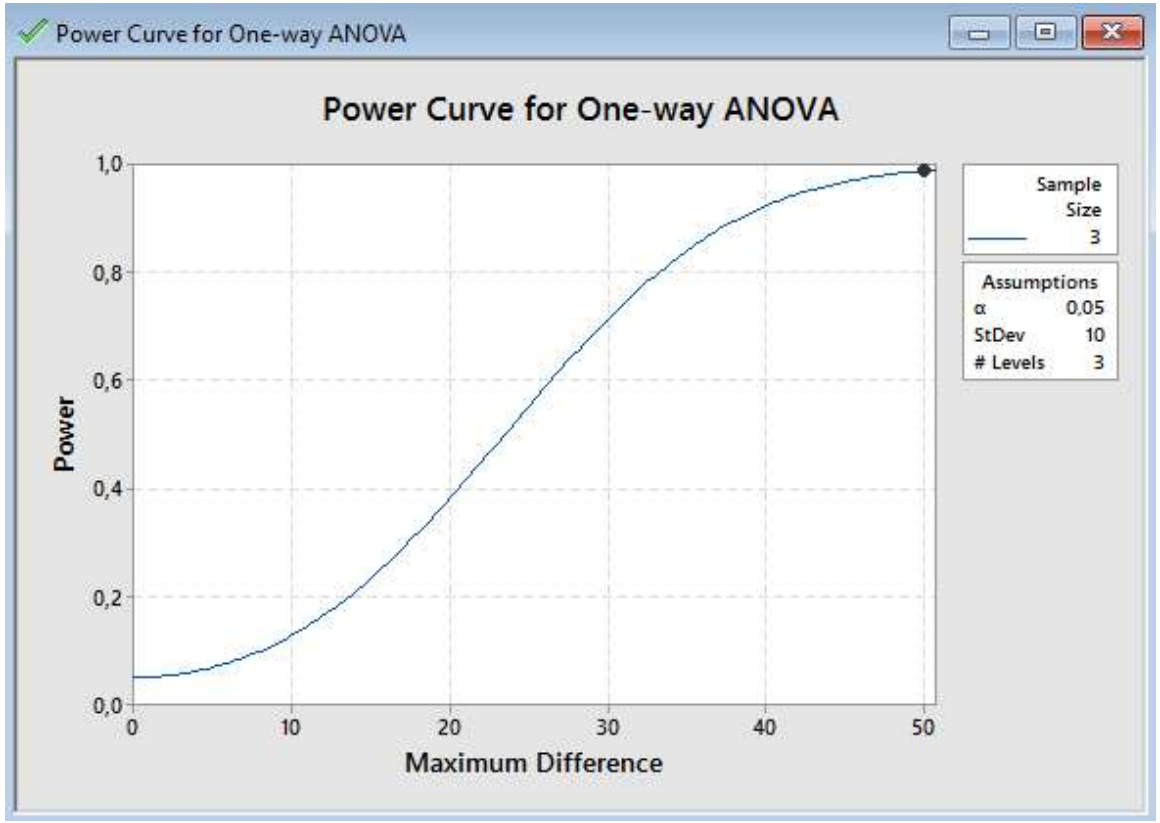

Power and Sample Size

```
One-way ANOVA

α = 0,05  Assumed standard deviation = 10

Factors: 1  Number of levels: 3


   Maximum  Sample  Target
Difference    Size   Power  Actual Power
        50       3     0,8      0,988251

The sample size is  each level.
```

Outros Conceitos Básicos

Tarefas Típicas para Aprendizagem de Máquina

- Classificação ou Categorização;
- Regressão;
- Detecção de Anomalias;
- Tradução;
- *Clustering* ou agrupamento.

Típicas Aplicações de Aprendizagem de Máquina

- Análise de dados de saúde;
- Detecção de anomalia;
- Detecção e prevenção de fraude;
- Recomendações de produtos em plataformas de compras *online*;
- Análise de sentimento e emoção;
- Previsão do tempo;
- Previsão do mercado de ações;
- Recomendação de conteúdo;
- Análise de cesta de mercado;
- Segmentação de clientes;
- Reconhecimento de fala;
- Previsão de chuva;
- Detecção e prevenção de falhas/defeitos;
- Reconhecimento de objeto e cena em imagens e vídeo;
- Filtragem de *spam* de e-mail e etc.

Alguns dos Principais Problemas em Sistemas de Aprendizagem de Máquina

- Qualidade de dados insuficiente;
- Aquisição, processamento e recuperação de dados;
- Falta de dados para um treinamento de alta qualidade em muitos cenários;
- Extração de características;
- Modelos de *underfitting* e *overfitting*;
- Maldição da Dimensionalidade.

Desafios em Projetos de Aprendizagem de Máquina

- **Desafios Relacionados aos Dados**
- **Qualidade dos Dados**
- **Características Irrelevantes**
- ***Overfitting* e *Underfitting* dos Dados**

Atividades de Laboratório

LAB02A

- Acessar o Moodle:
- Executar as tarefas solicitadas
- Vamos discutir as partes essenciais de cada tarefa
- Mãos à obra