UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Curso de Especialização

Inteligência Artificial para Engenheiros

Métodos Clássicos de Aprendizagem de Máquina (AMClas)

AULA 02B

Regressão Logística

Professor Dr. Alexandre Balbinot

2026

IA PARA ENGENHEIROS
UFRGS

Universidade Federal do Rio Grande do Sul
Escola de Engenharia
Curso de Especialização Inteligência Artificial para Engenheiros
Laboratório de Sistemas Elétricos Inteligentes (LASEI)

Métodos Clássicos de Aprendizagem de Máquina (AMClas)

Aula 02B

Regressão Logística

Prof. Dr. Alexandre Balbinot

Contatos

Prof. Dr. Alexandre ***Balbinot***

Curso de Especialização Inteligência Artificial para Engenheiros

Escola de Engenharia – UFRGS

Prédio do Instituto Eletrotécnico

Departamento de Engenharia Elétrica - DELET

Laboratório de Sistemas Elétricos Inteligentes (LASEI)

Sala 206D – (51) 3308-**4442**

alexandre.balbinot@ufrgs.br

Direitos Autorais

Este material possui Direitos Autorais e Direitos de Imagem e não pode ser duplicado, reproduzido, no todo ou em parte, sob quaisquer formas ou por quaisquer meios (eletrônicos, mecânico, gravação, fotocópia, distribuição na internet ou outros), sem permissão expressa do autor.

©

Termo de Responsabilidade da Própria UFRGS

Todos os materiais disponibilizados nos Ambientes Virtuais da UFRGS são exclusivamente para usos e fins didáticos, sendo vedada a sua utilização para qualquer outra finalidade, sob as penas legais.

Todos os materiais de terceiros que venham a ser utilizados ou disponibilizados devem ser referenciados, sob as penas legais, inclusive de plágio.

Tenho liberdade de expor ou não a minha imagem e voz nas atividades, o que não me desonera da participação efetiva nas mesmas.

Todas as gravações de atividades síncronas devem ser previamente informadas por parte dos professores.

Os alunos somente poderão gravar, armazenar ou compartilhar atividades mediante concordância prévia do professor, sob as penas legais.

Os alunos somente poderão armazenar ou compartilhar materiais mediante concordância prévia do professor ou se permitido no material, sob as penas legais.

É proibido disponibilizar, por quaisquer meios digitais ou físicos, os dados, a imagem e a voz dos alunos, dos colegas e do professor, sem autorização específica para a finalidade pretendida.

INTRODUÇÃO

Reforçando Características Básicas da Regressão

Variável Alvo
Todos os Preditores → **Regressor** → Equação Regressora

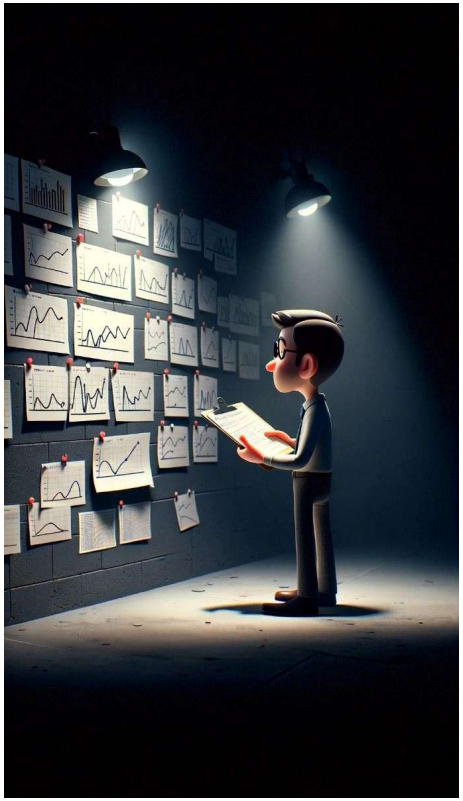

Regressão Linear versus Regressão Logística

Métodos de Regressão	Variável Alvo	Preditores
Linear	As notas dos alunos em um teste nacional para ingresso de um dado curso superior: considerando-se como uma variável contínua no intervalo de 0 a 10	Idade, gênero, , raça, média geral no ensino médio, renda familiar e etc
Logística	Variável Binária: Sim ou Não ou a variável alvo é a decisão do aluno de escolher uma opção de curso de engenharia: 1 (elétrica), 2 (mecânica), 3 (civil), 4 (química) e etc.	Idade, gênero, raça, média geral no ensino médio, renda familiar e etc

Equações de Regressão

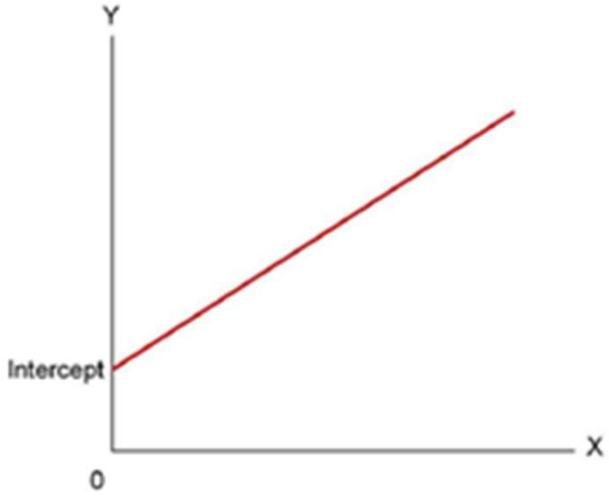

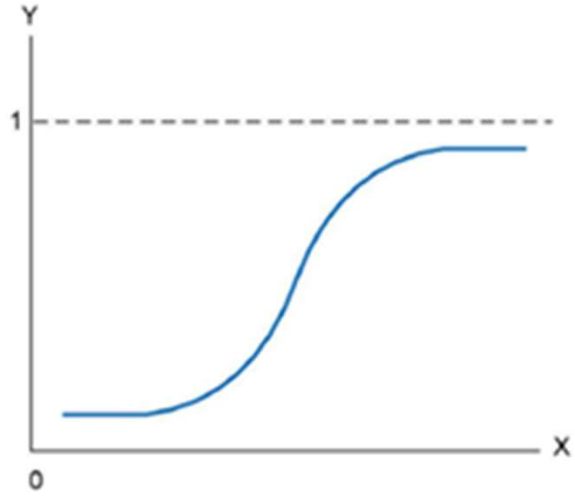

Regressão Logística na Classificação: outra técnica linear

Características Básicas da Regressão Logística

Predição Probabilística com a Regressão Logística

Exemplo 01: realização de uma previsão com a Regressão Logística

Considere o exemplo onde um habitante de um exoplaneta pode apresentar 3 ou 2 olhos baseado na sua altura. Considerando-se que este habitante tem uma altura de 150cm ele tem 3 ou 2 olhos?

$$y_p = \frac{e^{B_0+B_1\times x}}{1+e^{B_0+B_1\times x}} = \frac{e^{-100\quad,6\times 150}}{1+e^{-100+0,6\times 150}} = 0,0000453978687$$

Preparando os Dados para Regressão Logística

- Variável de Saída Binária
- Remoção de Ruído
- Distribuição Gaussiana
- Remoção de Entradas Correlacionadas
- Falha na Convergência

Exemplo 02: modelo analítico completo do processo de aprendizagem

Considere o seguinte conjunto de **dados de treinamento**
(nossa base de treinamento – não é toda a base de dados):

X_1	X_2	Y_d
2,7810836	2,550537003	0
1,465489372	2,362125076	0
3,396561688	4,400293529	0
1,38807019	1,850220317	0
3,06407232	3,005305973	0
7,627531214	2,759262235	1
5,332441248	2,088626775	1
6,922596716	1,77106367	1
8,675418651	-0,242068655	1
7,673756466	3,508563011	1

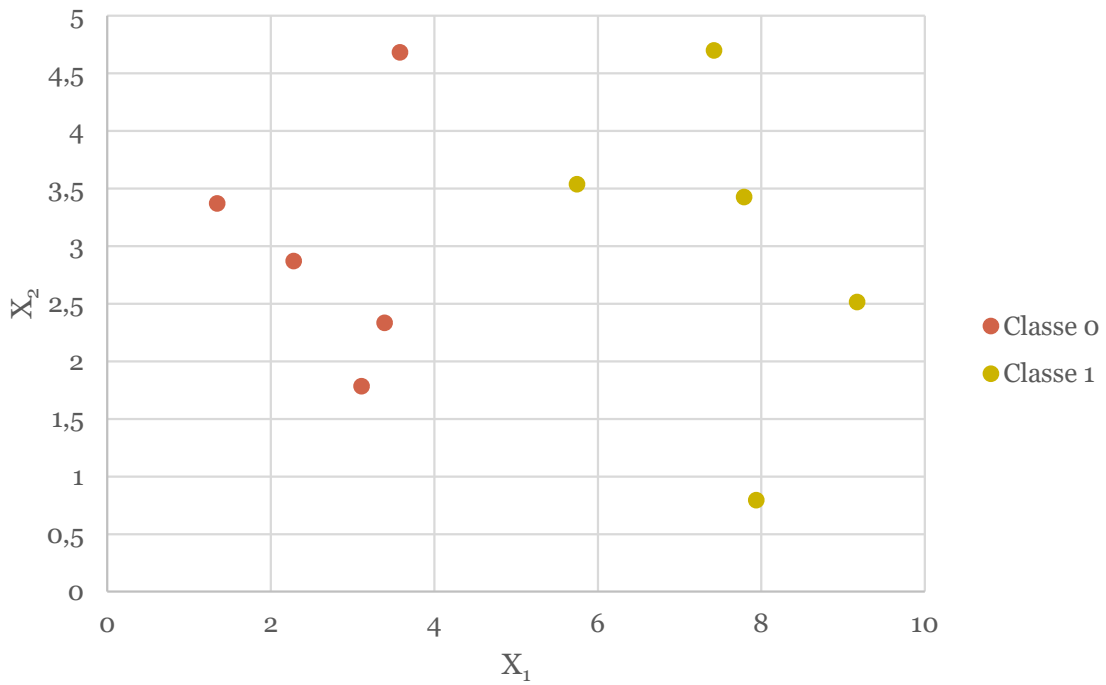

Otimizando pelo Gradiente Descendente (GD) - 1º iteração da 1º época:

$$y_p = \frac{1}{1 + e^{-(B_0 + B_1 \times x_1 + B_2 \times x_2)}}$$

$$y_p = \frac{1}{1 + e^{-(0{,}0 + 0{,}0 \times 2{,}7810836 + 0{,}0 \times 2{,}550537003)}}$$

$$y_p = 0{,}5$$

X_1	X_2	Y_d
2,7810836	2,550537003	0
1,465489372	2,362125076	0
3,396561688	4,400293529	0
1,38807019	1,850220317	0
3,06407232	3,005305973	0
7,627531214	2,759262235	1
5,332441248	2,088626775	1
6,922596716	1,77106367	1
8,675418651	-0,242068655	1
7,673756466	3,508563011	1

Repetindo o Processo para Treinamento do Modelo (obviamente com nossa base de treinamento):

Como tema de casa repetir o processo por 10 épocas (lembrando que a leitura completa da base de treinamento forma o que chamamos de época), portanto, deverá "ler" os dados 10x, ou seja, são 100 iterações (10 dados x 10 épocas).

X_1	X_2	Y_d
2,7810836	2,550537003	0
1,465489372	2,362125076	0
3,396561688	4,400293529	0
1,38807019	1,850220317	0
3,06407232	3,005305973	0
7,627531214	2,759262235	1
5,332441248	2,088626775	1
6,922596716	1,77106367	1
8,675418651	-0,242068655	1
7,673756466	3,508563011	1

10x

Ao final deverá encontrar aproximadamente:

$$B_0 = -0{,}406605464$$

$$B_1 = 0{,}852573316$$

$$B_2 = -1{,}104746259$$

Realizando as Predições:

Após as 10 épocas e uma análise do desempenho do modelo consideramos que o modelo foi "bem treinado".

Portanto, AGORA podemos realizar as predições e **devemos usar um conjunto de teste, ou seja, novos dados que não foram usados no treinamento** – ***SEMPRE UTILIZAR DADOS QUE NÃO FORAM USADOS NA BASE DE TREINAMENTO (exceção: isso se você não utilizou algum método de validação cruzada, como por exemplo, o k-fold, k-fold estratificado e etc):***

Base de Teste

X_1	X_2	Y_d	Predição (Y_p)
Novos Dados		0	0,298756986
		0	0,145951056
		0	0,085333265
		0	0,219737314
		0	0,247059
		1	0,954702135
		1	0,862034191
		1	0,971772905
		1	0,999295452
		1	0,905489323

X_1	X_2	Y	Predição (Y_p)	*Crisp* (Y_p)
Novos Dados		0	0,298756986	
		0	0,145951056	
		0	0,085333265	
		0	0,219737314	
		0	0,247059	
		1	0,954702135	
		1	0,862034191	
		1	0,971772905	
		1	0,999295452	
		1	0,905489323	

LAB04B

- Acessar o Moodle
- Executar todas as *Tarefas*
- Vamos discutir as partes essenciais de cada tarefa
- Mãos à obra