UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

IA PARA ENGENHEIROS
UFRGS

Curso de Especialização

Inteligência Artificial para Engenheiros

Disciplina: **Algoritmos para Agrupamento de Dados**

Aula: **Conceitos Fundamentais sobre Similaridade de Dados e o Algoritmo k-NN**

Professor: **Maurício Cagliari Tosin**

2026

Conteúdo programático

1. **06/03 –** Apresentação da disciplina. Método kNN (k-Nearest Neighbors)
2. **13/03 –** Apresentação dos métodos K-Means e K-Medoids
3. **20/03 –** Métodos hierárquicos de clusterização
4. **27/03 –** Clusterização baseado em densidade. Método DBSCAN
5. **10/04 –** Métricas para a avaliação de desempenho da clusterização
6. **11/04 –** Fundamentos de Deep Clustering. Exemplos de aplicações

Conceitos Fundamentais sobre Similaridade de Dados

Introdução

Observações:

- Alguns experimentos envolvem **dados sem um alvo determinado.**
- São experimentos da área de ***Aprendizagem Não Supervisionada.***
  - Diversas aplicações caracterizadas normalmente:
    - por envolver **base de dados de grande porte**;
    - e **minerar** o conhecimento nessas bases gigantes ***excede a habilidade humana***.
- **Agrupamento de Dados** (***Clustering***): método importante de **Mineração de Dados** (*Datamining*) para descoberta do conhecimento em dados multidimensionais:
  - ***objetivo*** identificar modelos ou grupos de objetos similares em um *dataset*;
  - área conhecida como "***Reconhecimento de Modelos***" ou "***Aprendizagem de Máquina Não Supervisionada***".
- ***Cluster*** é popular em diversas áreas, como por exemplo:
  - câncer: classificação de pacientes em subgrupos em função do perfil genético (identificação do perfil genético dos pacientes em função do prognóstico para compreensão da doença);
  - marketing: segmentação de mercados pela identificação de subgrupos de consumidores com perfis similares e como são receptivos a uma forma particular de propaganda;
  - planejamento de cidades: identificação de grupos de casas de acordo com seu tipo, valor, localização entre outras características consideradas essenciais;
  - e etc...

Exercício 01

Você é o responsável por gerenciar uma grande loja virtual e gostaria de conhecer o comportamento dos usuários durante o momento da compra:

(a) Qual o verdadeiro objetivo deste tipo de estudo?
(b) Forneça sugestões para alcançar o objetivo proposto.

Objetivo:

- melhorar a inserção do usuário no ambiente virtual para ***aumentar as vendas***.

Soluções Possíveis:

- fornecer a cada usuário um conjunto de sugestões de produtos no acesso ao site de vendas;
- não se conhece diretamente cada preferência pessoal, porém temos uma grande quantidade de dados (registros das compras realizadas por cada usuário);
- clássico problema de ***Aprendizagem de Máquina*** (inexistência de um modelo fundamental, mas existência de grande quantidade de dados);
- se for possível definir uma ***medida de similaridade*** entre consumidores com base no histórico de compra ➔ poderemos ***agrupar os consumidores*** em *k* grupos (cada grupo de consumidores irá apresentar um modelo de compra similar).

Classificador do Vizinho Mais Próximo (k-NN)

Para meditar:

- *Uma girafa é mais similar ao cavalo ou a zebra?*
- *Como estabelecer que um objeto é mais similar ao **x** do que ao **y**?*
- *Nem sempre é fácil caracterizar a similaridade de objetos.*

Exercício 02

Analisar os seguintes dados representando as diferenças entre peças de um vetor com atributos discretos. Considerar o Dado x como nossa referência. Determinar: (a) qual elemento é mais similar ao objeto x considerando-se os 12 elementos do vetor ? (b) qual é a classe do objeto x?

		Casca		Preenchimento		
Dado	**Formato**	***Tamanho***	***Sombra***	***Tamanho***	***Sombra***	**Classe**
x	***Quadrado***	***Grande***	***Cinza***	***Fino***	***Branca***	***?***
Dado1	Círculo	Grande	Cinza	Grande	Preta	Pos
Dado2	Círculo	Grande	Branca	Grande	Preta	Pos
Dado3	Triângulo	Grande	Preta	Grande	Cinza	Pos
Dado4	Círculo	Fina	Branca	Fino	Preta	Pos
Dado5	Quadrado	Grande	Preta	Fino	Branca	Pos
Dado6	Círculo	Grande	Branca	Fino	Preta	Pos
Dado7	Círculo	Grande	Cinza	Grande	Branca	Neg
Dado8	Quadrado	Grande	Branca	Grande	Cinza	Neg
Dado9	Triângulo	Fina	Cinza	Fino	Preta	Neg
Dado10	Círculo	Grande	Preta	Grande	Branca	Neg
Dado11	Quadrado	Grande	Branca	Grande	Preta	Neg
Dado12	Triângulo	Grande	branca	Grande	Cinza	Neg

Exercício 02

Estratégia adotada: atribuição de valores numéricos para os atributos, para posterior cômputo da diferença entre uma instância e outra.

Atributo	Classes	Valor	Atributo	Classes	Valor
Formato	Quadrado	3	Sombra da casca	Branca	3
	Círculo	2		Cinza	2
	Triângulo	1		Preta	1
Tamanho da casca	Grande	2	Sombra do preenchimento	Branca	3
	Fina	1		Cinza	2
Tamanho do preenchimento	Grande	2		Preta	1
	Fino	1			

$$Diferença_{A,B} = \sum_{i=1}^{N} |atributo_{Ai} - atributo_{Bi}|$$

Exercício 02

		Casca		Preenchimento			
Dado	**Formato**	***Tamanho***	***Sombra***	***Tamanho***	***Sombra***	**Classe**	**#diferença**
x	***Quadrado (3)***	***Grande (2)***	***Cinza (2)***	***Fino (1)***	***Branca (3)***	***?***	**-**
Dado1	Círculo (2)	Grande (2)	Cinza (2)	Grande (2)	Preta (1)	Pos	***4***
Dado2	Círculo (2)	Grande (2)	Branca (3)	Grande (2)	Preta (1)	Pos	***5***
Dado3	Triângulo (1)	Grande (2)	Preta (1)	Grande (2)	Cinza (2)	Pos	***5***
Dado4	Círculo (2)	Fina (1)	Branca (3)	Fino (1)	Preta (1)	Pos	***5***
Dado5	Quadrado (3)	Grande (2)	Preta (1)	Fino (1)	Branca (3)	Pos	***1***
Dado6	Círculo (2)	Grande (2)	Branca (3)	Fino (1)	Preta (1)	Pos	***4***
Dado7	Círculo (2)	Grande (2)	Cinza (2)	Grande (2)	Branca (3)	Neg	***2***
Dado8	Quadrado (3)	Grande (2)	Branca (3)	Grande (2)	Cinza (2)	Neg	***3***
Dado9	Triângulo (1)	Fina (1)	Cinza (2)	Fino (1)	Preta (1)	Neg	***5***
Dado10	Círculo (2)	Grande (2)	Preta (1)	Grande (2)	Branca (3)	Neg	***3***
Dado11	Quadrado (3)	Grande (2)	Branca (3)	Grande (2)	Preta (1)	Neg	***4***
Dado12	Triângulo (1)	Grande (2)	Branca (3)	Grande (2)	Cinza (2)	Neg	***5***

Qual é o elemento do conjunto de treinamento mais similar ao objeto x?
É o Dado5, pois é mais similar ao x, sendo assim, o rótulo ou a classe de x é Pos – a mesma classe do Dado5!

O Algoritmo do k Vizinho Mais Próximo (k-NN)

Pseudocódigo de 1 Vizinho para k Vizinhos

1.
Supor a existência de alguma métrica para avaliar a similaridade entre atributos de um dado vetor
Seja x o objeto cuja classe esperamos determinar

2.
Entre os exemplos de treinamento (dados), identificar os *k* vizinhos mais próximos a *x*
(exemplos mais similares a *x*)

3.
Seja c_i a classe mais frequentemente encontrada entre esses *k* vizinhos mais próximos

4.
Rotular *x* como c_i

Exercício 03

Considere o treinamento de 2 classes (positiva e negativa) cujos objetos círculos na cor azul devem ser classificados, ou seja, o classificador k-NN (com k = 1, ou seja, levar em consideração apenas 1 vizinho mais próximo: 1-NN) deve determinar a qual classe os mesmos pertencem. Portanto, qual é a classe dos círculos pretos?

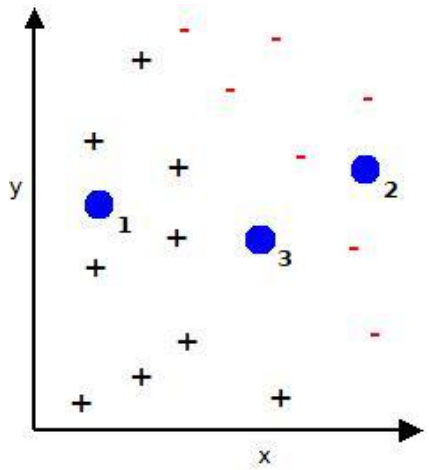

1 *e* ***2*** *estão cercados por elementos de uma mesma classe* ➔ ***classificação é confiável, ou seja, 1 é da classe positiva e 2 da classe negativa****.*

3 *está localizado na "****terra de ninguém****" - entre as regiões positiva e negativa – a classificação borderline* ***não é confiável****.*

Exercício 04

Considere o treinamento de 2 classes (positiva e negativa) cujo objeto círculo azul deve ser classificado, ou seja, o classificador k-NN deve determinar a qual classe o mesmo pertence. Considere que o círculo azul foi classificado de forma errônea, por exemplo, devido ao ruído, ou seja o classificador 1-NN errou. Como tentar corrigir este erro?

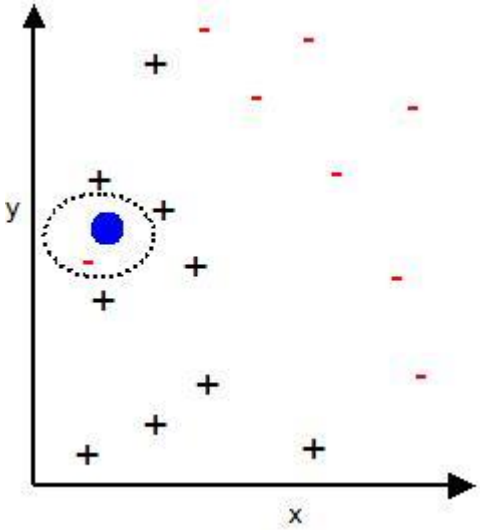

Círculo Azul *encontra-se mais próximo da região positiva, mas devido ao ruído foi rotulado erroneamente como negativo - o Classificador 1-NN errou!*

Este erro pode ser corrigido se usarmos um 3-NN (k=3 – como representado no grupo tracejado).

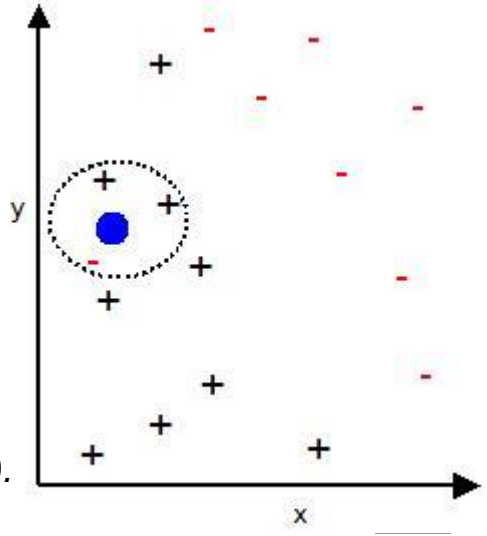

Medição de Similaridade pela Métrica Distância Euclidiana

Distância Euclidiana

- **Procedimento Básico:** Encontrar vizinhos próximos de **x** (dado a ser classificado) comparando as distâncias de cada objeto do conjunto de treinamento em relação a **x**.
- **Distância Euclidiana no Plano 2D:** Distância entre 2 pontos $(\boldsymbol{x} = (x_1, x_2)\ e\ \boldsymbol{y} =$

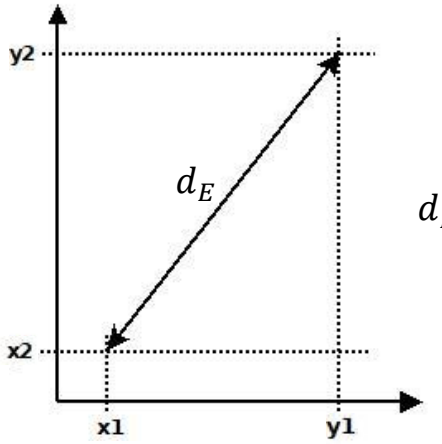

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

Generalizando:

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Exercício 05

Considerar o conjunto de treinamento indicado na tabela abaixo formada por 4 objetos (Dado1 a Dado4) representados por 3 atributos numéricos (características) e sua correspondente classe. Qual é a classe do objeto ou dado x = [2, 4, 2] utilizando o princípio do "Vizinho Mais Próximo" em um Espaço Euclidiano 3D (3 atributos para cada elemento do vetor)?

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

$Dado_1$	{[1,3,1], pos}
$Dado_2$	{[3,5,2], pos}
$Dado_3$	{[3,2,2], neg}
$Dado_4$	{[5,2,3], neg}

Solução:

Distância entre $Dado_{i=1\ a\ 4}$ e [2, 4, 2]?		
$Dado_1$	*{[1,3,1], pos}*	$\sqrt{(2-1)^2 + (4-3)^2 + (2-1)^2} = \sqrt{3}$
$Dado_2$	*{[3,5,2], pos}*	$\sqrt{(2-3)^2 + (4-5)^2 + (2-2)^2} = \sqrt{2}$
$Dado_3$	*{[3,2,2], neg}*	$\sqrt{(2-3)^2 + (4-2)^2 + (2-2)^2} = \sqrt{5}$
$Dado_4$	*{[5,2,3], neg}*	$\sqrt{(2-5)^2 + (4-2)^2 + (2-3)^2} = \sqrt{14}$

O vizinho mais próximo de ***x*** é o objeto *$Dado_2$*. Portanto, ***x*** é rotulado como ***pos***: classificador 1-NN retorna o rótulo positivo.

Outras Métricas para Medição da Distância entre Clusters

Métodos Clássicos – Principais Métricas

- **Distância Euclidiana:** distância em linha reta.

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

- **Distância Manhattan (city block distance):** mede a distância "caminhando" ao longo de eixos ortogonais, simulando quarteirões de uma cidade.

$$d_M(\boldsymbol{x}, \boldsymbol{y}) = \sum_{i=1}^{n} |x_i - y_i|$$

x e y são vetores de comprimento n

Medidas Baseadas em Correlação

- **Correlação de Pearson:** mede a dependência linear entre duas variáveis.
  - Definida no intervalo $[-1, 1]$
  - $$\begin{cases} r = -1 \rightarrow amostras\ perfeitamente \\ \quad correlacionadas\ (coef.negativo) \\ r = 0 \rightarrow amostras\ descorrelacionadas \\ r = 1 \rightarrow amostras\ perfeitamente \\ \quad correlacionadas\ (coef.positivo) \end{cases}$$

$$r = \frac{\sum_{i=1}^{n}[(x_i - \bar{x})(y_i - \bar{y})]}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

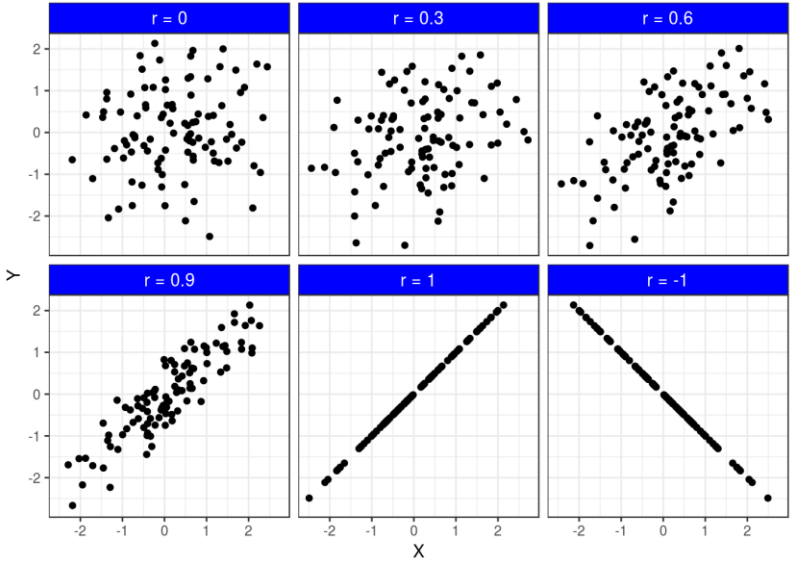

Medidas Baseadas em Correlação

- **Distância da correlação de Pearson:**

$$d_{correlação}(\boldsymbol{x}, \boldsymbol{y}) = 1 - \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

Amplo uso na análise de dados estocásticos, dados genéticos, etc.

A Importância da Escolha de Características Relevantes e a Normalização de Dados

Atributos Irrelevantes e Problemas de Escala

Observações:

- erro comum achar que todos os atributos são criados de forma igual. NÃO SÃO!
- alguns atributos podem ser irrelevantes E não tem sentido usá-los;
- atributos irrelevantes podem afetar o cálculo das distâncias geométricas entre os vetores.

Exemplo 01:
Considere o conjunto de treinamento apresentado graficamente onde o **paciente** indicado pelo **círculo azul** deve ser classificado como **saudável (classe positiva)** ou **doente (*classe negativa*)**. Porém, os dados foram caracterizados por 2 atributos numéricos: ***Temperatura do Corpo*** e ***Tamanho do Sapato***.

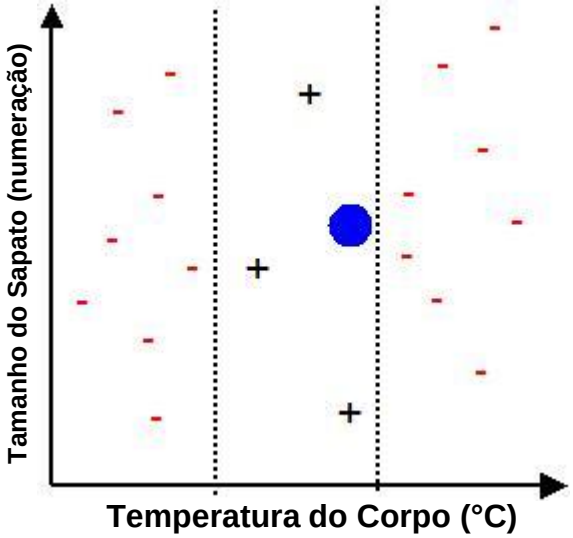

O atributo "Tamanho do Sapato" é irrelevante para a classificação, mas pode afetar as distâncias geométricas entre os dados. Neste exemplo, o Paciente 1 foi classificado como positivo (saudável), mas é o vizinho mais próximo do espaço 2D negativo (doente).

Exercício 06

Avaliar a similaridade de 2 dados caracterizados por 3 características: **x** = (Verdadeiro, 0,2, 254) e **y** = (Falso, 0,1, 194) calculando a distância Euclidiana entre eles. Esses dados são descritos por 3 atributos: o 1º atributo é Booleano (1 ou 0), o 2º atributo é contínuo com valores no intervalo de [0, 1] e o 3º atributo é contínuo com valores no intervalo de [0,1000]. Existe algum problema de escala?

Solução:

$$d_E(x, y) = \sqrt{(1-0)^2 + (0{,}2-0{,}1)^2 + (254-194)^2}$$

3° atributo é dominante e os outros atributos são insignificantes!
Famoso problema devido as escalas *dos valores dos atributos.*

Solução: balancear a importância de todos os atributos, pois a escala afeta radicalmente o comportamento do classificador *k*-NN!

Exercício 07

Considerar dois dados de treinamento: ex1 ((10,10)) da classe positivo) e ex2 ((20,0)) da classe negativo) e um dado que desejamos classificar em positivo ou negativo ***x (32,20)***. Cada dado possui apenas 2 características ou atributos. Baseado na métrica Distância Euclidiana determinar qual é a classe do objeto x?

Solução:

As distâncias são:

$$d_E(x, ex_1) = \sqrt{(32-10)^2 + (20-10)^2} = \sqrt{584}$$

$$d_E(x, ex_2) = \sqrt{(32-20)^2 + (20-0)^2} = \sqrt{544}$$

Última distância é a menor, ou seja, o classificador 1-NN irá rotular x como negativo.

Exercício 08

Considerar dois dados de treinamento: ex1 ((10,10)) da classe positivo) e ex2 ((20,0)) da classe negativo) e um dado que desejamos classificar em positivo ou negativo x (32,20). Cada dado possui apenas 2 características ou atributos. Antes de realizar a classificação transformar o segundo atributo de cada dado da escala ºC para a escala Fahrenheit. Baseado na métrica Distância Euclidiana determinar qual é a classe do objeto x? Qual o problema apresentado nesta questão?

Solução:

Realizando a transformação do **segundo atributo** (aproximadamente):

ex_1 ((10,**50**)) da classe positivo)

ex_2 ((20,**32**)) da classe negativo)

x ((32,**68**))

Como minimizar este tipo de problema?

Recalculando as distâncias:

$$d_E(x, ex_1) = \sqrt{(32-10)^2 + (68-50)^2} = \sqrt{808}$$

$$d_E(x, ex_2) = \sqrt{(32-20)^2 + (68-32)^2} = \sqrt{1440}$$

O classificador 1-NN classificou ***x*** como positivo.

Exercício 08

Considerar dois dados de treinamento: ex1 ((10,10)) da classe positivo) e ex2 ((20,0)) da classe negativo) e um dado que desejamos classificar em positivo ou negativo x (32,20). Cada dado possui apenas 2 características ou atributos. Antes de realizar a classificação transformar o segundo atributo de cada dado da escala ºC para a escala Fahrenheit. Baseado na métrica Distância Euclidiana determinar qual é a classe do objeto x? Qual o problema apresentado nesta questão?

Solução:

Realizando a transformação do **segundo atributo** (aproximadamente):

ex$_1$ ((10,**50**)) da classe positivo)

ex$_2$ ((20,**32**)) da classe negativo)

x ((32,**68**))

Como minimizar este tipo de problema?

Recalculand

$d_E(x, e$

icou ***x***

$d_E(x,$

Manter as mesmas unidades e normalizar os dados!

Normalização dos Atributos

Existem diversos métodos para normalizar dados e um dos mais usados é:

$$x_{normalizado} = \frac{x \ - Valor\ Mínimo}{Valor\ Máximo \ - Valor\ Mínimo} \qquad x_{normalizado} \rightarrow [0,1]$$

<u>Exercício 09</u>:
Considerar um conjunto de treinamento formado por 5 dados (cada dado possui um atributo apenas). Normalizar o correspondente conjunto de dados: [7; 4; 25; -5; 10].

Solução:

Valor Mínimo = -5 e Valor Máximo = 25
Subtraindo Valor Mínimo de cada dado (x): [7-(-5); 4-(-5); 25-(-5); -5-(-5); 10-(-5)]: ***[12; 9; 30; 0; 15]***
Finalmente o $x_{normalizado}$ é: [12; 9; 30; 0; 15] / 30 = ***[0,4; 0,3; 1; 0; 0,5]***

O Algoritmo Vizinho Mais Próximo Ponderado

Criação de Prioridade com o Vizinho Mais Próximo Ponderado

Na classificação k-NN a votação é democrática, ou seja, cada vizinho mais próximo tem seu voto com o mesmo peso, ou seja, com a mesma importância!

Exemplo 02:
Ao determinar a classe do ***dado ou objeto x*** (**círculo azul**) foi considerado os 3 vizinhos mais próximos negativos e os 2 vizinhos mais próximos positivos. Considerar que este classificador 5-NN rotulou ***x*** como negativo.

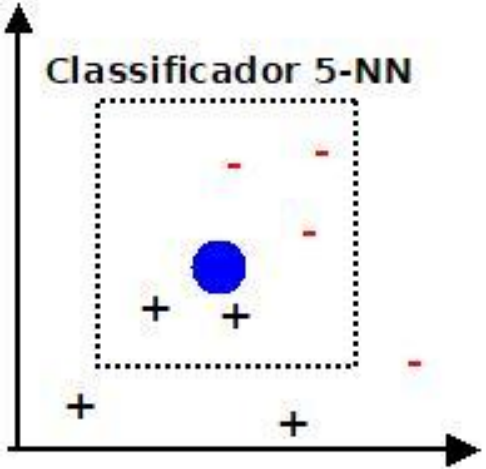

*Esta classificação ESTÁ ERRADA! Os 3 vizinhos negativos são mais distantes de **x, mas vamos imaginar que impactaram de forma significativa na classificação, pois entraram no cálculo da distância**!*

Problema: *os 3 vizinhos mais próximos negativos não merecem a mesma importância dos 2 vizinhos mais próximos positivos na classificação!*
Uma possível solução: *trabalhar com pesos diferentes, ou seja, ponderar.*

Criação de Prioridade com o Vizinho Mais Próximo Ponderado

Uma possível solução é usar a **Votação Ponderada**:

- vizinhos mais próximos receberão um peso maior (proporcional à distância do dado de interesse x);
- logo o vizinho mais próximo tem seu impacto aumentado!

O *k*-NN Ponderado soma os pesos desses vizinhos para classificar em Classe Positiva ou Classe Negativa. A classificação será baseada no somatório de maior peso para indicar a classe. Por exemplo, se:

$$\sum_{+} > \sum_{-}$$

então *x* é considerado da Classe Positiva; caso contrário, será da Classe Negativa.

Criação de Prioridade com o Vizinho Mais Próximo Ponderado

Exemplo 03:

Supor que os pesos 0,6 e 0,7 representam a Classe Positiva (ou rótulo positivo) e os pesos 0,1; 0,2 e 0,3 Classe Negativa (ou rótulo negativo). O algoritmo classificador ***k*-NN Ponderado** escolherá a classe positiva pois:

pesos dos vizinhos positivos (0.6 + 0.7 = 1.3) > (0.1 + 0.2 + 0.3 = 0.6) da classe negativa

Assim resolvemos o problema do Exemplo 02.

O rótulo negativo mesmo sendo mais frequente acabou sendo "depreciado" em função dos vizinhos mais próximos positivos (que são mais próximos ao dado de interesse ***x***).

Possível Medologia para Gerar Pesos ao k-NN Ponderado

k vizinhos são ordenados de acordo com os valores na ordem crescente de suas distâncias: $d_1, \dots, d_k$, onde $\boldsymbol{d_1}$ é a menor distância de x e $\boldsymbol{d_k}$ a maior distância de x.

Os pesos ω_i dos i-ésimos vizinhos são determinados por:

$$\omega_i = \begin{cases} \dfrac{d_k - d_i}{d_k - d_1}; & d_i \neq d_1 \\ 1; & d_i = d_1 \end{cases} \qquad \omega_i \rightarrow [0,1]$$

Exercício 10

Considerar que as ***distâncias*** (por exemplo, a Euclidiana) entre o ***dado x*** e os *5 vizinhos mais próximos* são: $d_1 = 1; d_2 = 3;\ d_3 = 4;\ d_4 = 5\ e\ d_5 = d_k = 8$. Determinar qual é a classe do ***dado x*** se os ***2 primeiros pesos pertencem a Classe Positiva e os restantes a Classe Negativa***. Utilizar um *Classificador 5-NN Ponderado*.

Solução:

Distância mínima: $d_1 = 1$
Distância máxima: $d_5 = d_k = 8$

$$\omega_i = \frac{d_5 - d_i}{d_5 - d_1} = \frac{8 - d_i}{8 - 1} = \frac{8 - d_i}{7}$$

Os pesos individuais são:

$$\omega_1 = \frac{8-d_1}{8-1} = \frac{8-1}{7} = 1;\ \omega_2 = \frac{8-3}{7} = \frac{5}{7};\ \omega_3 = \frac{8-4}{5} = \frac{4}{7};\ \omega_4 = \frac{8-5}{7} = \frac{3}{7}\ e\ \omega_5 = \frac{8-8}{7} = 0$$

x foi classificado como positivo, pois:

$$\sum\nolimits_{+} \left(1 + \frac{5}{7}\right) > \sum\nolimits_{-} \left(\frac{4}{7} + \frac{3}{7} + 0\right)$$

Considerações Finais

Considerações finais

Aumento do Número de Vizinhos:

- um classificador k-NN com k >1 aumenta o correspondente desempenho.

Limitações do algoritmo em aplicações:

- quantidade de dados pode ser pequena;
- aumento do número de vizinhos participantes pode ser contraprodutivo;
- pode ocorrer a situação representada pela curva de desempenho:

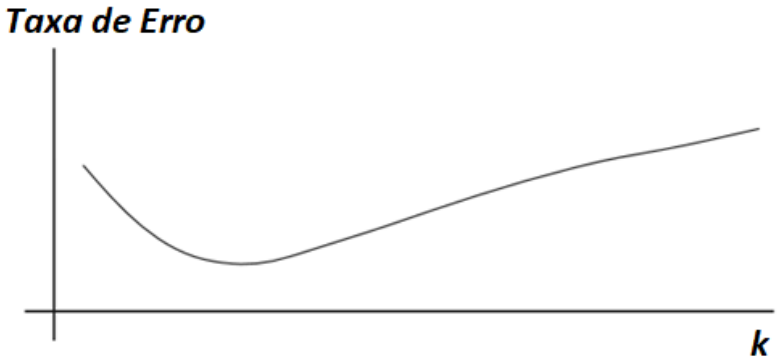

O valor ótimo de k é usualmente estabelecido com base em rodadas do algoritmo!

Considerações finais

Abordagem da Dimensionalidade

- Discussão sobre o quanto devemos aumentar o número de atributos, o número de dados de treinamento necessários para encontrar um espaço com adequada densidade.
- O aumento do número de atributos ocasiona aumento na dispersão dos dados (distância média).

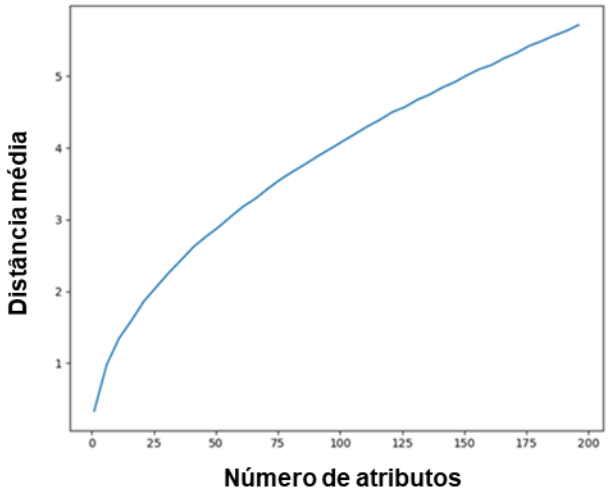

Quanto maior o número de atributos, maior a quantidade de amostras necessárias para um agrupamento robusto!

Esse aumento pode tornar impraticável o uso do classificador baseado no vizinho mais próximo!

Atividade Prática

Atividade Prática

- Faça o download do arquivo “Lab01” disponibilizado em nossa página no moodle.

- **Sugestão:** usar o GoogleColab (https://colab.research.google.com/) para o desenvolvimento e execução dos códigos em python;
- Outras alternativas: Pycharm, Jupyter, Spyder, Visual Studio Code, etc.