UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

IA PARA ENGENHEIROS
UFRGS

Curso de Especialização

Inteligência Artificial para Engenheiros

Disciplina: **Algoritmos para Agrupamento de Dados**

Aula: **Agrupamento Hierárquico**

Professor: **Maurício Cagliari Tosin**

2026

Agrupamento Hierárquico: Classificação Não-Supervisionada

Análise do Agrupamento Hierárquico

- É um algoritmo de aprendizado de máquina não supervisionado que agrupa dados em uma árvore de clusters aninhados;
- Ele opera unindo ou separando clusters com base na similaridade;
- Diferentemente dos métodos baseados em protóripo (agrupamento de particionamento), métodos hierárquicos não criam clusters isolados;
- Apresenta os agrupamentos na forma de um dendrograma.

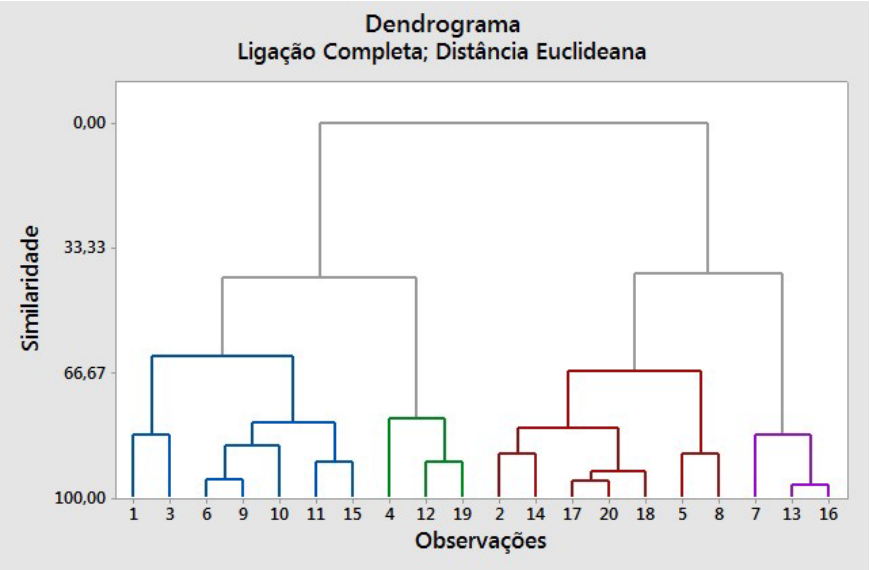

Análise do Agrupamento Hierárquico

- **Exemplo 01:** Realizar o agrupamento de 8 dados amostrais $\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$.

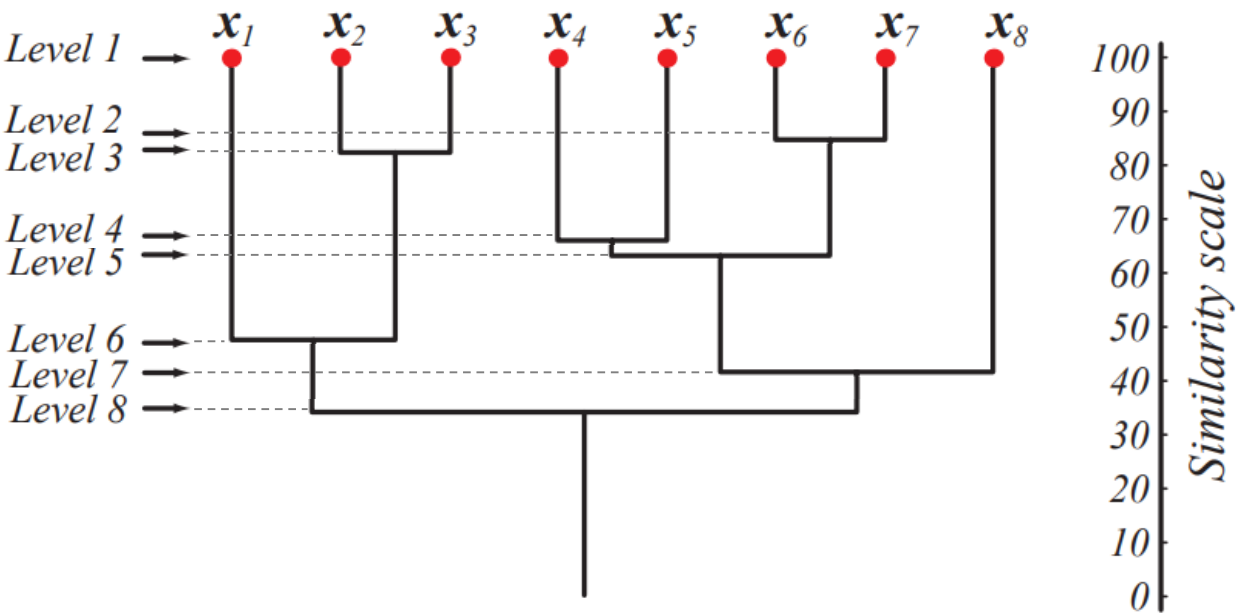

Análise do Agrupamento Hierárquico

- **Outras formas de visualização dos agrupamentos:**

Dendrograma

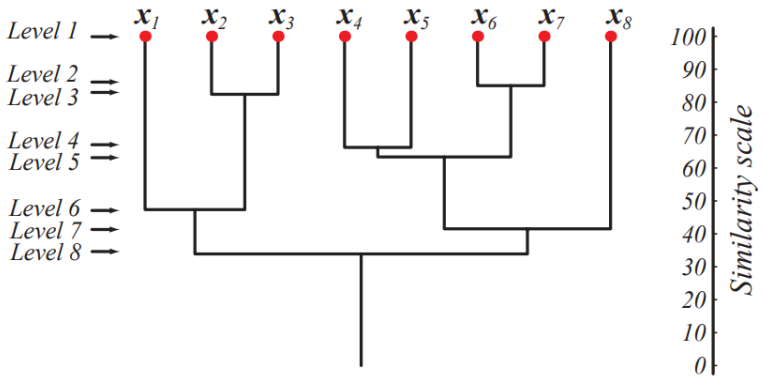

Diagrama de Venn

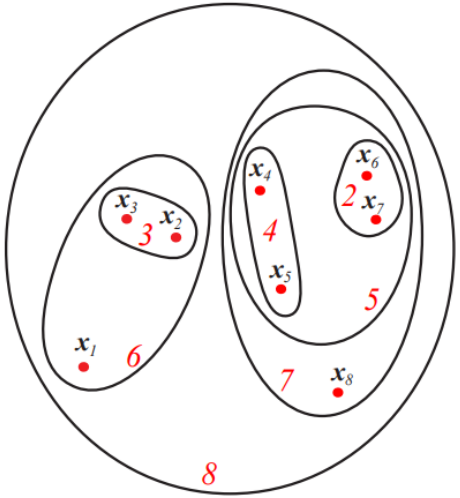

Textual

$$\left\{\{x_1, \{x_2, x_3\}\}, \left\{\{\{x_4, x_5\}, \{x_6, x_7\}\}, x_8\right\}\right\}$$

Análise do Agrupamento Hierárquico

Agrupamento Aglomerativo:

- Inicialmente cada dado individual é seu próprio cluster (uma folha). Em seguida, os clusters mais similares são sucessivamente misturados até a formação de clusters maiores (uma raiz).

Agrupamento Divisivo:

- Inicia com a raiz em que todos os dados são incluídos em um cluster. Então os clusters mais heterogêneos são sucessivamente divididos até que todas os dados tenham um cluster próprio.

Pseudocódigo do Método Aglomerativo

1.
Especificar o número de *clusters* (*k*) a serem criados

2.
Inicializar $\hat{c}$ igual ao número de dados e o conjunto de *clusters* $D_i,\ i = 1,2,\ldots,n$

3.
Faça $\hat{c} = \hat{c} - 1$
    Encontre os dois clusters mais próximos, D_i e D_j
    Mescle D_i e D_j
Até que o número de *clusters* seja igual a *k*

- Ao invés dos métodos baseados em particionamento, aqui os clusters são representados por um conjunto de pontos e não por vetores (centroide ou medoid);
- Se prosseguirmos o algoritmo até $c = 1$, teremos o dendograma similar ao do exemplo 01;
- A cada nível, a distância entre os *clusters* mais próximos pode fornecer o valor de dissimilaridade para esse nível.

Pseudocódigo do Método Divisivo

1.
Especificar o número de *clusters* (*k*) a serem criados

2.
Inicializar $\hat{c}$ igual a 1

3.
Faça $\hat{c} = \hat{c} + 1$
    Divida o grupo que produz os dois componentes com a maior distância inter-cluster
Até que o número de *clusters* seja igual a *k*

- Ao invés dos métodos baseados em particionamento, aqui os clusters são representados por um conjunto de pontos e não por vetores (centroide ou medoid);
- Se prosseguirmos o algoritmo até $c = n$, teremos o dendograma similar ao do exemplo 01;
- A cada nível, a distância entre os *clusters* mais próximos pode fornecer o valor de dissimilaridade para esse nível.

Método Aglomerativo – Medidas de Distância

- Distância mínima ($d_{mín}$):

$$d_{mín}(D_i, D_j) = \min_{x \in D_i,\, x' \in D_j} \|x - x'\|$$

- Distância máxima ($d_{máx}$):

$$d_{máx}(D_i, D_j) = \max_{x \in D_i,\, x' \in D_j} \|x - x'\|$$

- Distância média (d_{med}):

$$d_{med}(D_i, D_j) = \frac{1}{n_i n_j} \sum_{x \in D_i} \sum_{x' \in D_j} \|x - x'\|$$

Método Aglomerativo – Medidas de Distância

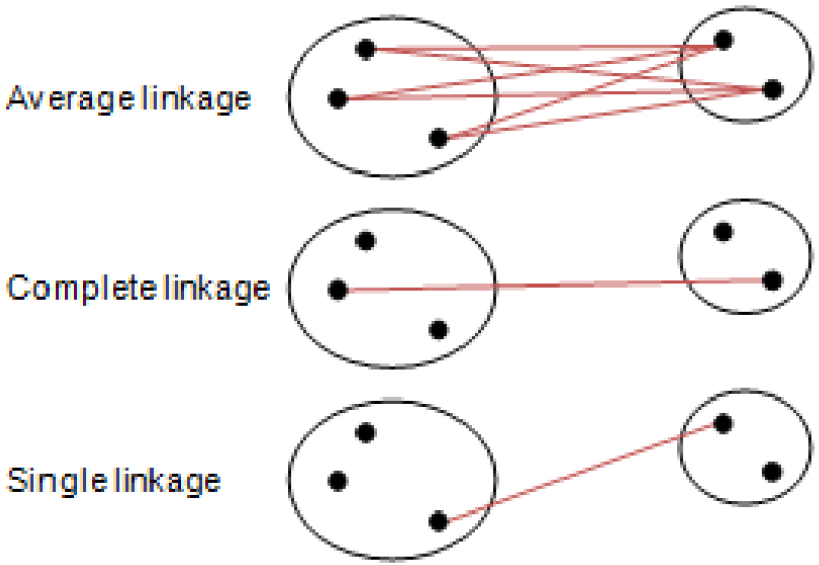

$$d_{med}(D_i, D_j) = \frac{1}{n_i n_j} \sum_{x \in D_i} \sum_{x' \in D_j} \|x - x'\|$$

$$d_{máx}(D_i, D_j) = \max_{x \in D_i,\, x' \in D_j} \|x - x'\|$$

$$d_{mín}(D_i, D_j) = \min_{x \in D_i,\, x' \in D_j} \|x - x'\|$$

Algoritmo *single linkage* ou Vizinho Mais Próximo

- Exemplo 02: Encontre o dendrograma para o conjunto de dados abaixo, utilizando o algoritmo do vizinho mais próximo:

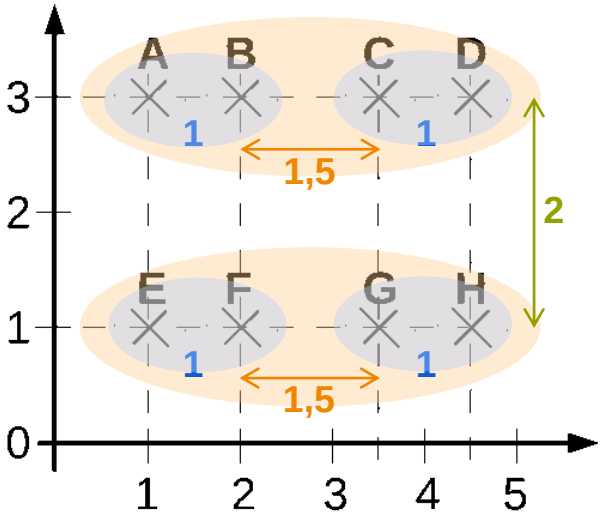

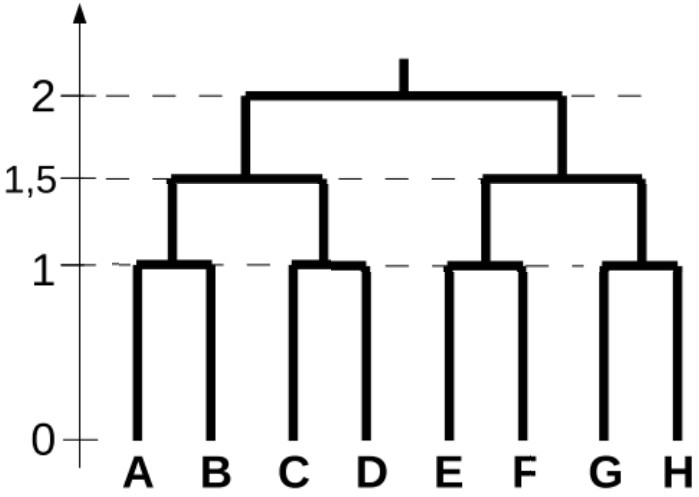

Algoritmo *complete linkage* ou Vizinho Mais Distante

- Exemplo 03: Encontre o dendrograma para o conjunto de dados abaixo, utilizando o algoritmo do vizinho mais distante:

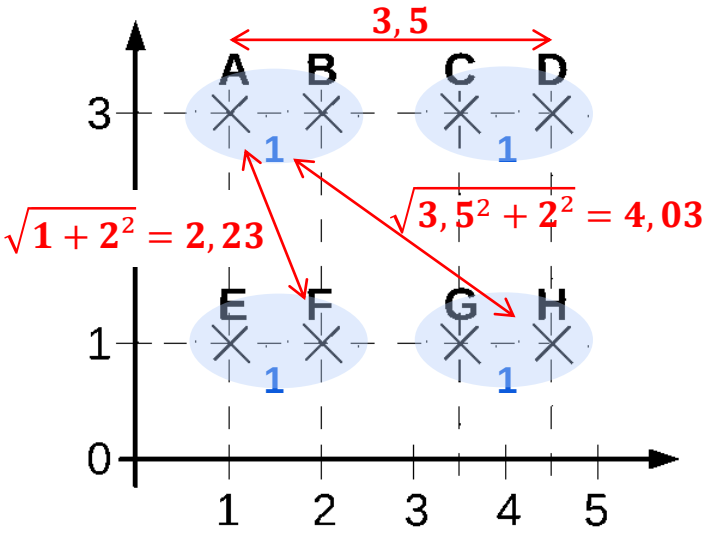

Algoritmo *complete linkage* ou Vizinho Mais Distante

- Exemplo 03: Encontre o dendrograma para o conjunto de dados abaixo, utilizando o algoritmo do vizinho mais distante:

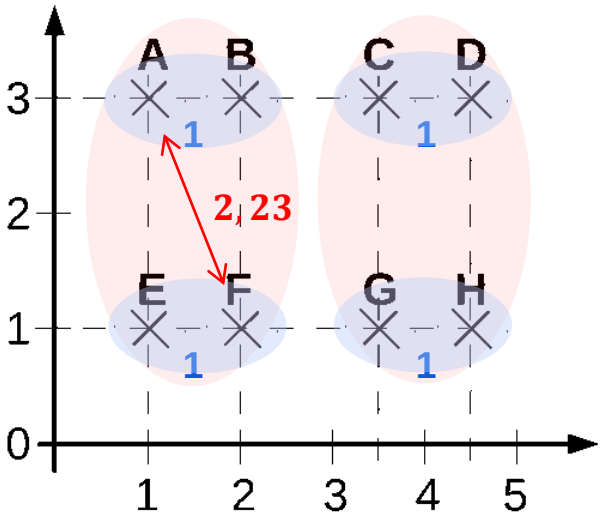

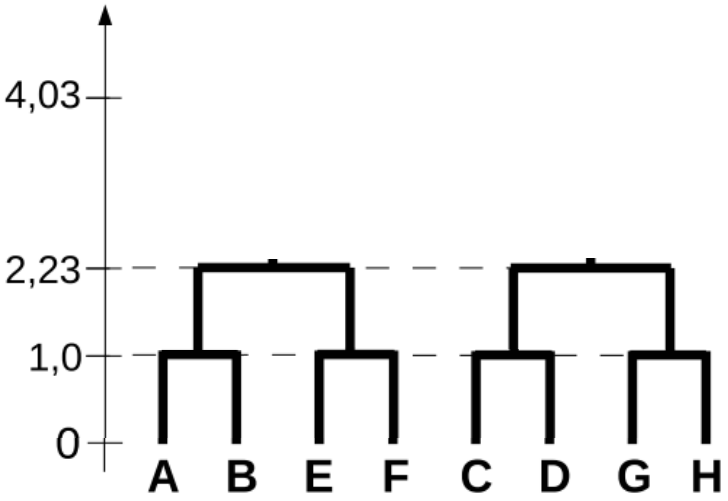

Algoritmo *complete linkage* ou Vizinho Mais Distante

- Exemplo 03: Encontre o dendrograma para o conjunto de dados abaixo, utilizando o algoritmo do vizinho mais distante:

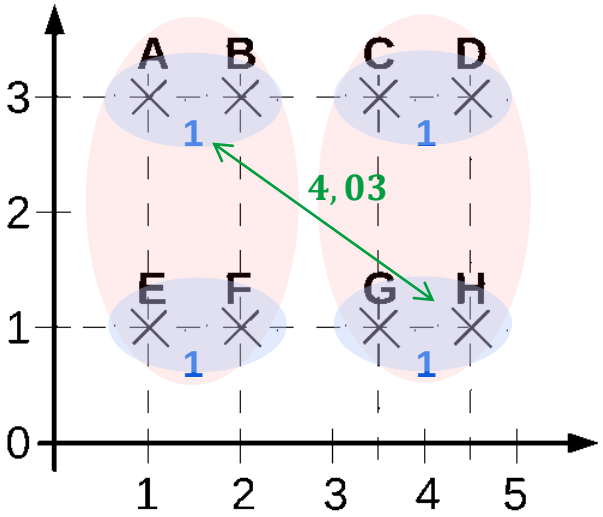

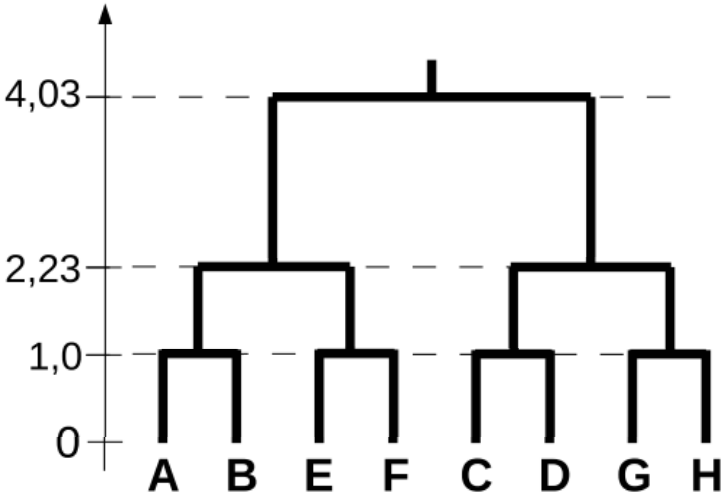

Algoritmo *single linkage* ou Vizinho Mais Próximo

- Exemplo 04:

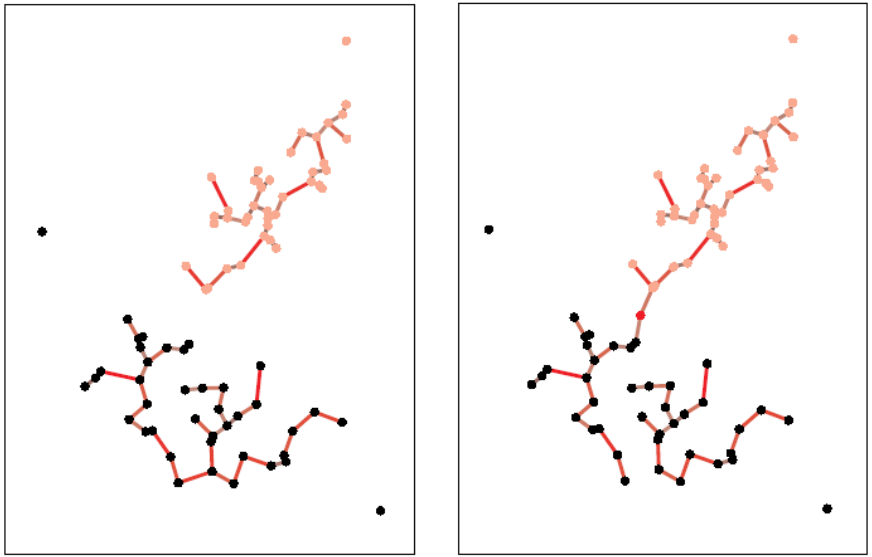

- Essa métrica não lida bem com bases ruidosas, visto que pequenas mudanças na posição dos pontos de dados acarreta em significativas mudanças nos resultados.

Algoritmo *complete linkage* ou Vizinho Mais Distante

- Exemplo 05:

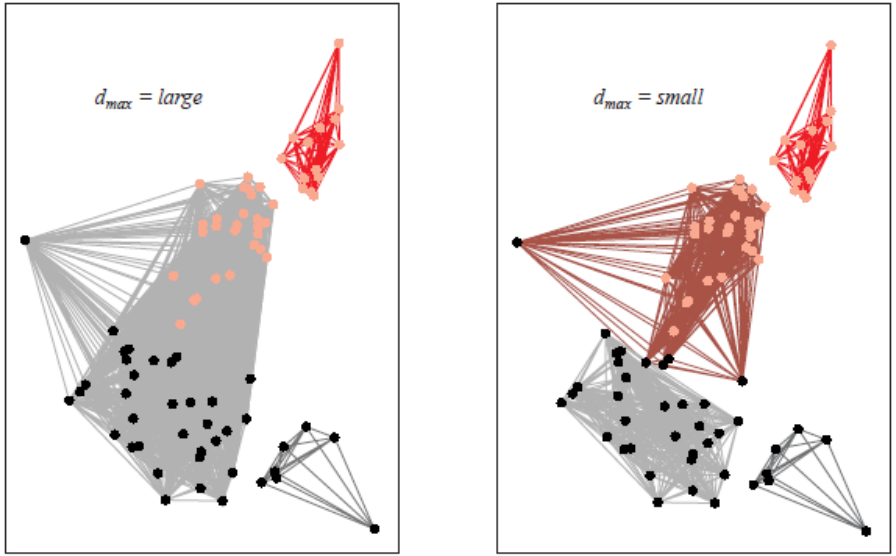

- Essa métrica desencoraja o crescimento de *clusters* alongados;
- Métrica recomendada quando os agrupamentos verdadeiros são compactos e têm tamanhos aproximadamente iguais.

Algoritmo *average linkage*

- Método que define a distância entre clusters como a distância média de todas as observações.

$$d_{med}(D_i, D_j) = \frac{1}{n_i n_j} \sum_{x \in D_i} \sum_{x' \in D_j} \|x - x'\|$$

- É a distância média entre pares de observações, onde um dado é de um cluster e o outro dado é de outro cluster.
- Este método tente a combinar clusters que tem pequena variância e também tende a produzir clusters com aproximadamente igual variância.
- Estratégia interessante para amenizar os problemas com dados esparsos e *outliers.*

Algoritmo de Ward

- Também denominado método da mínima variância.
- A cada passo, encontra-se o par de clusters que leva ao menor aumento na variância total dentro do cluster após a fusão.

$$d_{ward}(D_i, D_j) = SST_{D_i,D_j} - \left(SS_{D_i} + SS_{D_j}\right) = \frac{n_i n_j}{n_i + n_j} d^2_{D_i D_j}$$

$SS_{D_i(D_j)}$ → soma dos erros quadrados dentro do cluster $D_i(D_j)$
$SST_{D_i D_j}$ → soma total dos erros quadrados (agrupando os clusters D_i, D_j)
$d_{D_i D_j}$ → distância entre os centroides de D_i, D_j

Algoritmo de Ward

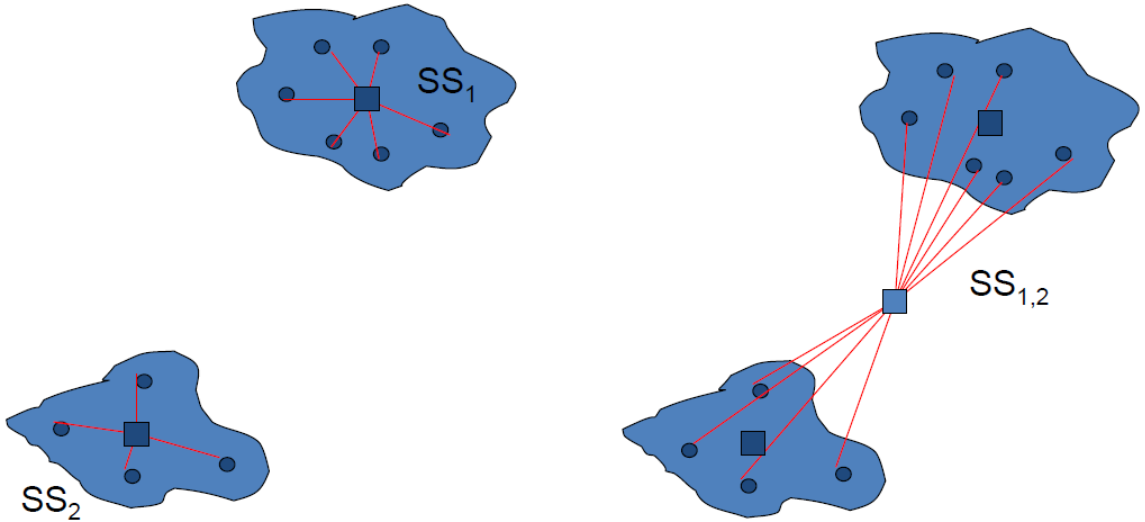

$$d_{ward}(D_i, D_j) = SST_{D_i,D_j} - \left(SS_{D_i} + SS_{D_j}\right)$$

Estimativa do Número Ótimo de Clusters e o Dendrograma

Regra do cotovelo

- Método desenvolvido por Mojena (1977) como uma maneira de determinar o número de grupos no agrupamento hierárquico;
- Utiliza tamanhos relativos de diferentes níveis de fusão;
- Considere os seguintes níveis de fusão: $\alpha_0, \alpha_1, \dots, \alpha_{n-1}$ correspondente aos estágios da hierarquia com $n, (n-1), \dots, 1$ clusters. Podemos indicar a média e o desvio padrão dos j níveis de fusão prévios por:

$$\bar{\boldsymbol{\alpha}} \quad \text{e} \quad \boldsymbol{S_\alpha}$$

- Para aplicar esta regra, estimamos o número de grupos como o primeiro nível em que temos:

$$\boldsymbol{\alpha_{j+1}} > \bar{\boldsymbol{\alpha}} + \boldsymbol{c S_\alpha}$$

c é uma constante

- Mojena sugeriu um valor de c entre 2.75 e 3.50, porém Milligan e Cooper em 1985 sugeriram um valor de 1.25 baseado em seus estudos relacionados a simulação de dados.

Regra do cotovelo

- Podemos também plotar esses valores abaixo em função de *j clusters*:

$$\frac{(\alpha_{j+1} - \bar{\alpha})}{S_\alpha}$$

- Uma quebra no gráfico é uma indicação do número de *clusters.*
- **Objetivo:** Se as distâncias de fusão aumentam drasticamente de um estágio para o outro, isso indica que dois grupos muito distintos foram unidos, o que sugere que o corte deve ser feito logo abaixo dessa união.

Agrupamento de Dados por Métodos Hierárquicos

Observações:

- Não existe uma resposta definitiva para essa questão;
- Muitas vezes essa escolha é subjetiva:
  - depende da métrica de medição de similaridade;
  - depende dos parâmetros usados para o particionamento dos dados;
- Solução subjetiva popular:

Inspeção do Dendograma para verificar um número particular de clusters

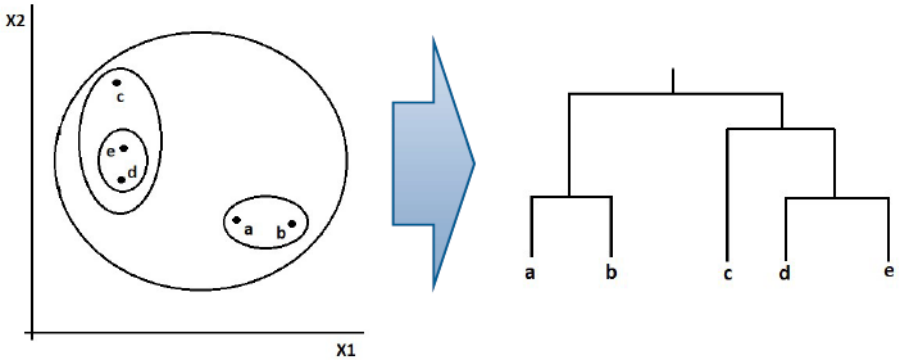

Atividade Prática

Atividade Prática

- Faça o download do arquivo “Lab03” disponibilizado em nossa página no moodle.

- **Sugestão:** usar o GoogleColab (https://colab.research.google.com/) para o desenvolvimento e execução dos códigos em python;
- Outras alternativas: Pycharm, Jupyter, Spyder, Visual Studio Code, etc.