UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

IA PARA ENGENHEIROS
UFRGS

Curso de Especialização

Inteligência Artificial para Engenheiros

Disciplina: **Algoritmos para Agrupamento de Dados**

Aula: **Métodos Baseados em Densidade: DBSCAN e HDSCAN**

Professor: **Maurício Cagliari Tosin**

2026

Agrupamento Baseado em Densidade: DBSCAN

Análise do Agrupamento por Densidade - DBSCAN

- Density-based spatial clustering of applications with noise (DBSCAN) é um algoritmo de clusterização baseado em densidade proposto por Ester et al. 1996;
- Considera agrupamentos como áreas de alta densidade separadas por áreas de baixa densidade;
- Cria agrupamentos de qualquer formato;
- Não requer a definição a priori do número de clusters;
- Possui dois parâmetros a ser especificados:
  - Número mínimo de dados ($Núm_mín$)
  - Raio (ε)
- Densidade é definida como o número de pontos dentro de um raio especificado ε.

Análise do Agrupamento por Densidade - DBSCAN

- Inicia com um dado aleatório não visitado (dado atual) – que pode ser classificado como:
- **Dado Central (DC):**
  - se tem um $Núm_mín$ de amostras vizinhas dentro do raio ε;
- **Dado Limítrofe (DL) ou Vizinho:**
  - tem um número menor de amostras de que o $Núm_mín$ dentro do ε, mas é vizinho de um DC;
- **Dado considerado um Ruído:**
  - dado que não é um DC nem um DL.

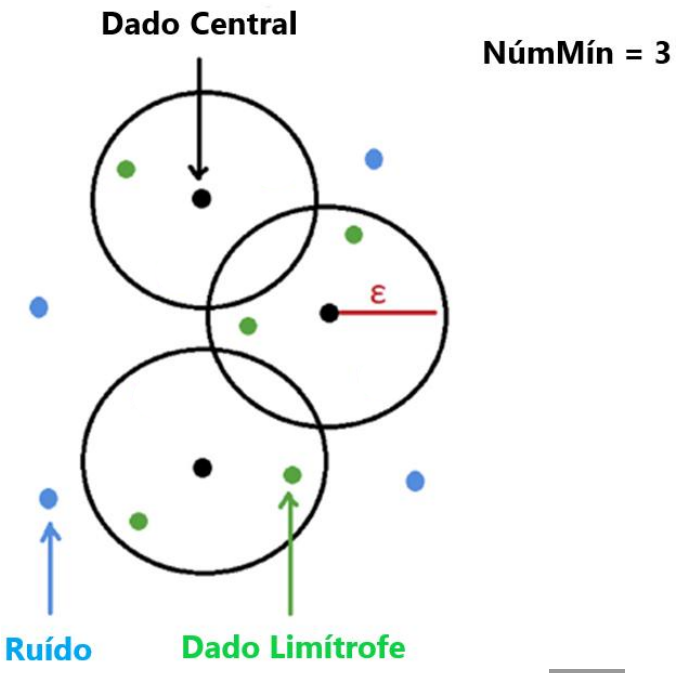

Análise do Agrupamento por Densidade - DBSCAN

Principais Vantagens:

- clusters com formas arbitrárias podem ser detectados;
- muito eficiente para conjuntos de dados muito grandes;
- os dados considerados Ruídos podem ser removidos;
  - logo não serão atribuídos a um cluster como no K-means ou nos métodos aglomerativos;
- não é necessário definir o número de clusters;
- ε e $Núm_mín$ são usados para determinar a densidade desejada;

Porém...

- o desafio é definir esses parâmetros;
- recomenda-se várias iterações para ajustar esses hiperparâmetros;
- diretrizes que alguns autores recomendam:
  - dados 2D: valor padrão de $Núm_mín$ = 4;
  - dados >2D: $Núm_mín$ = 2 * dimensões

Análise do Agrupamento por Densidade - DBSCAN

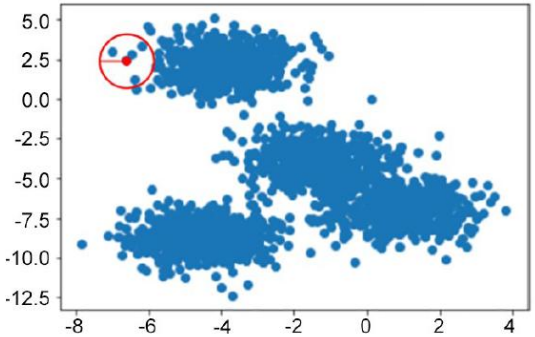

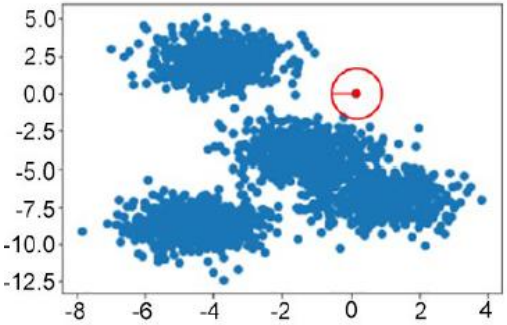

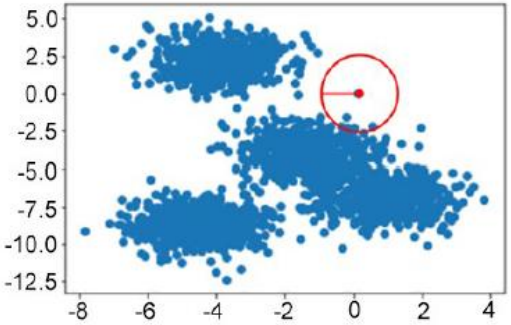

Pseudocódigo do Método DBSCAN

1.
Especificar o valor de $Núm_mín$ e ε

2.
Classificar cada amostra (d) do banco de dados (D) em central, limítrofe ou ruído

3.
Para todo $d \in D$
  Se d for central
    Forme um cluster separado ou anexe-o a um grupo conectado de pontos centrais
  Senão, se d for limítrofe
    Anexe-o ao cluster do seu dado central correspondente

- A atribuição do cluster de um dado limítrofe será ao primeiro cluster correspondente que for considerado pelo algoritmo, caso este esteja próximo a mais de um dado central;
- Assim como nos métodos hierárquicos, aqui os clusters são representados por um conjunto de pontos e não por vetores (centroide ou medoid);

Análise do Agrupamento por Densidade - DBSCAN

- **Exemplo 01:** Considerar o seguinte conjunto de dados no espaço 2D (cada dado será considerado o seu próprio cluster inicialmente): [(1,3)], [(-8,6)], [(-6,4)] , [(4,-2)], [(2,5)], [(-2,0)]:

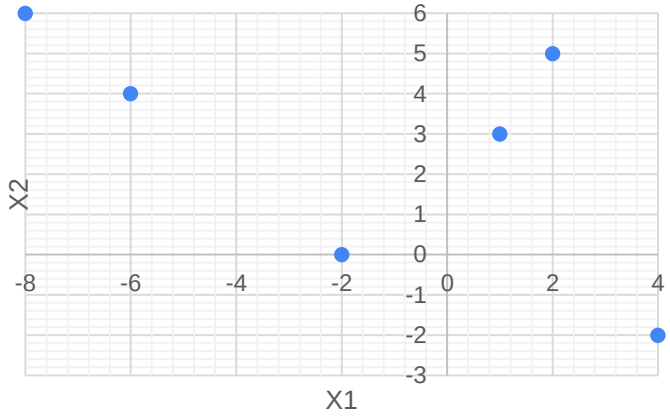

Análise do Agrupamento por Densidade - DBSCAN

Exemplo 01:

- Calculei a Distância Euclidiana pareada entre cada um dos dados:

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

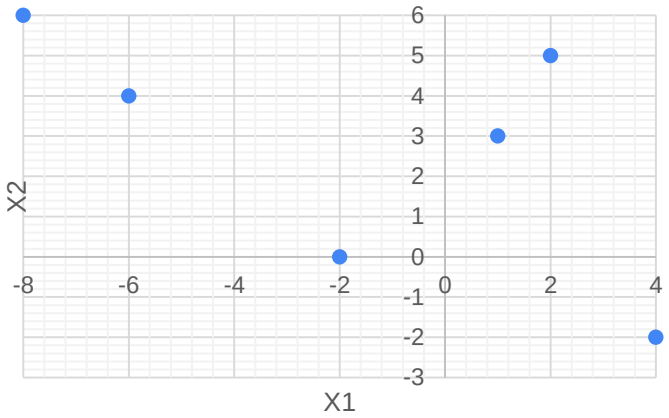

$$d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{(x_{x1} - y_{x1})^2 + (x_{x2} - y_{x2})^2}$$

Análise do Agrupamento por Densidade - DBSCAN

Exemplo 01:

- Obtenção da matriz das distâncias pareadas em python:

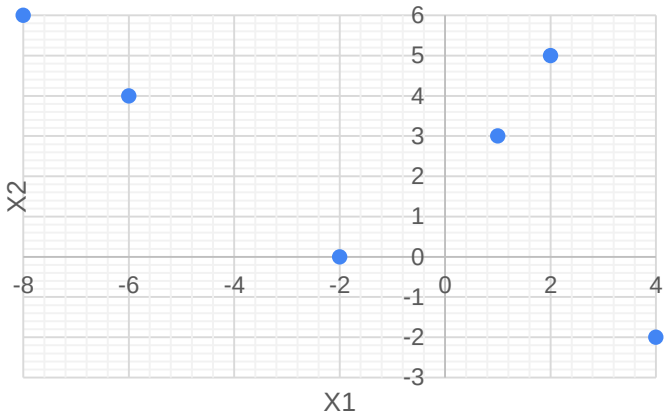


```python
# Importa as bibliotecas necessárias
import pandas as pd

# Gera os dados para o agrupamento
labels = ['ID_0','ID_1','ID_2','ID_3','ID_4','ID_5']
dados = pd.DataFrame({"X":[1,-8,-6,4,2,-2], "Y":[3,6,4,-2,5,0]}, index=labels)

# Encontra a matriz de dissimilaridade ou de distância
from scipy.spatial.distance import pdist, squareform
dist = pdist(dados, metric='euclidean');
row_dist = pd.DataFrame(squareform(pdist(dados, metric='euclidean')),columns=labels, index=labels)
```

- Consultar o código do Lab03Tarefa03

Análise do Agrupamento por Densidade - DBSCAN

- **Exemplo 01:**

- o raio de vizinhança é 5 ($\varepsilon = 5$): 2 dados serão vizinhos se $\varepsilon < 5$ unidades:
- por exemplo, o dado (1,3) tem os dados (2,5) e (-2,0) como vizinhos.

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Análise do DBSCAN

- **Exemplo 01:**

- Próximo passo, classificar cada dado.
- Considerei $Núm_mín = 2$.

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Dado Observado	Vizinhos (ε = 5)	NumMín de vizinhos = 2?	Contém um Dado Central como um vizinho	Classificação
(1, 3)				
(-8, 6)				
(-6, 4)				
(4, -2)				
(2, 5)				
(-2, 0)				

Análise do DBSCAN

- **Exemplo 01:**

➢ Próximo passo, atribuir cada dado não ruidoso a um cluster.

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Dado Observado	Vizinhos (ε = 5)	NumMín de vizinhos = 2?	Contém um Dado Central como um vizinho	Classificação	Agrupamento
(1, 3)	(2, 5), (-2, 0)	Sim	-	Dado Central	Cluster01
(-8, 6)	(-6, 4)	Não	Não	Ruído	Ruído
(-6, 4)	(-8, 6)	Não	Não	Ruído	Ruído
(4, -2)		Não	Não	Ruído	Ruído
(2, 5)	(1, 3)	Não	Sim	Dado de Fronteira	Cluster01
(-2, 0)	(1, 3)	Não	Sim	Dado de Fronteira	Cluster01

Análise do DBSCAN

Exemplo 01:

- Resultado para $\varepsilon = 5$ e $Núm_mín = 2$.
- lembrar que o desempenho do DBSCAN é dependente dos hiperparâmetros;

Qual hiperparâmetro vocês alterariam para uma segunda rodada do método??

Dado Observado	Agrupamento
(1, 3)	Cluster01
(-8, 6)	Ruído
(-6, 4)	Ruído
(4, -2)	Ruído
(2, 5)	Cluster01
(-2, 0)	Cluster01

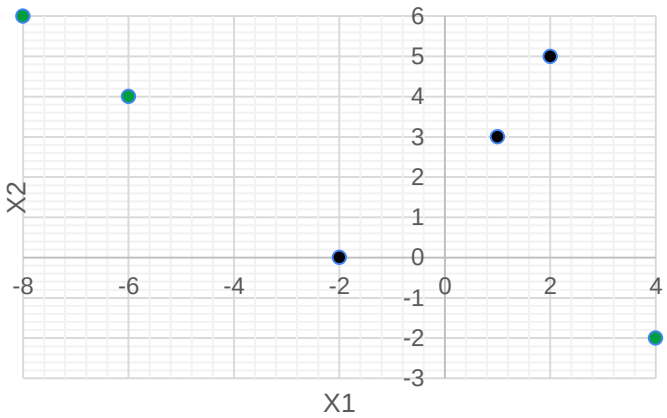

- relembro da necessidade de executar o DBSCAN algumas vezes com diferentes opções para entender como influenciam o desempenho.
- como o DBSCAN não usa o conceito de centróides ele funciona melhor para conjuntos de dados de maior complexidade. Funciona melhor também com bases que possuem outliers e ruído.

Análise do Agrupamento por Densidade - DBSCAN

- **Exemplo 01:**

➢ o raio de vizinhança é 6 ($\varepsilon = 6$): 2 dados serão vizinhos se $\varepsilon < 6$ unidades:

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Análise do DBSCAN

- **Exemplo 01:**

➢ Próximo passo, classificar cada dado.

➢ Considerei $Núm_mín = 2$.

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Dado Observado	Vizinhos (ε = 6)	NumMín de vizinhos = 2?	Contém um Dado Central como um vizinho	Classificação
(1, 3)				
(-8, 6)				
(-6, 4)				
(4, -2)				
(2, 5)				
(-2, 0)				

Análise do DBSCAN

- **Exemplo 01:**

➢ Próximo passo, atribuir cada dado não ruidoso a um cluster.

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Dado Observado	Vizinhos (ε = 6)	NumMín de vizinhos = 2?	Contém um Dado Central como um vizinho	Classificação	Agrupamento
(1, 3)	(2, 5), (-2, 0), (4, -2)	Sim	-	Dado Central	Cluster01
(-8, 6)	(-6, 4)	Não	Não	Dado de Fronteira	Cluster01
(-6, 4)	(-8, 6), (-2, 0)	Sim	Sim	Dado Central	Cluster01
(4, -2)	(1, 3)	Não	Sim	Dado de Fronteira	Cluster01
(2, 5)	(1, 3)	Não	Sim	Dado de Fronteira	Cluster01
(-2, 0)	(1, 3), (-6, 4)	Sim	Sim	Dado Central	Cluster01

Análise do Agrupamento por Densidade – DBSCAN*

- O algoritmo DBSCAN não é determinístico no que compete aos dados limítrofes;
- Em relação aos dados centrais e ruidosos, sim;
- Campello et al. (2013) propuseram o algoritmo DBSCAN*;
- DBSCAN*:
  - Não existe mais dados limítrofes;
  - Estes são assinalados como ruídos;
  - Clusters são formados por dados centrais que estão na vizinhança um do outro.

Justificativa: baseia-se na interpretação estatística de clusters como componentes conectados de um conjunto a um certo nível de densidade. Uma vez que os objetos de borda não pertencem tecnicamente a este conjunto de nível (sua densidade estimada está abaixo do limiar) eles não devem ser anexados ao cluster.

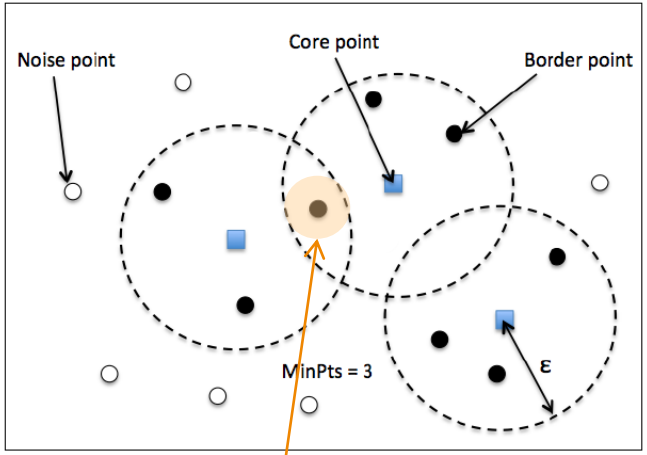

A que cluster este dado pertence?

Pseudocódigo do Método DBSCAN*

1.
Especificar o valor de $Núm_mín$ e ε

2.
Classificar cada amostra (d) do banco de dados (D) em central ou ruído

3.
Para todo $d \in D$
    Se d for central
        Forme um cluster separado ou anexe-o a um grupo conectado de pontos centrais

- Método prioriza a formação de clusters mais densos;
- Pode considerar grande quantidade de dados como ruído;
- Assim como nos métodos hierárquicos, aqui os clusters são representados por um conjunto de pontos e não por vetores (centroide ou medoid).

Agrupamento Baseado em Densidade: HDBSCAN

Análise do Agrupamento por Densidade - HDBSCAN

- Hierarchical Density-Based Spatial Clustering of Applications with Noise (DBSCAN) é uma extensão do DBSCAN proposto por Campello et al. 2013;
- O DBSCAN assume que o critério de agrupamento (ou seja, o requisito de densidade) é globalmente homogêneo;
- Dificulta o reconhecimento de agrupamentos com densidades diferentes;
- O HDBSCAN atenua essa suposição e explora todas as escalas de densidade possíveis;
- Possui apenas um parâmetro a ser especificado:
  - Número mínimo de dados ($Núm_mín$)
- Diferentes valores de ε são considerados gerando diferentes níveis de densidade hierárquicos;
- O HDBSCAN explora todas as escalas de densidade possíveis.

Sugestão de leitura: Campello, R; et al. ***Density-Based Clustering Based on Hierarchical Density Estimates****, 2013*

Análise do Agrupamento por Densidade - HDBSCAN

- **Distância Central – $\boldsymbol{d_{central}(x_p)}$:** a distância central de um dado x_p (considerando $Núm_mín = k$) é a distância de x_p para o $k_{ésimo}$ vizinho mais próximo;
- **Dado ε-Central:** um dado é considerado ε-Central quando $d_{central}(x_p) \leq \varepsilon$, para um dado valor de ε;
- **Distância de Acessibilidade Mútua – $\boldsymbol{d_{mútua}(x_p, x_q)}$:** a distância de acessibilidade mútua entre dois pontos x_p e x_q é definida por:

$$\boldsymbol{d_{mútua}(x_p, x_q) = \max\{d_{central}(x_p), d_{central}(x_q), d(x_p, x_q)\}}$$

- **Grafo de Acessibilidade Mútua:** é um grafo completo onde os dados são os vértices e o peso de cada aresta é a distância de acessibilidade mútua do respectivo par $\boldsymbol{d_{mútua}(x_p, x_q)}$.

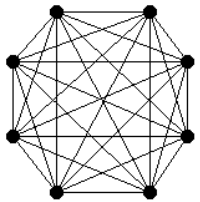

HDBSCAN – Procedimento

- **Exemplo 02:** aplicar o HDSCAN para agrupar os dados abaixo.

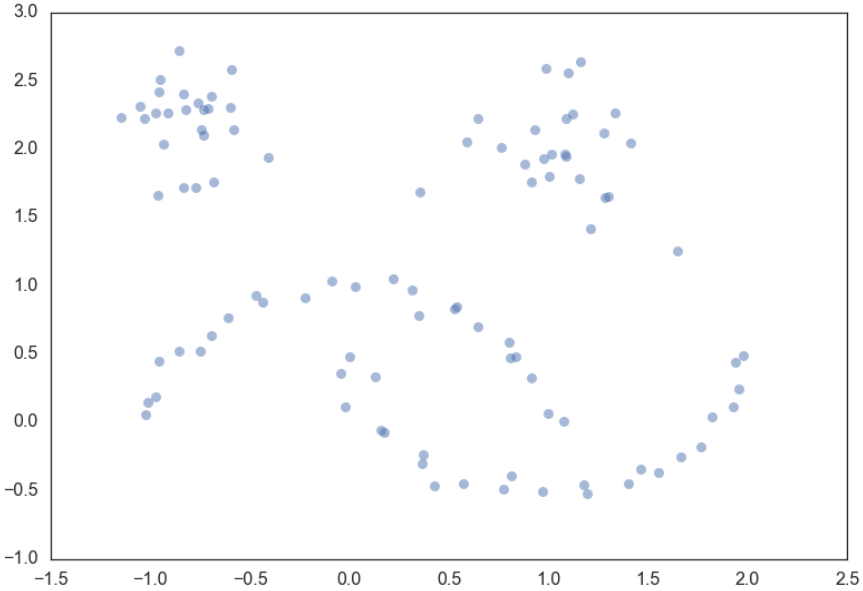

HDBSCAN – Procedimento

- **Passo 01:** obter a matriz de distância de acessibilidade mútua entre os dados;

$$Núm_mín = 5$$

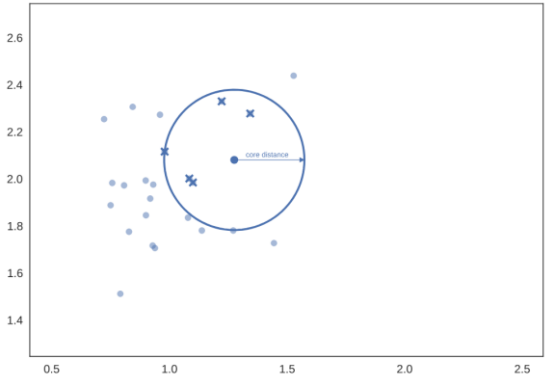

Distância Central – x_p

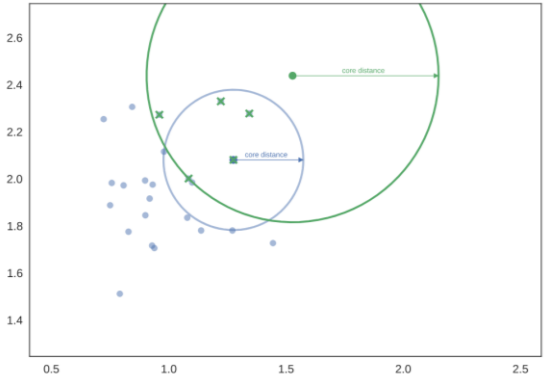

Distância Central – x_q

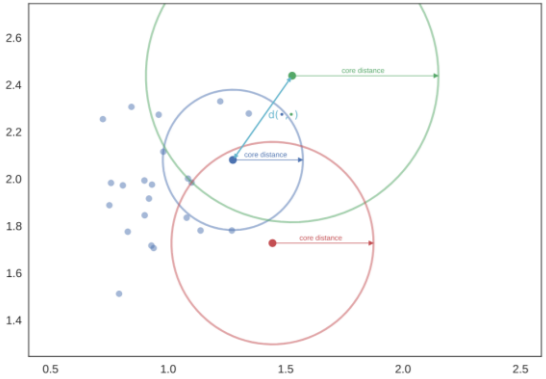

Distância de Acessibilidade Mútua

$$\boldsymbol{d_{mútua}(x_p, x_q) = \max\{d_{central}(x_p), d_{central}(x_q), d(x_p, x_q)\}}$$

HDBSCAN – Procedimento

- **Passo 02:** a partir do Grafo de Acessibilidade Mútua, obter a Árvore Geradora Mínima (é um subgrafo de um grafo conexo e ponderado que conecta todos os vértices com o menor peso total possível de arestas, sem formar ciclos);
  - Equivalente à aplicação do método hierárquico *Single Linkage* considerando a distância de acessibilidade mútua.

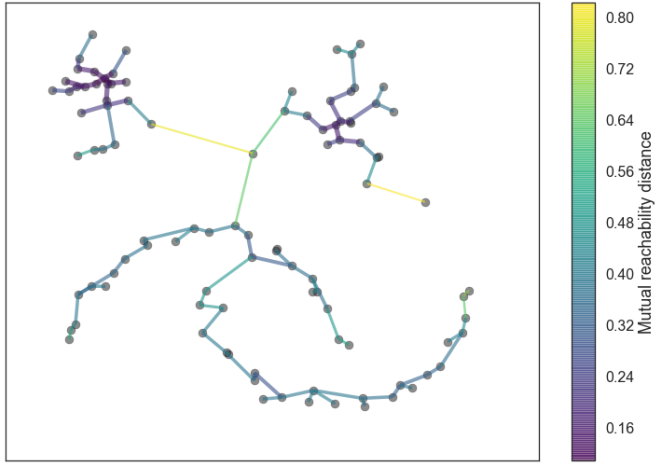

HDBSCAN – Procedimento

- **Passo 03:** a partir da a árvore geradora mínima, realizar a hierarquia de componentes conectados (geração do dendrograma – *Single Linkage*);

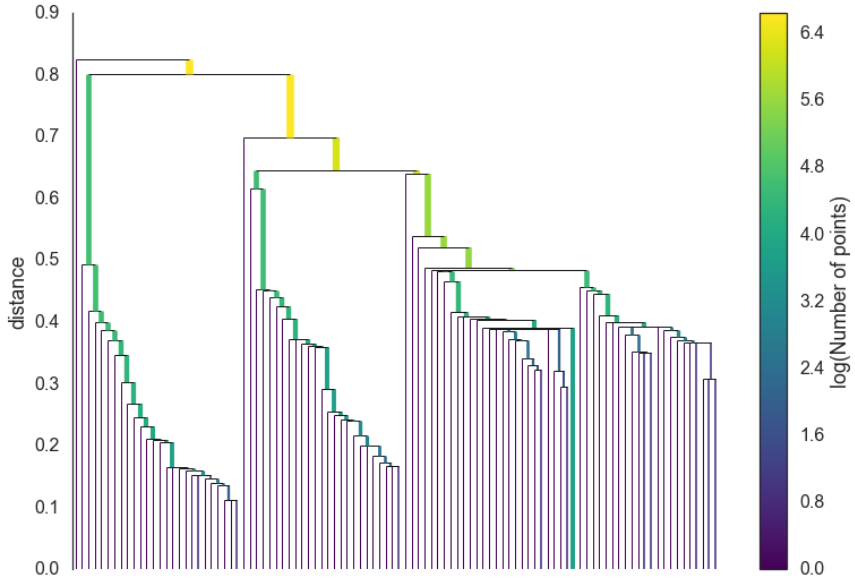

HDBSCAN – Procedimento

- **Passo 04 – Condensação do dendrograma:** uma divisão só será realizada se os custers resultantes tiverem mais dados do que um determinado valor mínimo;

➢ Surge um novo hiperparâmetro:

$$\boldsymbol{MinClusterSize}$$

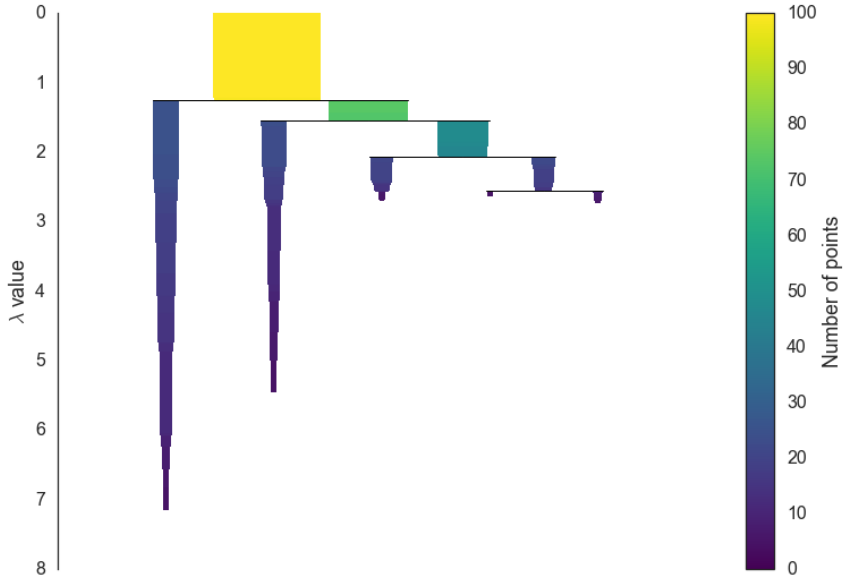

HDBSCAN – Procedimento

- **Passo 05 – Extração dos clusters:** retém clusters mais estáveis.

➢ Definição de estabilidade:

$$\boldsymbol{Estabilidade} = \sum_{x_p \in cluster} \left(\lambda_{x_p} - \lambda_{início}\right)$$

$$\lambda = \frac{1}{dist}$$

λ_p → valor de λ no ponto onde o dado saiu do cluster

$\lambda_{início}$ → valor de λ no ponto onde o cluster surgiu

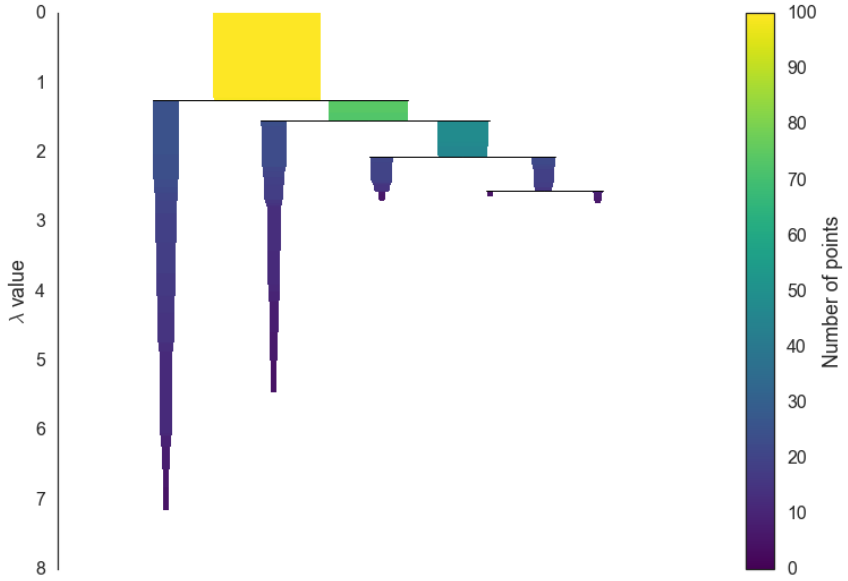

HDBSCAN – Procedimento

- **Passo 05 – Extração dos clusters:** retém clusters mais estáveis.

➢ Definição de estabilidade:

$$\boldsymbol{Estabilidade} = \sum_{x_p \in cluster} \left(\lambda_{x_p} - \lambda_{início}\right)$$

➢ Se a soma das estabilidades dos clusters filhos for maior que a estabilidade do cluster, definimos a estabilidade do cluster como a soma das estabilidades dos filhos;

➢ Se, por outro lado, a estabilidade do cluster for maior que a soma das estabilidades de seus filhos, declaramos o cluster como um cluster selecionado e desmarcamos todos os seus descendentes.

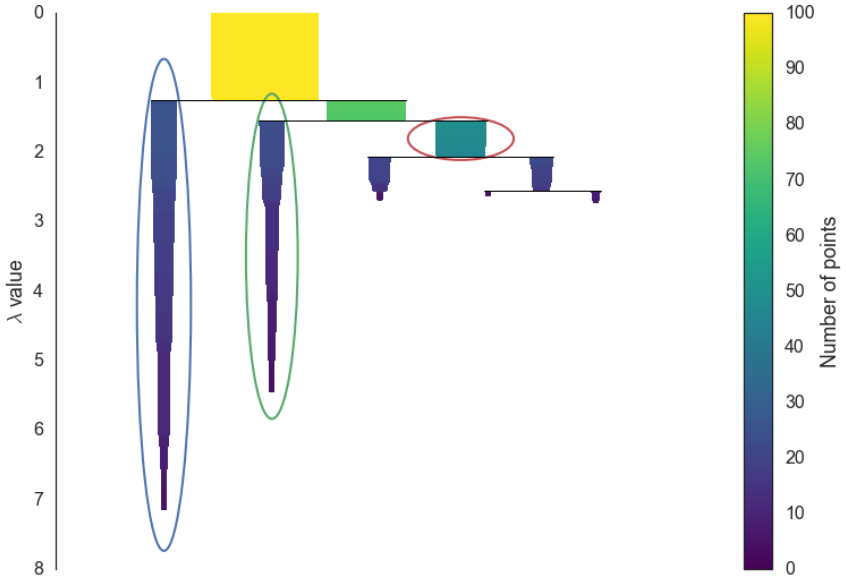

HDBSCAN – Procedimento

- **Exemplo 02:** aplicar o HDSCAN para agrupar os dados abaixo.

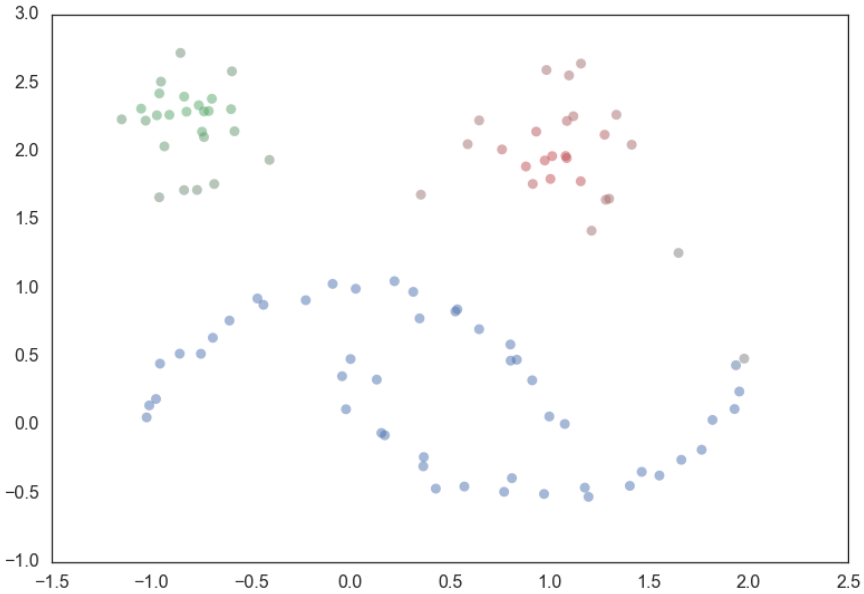

Atividade Prática

Atividade Prática

- Faça o download do arquivo “Lab04” disponibilizado em nossa página no moodle.

- **Sugestão:** usar o GoogleColab (https://colab.research.google.com/) para o desenvolvimento e execução dos códigos em python;
- Outras alternativas: Pycharm, Jupyter, Spyder, Visual Studio Code, etc.