LAB04

Clusters com os Algoritmos DBSCAN e HDBSCAN

UFRGS, © Tosin, Maurício; Balbinot, Alexandre

Objetivos

Implementar algoritmos baseados em densidade para agrupamento de dados. Aprofundar conhecimentos essenciais para trabalhar com bases de dados de maior porte. Exercitar o uso de bibliotecas em Python na área de aprendizagem de máquina com aplicações e foco em agrupamento de dados.

Conceitos Teóricos Adicionais

Revisar conceitos teóricos e experimentais apresentados nas aulas presenciais.

Datas Importantes

Aula(s) destinada a esta atividade: 10/04.

Data da entrega deste relatório: até as 23:59 de 17/04, via moodle.

Procedimento de Avaliação deste Laboratório:

Será cobrada a entrega do item *iv* na forma de relatório.

Procedimentos

Digitar, executar e avaliar os seguintes códigos:

1.1 Materiais e Ferramentas Computacionais

- 01 Computador adequado
- 01Ambiente adequado para programar em Python

1.2. Desenvolver:

i. *Tarefa em aula*: vamos implementar um agrupamento DBSCAN para comparar com modelos anteriormente estudados nesta disciplina. Métodos de agrupamento de partição, como k-means, e métodos de agrupamento hierárquico, como clustering aglomerativo, são bons para descobrir clusters esféricos ou convexos. Esses algoritmos são mais sensíveis a ruídos ou outliers, sendo assim, funcionam bem para clusters bem separados. Por outro lado, o DBSCAN é baseado na ideia principal de que cada dado de um grupo ou cluster tem um número mínimo de dados em um determinado raio. O principal objetivo do DBSCAN é descobrir a região densa que pode ser calculada usando o número mínimo de dados ($Núm_mín$) e um determinado raio (ε). O algoritmo DBSCAN tem a capacidade de gerar formas aleatórias de clusters e lidar com o ruído de um conjunto de dados. Também, não há necessidade de determinar o número de clusters, como por exemplo, no k-means. Portanto, o algoritmo DBSCAN identifica automaticamente o número de clusters de um conjunto de dados. Nesta tarefa, vamos analisar e rodar o código do arquivo **Lab04Tarefa01** disponibilizado na nossa Comunidade da disciplina no Moodle.

ii. *Tarefa em aula*: vamos implementar o algoritmo DBSCAN usando a biblioteca scikit-learn para avaliar o impacto do tamanho do raio de vizinhança. Nesta tarefa, vamos analisar e rodar o código do arquivo **Lab04Tarefa02** disponibilizado na nossa Comunidade da disciplina no Moodle.

iii. *Tarefa para aula*: vamos comparar o algoritmo DBSCAN com o HDBSCAN em uma base de dados com variação de densidade. Para isso baixar o arquivo **Lab04Tarefa03** disponibilizado na nossa Comunidade da disciplina no Moodle.

iv. *Tarefa para casa*: implemente um código para avaliar o efeito do hiperparâmetro $Núm_mín$ no algoritmo DBSCAN. Para tanto, considere $\varepsilon = 0{,}7$ e os seguintes valores para o referido fator: 5, 10, 19, 20, 25. Utilize o conjunto de dados fornecido no código **Lab04Tarefa04** e complete o mesmo para implementar a tarefa solicitada. Utilize o código da Tarefa02 como referência. A partir dos resultados, conclua sobre o valor mais adequado para o número de vizinhos.

UFRGS, © Tosin, Mauricio; Balbinot, Alexandre