UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Curso de Especialização

Inteligência Artificial para Engenheiros

Análise de Dados e Engenharia de Características

AULA 04A

Lidando e Revisando Problemas Comuns dos Dados

Professor Dr. Alexandre Balbinot

2026

IA PARA ENGENHEIROS
UFRGS

Universidade Federal do Rio Grande do Sul
Escola de Engenharia
Curso de Especialização Inteligência Artificial para Engenheiros
Laboratório de Sistemas Eletrônicos Inteligentes (LASEI)

Análise de Dados e Engenharia de Características

Aula 04A

Lidando e Revisando Problemas Comuns dos Dados

Prof. Dr. Alexandre Balbinot

Contatos

Prof. Dr. Alexandre ***Balbinot***

Curso de Especialização Inteligência Artificial para Engenheiros

Escola de Engenharia – UFRGS

Prédio do Instituto Eletrotécnico

Departamento de Engenharia Elétrica - DELET

Laboratório de Sistemas Eletrônicos Inteligentes (LASEI)

Sala 206D – (51) 3308-**4442**

alexandre.balbinot@ufrgs.br

Direitos Autorais

Este material possui Direitos Autorais e Direitos de Imagem e não pode ser duplicado, reproduzido, no todo ou em parte, sob quaisquer formas ou por quaisquer meios (eletrônicos, mecânico, gravação, fotocópia, distribuição na internet ou outros), sem permissão expressa do autor.

©

Termo de Responsabilidade da Própria UFRGS

Todos os materiais disponibilizados nos Ambientes Virtuais da UFRGS são exclusivamente para usos e fins didáticos, sendo vedada a sua utilização para qualquer outra finalidade, sob as penas legais.

Todos os materiais de terceiros que venham a ser utilizados ou disponibilizados devem ser referenciados, sob as penas legais, inclusive de plágio.

Tenho liberdade de expor ou não a minha imagem e voz nas atividades, o que não me desonera da participação efetiva nas mesmas.

Todas as gravações de atividades síncronas devem ser previamente informadas por parte dos professores.

Os alunos somente poderão gravar, armazenar ou compartilhar atividades mediante concordância prévia do professor, sob as penas legais.

Os alunos somente poderão armazenar ou compartilhar materiais mediante concordância prévia do professor ou se permitido no material, sob as penas legais.

É proibido disponibilizar, por quaisquer meios digitais ou físicos, os dados, a imagem e a voz dos alunos, dos colegas e do professor, sem autorização específica para a finalidade pretendida.

INTRODUÇÃO

Problemas mais Comuns

- características com valores ausentes;
- características com valores redundantes;
- características com valores inconsistentes;
- características com ruídos e/ou valores atípicos (*outliers*);
- desbalanceamento dos dados.

Vamos continuar nossa abordagem experimental revisando e possibilitando a aprendizagem baseada em problemas/projetos.

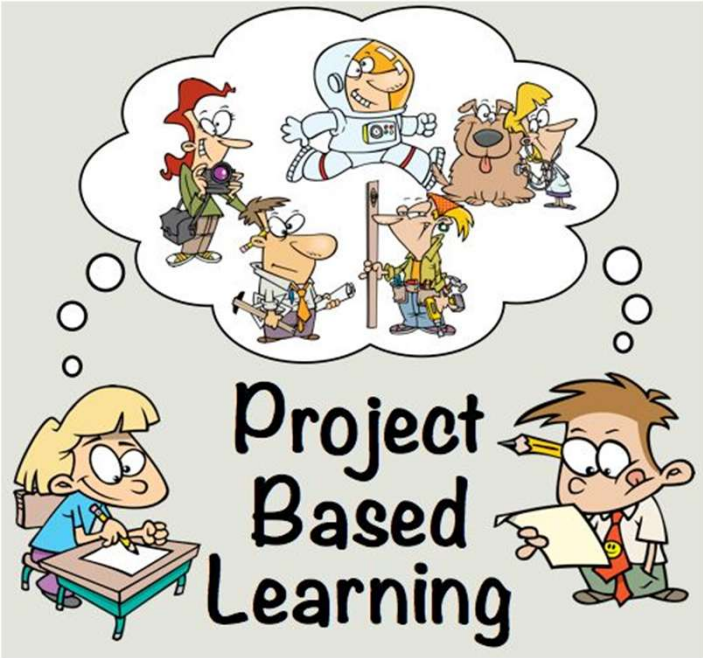

Ausência de Dados

Lidando com Ausência de Dados

Amostra Número	Características				
	A	B	C	D	E
1	40	56	90	56	
2	50	34	76	68	
3	60	39	77	76	34
4	70	45	79	43	
5	34	47	78	41	67
6	46	78	90	55	
7					
8	89	56	78	45	44
9	12	55	78	46	78
10	15	57	89	89	

Exemplo de valores ausentes em um conjunto de dados hipotético.

- **procedimentos mais populares para atuar neste tipo de problema:**
  - **Imputação pela Média**;
  - **Imputação por Regressão**;
  - **Coletar Dados**.

- geralmente a falta de dados é devida aos seguintes mecanismos:
  - **Ausência de Dado Completamente Aleatória (MCAR)**;
  - **Ausência de Dado Aleatória (MAR);**
  - **Ausência de Dado Não Aleatória (mNAR).**

Excesso de Dados

Lidando com Excesso de Dados

Métrica de Correlação			
Correlação	Valor	Característica	Exemplo
Perfeitamente Positiva	1	Uma variável aumenta e a outra também aumenta na mesma proporção	Custo da gasolina por semana para o carro e os litros usados (assumindo que o custo por litro não mude)
Nenhuma	0	Não há nenhuma relação linear entre as variáveis	A temperatura na Itália em comparação com a quantidade de litros de gasolina comprados em Porto Alegre em um determinado dia
Perfeitamente Negativa	-1	Uma variável aumenta, a outra diminui proporcionalmente	Você observa a velocidade de um carro e a distância até o destino

- Coeficiente de Pearson:

$$r_{xy} = \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}}$$

- Coeficiente de Spearman:

$$r_s = 1 - \frac{6\sum d_i^2}{(n^3 - n)}$$

- Coeficiente de Determinação (r^2)

- Coeficiente de Alienação ($1 - r^2$)

Outliers

Identificando e Lidando com *Outliers*

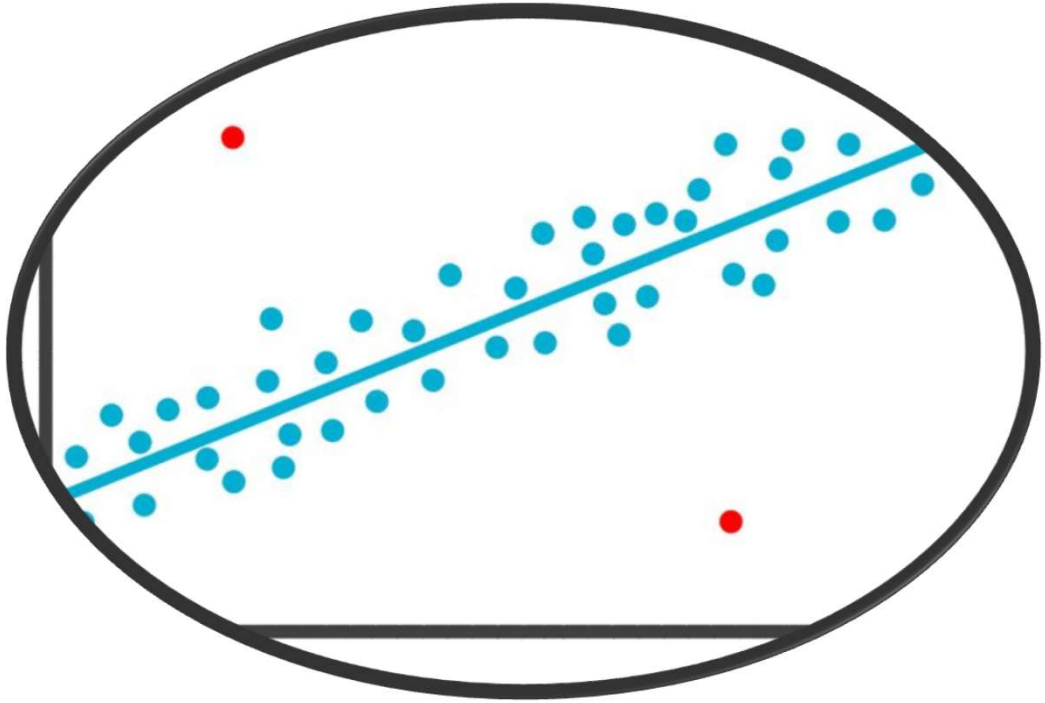

- **após detectar os *outliers* utilizamos um dos três procedimentos:**
  - **exclusão do *outlier***;
  - **determinar um valor limite**;
  - **atribuir um novo valor**;
  - maioria das vezes o número de *outliers* é uma pequena parte dos seus dados, sendo assim, é **melhor optar pela sua exclusão**.

Alguns Algoritmos para Detectar *Outliers*

- alguns algoritmos de interesse para detecção de anomalias:
  - Floresta Isolada;
  - LOF;
  - DBSCAN;
  - etc...

Revisando Modelos Baseados em Árvore

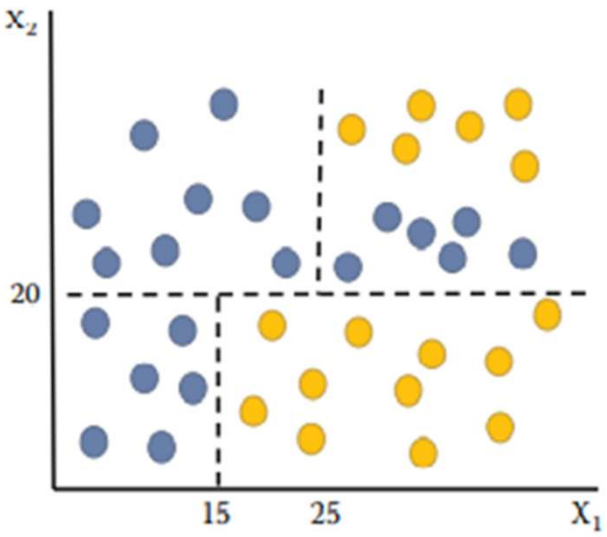

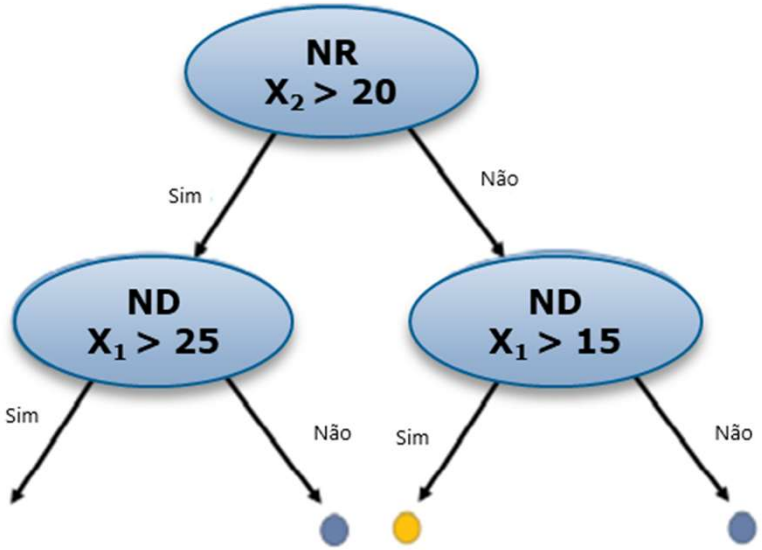

Resumindo o funcionamento da AD

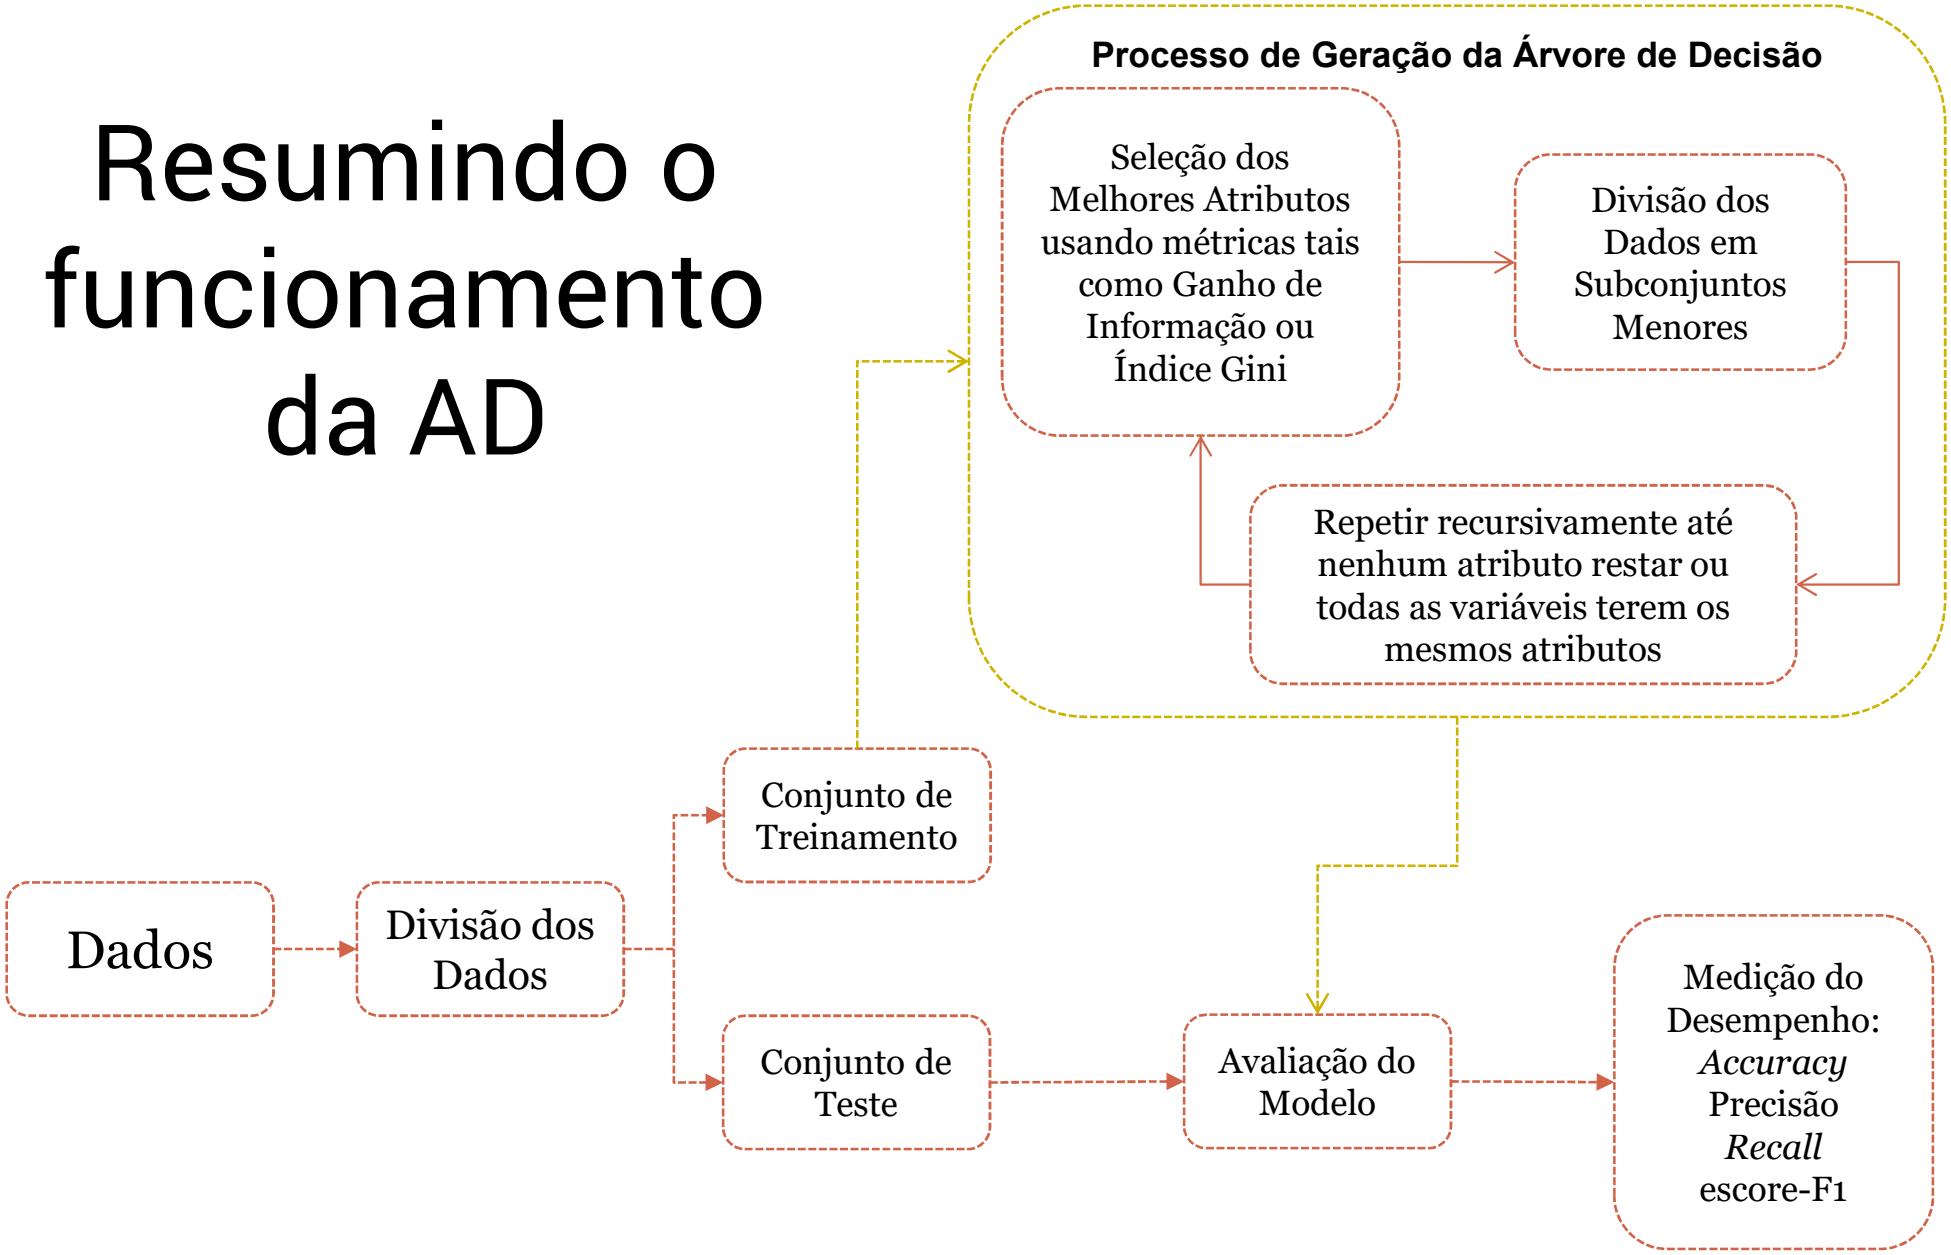

Detector de Outlier: o algoritmo Floresta de Isolamento

- **1º etapa: fase de treinamento**

A ideia deste algoritmo é que as anomalias são mais suscetíveis ao isolamento sob particionamento aleatório

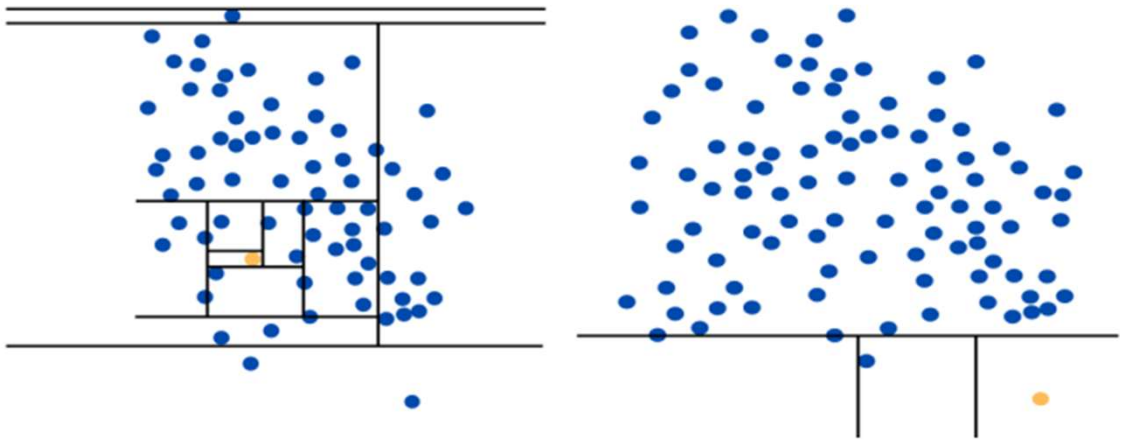

Dificuldade de Isolar uma Amostra Normal

Facilidade de Isolar uma Amostra Anômala

2º etapa: fase de avaliação

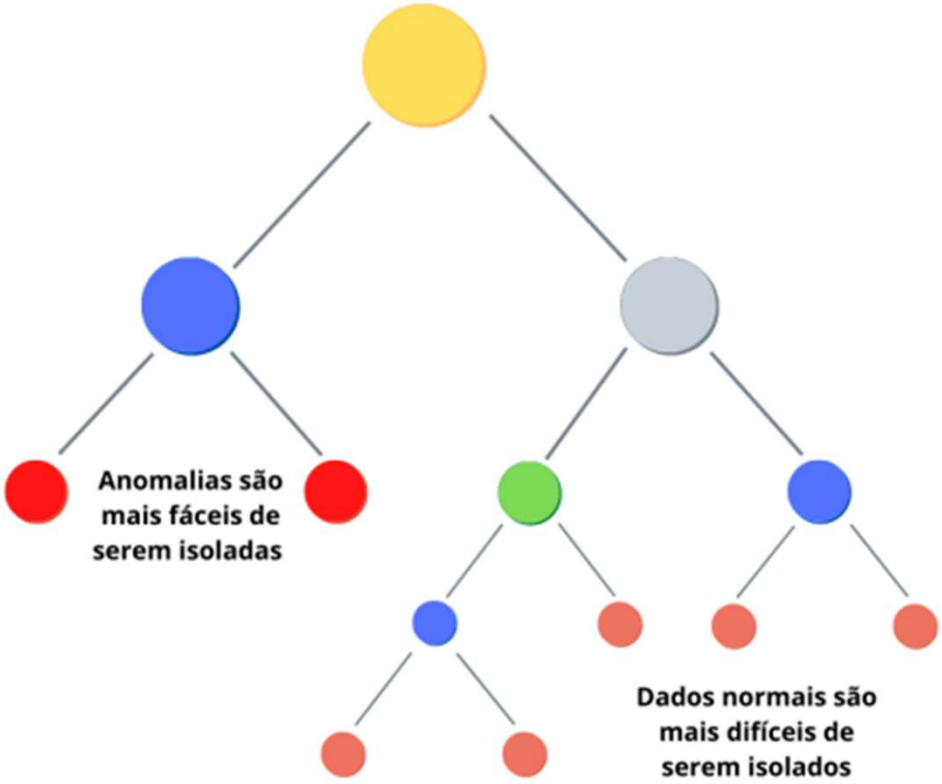

$$s(x,n) = 2^{-\frac{E(h(x))}{c(n)}}$$

- Pontuação próxima de 1: indica uma anomalia definida.
- Pontuação próxima de 0: indica dados normais;
- Pontuação próxima de 0,5: indica dados limítrofes que não podem ser classificados com certeza.

$$c(n) = 2H(n-1) - \left(\frac{2(n-1)}{n}\right)$$

$$H(i) = ln(i) + \gamma$$

<u>Exemplo 01</u>: considerar um conjunto de dados 2D adaptado de um artigo. Irei utilizá-lo, de forma didática, para ressaltar como funciona a Floresta Isolada e as correspondentes pontuações de anomalia. Observar que do ponto de vista prático a Floresta Isolada utiliza normalmente 100 árvores ou mais. Além disso, os comprimentos dos caminhos podem variar devido à natureza aleatória do algoritmo.

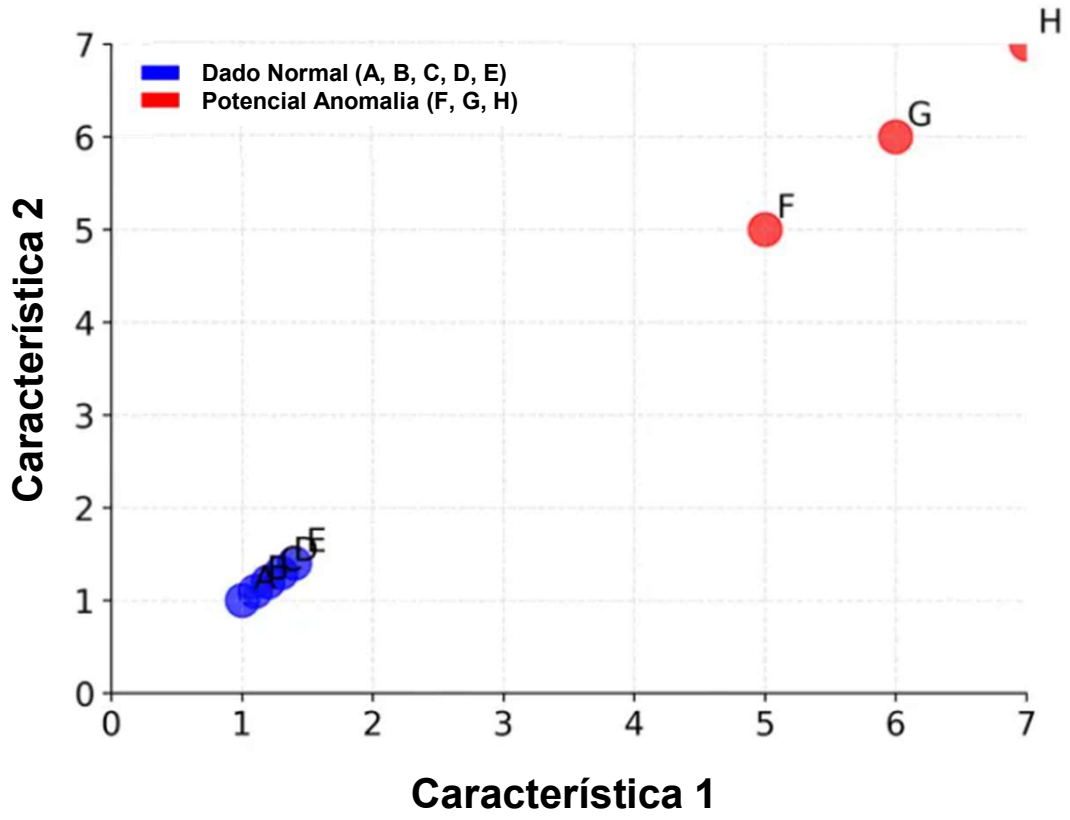

Este conjunto de dados possui 8 amostras: A: (1, 1) – dado normal; B: (1.1, 1.1) – dado normal; C: (1.2, 1.2) – dado normal; D: (1.3, 1.3) – dado normal e E: (1.4, 1.4) – dado normal. As potencias anomalias são: F: (5, 5); G: (6, 6) e H: (7, 7).

Passo 1: construção das árvores isoladas

Árvore 1

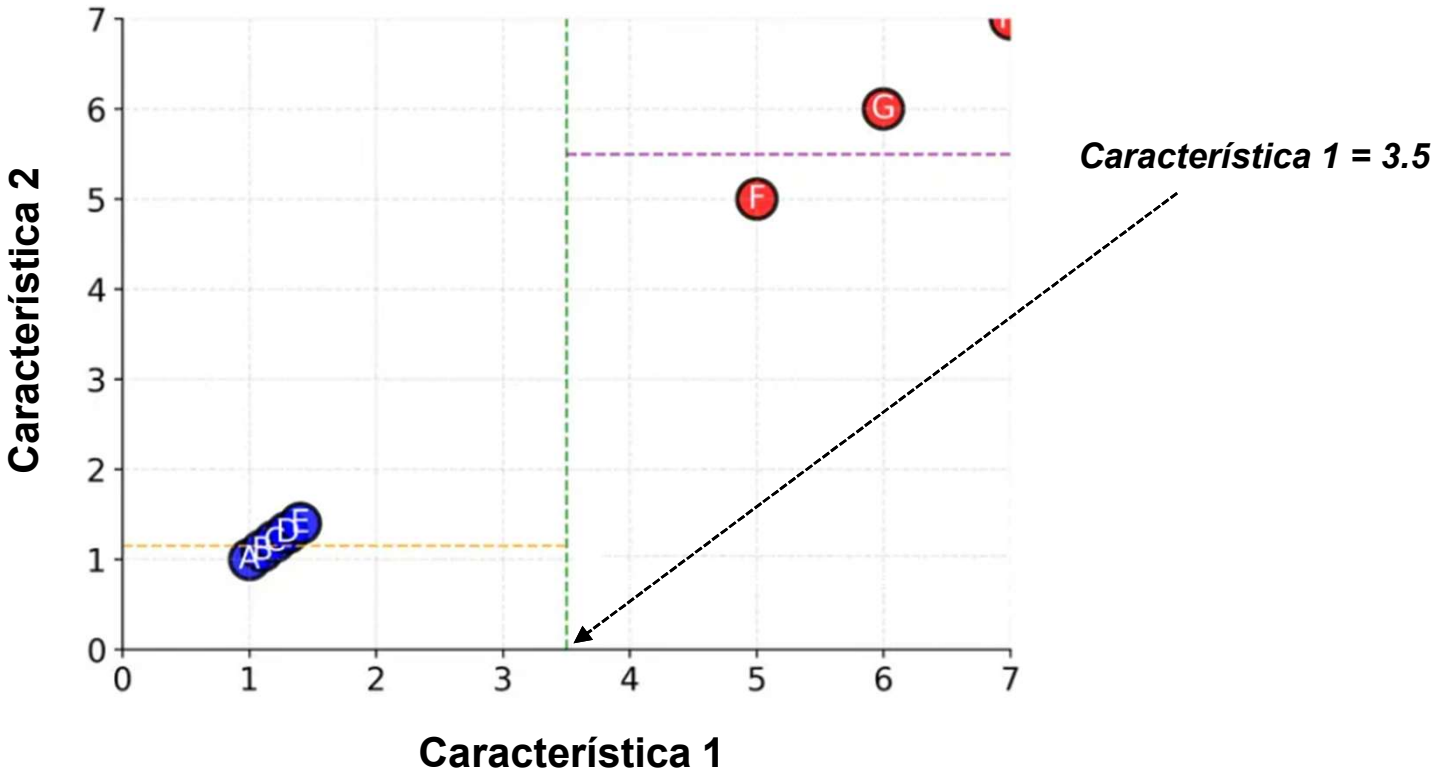

Árvore 1

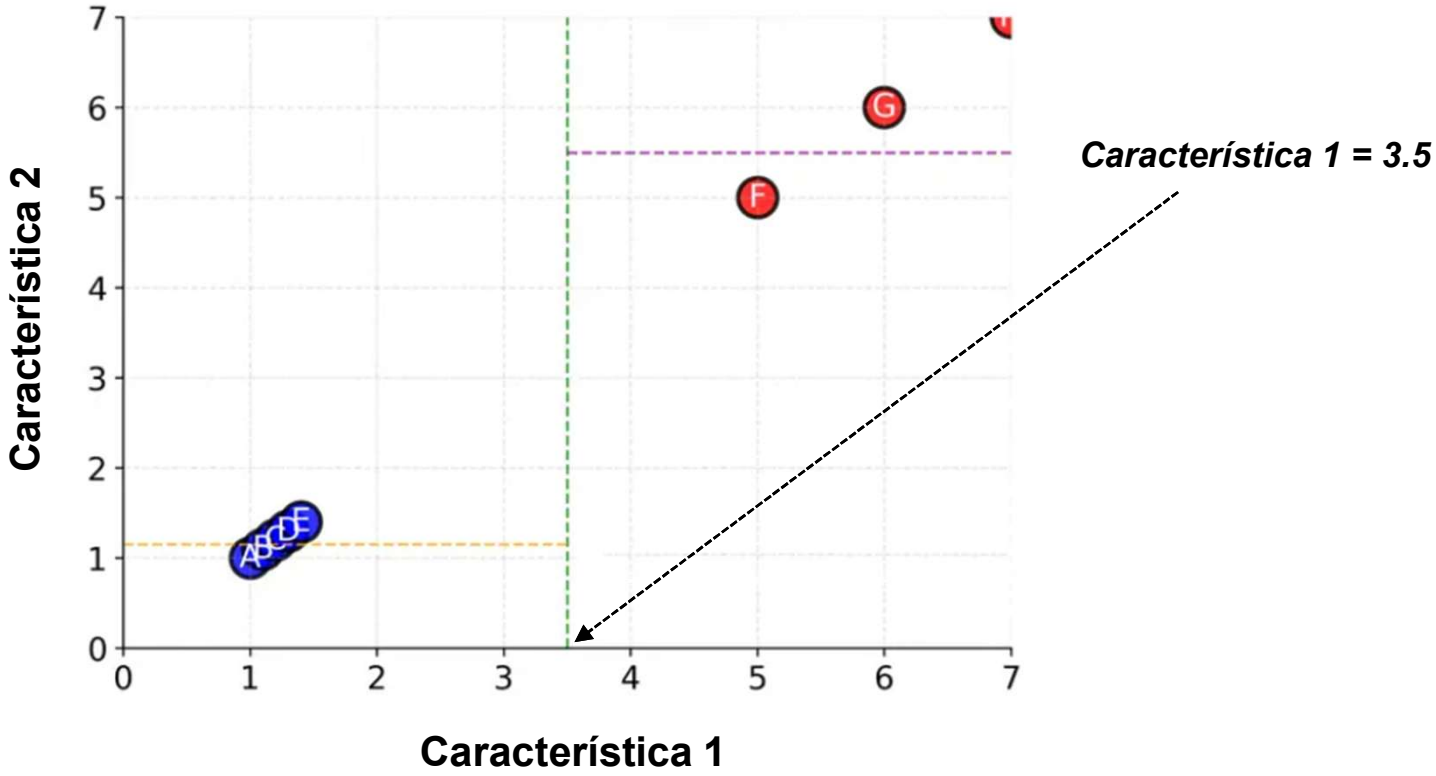
Característica 2
Característica 1
Característica 1 = 3.5
0
1
2
3
4
5
6
7
A
B
C
D
E
F
G

Árvore 2:

- Divisão Raiz: Característica 2 ≤ 3.5
  - Esquerda: Dados A, B, C, D, E (todas as Características 2 ≤ 3.5)
  - Direita: Dados F, G, H (todas as Características 2 > 3.5)

- Similar a estrutura da Árvore 1

Árvore 3:

- Divisão Raiz: Característica 1 ≤ 2.0
  - Esquerda: Dados A, B, C, D, E (todas as Características 1 ≤ 2.0)
  - Direita: Dados F, G, H (todas as Características 1 > 2.0)

- Similar a estrutura da Árvore 1

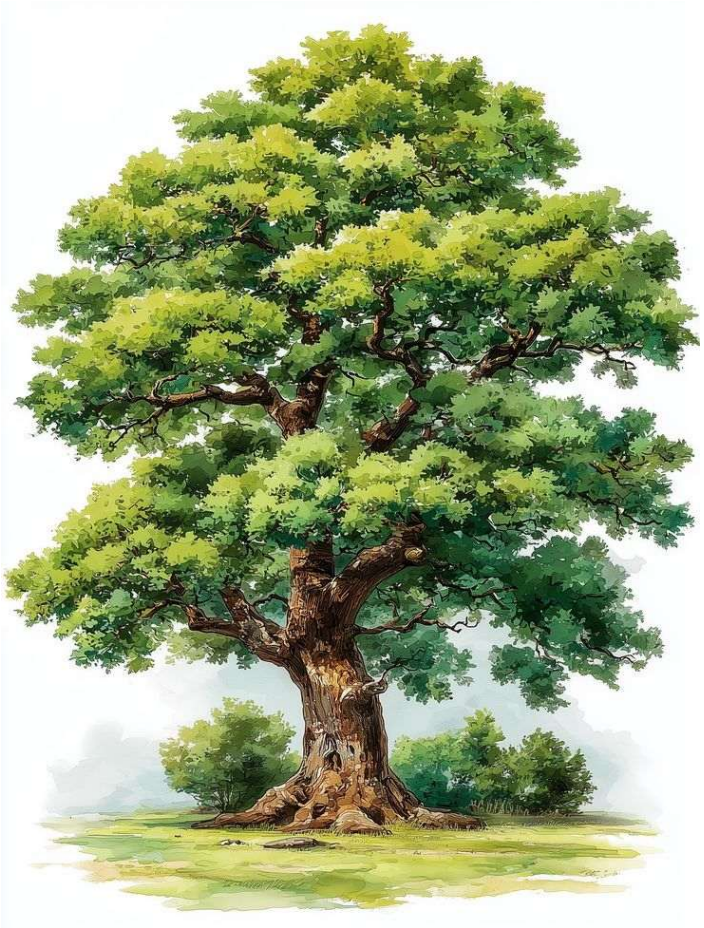

Passo 2: cálculos dos comprimentos dos caminhos

Passo 3: cálculo do comprimento do caminho esperado

$$c(n) = 2H(n-1) - \left(\frac{2(n-1)}{n}\right)$$

Passo 4: cálculos dos escores de anomalia

$$s(x,n) = 2^{-\frac{E\left(h(x)\right)}{c(n)}}$$

Amostra	Coordenadas	Tipo	$E(h(x))$	$s(x,n)$
A	(1, 1)	Normal	2.1	0.655
B	(1.1, 1.1)	Normal	1.8	0.695
C	(1.2, 1.2)	Normal	1.7	0.710
D	(1.3, 1.3)	Normal	1.8	0.695
E	(1.4, 1.4)	Normal	2.1	0.655
F	(5, 5)	Anomalia	1.4	0.754
G	(6, 6)	Anomalia	1.6	0.724
H	(7, 7)	Anomalia	1.2	0.785

Vantagens do Algoritmo Floresta Isolada

- Complexidade de tempo linear;
- Baixos requisitos de memória;
- Não requer suposições sobre a distribuição;
- Eficiência com dados de alta dimensionalidade;
- Paralelização;
- Não requer rotulagem.

Desvantagens e Limitações do Algoritmo Floresta Isolada

- Sensibilidade aos hiperparâmetros;
- Problemas com dados severamente desbalanceados;
- Interpretabilidade limitada;
- Desempenho ruim em anomalias locais;
- Sensibilidade a Recursos Irrelevantes.

Detector de Outlier: o algoritmo LOF (Local Outlier Factor)

- Nomenclatura:
  - k-distância de um objeto o:
    - $dist_k(o)$: distância entre o e seus $k^{ésimos}$ vizinhos mais próximos (NN)
  - k-distância da vizinhança de o:
    - $N_k(o) = \{o' | o' \ em \ D, dist(o, o') \leq dist_k(o)\}$
    - $N_k(o)$ pode ser maior que k, pois vários objetos podem ter distância idêntica a o.

Passos Principais do Algoritmo:

- calcular a distância entre o e todos os dados usando alguma métrica de distância, por exemplo, Euclidiana ou Manhattan;
- encontrar o k vizinho mais próximo:
  - exemplo, se $k = 3$ encontre a distância do 3º vizinho mais próximo (NN);
- encontrar os k dados mais próximos;
- encontrar a densidade de acessibilidade local usando a seguinte equação

$$lrd_k(o) = \frac{\|N_k(o)\|}{\sum_{o' \in N_k(o)} distância_k(o' \leftarrow o)}$$

- onde a distância de o' para o é calculada por ($\|N_k(o)\|$é $o\ número\ de\ vizinhos$):

$$distância_k(o' \leftarrow o) = máx\{dist_k(o), dist(o, o')\}$$

- último passo é calcular o ***fator outlier local (LOF)*** por:

$$LOF_k(o) = \frac{\sum_{o' \in N_{k(o)}} \frac{lrd_k(o')}{lrd_k(o)}}{\|N_k(o)\|}$$

Distância K e Vizinhos K:

- distância K é a distância entre o dado de interesse e seus K vizinhos mais próximos (***NN***);
- os vizinhos K, denotados por $N_k(A)$, incluem um conjunto de dados que estão dentro ou sobre o círculo de raio igual à distância K;
- o número de vizinhos K pode ser maior ou igual ao valor de K.

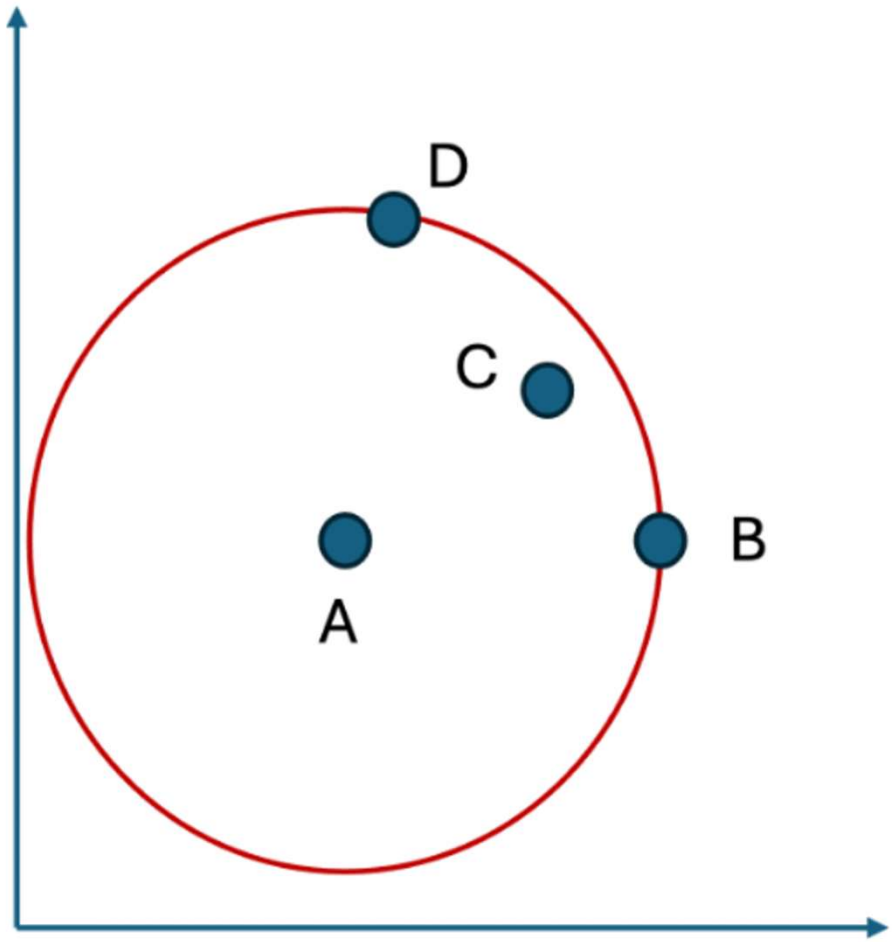

Distância de Alcance (RD):

- definida como o máximo da $k - distância$ de X_j e a distância entre X_i e X_j;
- medida de distância deve ser específica (Euclidiana, Manhattan, etc.);
- dada de forma genérica por:

$$RD(X_i, X_j) = distância_k(X_j \leftarrow X_i) = máx\{dist_k(X_j), dist(X_i, X_j)\}$$

- de forma simples:

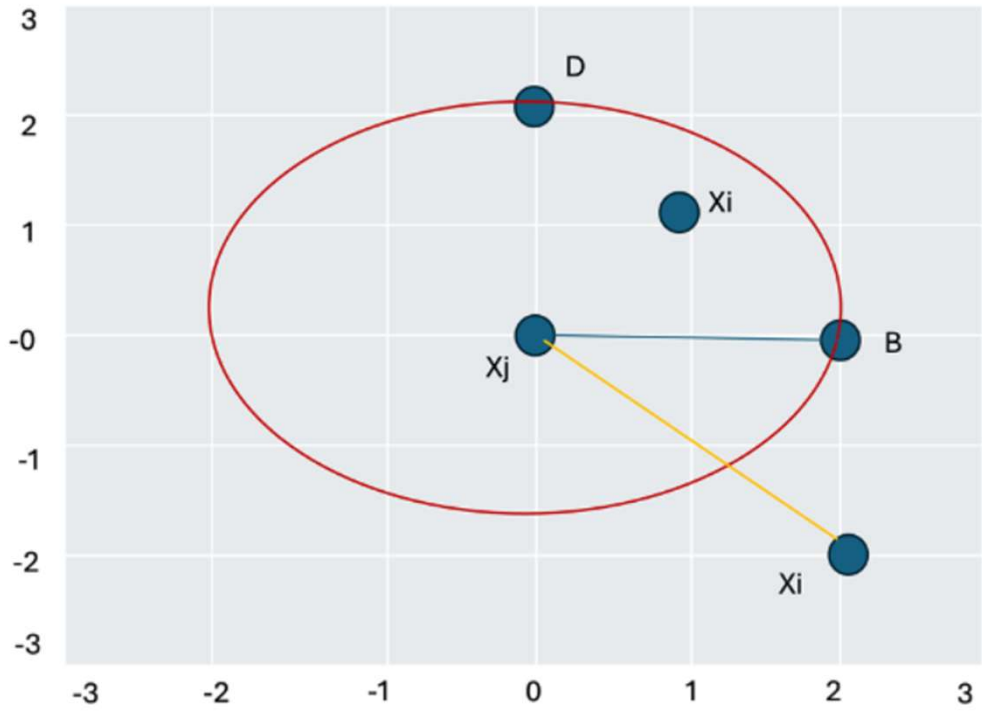

<u>Exemplo 02</u>: considerar o seguinte conjunto de dados 2D:

$$a(0,0);\ b(0,1);\ c(1,1);\ d(3,0)$$

Calcular o LOF de cada dado e mostrar o outlier. Considerar que o usuário selecionou $k = 2$. Utilizar a distância de similaridade de Manhattan:

1º Passo - com os dados fornecidos determinar as distâncias entre cada 2 dados:

2º Passo - calcular todas as $dist_k(o)$ (ou seja, $dist_2(o)$) - distâncias entre o e seu $k^{ésimo}$ NN:

Observação: as principais métricas de similaridade usadas em Clusters:

Métodos Clássicos:

- Distância Euclidiana: $d_E(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$

- Distância Manhattan (*city block distance*): $d_M(\boldsymbol{x}, \boldsymbol{y}) = \sum_{i=1}^{n} |x_i - y_i|$

x e y são vetores de comprimento n

Medidas Baseadas em Correlação ***(amplo uso na análise de dados estocásticos, dados genéticos, ...):***

- Distância da correlação de Pearson:

$$d_{correlação}(\boldsymbol{x}, \boldsymbol{y}) = 1 - \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

e etc...

3º Passo - calcular todas as $N_k(o)$ - k distâncias dos vizinhos de o:

4º Passo - calcular todos os $\boldsymbol{lrd_k(o)}$:

$$lrd_k(o) = \frac{\|N_k(o)\|}{\sum_{o' \in N_k(o)} distância_k(o' \leftarrow o)}$$

5º Passo - calcular todos os $\boldsymbol{LOF_k(o)}$:

$$LOF_k(o) = \frac{\sum_{o' \in N_{k(o)}} \frac{lrd_k(o')}{lrd_k(o)}}{\|N_k(o)\|} = \sum_{o' \in N_k(o)} lrd_k(o') \times \sum_{o' \in N_k(o)} distância_k(o' \leftarrow o)$$

6º Passo – classificar todos os $LOF_k(o)$:

Detector de Outlier: o algoritmo DBSCAN

(*Density-Based Spatial Clustering of Applications with Noise*)

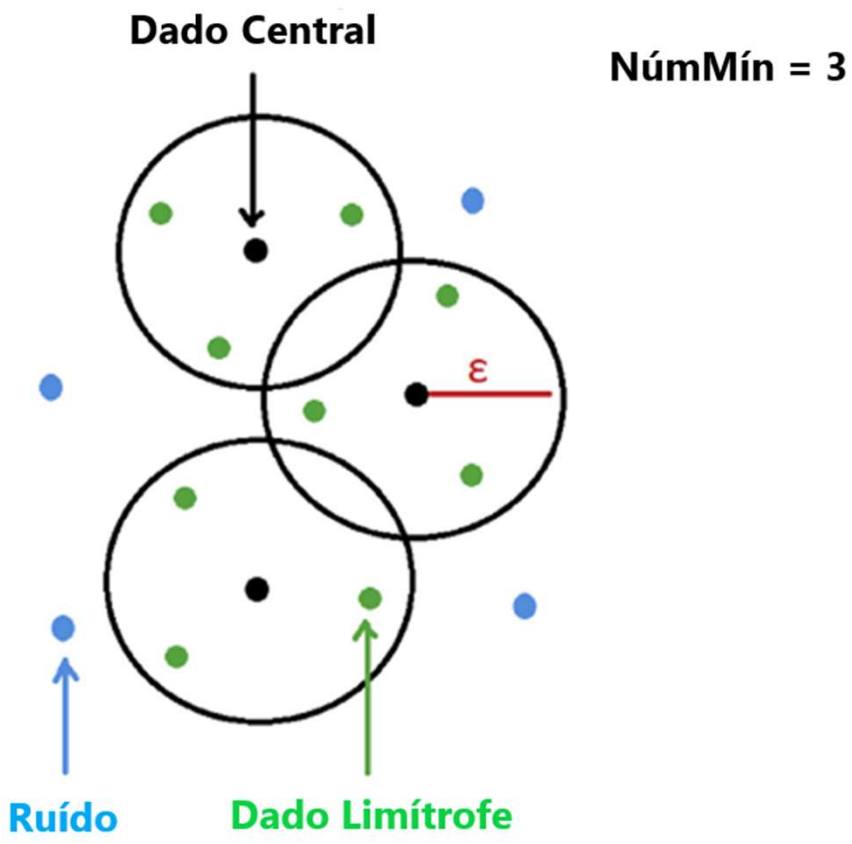

<u>Exemplo 03</u>: uso do DBSCAN

Considerar o seguinte conjunto de dados no espaço 2D (cada dado será considerado o seu próprio cluster inicialmente): [(1,3)], [(-8,6)], [(-6,4)] , [(4,-2)],] (2,5)], [(-2,0)]:

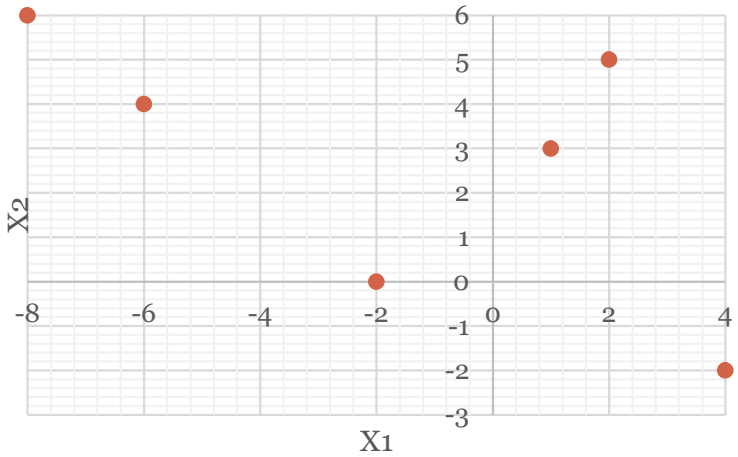

- Calculei a Distância Euclidiana pareada entre cada um dos dados:

- Calculei a Distância Euclidiana pareada entre cada um dos dados:

Dados	**(1, 3)**	**(-8, 6)**	**(-6, 4)**	**(4, -2)**	**(2, 5)**	**(-2, 0)**
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Dados	(1, 3)	(-8, 6)	(-6, 4)	(4, -2)	(2, 5)	(-2, 0)
(1, 3)	0	9,49	7,07	5,83	2,24	4,24
(-8, 6)	9,49	0	2,83	14,4	10,1	8,48
(-6, 4)	7,07	2,83	0	11,7	8,06	5,66
(4, -2)	5,83	14,4	11,7	0	7,28	6,32
(2, 5)	2,24	10,1	8,06	7,28	0	6,40
(-2, 0)	4,24	8,48	5,66	6,32	6,40	0

Dado Observado	Vizinhos (ε = 5)	NumMín de vizinhos = 2?	Contém um Dado Central como um vizinho	Classificação
(1, 3)	(2, 5), (-2, 0)	Sim	-	Dado Central
(-8, 6)	(-6, 4)	Não	Não	Ruído
(-6, 4)	(-8, 6)	Não	Não	Ruído
(4, -2)		Não	Não	Ruído
(2, 5)	(1, 3)	Não	Sim	Dado de Fronteira
(-2, 0)	(1, 3)	Não	Sim	Dado de Fronteira

CARACTERÍSTICA CATEGÓRICA

Identificando e Lidando com Característica Categórica

Tabela – Exemplo de um procedimento comum usado na Engenharia de Característica: a transformação de classes categóricas em valores numéricos.

Gênero Musical	Gênero Musical Transformado
Rock	1
Pop	2
Pop	2
País	3
Rock	1
Pop	2

Normalização ou Redimensionamento dos Dados

Normalização

- existem várias formas para normalizar ou redimensionar dados (ou reescalonar dados);
- as duas formas mais populares são:
  - **normalização dos dados:** basicamente consiste em redimensionar os valores de todas as características de modo que fiquem em um intervalo entre 0 e 1:

$$z_i = \frac{x_i - min(x)}{max(x) - min(x)}$$

onde z_i representa o i-ésimo valor normalizado e x representa todos os valores;

- **padronização dos dados:** técnica de redimensionamento que transforma os dados em uma Distribuição Gaussiana com média igual a 0 e desvio padrão igual a 1. Uma maneira simples de padronizar um recurso é mostrada na seguinte equação:

$$z_i = \frac{x_i - media(x)}{std(x)}$$

aqui, z_i corresponde ao i-ésimo valor padronizado e x representa todos os valores.

Atividades de Laboratório

LAB04A

- Acessar o Moodle
- Executar as tarefas solicitadas
- Vamos discutir as partes essenciais de cada tarefa
- Mãos à obra